

บทที่ 2

เอกสารและทฤษฎีที่เกี่ยวข้อง

แนวคิดและทฤษฎี

เนื้อหาในบทนี้สืบค้นจาก Google Scholar โดยใช้คำค้นที่เกี่ยวข้องกับ sign language recognition, Thai sign language, MediaPipe, hand landmarks, Support Vector Machine และ real-time sign language translation แล้วตรวจสอบชื่อผู้แต่ง ปีเผยแพร่ วิธีดำเนินการ และผลการทดลองกับหน้าต้นฉบับของวารสารหรือการประชุมวิชาการก่อนนำมาเรียบเรียง

ภาษามือและการรู้จำ: ภาษามือเป็นภาษาธรรมชาติที่ประกอบด้วยรูปมือ ตำแหน่ง ทิศทาง การเคลื่อนไหว สีหน้า และโครงสร้างทางภาษา การรู้จำแบบแยกคำรับคลิปของท่าหนึ่งคำและส่งออกหนึ่งป้ายกำกับ ส่วนการรู้จำแบบต่อเนื่องต้องแบ่งหน่วยท่าจากวิดีโอหลายคำและจัดการบริบท HandVox เลือกขอบเขตแบบแยกคำเพื่อให้พัฒนาและประเมินต้นแบบได้ชัดเจน

Camgoz และคณะ (2018)

อธิบายว่าการรู้จำภาษามือไม่ควรถูกมองเป็นเพียงการจำแนกท่าทาง เพราะภาษามือมีลำดับคำและโครงสร้างไวยากรณ์ที่แตกต่างจากภาษาพูด งานดังกล่าวแยกปัญหา Sign Language Recognition ซึ่งมุ่งระบุหน่วยท่า ออกจาก Sign Language Translation ซึ่งมุ่งสร้างประโยคภาษาพูดที่มีความหมายสอดคล้องกัน แนวคิดนี้ใช้กำหนดให้ HandVox รุ่นปัจจุบันเป็นระบบรู้จำแบบแยกคำ ไม่อ้างว่าเป็นระบบแปลภาษามืออย่างสมบูรณ์

การจำแนกรูปมือจากภาพนิ่งเหมาะสมกับคำที่รูปมือในช่วงใดช่วงหนึ่งมีข้อมูลเพียงพอ แต่ท่าจำนวนมากมีความหมายต่างกันจากทิศทาง การเคลื่อนเข้า-ออก การหมุนข้อมือ หรือการเปลี่ยนตำแหน่งสัมพันธ์กับร่างกาย หากใช้ภาพเพียงเฟรมเดียว ระบบอาจมองไม่เห็นลำดับดังกล่าว การใช้คลิปจึงช่วยให้แบบจำลองได้รับข้อมูลก่อน ระหว่าง และหลังการเคลื่อนไหว

สำหรับการรู้จำแบบแยกคำ

ผู้เก็บข้อมูลต้องกำหนดจุดเริ่มและจุดสิ้นสุดของท่าให้ใกล้เคียงกันในทุกตัวอย่าง ถ้าบางคลิปเริ่มช้า

บางคลิปจบเร็ว หรือมีช่วงอยู่นิ่งยาวเกินไป แบบจำลองอาจเรียนรู้จังหวะที่ไม่เกี่ยวข้องกับความหมาย HandVox จึงกำหนดจำนวนเฟรมคงที่และใช้คำแนะนำการเก็บข้อมูลแบบเดียวกันทุกคลาส

รูปแบบ	ข้อมูลนำเข้า	ผลลัพธ์	ขอบเขต
ภาพนิ่ง	หนึ่งเฟรม	คลาสของรูปมือ	ไม่แทนลำดับการเคลื่อนไหว
แบบแยกคำ	คลิปของหนึ่งท่า	หนึ่งคำหรือป้ายกำกับ	เหมาะกับท่าที่มีจุดเริ่มและสิ้นสุดชัดเจน
แบบต่อเนื่อง	วิดีโอหลายท่าต่อกัน	ลำดับคำหรือประโยค	ต้องแบ่งหน่วยท่าและจัดการบริบท

ตารางที่ 2.1 การเปรียบเทียบรูปแบบการรู้จำ

การเลือกแบบแยกคำทำให้ขอบเขตของปัญหาชัดเจนและเหมาะกับชุดข้อมูลขนาดเล็ก ผู้ใช้ต้องทำท่าหนึ่งคำภายในหน้าต่างเก็บข้อมูล และระบบคืนผลหนึ่งป้ายกำกับต่อครั้ง ข้อดีคือสามารถตรวจผลรายคำได้ตรงไปตรงมา ส่วนข้อจำกัดคือยังไม่สามารถแบ่งคำจากการเคลื่อนไหวต่อเนื่องหรือเรียงผลเป็นประโยคภาษาพูดโดยอัตโนมัติ

การมองเห็นด้วยคอมพิวเตอร์: OpenCV ทำหน้าที่รับภาพจากกล้อง วาดส่วนติดต่อ และแสดงผล ส่วน MediaPipe Holistic ประเมินตำแหน่งจุดสำคัญของร่างกายและมือ การใช้พิกัดจุดสำคัญแทนภาพดิบช่วยลดมิติข้อมูลและทำให้ระบบเน้นโครงสร้างการเคลื่อนไหว แต่ผลยังขึ้นกับแสง มุมกล้อง การบังมือ และความเร็วของผู้ใช้

Lugaresi และคณะ (2019) เสนอ MediaPipe เป็นกรอบงานสำหรับสร้าง perception pipeline แบบข้ามแพลตฟอร์ม โดยเชื่อมส่วนรับสื่อ แบบจำลอง และการแปลงข้อมูลเป็นกราฟการประมวลผล ช่วยให้พัฒนาต้นแบบและวัดประสิทธิภาพบนอุปกรณ์เป้าหมายได้ ส่วน Zhang และคณะ (2020) พัฒนา MediaPipe Hands ซึ่งใช้ palm detector ร่วมกับ hand landmark model เพื่อประมาณโครงมือ 21 จุดจากภาพกล้องเดียวและทำงานแบบเวลาจริงบนอุปกรณ์เคลื่อนที่ แนวคิดทั้งสองเป็นฐานของการใช้ MediaPipe Holistic ใน HandVox

กระบวนการตรวจจับจุดสำคัญมีสองช่วงหลัก คือการตรวจว่าร่างกายหรือมืออยู่บริเวณใดในภาพ

และการประมาณพิกัดของจุดข้อต่อภายในบริเวณนั้น เมื่อประมวลผลวิดีโอต่อเนื่อง ระบบสามารถติดตามตำแหน่งจากเฟรมก่อนหน้าเพื่อลดภาระการตรวจใหม่ทุกครั้ง แต่หากมือเคลื่อนเร็ว หลุดกรอบ หรือถูกบัง พิกัดอาจหายหรือกระโดดจนส่งผลต่อเวกเตอร์คุณลักษณะ

HandVox เปิดใช้งานการประมวลผลแบบวิดีโอต่อเนื่อง ใช้ model complexity ระดับกลาง เปิดการทำให้จุดต่อเนื่องราบรื่น และกำหนดค่าความเชื่อมั่นขั้นต่ำของการตรวจจับกับการติดตามเท่ากับ 0.70 การตั้งค่านี้นี้เป็นจุดสมดุลเบื้องต้นระหว่างความเสถียรกับความเร็ว และควรทดสอบใหม่เมื่อเปลี่ยนกล้องหรือสภาพแวดล้อม

จุดสำคัญที่ใช้ใน HandVox: ระบบเลือกจุดช่วงบน 15 จุด และมือซ้ายกับมือขวาข้างละ 21 จุด แต่ละจุดมีพิกัด x , y และ z จึงมีข้อมูลรวม 171 ค่าในหนึ่งเฟรม หากพบมือเพียงข้างเดียว ระบบเติมศูนย์ให้ข้อมูลมืออีกข้างเพื่อรักษาขนาดข้อมูลให้เท่ากัน

จุดช่วงบนช่วยอธิบายตำแหน่งของมือเมื่อเทียบกับศีรษะ ไหล่ ศอก และลำตัว ขณะที่จุดมืออธิบายรูปร่างและทิศทางฝ่ามือ การใช้ทั้งสองกลุ่มร่วมกันเหมาะกับการทำที่รูปร่างคล้ายกันแต่เกิดคนละตำแหน่ง หากไม่พบโครงร่างของช่วงบนหรือไม่พบมือทั้งสองข้าง ระบบจะไม่รับเฟรมนั้น เพราะข้อมูลไม่เพียงพอสำหรับสร้างตัวอย่างที่สอดคล้องกับชุดฝึก

การเติมศูนย์เมื่อพบมือเพียงข้างเดียวทำให้ทุกเฟรมมีจำนวนคุณลักษณะเท่ากัน แต่ศูนย์ในกรณีนี้หมายถึงข้อมูลที่ไม่ตรวจพบ ไม่ใช่ตำแหน่งจริงของมือ ดังนั้นสัดส่วนเฟรมที่มือหายไม่ควรมากเกินไป และควรตรวจคุณภาพคลิปก่อนรวมเข้าในชุดข้อมูล มิฉะนั้นแบบจำลองอาจเรียนรู้รูปแบบของข้อมูลหายแทนรูปแบบของท่าทาง

การปรับมาตรฐานและการแทนลำดับ:

ระบบใช้จุดกึ่งกลางระหว่างไหล่เป็นจุดอ้างอิงและใช้ระยะระหว่างไหล่เป็นตัวปรับขนาด เพื่อลดผลจากตำแหน่งและระยะห่างจากกล้อง หนึ่งคลิปมี 30 เฟรม เฟรมละ 171 ค่า ก่อนฝึกจะเรียงเป็นเวกเตอร์ 5,130 ค่า โดยลำดับของตำแหน่งในเวกเตอร์ยังคงข้อมูลการเคลื่อนไหวตามเวลา

ให้ c เป็นจุดกึ่งกลางระหว่างไหล่ซ้ายกับไหล่ขวา และให้ s เป็นระยะยุคลิดระหว่างไหล่
พิกัดของจุดแต่ละจุดถูกเลื่อนด้วย c และหารด้วย s ก่อนจัดเก็บ

วิธีนี้ลดผลจากการยืนค่อนไปทางซ้ายหรือขวาและการอยู่ใกล้หรือไกลกล้อง อย่างไรก็ตาม
การปรับดังกล่าวยังไม่ทำให้ข้อมูลไม่แปรผันต่อการหมุนตัว มุมกล้อง หรือสัดส่วนร่างกายทั้งหมด

การเรียงข้อมูล 30 เฟรมต่อกันเป็นเวกเตอร์ทำให้ SVM
สามารถใช้ข้อมูลเวลาได้โดยไม่ต้องมีโครงสร้างแบบจำลองลำดับเฉพาะ ตำแหน่งลำดับที่ 1-171
แทนเฟรมแรก และตำแหน่งช่วงท้ายแทนเฟรมที่ 30
ดังนั้นท่าที่เคลื่อนไหวในทิศทางตรงข้ามจะให้ลำดับค่าแตกต่างกัน แม้บางเฟรมจะมีรูปมือคล้ายกัน

ข้อจำกัดของการกำหนด 30 เฟรมคือผู้ที่ทำต้องปรับจังหวะให้พอดีกับหน้าต่างข้อมูล
หากทำเร็วมากจะมีช่วงอยู่นิ่งเหลือมาก แต่หากทำช้ามากทำอาจไม่จบภายในคลิป
แบบจำลองจึงอาจไวต่อความเร็ว
การเก็บข้อมูลควรมีหลายจังหวะและในอนาคตอาจใช้การปรับแนวเวลา
หรือแบบจำลองที่รองรับความยาวลำดับไม่เท่ากัน

Support Vector Machine: Cortes และ Vapnik (1995) เสนอ Support-Vector
Networks สำหรับสร้างขอบเขตการตัดสินใจที่มีระยะห่างจากตัวอย่างสำคัญมากที่สุด
และใช้การแปลงข้อมูลไปยังปริภูมิมิติสูงเพื่อรองรับข้อมูลที่ไม่สามารถแยกด้วยเส้นตรง
แนวคิดดังกล่าวพัฒนาต่อมาเป็น SVM ที่ใช้ kernel ได้ HandVox ใช้ RBF kernel
เพื่อรองรับความสัมพันธ์ที่ไม่เป็นเส้นตรง กำหนด $C=10$, $\text{gamma}=\text{scale}$, $\text{probability}=\text{True}$ และ
 $\text{class_weight}=\text{balanced}$

ค่า C
ควบคุมการแลกเปลี่ยนระหว่างการยอมให้มีข้อผิดพลาดบนข้อมูลฝึกกับการสร้างขอบเขตที่ยืดหยุ่น
ค่า gamma กำหนดระยะอิทธิพลของตัวอย่างต่อรูปร่างขอบเขต ส่วน $\text{class_weight}=\text{balanced}$
เพิ่มน้ำหนักให้คลาสที่มีตัวอย่างน้อยกว่า
การตั้งค่าปัจจุบันยึดตามการทดลองของโครงการและควรปรับด้วยชุดตรวจสอบที่แยกจากชุดทดสอบ
เมื่อมีข้อมูลมากขึ้น

การเปิด probability ทำให้โปรแกรมใช้ predict_proba
 เพื่อรายงานค่าประกอบการตัดสินใจแบบเวลาจริง
 แต่ค่าความน่าจะเป็นดังกล่าวขึ้นกับการสอบเทียบของแบบจำลองและลักษณะข้อมูล
 ไม่ควรตีความว่าเป็นความถูกต้องที่รับประกันในทุกสภาพแวดล้อม เกณฑ์ 0.40
 จึงเป็นค่าตั้งต้นที่ต้องตรวจสอบกับข้อมูลภายนอก

การแบ่งข้อมูลและการป้องกันการรั่วไหล: การแบ่งแบบ stratified
 ช่วยรักษาสัดส่วนของแต่ละคลาสระหว่างชุดฝึกกับชุดทดสอบ
 แต่ถ้าคลิจากผู้ทำท่าหรือเซสชันเดียวกันกระจายอยู่ทั้งสองชุด
 คะแนนอาจสะท้อนความคล้ายของผู้ทำท่าและฉากหลังมากกว่าความสามารถกับผู้ใช้ใหม่
 แนวทางที่เข้มงวดกว่าคือแบ่งตามรหัสผู้ให้ข้อมูลหรือเซสชัน
 และเก็บชุดทดสอบภายนอกที่ไม่ใช่ระหว่างการพัฒนา

การประเมินผล: Accuracy ใช้สรุปสัดส่วนการทำนายถูกทั้งหมด ส่วน Precision, Recall
 และ F1-score ช่วยพิจารณาผลรายคลาส ค่า Macro F1 ให้น้ำหนักทุกคลาสเท่ากัน และ
 Confusion Matrix แสดงค่าที่ระบบทำนายสับสน
 การแบ่งข้อมูลควรแยกผู้ทำท่าหรือเซสชันเพื่อป้องกันข้อมูลที่คล้ายกันรั่วไหลระหว่างชุดฝึกและชุดทดสอบ

การทำงานแบบเวลาจริงและเสียงพูด: ระบบสะสมคุณลักษณะล่าสุด 30 เฟรม
 รับผลที่มีค่าความเชื่อมั่นอย่างน้อย 0.40 และลงคะแนนจากผลล่าสุด 3 ครั้งเพื่อให้ข้อความนิ่งขึ้น
 ผลที่ยืนยันแล้วสามารถเพิ่มลงในประโยคและอ่านออกเสียงภาษาไทยผ่านระบบ Text-to-Speech

กลไกรวมผลย้อนหลังช่วยลดการเปลี่ยนป้ายกำกับไปมาระหว่างเฟรม
 แต่ทำให้เกิดความหน่วงเพิ่มขึ้นเล็กน้อย หากไม่พบมีอนานกว่า 0.4 วินาที
 ระบบจะล้างคิวและสถานะเดิมเพื่อป้องกันผลเก่าค้างบนหน้าจอ การตั้งค่าทั้งสามส่วน ได้แก่
 ขนาดหน้าต่าง เกณฑ์ความเชื่อมั่น และจำนวนผลย้อนหลัง มีผลต่อความไวกับความเสถียรของระบบ

ส่วน Text-to-Speech ทำหน้าที่เปลี่ยนชื่อท่าหรือข้อความสะสมเป็นเสียงภาษาไทย
 ช่วยส่งผลลัพธ์ไปยังคู่สนทนาโดยไม่ต้องอ่านหน้าจอ

การสร้างเสียงทำงานแยกจากวงจรบล็อกรั้งเพื่อลดการหยุดค้าง แต่ gTTS ต้องใช้อินเทอร์เน็ต
จึงควรมีทางเลือกเสียงแบบออฟไลน์ในรุ่นที่ต้องใช้งานในพื้นที่เครือข่ายไม่เสถียร

งานวิจัยที่เกี่ยวข้อง

การคัดเลือกงานวิจัยพิจารณาความใกล้เคียงกับ HandVox ใน 4 ด้าน ได้แก่
การรู้จำภาษามือไทย การใช้ภาพหรือจุดสำคัญของร่างกาย การจำแนกท่าจากลำดับเวลา
และการทำงานแบบเวลาจริง
งานที่นำมาอ้างอิงมีทั้งงานภาษาไทยซึ่งสะท้อนข้อจำกัดด้านข้อมูลในประเทศ
และงานต่างประเทศที่แสดงแนวทางเมื่อจำนวนคำกับผู้ทำท่าเพิ่มขึ้น

การรู้จำนิ้วสะกดภาษาไทยด้วย SVM: Pariwat และ Seresangtakul (2017)

ศึกษาการรู้จำนิ้วสะกดภาษาไทยจากคุณลักษณะภาพแบบ global และ local แล้วเปรียบเทียบ
SVM หลาย kernel ข้อมูลที่รายงานในงานทบทวนภายหลังมี 15 ท่า 75 ภาพ จากผู้ทำท่า 5 คน
ผลเฉลี่ยของ RBF kernel เท่ากับ 91.2% สูงกว่า linear, polynomial และ sigmoid
งานนี้สนับสนุนการเลือก RBF สำหรับข้อมูลท่าทางที่ขอบเขตคลาสไม่เป็นเส้นตรง
แต่เป็นภาพนิ่งและชุดข้อมูลขนาดเล็ก จึงไม่ยืนยันผลของ HandVox ที่ใช้ลำดับ 30 เฟรมโดยตรง

การรู้จำนิ้วสะกดภาษาไทยด้วย CNN และการปฏิเสธท่าที่ไม่รู้จัก: Nakjai และ Katanyukul

(2019) พัฒนาระบบการสองขั้นตอน คือค้นหาและตัดบริเวณมือ ก่อนจำแนกภาพด้วย CNN หรือ
HOG งานใช้นิ้วสะกดภาษาไทย 25 ท่า 125 ภาพ จากผู้ทำท่า 11 คน และรายงาน mean
Average Precision 91.26 งานยังเสนอ confidence ratio
เพื่อช่วยแยกท่าที่ถูกต้องออกจากท่าช่วงเปลี่ยนหรือท่าที่ไม่อยู่ในชุดคำ แนวคิดดังกล่าวชี้ว่า
HandVox ควรมีสถานะ “ไม่ทราบ” แทนการบังคับเลือกหนึ่งใน 16 คลาสทุกครั้ง

ชุดข้อมูลวิดีโอเลขภาษามือไทย: Vijitkunsawat, Racharak, Nguyen และ Minh (2023)

สร้างชุดข้อมูลวิดีโอเลขภาษามือไทย 9 ท่า มีประมาณ 63 วิดีโอต่อท่า รวม 567 วิดีโอจากผู้ทำท่า 21
คน แล้วเปรียบเทียบ CNN-Mode, CNN-LSTM, VGG-Mode และ VGG-LSTM
ทั้งภาพเต็มกับภาพที่ตัดเฉพาะมือ ผลพบว่า VGG-LSTM
ร่วมกับการประมวลผลล่วงหน้าให้ผลดีที่สุดทั้งชุดทดสอบภายในและภายนอก

งานนี้แสดงความสำคัญของจำนวนผู้ทำท่า การเก็บข้อมูลเป็นวิดีโอ และการรายงานผลกับผู้ทำท่าที่ต่างจากชุดพัฒนา

ระบบตรวจจับภาษามือไทยด้วย MediaPipe และ LSTM: Damrongekarun, Pisitpipattana, Waijanya และ Promrit (2023) ใช้ MediaPipe ดึงจุดสำคัญของมือ ใบหน้า และท่าทางจากวิดีโอ แล้วใช้ LSTM วิเคราะห์ลำดับ แบ่งข้อมูลฝึกและทดสอบ 80:20 ได้ค่า Accuracy 0.83 และนำผลไปแสดงบนแอป Flutter ผ่าน Flask API งานนี้มีโครงสร้างใกล้เคียง HandVox ในด้านการใช้พิกัดจุดสำคัญและการส่งผลเป็นข้อความไทย แต่เลือกแบบจำลองลำดับเชิงลึกแทน SVM

การแปลภาษามือไทยเป็นข้อความแบบเวลาจริง: Jintanachaiwat และคณะ (2024) ใช้ MediaPipe Holistic เก็บจุดมือ ร่างกาย และใบหน้าเป็นลำดับ 30 เฟรม เฟรมละ 1,662 ค่า แล้วเปรียบเทียบ RNN, Bi-RNN, LSTM, Bi-LSTM และ FNN-LSTM สำหรับคำภาษาไทยที่ใช้ในการประชุม ผลของ LSTM บนชุดทดสอบเท่ากับ 100% แต่ลดเหลือ 86% เมื่อทดสอบแบบเวลาจริง ผู้วิจัยระบุว่าการเก็บข้อมูลจากผู้ทำท่าเพียงคนเดียวเสี่ยงต่อ overfitting ผลดังกล่าวยืนยันว่าคะแนนจากชุดทดสอบภายในอาจสูงกว่าการใช้งานจริงและควรเก็บข้อมูลหลายบุคคล

ชุดข้อมูลภาษามือระดับคำขนาดใหญ่: Li, Rodriguez, Yu และ Li (2020) เสนอ WLASL ซึ่งมีภาษามืออเมริกันระดับคำมากกว่า 2,000 คำและผู้ทำท่ามากกว่า 100 คน พร้อมเปรียบเทียบวิธีที่ใช้ภาพลักษณะโดยรวมกับวิธีที่ใช้โครงร่าง และเสนอ Pose-TGCN เพื่อเรียนรู้ความสัมพันธ์เชิงพื้นที่กับเวลา งานนี้แสดงความหลากหลายของผู้ทำท่าและขนาดคำศัพท์ทำให้ปัญหายากขึ้นมาก การเพิ่มคลาสใน HandVox จึงต้องเพิ่มข้อมูลและทดสอบวิธีลำดับที่ซับซ้อนกว่า SVM ควบคู่กัน

การรู้จำและการแปลภาษามือต่อเนื่อง: Camgoz, Hadfield, Koller, Ney และ Bowden (2018) เสนอปัญหา Neural Sign Language Translation และชุดข้อมูล RWTH-PHOENIX-Weather 2014T ซึ่งมีมากกว่า 67,000 หน่วยท่าจากคำศัพท์ภาษามือมากกว่า 1,000 หน่วย งานใช้แนวคิด Neural Machine Translation เพื่อเชื่อมวิดีโอกับประโยคภาษาพูด

ผลงานนี้มีขอบเขตกว้างกว่า HandVox เพราะต้องแบ่งทำต่อเนื่องและจัดการไวยากรณ์

แต่เป็นแนวทางระยะยาวสำหรับการพัฒนาจากการสะสมคำไปสู่การแปลประโยค

ผู้วิจัยและปี	ข้อมูลและวิธี	ผลสำคัญ	สิ่งที่ HandVox นำมาใช้
Pariwat และ Seresangtakul (2017) KST 2017, หน้า 116–120	15 ท่า; 75 ภาพ; 5 คน; คุณสมบัติ global/local และ SVM	RBF เฉลี่ย 91.2%	เลือก RBF และระบุข้อจำกัดของข้อมูลขนาดเล็ก
Nakjai และ Katanyukul (2019) DOI: 10.1007/s11265-018-1375-6	25 ท่า; 125 ภาพ; 11 คน; CNN เทียบ HOG	mAP 91.26 และเสนอ confidence ratio	เสนอให้เพิ่มสถานะไม่ทราบและตรวจท่าช่วงเปลี่ยน
Vijitkunsawat และคณะ (2023) DOI: 10.5220/0011643700003411	9 ท่าเลข; 567 วิดีโอ; 21 คน; CNN/LSTM และ VGG/LSTM	VGG-LSTM หลังตัดบริเวณมือให้ผลดีที่สุด	เก็บวิดีโอหลายคนและแยกทดสอบภายนอก
Damrongekarun และคณะ (2023) DOI: 10.14456/kkuscij.2023.19	MediaPipe landmarks, LSTM, แบ่ง 80:20 และแอป Flutter	Accuracy 0.83	ใช้พิกัดจุดสำคัญและแสดงผลเป็นข้อความไทย
Jintanachaiwat และคณะ (2024) DOI: 10.1007/s44163-024-00113-8	MediaPipe Holistic; 30 เฟรม; เปรียบเทียบ RNN และ LSTM	LSTM ชุดทดสอบ 100%; เวลาจริง 86%	แยกผลภายในออกจากเวลาจริงและระวังข้อมูลคนเดียวยาว
Li และคณะ (2020) WACV 2020, หน้า 1459–1469	WLASL มากกว่า 2,000 คำ; มากกว่า 100 คน; appearance/pose/Pose-TGCN	แสดงความท้าทายเมื่อคำและผู้ทำท่าเพิ่ม	วางแผนขยายข้อมูลและเปรียบเทียบโมเดลลำดับ
Camgoz และคณะ (2018) DOI: 10.1109/CVPR.2018.00812	วิดีโอต่อเนื่อง มากกว่า 67,000 หน่วยท่า และ Neural Translation	แปลภาษามือโดยคำนึงถึงลำดับและไวยากรณ์	กำหนดขอบเขตปัจจุบันเป็นแยกคำและวางแผนทางอนาคต

ตารางที่ 2.2 การเปรียบเทียบงานวิจัยที่เกี่ยวข้องกับ HandVox

เมื่อเปรียบเทียบกับงานข้างต้น HandVox มีจุดร่วมกับงาน MediaPipe–LSTM

ของไทยตรงการใช้จุดสำคัญและลำดับ 30 เฟรม แต่เลือก SVM แบบ RBF

เพื่อให้ฝึกได้รวดเร็วกับข้อมูล 350 คลิป จุดต่างสำคัญคือ HandVox เชื่อมเมนูเพิ่มหรือลบท่า

การเก็บข้อมูล การฝึกใหม่ การทำนาย การสะสมคำ และเสียงภาษาไทยไว้ในต้นแบบเดียว ขณะที่ผล 94.29% ของ HandVox มาจากการแบ่งคลิปภายในชุดข้อมูล

จึงไม่ควรนำไปเปรียบเทียบโดยตรงกับผลจากชุดข้อมูลหรือวิธีแบ่งคนละแบบ

ข้อสรุปจากงานวิจัยคือ คุณภาพของระบบไม่ได้ขึ้นกับตัวจำแนกเพียงอย่างเดียว แต่ขึ้นกับจำนวนผู้ทำท่า ความสมดุลของคลาส การกำหนดจุดเริ่มและจบ การจัดการท่าที่ไม่รู้จัก และวิธีแบ่งชุดทดสอบ HandVox จึงควรพัฒนาต่อโดยเพิ่มผู้ทำท่า บันทึกให้สอดคล้องกับเซสชัน สร้างชุดทดสอบภายนอก เพิ่มสถานะไม่ทราบ และเปรียบเทียบ SVM กับ LSTM หรือแบบจำลองลำดับอื่นภายใต้ข้อมูลชุดเดียวกัน