

บทที่ 2

เอกสารและทฤษฎีที่เกี่ยวข้อง

แนวคิดและทฤษฎี

เนื้อหาในบทนี้สืบค้นจาก Google Scholar โดยใช้คำค้นที่เกี่ยวข้องกับ sign language recognition, Thai sign language, MediaPipe, hand landmarks, Support Vector Machine และ real-time sign language translation แล้วตรวจสอบชื่อผู้แต่ง ปีเผยแพร่ วิธีดำเนินการ และผลการทดลองกับหน้าต้นฉบับของวารสารหรือการประชุมวิชาการก่อนนำมาเรียบเรียง

ภาษามือและการรู้จำ: ภาษามือเป็นภาษาธรรมชาติที่ประกอบด้วยรูปมือ ตำแหน่ง ทิศทาง การเคลื่อนไหว สีหน้า และโครงสร้างทางภาษา การรู้จำแบบแยกคำรับคลิปของท่าหนึ่งคำและส่งออกหนึ่งป้ายกำกับ ส่วนการรู้จำแบบต่อเนื่องต้องแบ่งหน่วยท่าจากวิดีโอหลายคำและจัดการบริบท HandVox เลือกขอบเขตแบบแยกคำเพื่อให้พัฒนาและประเมินต้นแบบได้ชัดเจน

Camgoz และคณะ (2018)

อธิบายว่าการรู้จำภาษามือไม่ควรถูกมองเป็นเพียงการจำแนกท่าทาง เพราะภาษามือมีลำดับคำและโครงสร้างไวยากรณ์ที่แตกต่างจากภาษาพูด งานดังกล่าวแยกปัญหา Sign Language Recognition ซึ่งมุ่งระบุหน่วยท่า ออกจาก Sign Language Translation ซึ่งมุ่งสร้างประโยคภาษาพูดที่มีความหมายสอดคล้องกัน แนวคิดนี้ใช้กำหนดให้ HandVox รุ่นปัจจุบันเป็นระบบรู้จำแบบแยกคำ ไม่อ้างว่าเป็นระบบแปลภาษามืออย่างสมบูรณ์

การจำแนกรูปมือจากภาพนิ่งเหมาะสมกับคำที่รูปมือในช่วงใดช่วงหนึ่งมีข้อมูลเพียงพอ แต่ท่าจำนวนมากมีความหมายต่างกันจากทิศทาง การเคลื่อนเข้า-ออก การหมุนข้อมือ หรือการเปลี่ยนตำแหน่งสัมพันธ์กับร่างกาย หากใช้ภาพเพียงเฟรมเดียว ระบบอาจมองไม่เห็นลำดับดังกล่าว การใช้คลิปจึงช่วยให้แบบจำลองได้รับข้อมูลก่อน ระหว่าง และหลังการเคลื่อนไหว

สำหรับการรู้จำแบบแยกคำ

ผู้เก็บข้อมูลต้องกำหนดจุดเริ่มและจุดสิ้นสุดของท่าให้ใกล้เคียงกันในทุกตัวอย่าง ถ้าบางคลิปเริ่มช้า

บางคลิปจบเร็ว หรือมีช่วงอยู่นิ่งยาวเกินไป แบบจำลองอาจเรียนรู้จังหวะที่ไม่เกี่ยวข้องกับความหมาย HandVox จึงกำหนดจำนวนเฟรมคงที่และใช้คำแนะนำการเก็บข้อมูลแบบเดียวกันทุกคลาส

รูปแบบ	ข้อมูลนำเข้า	ผลลัพธ์	ขอบเขต
ภาพนิ่ง	หนึ่งเฟรม	คลาสของรูปมือ	ไม่แทนลำดับการเคลื่อนไหว
แบบแยกคำ	คลิปของหนึ่งท่า	หนึ่งคำหรือป้ายกำกับ	เหมาะกับท่าที่มีจุดเริ่มและสิ้นสุดชัดเจน
แบบต่อเนื่อง	วิดีโอหลายท่าต่อกัน	ลำดับคำหรือประโยค	ต้องแบ่งหน่วยท่าและจัดการบริบท

ตารางที่ 2.1 การเปรียบเทียบรูปแบบการรู้จำ

การเลือกแบบแยกคำทำให้ขอบเขตของปัญหาชัดเจนและเหมาะกับชุดข้อมูลขนาดเล็ก

ผู้ใช้งานทำท่าหนึ่งคำภายในหน้าต่างเก็บข้อมูล และระบบคืนผลหนึ่งป้ายกำกับต่อครั้ง

ข้อดีคือสามารถตรวจผลรายคำได้ตรงไปตรงมา

ส่วนข้อจำกัดคือยังไม่สามารถแบ่งคำจากการเคลื่อนไหวต่อเนื่องหรือเรียงผลเป็นประโยคภาษาพูดโดยอัตโนมัติ

การมองเห็นด้วยคอมพิวเตอร์: OpenCV ทำหน้าที่รับภาพจากกล้อง วาดส่วนติดต่อ และแสดงผล ส่วน MediaPipe Holistic ประเมินตำแหน่งจุดสำคัญของร่างกายและมือ การใช้พิกัดจุดสำคัญแทนภาพดิบช่วยลดมิติข้อมูลและทำให้ระบบเน้นโครงสร้างการเคลื่อนไหว แต่ผลยังขึ้นกับแสง มุมกล้อง การบังมือ และความเร็วของผู้ใช้

Lugaresi และคณะ (2019) เสนอ MediaPipe เป็นกรอบงานสำหรับสร้าง perception pipeline แบบข้ามแพลตฟอร์ม โดยเชื่อมส่วนรับสื่อ แบบจำลอง และการแปลงข้อมูลเป็นกราฟการประมวลผล ช่วยให้พัฒนาต้นแบบและวัดประสิทธิภาพบนอุปกรณ์เป้าหมายได้ ส่วน Zhang และคณะ (2020) พัฒนา MediaPipe Hands ซึ่งใช้ palm detector ร่วมกับ hand landmark model เพื่อประมาณโครงมือ 21 จุดจากภาพกล้องเดียวและทำงานแบบเวลาจริงบนอุปกรณ์เคลื่อนที่ แนวคิดทั้งสองเป็นฐานของการใช้ MediaPipe Holistic ใน HandVox

กระบวนการตรวจจับจุดสำคัญมีสองช่วงหลัก

คือการตรวจว่าร่างกายหรือมืออยู่บริเวณใดในภาพ

และการประมาณพิกัดของจุดข้อต่อภายในบริเวณนั้น เมื่อประมวลผลวิดีโอต่อเนื่อง ระบบสามารถติดตามตำแหน่งจากเฟรมก่อนหน้าเพื่อลดภาระการตรวจใหม่ทุกครั้ง แต่หากมือเคลื่อนเร็ว หลุดกรอบ หรือถูกบัง พิกัดอาจหายหรือกระโดดจนส่งผลต่อเวกเตอร์คุณลักษณะ

HandVox เปิดใช้งานการประมวลผลแบบวิดีโอต่อเนื่อง ใช้ model complexity ระดับกลาง เปิดการทำให้จุดต่อเนื่องราบรื่น และกำหนดค่าความเชื่อมั่นขั้นต่ำของการตรวจจับกับการติดตามเท่ากับ 0.70 การตั้งค่านี้นี้เป็นจุดสมดุลเบื้องต้นระหว่างความเสถียรกับความเร็ว และควรทดสอบใหม่เมื่อเปลี่ยนกล้องหรือสภาพแวดล้อม

จุดสำคัญที่ใช้ใน HandVox: ระบบเลือกจุดช่วงบน 15 จุด และมือซ้ายกับมือขวาข้างละ 21 จุด แต่ละจุดมีพิกัด x , y และ z จึงมีข้อมูลรวม 171 ค่าในหนึ่งเฟรม หากพบมือเพียงข้างเดียว ระบบเติมศูนย์ให้ข้อมูลมืออีกข้างเพื่อรักษาขนาดข้อมูลให้เท่ากัน

จุดช่วงบนช่วยอธิบายตำแหน่งของมือเมื่อเทียบกับศีรษะ ไหล่ ศอก และลำตัว ขณะที่จุดมืออธิบายรูปร่างและทิศทางฝ่ามือ การใช้ทั้งสองกลุ่มร่วมกันเหมาะกับการทำที่รูปร่างคล้ายกันแต่เกิดคนละตำแหน่ง หากไม่พบโครงร่างของช่วงบนหรือไม่พบมือทั้งสองข้าง ระบบจะไม่รับเฟรมนั้น เพราะข้อมูลไม่เพียงพอสำหรับสร้างตัวอย่างที่สอดคล้องกับชุดฝึก

การเติมศูนย์เมื่อพบมือเพียงข้างเดียวทำให้ทุกเฟรมมีจำนวนคุณลักษณะเท่ากัน แต่ศูนย์ในกรณีนี้หมายถึงข้อมูลที่ไม่ตรวจพบ ไม่ใช่ตำแหน่งจริงของมือ ดังนั้นสัดส่วนเฟรมที่มือหายไม่ควรมากเกินไป และควรตรวจคุณภาพคลิปก่อนรวมเข้าในชุดข้อมูล มิฉะนั้นแบบจำลองอาจเรียนรู้รูปแบบของข้อมูลหายแทนรูปแบบของท่าทาง

การปรับมาตรฐานและการแทนลำดับ:

ระบบใช้จุดกึ่งกลางระหว่างไหล่เป็นจุดอ้างอิงและใช้ระยะระหว่างไหล่เป็นตัวปรับขนาด เพื่อลดผลจากตำแหน่งและระยะห่างจากกล้อง หนึ่งคลิปมี 30 เฟรม เฟรมละ 171 ค่า ก่อนฝึกจะเรียงเป็นเวกเตอร์ 5,130 ค่า โดยลำดับของตำแหน่งในเวกเตอร์ยังคงข้อมูลการเคลื่อนไหวตามเวลา

ให้ c เป็นจุดกึ่งกลางระหว่างไหล่ซ้ายกับไหล่ขวา และให้ s เป็นระยะยุคลิดระหว่างไหล่
พิกัดของจุดแต่ละจุดถูกเลื่อนด้วย c และหารด้วย s ก่อนจัดเก็บ

วิธีนี้ลดผลจากการยืนค่อนไปทางซ้ายหรือขวาและการอยู่ใกล้หรือไกลกล้อง อย่างไรก็ตาม
การปรับดังกล่าวยังไม่ทำให้ข้อมูลไม่แปรผันต่อการหมุนตัว มุมกล้อง หรือสัดส่วนร่างกายทั้งหมด

การเรียงข้อมูล 30 เฟรมต่อกันเป็นเวกเตอร์ทำให้ SVM
สามารถใช้ข้อมูลเวลาได้โดยไม่ต้องมีโครงสร้างแบบจำลองลำดับเฉพาะ ตำแหน่งลำดับที่ 1-171
แทนเฟรมแรก และตำแหน่งช่วงท้ายแทนเฟรมที่ 30
ดังนั้นท่าที่เคลื่อนไหวในทิศทางตรงข้ามจะให้ลำดับค่าแตกต่างกัน แม้บางเฟรมจะมีรูปมือคล้ายกัน

ข้อจำกัดของการกำหนด 30 เฟรมคือผู้ที่ทำต้องปรับจังหวะให้พอดีกับหน้าต่างข้อมูล
หากทำช้าเร็วมากจะมีช่วงอยู่นิ่งเหลือมาก แต่หากทำช้ามากทำอาจไม่จบภายในคลิป
แบบจำลองจึงอาจไวต่อความเร็ว
การเก็บข้อมูลควรมีหลายจังหวะและในอนาคตอาจใช้การปรับแนวเวลา
หรือแบบจำลองที่รองรับความยาวลำดับไม่เท่ากัน

Support Vector Machine: Cortes และ Vapnik (1995) เสนอ Support-Vector
Networks สำหรับสร้างขอบเขตการตัดสินใจที่มีระยะห่างจากตัวอย่างสำคัญมากที่สุด
และใช้การแปลงข้อมูลไปยังปริภูมิมิติสูงเพื่อรองรับข้อมูลที่ไม่สามารถแยกด้วยเส้นตรง
แนวคิดดังกล่าวพัฒนาต่อมาเป็น SVM ที่ใช้ kernel ได้ HandVox ใช้ RBF kernel
เพื่อรองรับความสัมพันธ์ที่ไม่เป็นเส้นตรง กำหนด $C=10$, $\text{gamma}=\text{scale}$, $\text{probability}=\text{True}$ และ
 $\text{class_weight}=\text{balanced}$

ค่า C
ควบคุมการแลกเปลี่ยนระหว่างการยอมให้มีข้อผิดพลาดบนข้อมูลฝึกกับการสร้างขอบเขตที่ยืดหยุ่น
ค่า gamma กำหนดระยะอิทธิพลของตัวอย่างต่อรูปร่างขอบเขต ส่วน $\text{class_weight}=\text{balanced}$
เพิ่มน้ำหนักให้คลาสที่มีตัวอย่างน้อยกว่า
การตั้งค่าปัจจุบันยึดตามการทดลองของโครงการและควรปรับด้วยชุดตรวจสอบที่แยกจากชุดทดสอบ
เมื่อมีข้อมูลมากขึ้น

การเปิด probability ทำให้โปรแกรมใช้ predict_proba
 เพื่อรายงานค่าประกอบการตัดสินใจแบบเวลาจริง
 แต่ค่าความน่าจะเป็นดังกล่าวขึ้นกับการสอบเทียบของแบบจำลองและลักษณะข้อมูล
 ไม่ควรตีความว่าเป็นความถูกต้องที่รับประกันในทุกสภาพแวดล้อม เกณฑ์ 0.40
 จึงเป็นค่าตั้งต้นที่ต้องตรวจสอบกับข้อมูลภายนอก

การแบ่งข้อมูลและการป้องกันการรั่วไหล: การแบ่งแบบ stratified
 ช่วยรักษาสัดส่วนของแต่ละคลาสระหว่างชุดฝึกกับชุดทดสอบ
 แต่ถ้าคลิจากผู้ทำท่าหรือเซสชันเดียวกันกระจายอยู่ทั้งสองชุด
 คะแนนอาจสะท้อนความคล้ายของผู้ทำท่าและฉากหลังมากกว่าความสามารถกับผู้ใช้ใหม่
 แนวทางที่เข้มงวดกว่าคือแบ่งตามรหัสผู้ให้ข้อมูลหรือเซสชัน
 และเก็บชุดทดสอบภายนอกที่ไม่ใช่ระหว่างการพัฒนา

การประเมินผล: Accuracy ใช้สรุปสัดส่วนการทำนายถูกทั้งหมด ส่วน Precision, Recall
 และ F1-score ช่วยพิจารณาผลรายคลาส ค่า Macro F1 ให้น้ำหนักทุกคลาสเท่ากัน และ
 Confusion Matrix แสดงค่าที่ระบบทำนายสับสน
 การแบ่งข้อมูลควรแยกผู้ทำท่าหรือเซสชันเพื่อป้องกันข้อมูลที่คล้ายกันรั่วไหลระหว่างชุดฝึกและชุดทดสอบ

การทำงานแบบเวลาจริงและเสียงพูด: ระบบสะสมคุณลักษณะล่าสุด 30 เฟรม
 รับผลที่มีค่าความเชื่อมั่นอย่างน้อย 0.40 และลงคะแนนจากผลล่าสุด 3 ครั้งเพื่อให้ข้อความนิ่งขึ้น
 ผลที่ยืนยันแล้วสามารถเพิ่มลงในประโยคและอ่านออกเสียงภาษาไทยผ่านระบบ Text-to-Speech

กลไกรวมผลย้อนหลังช่วยลดการเปลี่ยนป้ายกำกับไปมาระหว่างเฟรม
 แต่ทำให้เกิดความหน่วงเพิ่มขึ้นเล็กน้อย หากไม่พบมีอนานกว่า 0.4 วินาที
 ระบบจะล้างคิวและสถานะเดิมเพื่อป้องกันผลเก่าค้างบนหน้าจอ การตั้งค่าทั้งสามส่วน ได้แก่
 ขนาดหน้าต่าง เกณฑ์ความเชื่อมั่น และจำนวนผลย้อนหลัง มีผลต่อความไวกับความเสถียรของระบบ

ส่วน Text-to-Speech ทำหน้าที่เปลี่ยนชื่อท่าหรือข้อความสะสมเป็นเสียงภาษาไทย
 ช่วยส่งผลลัพธ์ไปยังคู่สนทนาโดยไม่ต้องอ่านหน้าจอ

การสร้างเสียงทำงานแยกจากวงจรบล็อกรั้งเพื่อลดการหยุดค้าง แต่ gTTS ต้องใช้อินเทอร์เน็ต
จึงควรมีทางเลือกเสียงแบบออฟไลน์ในรุ่นที่ต้องใช้งานในพื้นที่เครือข่ายไม่เสถียร

งานวิจัยที่เกี่ยวข้อง

การคัดเลือกงานวิจัยพิจารณาความใกล้เคียงกับ HandVox ใน 4 ด้าน ได้แก่
การรู้จำภาษามือไทย การใช้ภาพหรือจุดสำคัญของร่างกาย การจำแนกท่าจากลำดับเวลา
และการทำงานแบบเวลาจริง
งานที่นำมาอ้างอิงมีทั้งงานภาษาไทยซึ่งสะท้อนข้อจำกัดด้านข้อมูลในประเทศ
และงานต่างประเทศที่แสดงแนวทางเมื่อจำนวนคำกับผู้ทำท่าเพิ่มขึ้น

การรู้จำนิ้วสะกดภาษาไทยด้วย SVM: Pariwat และ Seresangtakul (2017)

ศึกษาการรู้จำนิ้วสะกดภาษาไทยจากคุณลักษณะภาพแบบ global และ local แล้วเปรียบเทียบ
SVM หลาย kernel ข้อมูลที่รายงานในงานทบทวนภายหลังมี 15 ท่า 75 ภาพ จากผู้ทำท่า 5 คน
ผลเฉลี่ยของ RBF kernel เท่ากับ 91.2% สูงกว่า linear, polynomial และ sigmoid
งานนี้สนับสนุนการเลือก RBF สำหรับข้อมูลท่าทางที่ขอบเขตคลาสไม่เป็นเส้นตรง
แต่เป็นภาพนิ่งและชุดข้อมูลขนาดเล็ก จึงไม่ยืนยันผลของ HandVox ที่ใช้ลำดับ 30 เฟรมโดยตรง

การรู้จำนิ้วสะกดภาษาไทยด้วย CNN และการปฏิเสธท่าที่ไม่รู้จัก: Nakjai และ Katanyukul

(2019) พัฒนาระบบการสองขั้นตอน คือค้นหาและตัดบริเวณมือ ก่อนจำแนกภาพด้วย CNN หรือ
HOG งานใช้นิ้วสะกดภาษาไทย 25 ท่า 125 ภาพ จากผู้ทำท่า 11 คน และรายงาน mean
Average Precision 91.26 งานยังเสนอ confidence ratio
เพื่อช่วยแยกท่าที่ถูกต้องออกจากท่าช่วงเปลี่ยนหรือท่าที่ไม่อยู่ในชุดคำ แนวคิดดังกล่าวชี้ว่า
HandVox ควรมีสถานะ “ไม่ทราบ” แทนการบังคับเลือกหนึ่งใน 16 คลาสทุกครั้ง

ชุดข้อมูลวิดีโอเลขภาษามือไทย: Vijitkunsawat, Racharak, Nguyen และ Minh (2023)

สร้างชุดข้อมูลวิดีโอเลขภาษามือไทย 9 ท่า มีประมาณ 63 วิดีโอต่อท่า รวม 567 วิดีโอจากผู้ทำท่า 21
คน แล้วเปรียบเทียบ CNN-Mode, CNN-LSTM, VGG-Mode และ VGG-LSTM
ทั้งภาพเต็มกับภาพที่ตัดเฉพาะมือ ผลพบว่า VGG-LSTM
ร่วมกับการประมวลผลล่วงหน้าให้ผลดีที่สุดทั้งชุดทดสอบภายในและภายนอก

งานนี้แสดงความสำคัญของจำนวนผู้ทำท่า การเก็บข้อมูลเป็นวิดีโอ และการรายงานผลกับผู้ทำท่าที่ต่างจากชุดพัฒนา

ระบบตรวจจับภาษามือไทยด้วย MediaPipe และ LSTM: Damrongekarun, Pisitpipattana, Waijanya และ Promrit (2023) ใช้ MediaPipe ดึงจุดสำคัญของมือ ใบหน้า และท่าทางจากวิดีโอ แล้วใช้ LSTM วิเคราะห์ลำดับ แบ่งข้อมูลฝึกและทดสอบ 80:20 ได้ค่า Accuracy 0.83 และนำผลไปแสดงบนแอป Flutter ผ่าน Flask API งานนี้มีโครงสร้างใกล้เคียง HandVox ในด้านการใช้พิกัดจุดสำคัญและการส่งผลเป็นข้อความไทย แต่เลือกแบบจำลองลำดับเชิงลึกแทน SVM

การแปลภาษามือไทยเป็นข้อความแบบเวลาจริง: Jintanachaiwat และคณะ (2024) ใช้ MediaPipe Holistic เก็บจุดมือ ร่างกาย และใบหน้าเป็นลำดับ 30 เฟรม เฟรมละ 1,662 ค่า แล้วเปรียบเทียบ RNN, Bi-RNN, LSTM, Bi-LSTM และ FNN-LSTM สำหรับคำภาษาไทยที่ใช้ในการประชุม ผลของ LSTM บนชุดทดสอบเท่ากับ 100% แต่ลดเหลือ 86% เมื่อทดสอบแบบเวลาจริง ผู้วิจัยระบุว่าการเก็บข้อมูลจากผู้ทำท่าเพียงคนเดียวเสี่ยงต่อ overfitting ผลดังกล่าวยืนยันว่าคะแนนจากชุดทดสอบภายในอาจสูงกว่าการใช้งานจริงและควรเก็บข้อมูลหลายบุคคล

ชุดข้อมูลภาษามือระดับคำขนาดใหญ่: Li, Rodriguez, Yu และ Li (2020) เสนอ WLASL ซึ่งมีภาษามืออเมริกันระดับคำมากกว่า 2,000 คำและผู้ทำท่ามากกว่า 100 คน พร้อมเปรียบเทียบวิธีที่ใช้ภาพลักษณะโดยรวมกับวิธีที่ใช้โครงร่าง และเสนอ Pose-TGCN เพื่อเรียนรู้ความสัมพันธ์เชิงพื้นที่กับเวลา งานนี้แสดงความหลากหลายของผู้ทำท่าและขนาดคำศัพท์ทำให้ปัญหายากขึ้นมาก การเพิ่มคลาสใน HandVox จึงต้องเพิ่มข้อมูลและทดสอบวิธีลำดับที่ซับซ้อนกว่า SVM ควบคู่กัน

การรู้จำและการแปลภาษามือต่อเนื่อง: Camgoz, Hadfield, Koller, Ney และ Bowden (2018) เสนอปัญหา Neural Sign Language Translation และชุดข้อมูล RWTH-PHOENIX-Weather 2014T ซึ่งมีมากกว่า 67,000 หน่วยท่าจากคำศัพท์ภาษามือมากกว่า 1,000 หน่วย งานใช้แนวคิด Neural Machine Translation เพื่อเชื่อมวิดีโอกับประโยคภาษาพูด

ผลงานนี้มีขอบเขตกว้างกว่า HandVox เพราะต้องแบ่งทำต่อเนื่องและจัดการไวยากรณ์

แต่เป็นแนวทางระยะยาวสำหรับการพัฒนาจากการสะสมคำไปสู่การแปลประโยค

ผู้วิจัยและปี	ข้อมูลและวิธี	ผลสำคัญ	สิ่งที่ HandVox นำมาใช้
Pariwat และ Seresangtakul (2017) KST 2017, หน้า 116–120	15 ท่า; 75 ภาพ; 5 คน; คุณสมบัติ global/local และ SVM	RBF เฉลี่ย 91.2%	เลือก RBF และระบุข้อจำกัดของข้อมูลขนาดเล็ก
Nakjai และ Katanyukul (2019) DOI: 10.1007/s11265-018-1375-6	25 ท่า; 125 ภาพ; 11 คน; CNN เทียบ HOG	mAP 91.26 และเสนอ confidence ratio	เสนอให้เพิ่มสถานะไม่ทราบและตรวจท่าช่วงเปลี่ยน
Vijitkunsawat และคณะ (2023) DOI: 10.5220/0011643700003411	9 ท่าเลข; 567 วิดีโอ; 21 คน; CNN/LSTM และ VGG/LSTM	VGG-LSTM หลังตัดบริเวณมือให้ผลดีที่สุด	เก็บวิดีโอหลายคนและแยกทดสอบภายนอก
Damrongekarun และคณะ (2023) DOI: 10.14456/kkuscij.2023.19	MediaPipe landmarks, LSTM, แบ่ง 80:20 และแอป Flutter	Accuracy 0.83	ใช้พิกัดจุดสำคัญและแสดงผลเป็นข้อความไทย
Jintanachaiwat และคณะ (2024) DOI: 10.1007/s44163-024-00113-8	MediaPipe Holistic; 30 เฟรม; เปรียบเทียบ RNN และ LSTM	LSTM ชุดทดสอบ 100%; เวลาจริง 86%	แยกผลภายในออกจากเวลาจริงและระวังข้อมูลคนเดียวยาว
Li และคณะ (2020) WACV 2020, หน้า 1459–1469	WLASL มากกว่า 2,000 คำ; มากกว่า 100 คน; appearance/pose/Pose-TGCN	แสดงความท้าทายเมื่อคำและผู้ทำท่าเพิ่ม	วางแผนขยายข้อมูลและเปรียบเทียบโมเดลลำดับ
Camgoz และคณะ (2018) DOI: 10.1109/CVPR.2018.00812	วิดีโอต่อเนื่อง มากกว่า 67,000 หน่วยท่า และ Neural Translation	แปลภาษามือโดยคำนึงถึงลำดับและไวยากรณ์	กำหนดขอบเขตปัจจุบันเป็นแยกคำและวางแผนทางอนาคต

ตารางที่ 2.2 การเปรียบเทียบงานวิจัยที่เกี่ยวข้องกับ HandVox

ข้อสรุปจากงานวิจัยคือ คุณภาพของระบบไม่ได้ขึ้นกับตัวจำแนกเพียงอย่างเดียว

แต่ขึ้นกับจำนวนผู้ทำท่า ความสมดุลงานคลาส การกำหนดจุดเริ่มและจบ การจัดการท่าที่ไม่รู้จัก

และวิธีแบ่งชุดทดสอบ HandVox จึงควรเพิ่มผู้ทำท่าและชุดทดสอบภายนอก เพิ่มสถานะไม่ทราบ
และเปรียบเทียบ SVM กับ LSTM ภายใต้อข้อมูลชุดเดียวกัน