

บทที่ 2

เอกสารและทฤษฎีที่เกี่ยวข้อง

แนวคิดและทฤษฎี

ภาษามือและการรู้จำ: ภาษามือเป็นภาษาธรรมชาติที่ประกอบด้วยรูปมือ ตำแหน่ง ทิศทาง การเคลื่อนไหว สีหน้า และโครงสร้างทางภาษา การรู้จำแบบแยกคำรับคลิบของท่าหนึ่งคำและส่งออกหนึ่งป้ายกำกับ ส่วนการรู้จำแบบต่อเนื่องต้องแบ่งหน่วยท่าจากวิดีโอหลายคำและจัดการบริบท HandVox เลือกขอบเขตแบบแยกคำเพื่อให้พัฒนาและประเมินต้นแบบได้ชัดเจน

การจำแนกรูปมือจากภาพนิ่งเหมาะกับคำที่รูปมือในช่วงใดช่วงหนึ่งมีข้อมูลเพียงพอ แต่ท่าจำนวนมากมีความหมายต่างกันจากทิศทาง การเคลื่อนเข้า-ออก การหมุนข้อมือ หรือการเปลี่ยนตำแหน่งสัมพันธ์กับร่างกาย หากใช้ภาพเพียงเฟรมเดียว ระบบอาจมองไม่เห็นลำดับดังกล่าว การใช้คลิบจึงช่วยให้แบบจำลองได้รับข้อมูลก่อน ระหว่าง และหลังการเคลื่อนไหว

สำหรับการรู้จำแบบแยกคำ ผู้เก็บข้อมูลต้องกำหนดจุดเริ่มและจุดสิ้นสุดของท่าให้ใกล้เคียงกันในทุกตัวอย่าง ถ้าบางคลิบเริ่มช้า บางคลิบจบเร็ว หรือมีช่วงอยู่นิ่งยาวเกินไป แบบจำลองอาจเรียนรู้จังหวะที่ไม่เกี่ยวข้องกับความหมาย HandVox จึงกำหนดจำนวนเฟรมคงที่และใช้คำแนะนำการเก็บข้อมูลแบบเดียวกันทุกคลาส

รูปแบบ	ข้อมูลนำเข้า	ผลลัพธ์	ขอบเขต
ภาพนิ่ง	หนึ่งเฟรม	คลาสของรูปมือ	ไม่แทนลำดับการเคลื่อนไหว
แบบแยกคำ	คลิบของหนึ่งท่า	หนึ่งคำหรือป้ายกำกับ	เหมาะกับท่าที่มีจุดเริ่มและสิ้นสุดชัดเจน
แบบต่อเนื่อง	วิดีโอหลายท่าต่อกัน	ลำดับคำหรือประโยค	ต้องแบ่งหน่วยท่าและจัดการบริบท

ตารางที่ 2.1 การเปรียบเทียบรูปแบบการรู้จำ

การเลือกแบบแยกคำทำให้ขอบเขตของปัญหาชัดเจนและเหมาะกับชุดข้อมูลขนาดเล็ก
 ผู้ใช้ต้องทำท่าหนึ่งคำภายในหน้าต่างเก็บข้อมูล และระบบคืนผลหนึ่งป้ายกำกับต่อครั้ง
 ข้อดีคือสามารถตรวจผลรายคำได้ตรงไปตรงมา
 ส่วนข้อจำกัดคือยังไม่สามารถแบ่งคำจากการเคลื่อนไหวต่อเนื่องหรือเรียงผลเป็นประโยคภาษาพูดโดย
 อัตโนมัติ

การมองเห็นด้วยคอมพิวเตอร์: OpenCV ทำหน้าที่รับภาพจากกล้อง วาดส่วนติดต่อ
 และแสดงผล ส่วน MediaPipe Holistic ประมาณตำแหน่งจุดสำคัญของร่างกายและมือ
 การใช้พิกัดจุดสำคัญแทนภาพดิบช่วยลดมิติข้อมูลและทำให้ระบบเน้นโครงสร้างการเคลื่อนไหว
 แต่ผลยังขึ้นกับแสง มุมกล้อง การบังมือ และความเร็วของผู้ใช้

กระบวนการตรวจจับจุดสำคัญมีสองช่วงหลัก
 คือการตรวจว่าร่างกายหรือมืออยู่บริเวณใดในภาพ
 และการประมาณพิกัดของจุดข้อต่อภายในบริเวณนั้น เมื่อประมวลผลวิดีโอต่อเนื่อง
 ระบบสามารถติดตามตำแหน่งจากเฟรมก่อนหน้าเพื่อลดภาระการตรวจใหม่ทุกครั้ง
 แต่หากมือเคลื่อนเร็ว หลุดกรอบ หรือถูกบัง
 พิกัดอาจหายหรือกระโดดจนส่งผลต่อเวกเตอร์คุณลักษณะ

HandVox เปิดใช้งานการประมวลผลแบบวิดีโอต่อเนื่อง ใช้ model complexity
 ระดับกลาง เปิดการทำให้จุดต่อเนื่องราบรื่น
 และกำหนดค่าความเชื่อมั่นขั้นต่ำของการตรวจจับกับการติดตามเท่ากับ 0.70
 การตั้งค่านี้นับเป็นจุดสมดุลเบื้องต้นระหว่างความเสถียรกับความเร็ว
 และควรทดสอบใหม่เมื่อเปลี่ยนกล้องหรือสภาพแวดล้อม


จุดสำคัญที่ใช้ใน HandVox: ระบบเลือกจุดช่วงบน 15 จุด และมือซ้ายกับมือขวาข้างละ 21
 จุด แต่ละจุดมีพิกัด x, y และ z จึงมีข้อมูลรวม 171 ค่าในหนึ่งเฟรม หากพบมือเพียงข้างเดียว
 ระบบเติมศูนย์ให้ข้อมูลมืออีกข้างเพื่อรักษารูปแบบขนาดข้อมูลให้เท่ากัน

จุดช่วงบนช่วยอธิบายตำแหน่งของมือเมื่อเทียบกับศีรษะ ไหล่ ศอก และลำตัว
 ขณะที่จุดมืออธิบายรูปร่างและทิศทางฝ่ามือ
 การใช้ทั้งสองกลุ่มร่วมกันเหมาะกับท่าที่รูปมือคล้ายกันแต่เกิดคนละตำแหน่ง

หากไม่พบโครงร่างของช่วงบนหรือไม่พบมือทั้งสองข้าง ระบบจะไม่รับเฟรมนั้น
เพราะข้อมูลไม่เพียงพอสำหรับสร้างตัวอย่างที่สอดคล้องกับชุดฝึก

กลุ่มจุด	จำนวนจุด	พิกัดต่อจุด	จำนวนคุณลักษณะ
ช่วงบน	15	x, y, z	45
มือซ้าย	21	x, y, z	63
มือขวา	21	x, y, z	63
รวมต่อเฟรม	57	3	171

ตารางที่ 2.2 คุณลักษณะที่ HandVox เลือกใช้



ภาพที่ 2.1 จุดสำคัญที่ HandVox เลือกใช้จาก MediaPipe Holistic

การเติมศูนย์เมื่อพบมือเพียงข้างเดียวทำให้ทุกเฟรมมีจำนวนคุณลักษณะเท่ากัน
แต่ศูนย์ในกรณีนี้หมายถึงข้อมูลที่ไม่ตรวจพบ ไม่ใช่ตำแหน่งจริงของมือ
ดังนั้นสัดส่วนเฟรมที่มีมือหายไม่ควรมากเกินไป และควรตรวจสอบคุณภาพคลิปก่อนรวมเข้าในชุดข้อมูล
มีฉะนั้นแบบจำลองอาจเรียนรู้รูปแบบของข้อมูลหายแทนรูปแบบของท่าทาง

การปรับมาตรฐานและการแทนลำดับ:

ระบบใช้จุดกึ่งกลางระหว่างไหล่เป็นจุดอ้างอิงและใช้ระยะระหว่างไหล่เป็นตัวปรับขนาด
เพื่อลดผลจากตำแหน่งและระยะห่างจากกล้อง หนึ่งคลิปมี 30 เฟรม เฟรมละ 171 ค่า

ก่อนฝึกจะเรียงเป็นเวกเตอร์ 5,130 ค่า

โดยลำดับของตำแหน่งในเวกเตอร์ยังคงข้อมูลการเคลื่อนไหวตามเวลา

ให้ c เป็นจุดกึ่งกลางระหว่างไหล่ซ้ายกับไหล่ขวา และให้ s เป็นระยะยูกติระหว่างไหล่
พิกัดของจุดแต่ละจุดถูกเลื่อนด้วย c และหารด้วย s ก่อนจัดเก็บ

วิธีนี้ลดผลจากการยืนค่อนไปทางซ้ายหรือขวาและการอยู่ใกล้หรือไกลกล้อง อย่างไรก็ตาม
การปรับดังกล่าวยังไม่ทำให้ข้อมูลไม่แปรผันต่อการหมุนตัว มุมกล้อง หรือสัดส่วนร่างกายทั้งหมด

การเรียงข้อมูล 30 เฟรมต่อกันเป็นเวกเตอร์ทำให้ SVM

สามารถใช้ข้อมูลเวลาได้โดยไม่ต้องมีโครงสร้างแบบจำลองลำดับเฉพาะ ตำแหน่งลำดับที่ 1-171

แทนเฟรมแรก และตำแหน่งช่วงท้ายแทนเฟรมที่ 30

ดังนั้นท่าที่เคลื่อนไหวในทิศทางตรงข้ามจะให้ลำดับค่าแตกต่างกัน แม้บางเฟรมจะมีรูปมือน้อยคล้ายกัน



ภาพที่ 2.2 การแทนคลิปหนึ่งท่าเป็นลำดับ 30 เฟรม

ข้อจำกัดของการกำหนด 30 เฟรมคือผู้ที่ทำท่าต้องปรับจังหวะให้พอดีกับหน้าต่างข้อมูล

หากทำท่าเร็วมากจะมีช่วงอยู่นิ่งเหลือมาก แต่หากทำช้ามากท่าอาจไม่จบภายในคลิป

แบบจำลองจึงอาจไวต่อความเร็ว

การเก็บข้อมูลควรมีหลายจังหวะและในอนาคตอาจใช้การปรับแนวเวลา

หรือแบบจำลองที่รองรับความยาวลำดับไม่เท่ากัน

Support Vector Machine: SVM

เป็นแบบจำลองการเรียนรู้แบบมีผู้สอนที่สร้างขอบเขตการตัดสินใจระหว่างคลาส HandVox ใช้ RBF

kernel เพื่อรองรับความสัมพันธ์ที่ไม่เป็นเส้นตรง กำหนด $C=10$, $\gamma=\text{scale}$,

probability=True และ class_weight=balanced

เพื่อถ่วงผลจากจำนวนคลิป์ที่ไม่เท่ากันและส่งค่าความเชื่อมั่นประกอบการทำนาย

ค่า C

ควบคุมการแลกเปลี่ยนระหว่างการยอมให้มีข้อผิดพลาดบนข้อมูลฝึกกับการสร้างขอบเขตที่ยืดหยุ่น

ค่า gamma กำหนดระยะอิทธิพลของตัวอย่างต่อรูปร่างขอบเขต ส่วน class_weight=balanced

เพิ่มน้ำหนักให้คลาสที่มีตัวอย่างน้อยกว่า

การตั้งค่าปัจจุบันยึดตามการทดลองของโครงการและควรปรับด้วยชุดตรวจสอบที่แยกจากชุดทดสอบ
เมื่อมีข้อมูลมากขึ้น

การเปิด probability ทำให้โปรแกรมใช้ predict_proba

เพื่อรายงานค่าประกอบการตัดสินใจแบบเวลาจริง

แต่ค่าความน่าจะเป็นดังกล่าวขึ้นกับการสอบเทียบของแบบจำลองและลักษณะข้อมูล

ไม่ควรตีความว่าเป็นความถูกต้องที่รับประกันในทุกสภาพแวดล้อม เกณฑ์ 0.40

จึงเป็นค่าตั้งต้นที่ต้องตรวจสอบกับข้อมูลภายนอก

การแบ่งข้อมูลและการป้องกันการรั่วไหล: การแบ่งแบบ stratified

ช่วยรักษาสัดส่วนของแต่ละคลาสระหว่างชุดฝึกกับชุดทดสอบ

แต่ถ้าคลิป์จากผู้ทำท่าหรือเซสชันเดียวกันกระจายอยู่ทั้งสองชุด

คะแนนอาจสะท้อนความคล้ายของผู้ทำท่าและฉากหลังมากกว่าความสามารถกับผู้ใช้ใหม่

แนวทางที่เข้มงวดกว่าคือแบ่งตามรหัสผู้ให้ข้อมูลหรือเซสชัน

และเก็บชุดทดสอบภายนอกที่ไม่ใช้ระหว่างการพัฒนา

การประเมินผล: Accuracy ใช้สรุปสัดส่วนการทำนายถูกทั้งหมด ส่วน Precision, Recall

และ F1-score ช่วยพิจารณาผลรายคลาส ค่า Macro F1 ให้น้ำหนักทุกคลาสเท่ากัน และ

Confusion Matrix แสดงคู่ท่าที่ระบบทำนายสับสน

การแบ่งข้อมูลควรแยกผู้ทำท่าหรือเซสชันเพื่อป้องกันข้อมูลที่คล้ายกันรั่วไหลระหว่างชุดฝึกและชุดทดสอบ

ตัวชี้วัด	ความหมาย	การใช้กับ HandVox
Accuracy	สัดส่วนตัวอย่างที่ทำนายถูกทั้งหมด	สรุปผลรวมของชุดทดสอบ

ตัวชี้วัด	ความหมาย	การใช้กับ HandVox
Precision	สัดส่วนผลทำนายของคลาสที่เป็นตัวอย่างจริง	ตรวจการทำนายคลาสเกิน
Recall	สัดส่วนตัวอย่างจริงของคลาสที่ระบบค้นพบ	ตรวจการพลาดตัวอย่างของคลาส
F1-score	ค่าเฉลี่ยฮาร์โมนิกของ Precision และ Recall	เปรียบเทียบสมมูลผลรายคลาส
Macro F1	ค่าเฉลี่ย F1 โดยให้น้ำหนักทุกคลาสเท่ากัน	ลดการครอบงำของคลาสที่มีข้อมูลมา ก
Confusion Matrix	จำนวนตัวอย่างจริงและผลทำนายของทุกคู่คลาส	ค้นหาทำที่ระบบสับสนกัน

ตารางที่ 2.3 ตัวชี้วัดที่ใช้ประเมินระบบ

การทำงานแบบเวลาจริงและเสียงพูด: ระบบสะสมคุณลักษณะล่าสุด 30 เฟรม

รับผลที่มีค่าความเชื่อมั่นอย่างน้อย 0.40 และลงคะแนนจากผลล่าสุด 3 ครั้งเพื่อให้ข้อความนิ่งขึ้น ผลที่ยืนยันแล้วสามารถเพิ่มลงในประโยคและอ่านออกเสียงภาษาไทยผ่านระบบ Text-to-Speech

กลไกรวมผลย้อนหลังช่วยลดการเปลี่ยนป้ายกำกับไปมาระหว่างเฟรม

แต่ทำให้เกิดความหน่วงเพิ่มขึ้นเล็กน้อย หากไม่พบมีอนานกว่า 0.4 วินาที

ระบบจะล้างคิวและสถานะเดิมเพื่อป้องกันผลเก่าค้างบนหน้าจอ การตั้งค่าทั้งสามส่วน ได้แก่ ขนาดหน้าต่าง เกณฑ์ความเชื่อมั่น และจำนวนผลย้อนหลัง มีผลต่อความไวกับความเสถียรของระบบ

ส่วน Text-to-Speech ทำหน้าที่เปลี่ยนชื่อท่าหรือข้อความสะสมเป็นเสียงภาษาไทย

ช่วยส่งผลลัพธ์ไปยังคู่สนทนาโดยไม่ต้องอ่านหน้าจอ

การสร้างเสียงทำงานแยกจากวงจรบล็อกรเพื่อลดการหยุดค้าง แต่ gTTS ต้องใช้อินเทอร์เน็ต

จึงควรมีทางเลือกเสียงแบบออฟไลน์ในรุ่นที่ต้องใช้งานในพื้นที่เครือข่ายไม่เสถียร

งานวิจัยที่เกี่ยวข้อง

การพัฒนา HandVox นำแนวทางจากงานด้านการตรวจหาจุดมือ การรู้จำท่าทางแบบลำดับ และการประเมินตัวจำแนกหลายคลาสมาประยุกต์ร่วมกัน แนวทางที่เกี่ยวข้องสามารถสรุปได้ดังนี้

งานกลุ่มแรกเน้นการใช้จุดสำคัญของมือหรือโครงร่างร่างกายแทนภาพดิบ

วิธีนี้ลดขนาดข้อมูลและอธิบายตำแหน่งข้อต่อได้โดยตรง เหมาะกับระบบเวลาจริงที่มีทรัพยากรจำกัด แต่ความแม่นยำขึ้นกับตัวตรวจจับจุด หากมือถูกบังหรือออกนอกภาพ คุณลักษณะที่ได้จะไม่สมบูรณ์

งานกลุ่มที่สองศึกษาการรู้จำท่าทางแบบแยกคำจากลำดับภาพ
แนวทางทั่วไปคือกำหนดคลิปหนึ่งท่าต่อหนึ่งป้ายกำกับแล้วเรียนรู้ความเปลี่ยนแปลงตามเวลา
บางระบบใช้ SVM หรือ HMM เมื่อข้อมูลมีขนาดเล็ก ขณะที่ระบบที่มีข้อมูลจำนวนมากอาจใช้ LSTM,
Temporal Convolution หรือ Transformer เพื่อเรียนรู้ลำดับโดยตรง

งานกลุ่มที่สามมุ่งรู้จำหลายคำต่อเนื่องหรือแปลเป็นประโยค
ซึ่งต้องแก้ปัญหาการหาจุดแบ่งระหว่างท่า การจัดการท่าเชื่อม
และความแตกต่างระหว่างไวยากรณ์ภาษามือกับภาษาพูด งานกลุ่มนี้มีขอบเขตกว้างกว่า HandVox
รุ่นปัจจุบัน แต่เป็นทิศทางสำหรับการพัฒนาเมื่อมีข้อมูลที่หลากหลายและต่อเนื่องเพียงพอ

งานด้านระบบช่วยสื่อสารยังให้ความสำคัญกับประสบการณ์ผู้ใช้ เวลาแฝง
ความสามารถในการปฏิเสธคำที่ไม่รู้จัก ความเป็นส่วนตัว และการทดสอบร่วมกับชุมชนผู้ใช้ภาษามือ
ประเด็นเหล่านี้ช่วยเตือนว่าคะแนนจำแนกเพียงอย่างเดียวไม่เพียงพอที่จะยืนยันว่าระบบเหมาะกับกา
รใช้งานจริง

แนวทางของงานที่เกี่ยวข้อง	แนวคิดสำคัญ	สิ่งที่นำมาใช้กับ HandVox
การรู้จำรูปมือจากจุดสำคัญ	ใช้พิกัดข้อต่อมือแทนภาพดิบเพื่อลดขนาดข้อมูล	ใช้จุดมือ 21 จุดต่อข้างร่วมกับจุดช่วงบน
การรู้จำท่าทางแบบแยกคำ	ใช้คลิปของหนึ่งท่าและพิจารณาลำดับการเคลื่อนไหว	กำหนดหนึ่งคลิป 30 เฟรมและหนึ่งผลลัพธ์ต่อคลิป
การรู้จำด้วยแบบจำลองดั้งเดิม	แปลงคุณลักษณะเป็นเวกเตอร์แล้วจำแนกหลายคลาส	ใช้ SVM แบบ RBF กับเวกเตอร์ 5,130 ค่า
การประเมินระบบรู้จำ	รายงานผลรวม ผลรายคลาส และคู่ที่สับสน	ใช้ Accuracy, Macro F1 และ Confusion Matrix
ระบบช่วยสื่อสารแบบเวลาจริง	เชื่อมการทำนายกับข้อความ ประโยค และเสียง	แสดงชื่อท่า สะสมคำ และอ่านเสียงภาษาไทย
การป้องกันข้อมูลรั่วไหล	แบ่งข้อมูลตามผู้ทำท่าหรือเซสชัน	กำหนดเป็นแนวทางประเมินรุ่นถัดไป

แนวทางของงานที่เกี่ยวข้อง	แนวคิดสำคัญ	สิ่งที่นำมาใช้กับ HandVox
การออกแบบร่วมกับผู้ใช้	ตรวจคำศัพท์ ความหมาย และความสะดวกในการใช้งาน	กำหนดเป็นขั้นตอนก่อนนำไปใช้จริง

ตารางที่ 2.4 แนวทางงานที่เกี่ยวข้องกับ HandVox

เมื่อเปรียบเทียบกับแนวทางข้างต้น HandVox เน้นการเชื่อมกระบวนการเก็บข้อมูล

ฝึกแบบจำลอง ทำนาย และนำเสนอผลไว้ในต้นแบบเดียว

จุดที่ต้องพัฒนาต่อการเพิ่มจำนวนผู้ทำท่าและคำศัพท์ การแบ่งข้อมูลแบบแยกบุคคล

และการทดสอบในสภาพแวดล้อมจริง

จุดเด่นของแนวทางปัจจุบันคือโครงสร้างไม่ซับซ้อนเกินไป

ผู้พัฒนาสามารถตรวจเช็คเงื่อนไขและฝึกแบบจำลองได้รวดเร็ว

จึงเหมาะกับการพิสูจน์กระบวนการตั้งแต่ต้นจนจบ อย่างไรก็ตาม เมื่อจำนวนคำและผู้ทำท่าเพิ่มขึ้น

ควรทดสอบว่าวิธีเรียง 30 เฟรมเป็นเวกเตอร์ยังรองรับความหลากหลายได้เพียงใด

และควรเปรียบเทียบกับแบบจำลองลำดับภายใต้ชุดทดสอบเดียวกัน

บทเรียนจากงานที่เกี่ยวข้องจึงนำไปสู่หลักการสำคัญสามประการสำหรับ HandVox ได้แก่

ต้องกำหนดขอบเขตความรู้จำให้ตรงกับความสามารถจริง

ต้องแยกข้อมูลทดสอบออกจากผู้ทำท่าหรือเซสชันที่ใช้พัฒนา และต้องประเมินทั้งความแม่นยำ

สมรรถนะเวลาจริง และความเหมาะสมต่อผู้ใช้อีก่อนสรุปผลการนำไปใช้