

บทที่ 4

ผลการดำเนินงาน

ผลการวิเคราะห์และทดลอง

ชุดข้อมูล HandVox มี 350 คลิป แต่ละคลิปประกอบด้วยข้อมูล 30 เฟรมและแต่ละเฟรมมี 171 คุณลักษณะ รวมเป็นเวกเตอร์ 5,130 ค่าต่อคลิป ชุดข้อมูลมี 16 ป้ายกำกับ จำนวนตัวอย่างต่อป้ายกำกับอยู่ระหว่าง 10–30 คลิป การตรวจสอบไม่พบค่า NaN หรือ infinity และไม่พบคลิปที่ซ้ำกันทุกค่าแบบตรงตัว

ข้อมูลถูกจัดเก็บเป็นอาร์เรย์ชนิด float32 รูปร่าง $350 \times 30 \times 171$ การตรวจสอบมิติยืนยันว่าทุกคลิปมีจำนวนเฟรมและจำนวนคุณลักษณะเท่ากัน จึงสามารถเรียงเป็นเมทริกซ์สองมิติสำหรับ SVM ได้โดยไม่ต้องเติมความยาวเพิ่มเติม สัดส่วนค่าศูนย์ประมาณ 12.93% ซึ่งรวมทั้งค่าที่เกิดจากมือที่ตรวจไม่พบและค่าที่เป็นศูนย์จริงหลังปรับมาตรฐาน

ชุดข้อมูลประกอบด้วยข้อมูลฐานเดิม 120 คลิปจาก 4 ท่า และ Dataset V2 จำนวน 230 คลิปจาก 12 ท่า ข้อมูล Dataset V2 มีรหัสผู้ทำท่า 2 รหัสและเซสชัน 2 รอบ พร้อมสถานะ accepted ส่วนข้อมูลฐานเดิมไม่มี metadata ระดับบุคคลและเซสชัน ความแตกต่างนี้เป็นข้อจำกัดสำคัญเมื่อต้องการแบ่งข้อมูลแบบแยกผู้ทำท่า

รายการ	ผลที่ตรวจสอบได้	ความหมาย
รูปร่างชุดข้อมูล	$350 \times 30 \times 171$	350 คลิป; คลิปละ 30 เฟรม; เฟรมละ 171 ค่า
จำนวนป้ายกำกับ	16 ป้ายกำกับ	ท่าที่ระบบสามารถจำแนกได้ในรุ่นปัจจุบัน
จำนวนต่อป้ายกำกับ	10–30 คลิป	ข้อมูลยังไม่สมดุล
ชนิดข้อมูล	float32	สอดคล้องกับขั้นตอนฝึกและทำนาย
ค่าที่ไม่เป็นจำนวนจำกัด	ไม่พบ	ทุกค่าผ่านการตรวจสอบ
คลิปซ้ำแบบตรงตัว	0 คลิป	คลิปทั้ง 350 รายการมีเวกเตอร์ต่างกัน

ตารางที่ 4.1 ผลการตรวจสอบชุดข้อมูล HandVox

กลุ่มป้ายกำกับ	จำนวนต่อท่า	จำนวนคลิป	สถานะข้อมูล
ขอบคุณ ขอโทษ สวัสดี และไม่เป็นไร	30	120	ข้อมูลฐานเดิม ไม่มี metadata รายคลิป
กิน ช่วยด้วย ต้องการ น้ำ หมอ หยุด ห้องน้ำ เข้าใจ เจ็บ ไข้ และไม่เข้าใจ	20	220	Dataset V2 มีรหัสผู้ทำท่าและเซสชัน
ไม่ใช่	10	10	Dataset V2 มีรหัสผู้ทำท่าและเซสชัน
รวม 16 ท่า	10-30	350	ใช้ร่วมกันในการทดลองรอบปี ปัจจุบัน

ตารางที่ 4.2 การกระจายจำนวนคลิปในชุดข้อมูล

จำนวนตัวอย่างที่ไม่เท่ากันทำให้คลาสที่มี 30 คลิปมีอิทธิพลต่อการฝึกมากกว่าคลาสที่มี 10 คลิป โครงการจึงเปิด `class_weight=balanced` เพื่อถ่วงน้ำหนัก แต่การถ่วงน้ำหนักไม่สามารถทดแทนความหลากหลายของข้อมูลได้ โดยเฉพาะคลาสที่มีผู้ทำท่าหรือเซสชันจำนวนน้อย จึงยังต้องเก็บข้อมูลเพิ่มอย่างสมดุล

การทดลองแบ่งข้อมูลแบบ stratified holdout 80:20 โดยใช้ชุดฝึก 280 คลิปและชุดทดสอบ 70 คลิป กำหนด random state เท่ากับ 42 และใช้ SVC แบบ RBF ที่มี $C=10$, $\gamma=scale$, $probability=True$ และ `class_weight=balanced` การทดลองนี้ใช้สำหรับประเมินต้นแบบภายในชุดข้อมูลปัจจุบัน

รายการ	ค่าที่ใช้	รายละเอียด
การแบ่งข้อมูล	80:20 แบบ stratified	ฝึก 280 คลิป; ทดสอบ 70 คลิป
Random state	42	ทำซ้ำการแบ่งเดิมได้
แบบจำลอง	SVC แบบ RBF	$C=10$ และ $\gamma=scale$
การรายงานความเชื่อมั่น	$probability=True$	ใช้ประกอบการทำนายแบบเวลาจริง
การถ่วงคลาส	<code>class_weight=balanced</code>	ลดผลจากจำนวนคลิปที่ไม่เท่ากัน

ตารางที่ 4.3 การตั้งค่าการทดลอง

การแบ่งแบบ stratified ทำให้ทุกคลาสมีตัวอย่างอยู่ในชุดฝึกและชุดทดสอบตามสัดส่วนเดิม โดยคลาสหนึ่งมีตัวอย่างในชุดทดสอบประมาณ 2–6 คลิป การกำหนด random state ช่วยให้ทำการแบ่งรอบนี้ได้ แต่ไม่ได้ทำให้ผลเป็นอิสระจากผู้ทำซ้ำ หากคลิปที่คล้ายกันจากเซตชั้นเดียวกันอยู่คนละชุด คะแนนยังอาจสูงกว่าการทดสอบกับข้อมูลใหม่ แบบจำลองไม่ได้ปรับพารามิเตอร์จากชุดทดสอบในรอบนี้ การตั้งค่า C และ gamma ใช้ค่าที่กำหนดในซอร์สโค้ด การทดลองจึงมีลักษณะเป็น quick trial สำหรับตรวจว่ากระบวนการและคุณลักษณะสามารถแยกคลาสเบื้องต้นได้หรือไม่ ก่อนวางแผนสร้างชุดตรวจสอบและเปรียบเทียบพารามิเตอร์อย่างเป็นระบบ

แบบจำลองทำนายถูก 66 จาก 70 คลิปและผิด 4 คลิป คิดเป็น Accuracy 94.29% ค่า Macro Precision, Macro Recall และ Macro F1 เท่ากับ 93.75% โดย 14 จาก 16 คลาสได้ผลสมบูรณ์ในรอบทดลอง ส่วนทำ “เข้าใจ” และ “ไม่เข้าใจ” มี F1 เท่ากับ 0.500 และถูกทำนายสลับกัน

ตัวชี้วัด	ผลลัพธ์	การตีความ
ทำนายถูก / ผิด	66 / 4 คลิป	ชุดทดสอบรวม 70 คลิป
Accuracy	94.29%	ผลรวมของการทำนายทุกคลาส
Macro Precision	93.75%	ให้น้ำหนักทุกคลาสเท่ากัน
Macro Recall	93.75%	สองคลาสมีค่าต่ำกว่าคลาสอื่น
Macro F1	93.75%	ผลเฉลี่ยรายคลาส

ตารางที่ 4.4 ผลการประเมินภาพรวม

Accuracy และ Weighted F1 มีค่า 94.29% เท่ากัน


เพราะแบบจำลองทำนายถูกในคลาสส่วนใหญ่และข้อผิดพลาดเกิดในคลาสที่มีจำนวนตัวอย่างไม่มาก ค่า Macro F1 ต่ำกว่าเล็กน้อยที่ 93.75% เนื่องจากให้น้ำหนักทุกคลาสเท่ากัน จึงสะท้อนผลของคลาสเข้าใจและไม่เข้าใจที่มี F1 เพียง 0.500 ชัดกว่าค่าที่ถ่วงตามจำนวนตัวอย่าง

กลุ่มผลลัพธ์	Support	Precision	Recall	F1-score
14 คลาสที่ทำนายถูกทั้งหมด	2–6 ต่อคลาส	1.000	1.000	1.000

กลุ่มผลลัพธ์	Support	Precision	Recall	F1-score
เข้าใจ	4	0.500	0.500	0.500
ไม่เข้าใจ	4	0.500	0.500	0.500
Macro average	70	0.9375	0.9375	0.9375
Weighted average	70	0.9429	0.9429	0.9429

ตารางที่ 4.5 ผลการจำแนกตามกลุ่มคลาส

ความผิดพลาดทั้ง 4 คลิปเกิดจากคู่ทำเข้าใจและไม่เข้าใจ โดยตัวอย่างจริงของแต่ละคลาส 2 จาก 4 คลิปถูกทำนายสลับกัน
 รูปแบบนี้แสดงว่าคุณลักษณะหรือข้อมูลฝึกยังไม่แยกจุดต่างของสองทำได้ชัดเจน
 ควรตรวจสอบลำดับการเคลื่อนไหวของมือ ช่วงเริ่ม-จบ และคำอธิบายป้ายกำกับ
 พร้อมเก็บตัวอย่างจากหลายคนเพิ่มเติม



ภาพที่ 4.1 Confusion Matrix ของการทดลอง HandVox 16 ท่า

Confusion Matrix แสดงแนวแยงเข้มสำหรับ 14 คลาส

แปลว่าตัวอย่างในชุดทดสอบรอบนี้ถูกจัดเข้าคลาสดังทั้งหมด

ส่วนตำแหน่งนอกแนวแยงระหว่างเข้าใจกับไม่เข้าใจแสดงการสับสนแบบสองทิศทาง

การวิเคราะห์ตำแหน่งเหล่านี้มีประโยชน์กว่าการดูคะแนนรวมเพียงค่าเดียว

เพราะระบุได้ว่าควรปรับข้อมูลของคู่ทำใด

การประเมินผล

ผลการตรวจสอบการทำงานของโปรแกรมพบว่ากระบวนการเก็บข้อมูลและการใช้งานจริงใช้

ฟังก์ชันสกัดคุณลักษณะรูปแบบเดียวกัน

ระบบตรวจจำนวนคุณลักษณะและรายชื่อคลาสก่อนเริ่มทำนาย สะสมข้อมูลล่าสุด 30 เฟรม

รับผลที่ผ่านเกณฑ์ความเชื่อมั่น และแสดงผลต่อผู้ใช้แบบเวลาจริง

ความครบถ้วนของฟังก์ชัน: ระบบสามารถเปิดกล้อง ตรวจจุดสำคัญ สะสมลำดับ

เรียกแบบจำลอง แสดงข้อหาและค่าความเชื่อมั่น รวมผลย้อนหลัง และรีเซ็ตเมื่อไม่พบมือ

นอกจากนี้ยังรองรับการสร้างประโยค อ่านเสียง เพิ่มหรือลบท่า เก็บคลิป สำรองข้อมูล

และฝึกแบบจำลองใหม่

ความสอดคล้องของข้อมูลกับโมเดล: ก่อนเริ่มทำนาย

โปรแกรมตรวจว่าจำนวนคุณลักษณะของโมเดลเท่ากับ 5,130

ค่าและรายชื่อคลาสตรงกับไฟล์กำหนดค่า หากไม่ตรงจะหยุดและแจ้งให้ฝึกใหม่

การตรวจนี้ช่วยป้องกันการนำโมเดลเก่าไปใช้กับรายการท่าที่เปลี่ยนแล้ว

ความสามารถ	ผลที่ตรวจสอบได้	เงื่อนไข
ทำนายจากการเคลื่อนไหว	สะสม 30 เฟรมแล้วใช้ predict_proba	ต้องตรวจพบช่วงบนและมือ
ยืนยันข้อหา	รับผลเมื่อค่าความเชื่อมั่นไม่น้อยกว่า 0.40	ยังต้องปรับจากข้อมูลภายนอก
ลดการสั่นของผล	ลงคะแนนจากผลล่าสุด 3 ครั้ง	ช่วยให้ข้อความบนหน้าจอนิ่งขึ้น
สร้างประโยค	เพิ่ม ลบ ล้าง และอ่านค่าที่สะสม	ควบคุมผ่านแป้นพิมพ์
อ่านเสียงภาษาไทย	สร้างและเล่นเสียงด้วย gTTS	ต้องเชื่อมต่ออินเทอร์เน็ต

ความสามารถ	ผลที่ตรวจสอบได้	เงื่อนไข
จัดการท่า	เพิ่ม ลบ เก็บคลิป สำรอง และฝึกใหม่	ทำงานผ่านเมนูของโครงการ

ตารางที่ 4.6 ผลการประเมินการทำงานของระบบ

ในด้านการตอบสนอง ระบบต้องรอสะสมข้อมูลครบ 30

เฟรมก่อนทำนายและต้องผ่านการรวมผลย้อนหลัง 3 ครั้ง จึงมีความหน่วงโดยธรรมชาติ

แม้กลไกนี้ช่วยให้ผลนิ่งขึ้น แต่โครงการยังไม่ได้บันทึก FPS และเวลาแฝงตั้งแต่รับภาพจนแสดงผล


จึงยังไม่สามารถสรุปสมรรถนะเวลาจริงเป็นตัวเลขได้

ในด้านความทนทาน

ระบบจัดการกรณีไม่พบมือด้วยการหยุดเพิ่มเฟรมและล้างสถานะเมื่อหายไปนานกว่า 0.4 วินาที

แต่ยังไม่มีผลทดสอบเชิงระบบภายใต้แสงน้อย ฉากหลังซับซ้อน ระยะหลายระดับ มุมกล้องต่างกัน

หรือการบังมือ การตรวจจอร์สียืนยันกลไกที่พัฒนาได้ แต่ไม่ทดแทนการทดลองภาคสนาม



ภาพที่ 4.2 หน้าจอการทำงานของ HandVox

หน้าจอภาพรวมแสดงจำนวนท่าที่ไม่เคยรู้จัก จำนวนคำที่วางแผน สถานะข้อมูล

และความพร้อมของส่วนประกอบ ช่วยให้ผู้ใช้ตรวจสอบภาพระบบก่อนเริ่มงาน

ส่วนหน้าจอตรวจจับแสดงภาพกล้อง จุดสำคัญ ชื่อท่า ค่าความเชื่อมั่น และข้อความสะสม

การจัดข้อมูลเหล่านี้ไว้ในตำแหน่งมองเห็นง่ายช่วยลดความสับสนระหว่างการเก็บข้อมูลกับการใช้งานจริง

ผลการทดลองแสดงว่า HandVox สามารถเชื่อมขั้นตอนเก็บข้อมูล ฝึกแบบจำลอง และทำนายแบบเวลาจริงได้ตามวัตถุประสงค์ของต้นแบบ อย่างไรก็ตาม คะแนนที่รายงานมาจากการสุ่มแบ่งคลิปภายในชุดข้อมูลเดียวกัน ข้อมูลฐานเดิมบางส่วนไม่มีรหัสผู้ทำท่าและเซสชัน และยังไม่มีการทดสอบภายนอก จึงไม่ควรใช้คะแนนนี้ยืนยันความแม่นยำกับผู้ใช้ทั่วไป

การประเมินรุ่นถัดไปควรเก็บข้อมูลจากผู้ทำท่าหลายคนและหลายเซสชัน แยกชุดทดสอบตามบุคคล วัตถุประสงค์และอัตราเฟรม ทดสอบแสง ฉากหลัง ระยะ และมุมกล้อง รวมทั้งประเมินความสะดวกในการใช้งานร่วมกับกลุ่มเป้าหมายจริง

ด้านที่ต้องประเมินต่อ	ข้อมูลที่ต้องเก็บ	เกณฑ์หรือผลที่ต้องรายงาน
ความสามารถทั่วไป	ผู้ทำท่าและเซสชันที่ไม่อยู่ในชุดฝึก	Accuracy และ Macro F1 บนชุดภายนอก
สมรรถนะเวลาจริง	FPS และเวลาแฝงต่อการทำนาย	ค่าเฉลี่ย ค่าต่ำสุด และช่วงการกระจาย
ความทนทาน	แสง ฉากหลัง ระยะ มุม และการบังมือ	อัตราค่าผิดและอัตราปฏิเสธในแต่ละสภาพ
ระบบเสียง	เวลาสร้างเสียงและอัตราความสำเร็จ	ผลเมื่อเครือข่ายปกติและไม่เสถียร
ประสบการณ์ผู้ใช้	ภารกิจและแบบประเมินจากกลุ่มเป้าหมาย	ความสำเร็จ เวลา และข้อเสนอแนะ

ตารางที่ 4.7 แผนการประเมินสำหรับการใช้งานจริง