

บทที่ 5

สรุปผล อภิปรายผล และข้อเสนอแนะ

บทนี้สรุปผลการพัฒนา HandVox เทียบกับวัตถุประสงค์
อภิปรายความหมายของผลประมินภายในชุดข้อมูล ระบุข้อจำกัด
และเสนอแนวทางพัฒนาระบบกับงานวิจัยต่อยอด โดยชี้คขอบเขตว่า HandVox
เป็นระบบรู้จำท่าทางภาษามือแบบแยกคำจากคลิปสั้น
ไม่ใช่ระบบแปลภาษามือไทยต่อเนื่องทั้งภาษา โดยมีหัวข้อดังนี้

- 5.1 สรุปผลการพัฒนา
- 5.2 ผลสำเร็จตามวัตถุประสงค์
- 5.3 อภิปรายผล
- 5.4 ข้อจำกัดของโครงการ
- 5.5 ข้อเสนอแนะ
- 5.6 สรุปภาพรวม

5.1 สรุปผลการพัฒนา

โครงการนี้ได้พัฒนา HandVox ซึ่งรับภาพเว็บแคม ใช้ MediaPipe Holistic สกัดจุดช่วงบน 15 จุดและมือข้างละ 21 จุด รวม 171 คุณลักษณะต่อเฟรม ปรับมาตรฐานด้วยจุดกึ่งกลางและระยะระหว่างไหล่ สะสม 30 เฟรมเป็นเวกเตอร์ 5,130 ค่า และใช้ SVC แบบ RBF จำแนกท่าที่กำหนดไว้ล่วงหน้า

ระบบรองรับวงจรตั้งแต่เพิ่มข้อเท้า เก็บคลิปให้ครบ ทดสอบความพร้อมของข้อมูล ฝึกแบบจำลอง บันทึกโมเดล ใช้งานแบบเวลาจริง แสดงค่าความเชื่อมั่น สะสมค่าเป็นประโยชน์ อ่านเสียงภาษาไทย และลบท่าพร้อมสำรองข้อมูล ชุดข้อมูลปัจจุบันมี 4 ท่า ได้แก่ สวัสดิ์ ขอโทษ ไม่เป็นไร และขอบคุณ ป้ายกำกับละ 30 คลิป รวม 120 คลิป

การประเมินภายในแบบแบ่งข้อมูล 80:20 ให้ accuracy 100.00% จากการทำนายถูก 24 จาก 24 คลิป และค่า macro precision, recall และ F1-score เท่ากับ 1.000 การตรวจสอบไขว้ 5 ส่วนให้ accuracy 100.00% ทุกส่วน อย่างไรก็ตาม

ตัวเลขนี้สะท้อนเฉพาะการแบ่งระดับคลิปภายในชุดข้อมูลเดียวกัน

ตารางที่ 5.1 สรุปผลการพัฒนา HandVox

ด้าน	ผลการพัฒนาที่ตรวจสอบได้
ข้อมูล	120 คลิป $\times$ 30 เฟรม $\times$ 171 คุณลักษณะ; 4 ป้ายกำกับสมดุลกัน
แบบจำลอง	SVC แบบ RBF, C=10, gamma=scale, probability=True
การประเมิน	Holdout 24/24 ถูก; 5-fold accuracy 100% ทุกส่วน
ระบบเวลาจริง	หน้าต่าง 30 เฟรม เกณฑ์ 0.40 และ smoothing 3 ผลต่ำสุด
การนำเสนอ	ข้อเท้า ความเชื่อมั่น ประโยค และเสียงภาษาไทย
การจัดการ	เพิ่ม/ลบท่า เก็บคลิป ฝึกใหม่ และสำรองข้อมูล

5.2 ผลสำเร็จตามวัตถุประสงค์

ตารางที่ 5.2 ผลสำเร็จเทียบกับวัตถุประสงค์

วัตถุประสงค์	ผลที่ได้	สถานะและหลักฐาน
รู้จำท่าจากลำดับภาพแบบเวลาจริง	พัฒนาต่อประมวลผล 30 เฟรมและ SVM	บรรลุในระดับต้นแบบ; run_detector.py
เพิ่ม/ลบท่าและฝึกใหม่โดยไม่แก้ไขโค้ด	มีเมนู ไฟล์ BAT และ custom_gestures.json	บรรลุตามฟังก์ชันที่พัฒนา
แสดงข้อความ ประโยค และเสียงไทย	มีชื่อท่า ความเชื่อมั่น ตัวแก้ไขประโยค และ TTS	บรรลุตามซอร์ส; TTS ต้องทดสอบเครือข่ายจริง
ประเมินผลและระบุข้อจำกัด	มี holdout ราชคาส confusion matrix และ 5-fold CV	บรรลุสำหรับข้อมูลภายใน; การประเมินภายนอกยังไม่เสร็จ

5.3 อภิปรายผล

5.3.1 ความหมายของผลการประเมิน

คะแนน 100% ทั้ง holdout และ cross-validation แสดงว่าคุณลักษณะลำดับ 5,130 ค่าและ SVM สามารถแยกตัวอย่างในชุดข้อมูลปัจจุบันได้ชัดเจน อีกทั้งผลรายคลาสเท่ากันทุกคลาส จึงไม่มีหลักฐานว่าคะแนนรวมถูกดันขึ้นจากคลาสใดคลาสหนึ่ง

อย่างไรก็ตาม

คะแนนที่สมบูรณ์แบบจากชุดข้อมูลขนาดเล็กควรเป็นเหตุให้ตรวจสอบความง่ายของงานและการรู้วไหลเชิงเซสชัน ไม่ใช่เหตุให้สรุปว่าระบบทำงานกับผู้ใช้อย่างทั่วไปได้ทันที หากคลิปปากคนเดียว สถานที่เดียว หรือรอบเก็บต่อเนื่องถูกสุ่มไปอยู่ทั้งสองชุด โมเดลอาจใช้รูปแบบเฉพาะของเซสชันช่วยตัดสินใจ

5.3.2 ผลของการใช้ข้อมูลลำดับการเคลื่อนไหว

การเปลี่ยนจากภาพนิ่งหนึ่งเฟรมเป็นลำดับ 30 เฟรมทำให้ข้อมูลคงลำดับการเคลื่อนไหวของแขนและมือไว้ และการใช้จุดช่วงบนร่วมกับมือสองข้างช่วยอธิบายตำแหน่งสัมพันธ์กับร่างกายได้มากขึ้นกว่าคุณลักษณะมือข้างเดียว อย่างไรก็ตาม อย่างไรก็ดี การเรียงทุกเฟรมเป็นเวกเตอร์ยาวทำให้โมเดลไวต่อจังหวะและกำหนดให้ทุกคลิปยาวเท่ากัน

5.3.3 การใช้งานแบบเวลาจริง

เกณฑ์ความเชื่อมั่น 0.40 การรวมผลล่าสุด 3 ครั้ง และการรีเซ็ตเมื่อไม่พบมือ 0.4 วินาทีเป็นกลไกจัดการผลหลังการทำนาย ช่วยให้ข้อความบนหน้าจอมีเสถียรภาพและลดคำเติมค้าง แต่ยังไม่มีการทดลองเปรียบเทียบค่าพารามิเตอร์เหล่านี้กับอัตราความผิดพลาดหรือเวลาแฝง การสะสมค่าและเสียงไทยช่วยให้ผู้ใช้ส่งผลลัพธ์ต่อไปยังผู้ฟังได้ แต่ไม่ใช่การวิเคราะห์ไวยากรณ์ภาษาเมื่อ ประโยคเกิดจากการเลือกคำที่ละคำของผู้ใช้ และ gTTS ต้องใช้อินเทอร์เน็ตขณะสร้างเสียงตามสถาปัตยกรรมปัจจุบัน

5.4 ข้อจำกัดของโครงการ

ตารางที่ 5.3 ข้อจำกัดของโครงการ

ประเด็น	ข้อจำกัด	ผลต่อข้อสรุป
ขอบเขตภาษา	รู้จำเพียง 4 ท่าแบบแยกคำ	ไม่เท่ากับการแปลภาษามือไทยต่อเนื่อง
ผู้ให้ข้อมูล	ไม่มีจำนวนและรหัสผู้ให้ข้อมูล	ประเมินแบบแยกผู้ทำทำไม่ได้
เซสชัน	ไม่มีรหัสรอบการเก็บและสภาพแวดล้อม	ตรวจการรบกวนหรือเซสชันไม่ได้
การประเมิน	สุ่มแบ่งระดับคลิปจากชุดเดียวกัน	คะแนนอาจสูงกว่าการใช้งานกับข้อมูลใหม่
ข้อมูล	120 คลิปและไม่มีชุดทดสอบภายนอก	ยังสรุปความสามารถทั่วไปไม่ได้
ความเร็ว	ไม่มีบันทึก FPS และเวลาแฝง	ยังสรุปสมรรถนะเวลาจริงเชิงปริมาณไม่ได้

ประเด็น	ข้อจำกัด	ผลต่อข้อสรุป
เสียง	gTTS ฟังอินเทอร์เน็ต	เสียงอาจไม่พร้อมในพื้นที่เครือข่ายไม่เสถียร
ผู้ใช้	ยังไม่มี user study กับกลุ่มเป้าหมาย	ยังไม่ทราบความสะดวกและความเหมาะสมจริง

5.5 ข้อเสนอแนะ

5.5.1 ข้อเสนอแนะเพื่อปรับปรุงระบบ

- 1) ตรวจสอบและกำหนดพจนานุกรมป้ายกำกับร่วมกับผู้รู้ภาษามือหรือผู้เชี่ยวชาญ
แก้คำอธิบายที่สับสนผิด และกำหนดวิธีเริ่ม-จบทำให้เหมือนกันก่อนเก็บข้อมูลเพิ่ม
- 2) เพิ่ม metadata ได้แก่ รหัสผู้ให้ข้อมูล รหัสเซสชัน แสง ฉากหลัง ระยะเวลา มุม กล้อง และความเร็ว
เพื่อรองรับการตรวจสอบและแบ่งข้อมูลแบบกลุ่ม
- 3) แยกชุดฝึก ชุดตรวจสอบ และชุดทดสอบภายนอกตามผู้ให้ข้อมูลหรือเซสชัน
ห้ามให้ข้อมูลของกลุ่มทดสอบปรากฏในกระบวนการปรับโมเดล
- 4) วัด FPS เวลาแฝง อัตราการปฏิเสธคำ อัตราคำผิด และความสำเร็จของ TTS
ในสภาพแวดล้อมหลายแบบ พร้อมบันทึกเวอร์ชันข้อมูลและซอฟต์แวร์
- 5) ปรับเกณฑ์ความเชื่อมั่นจากชุดตรวจสอบ เพิ่มสถานะไม่ทราบ/ปฏิเสธเมื่อไม่มีคลาสเหมาะสม
และประเมินการสอบเทียบค่าความน่าจะเป็น
- 6) เพิ่มทางเลือกเสียงภาษาไทยแบบออฟไลน์และตัวเลือกปิดการพูดอัตโนมัติ
เพื่อรองรับพื้นที่เครือข่ายจำกัดและความต้องการที่ต่างกัน

5.5.2 ข้อเสนอแนะสำหรับงานวิจัยต่อยอด

- 1) ขยายจำนวนคำและผู้ที่ทำอย่างเป็นระบบ โดยวางแผนตัวอย่างต่อกลุ่มก่อนเก็บข้อมูล
ไม่เพิ่มเฉพาะคลิปจากสถานการณ์เดิม
- 2) เปรียบเทียบ SVM กับแบบจำลองลำดับ เช่น HMM, LSTM, Temporal Convolutional Network
หรือ Transformer เมื่อมีข้อมูลมากพอและใช้ชุดทดสอบเดียวกันอย่างยุติธรรม

- 3) ศึกษาการแบ่งช่วงทำอัตโนมัติและการรู้จำหลายคำต่อเนื่อง โดยแยกโจทย์การแบ่งหน่วยทำการรู้จำ และการจัดลำดับภาษาปลายทาง
- 4)
- พิจารณาคุณลักษณะสีหน้าและท่าทางที่ไม่ใช้มือเมื่อความหมายของคำต้องอาศัยองค์ประกอบดังกล่าว พร้อมประเมินผลกระทบด้านความเป็นส่วนตัว
- 5) ออกแบบและทดสอบร่วมกับชุมชนผู้ใช้งานมือ ผู้เชี่ยวชาญด้านภาษาและผู้เชี่ยวชาญด้านการเข้าถึง เพื่อให้โจทย์ คำศัพท์ และเกณฑ์ความสำเร็จสอดคล้องกับการใช้งานจริง

5.6 สรุปภาพรวม

HandVox แสดงให้เห็นความเป็นไปได้ของการใช้ MediaPipe Holistic ร่วมกับ SVM เพื่อรู้จำท่าทางแบบแยกคำจากคลิปสั้น ระบบเชื่อมขั้นตอนเก็บข้อมูล ฝึกแบบจำลอง ทำนาย แสดงข้อความ สร้างประโยค และอ่านเสียงไว้ในต้นแบบเดียว

ผลภายในชุดข้อมูลอยู่ในระดับสมบูรณ์สำหรับ 4 ท่าที่มีอยู่

คุณค่าของผลลัพธ์จึงอยู่ที่การพิสูจน์กระบวนการและเป็นฐานสำหรับทดลองต่อมากกว่าการรับรองความแม่นยำในโลกจริง

ขั้นตอนสำคัญถัดไปคือเก็บข้อมูลหลายผู้ทำท่าและหลายเซสชัน จัดทำ metadata ประเมินแบบแยกกลุ่มและภายนอก วัดเวลาแฝง และทดสอบกับผู้ใช้งานภายใต้การขอความยินยอมและการคุ้มครองข้อมูลที่เหมาะสม