

บทที่ 2

ความรู้พื้นฐานและงานที่เกี่ยวข้อง

บทนี้อธิบายแนวคิดที่จำเป็นต่อการพัฒนา HandVox

ตั้งแต่ขอบเขตของการรู้จำภาษาพูดด้วยคอมพิวเตอร์ การตรวจหาจุดสำคัญ

การแทนลำดับการเคลื่อนไหว การจำแนก และหลักการประเมินผล โดยมีหัวข้อดังนี้

- 2.1 ภาษาพูด การรู้จำ และการแปล
- 2.2 การรู้จำแบบภาพนิ่ง แบบแยกคำ และแบบต่อเนื่อง
- 2.3 การมองเห็นด้วยคอมพิวเตอร์และจุดสำคัญ
- 2.4 MediaPipe Holistic ในโครงงาน
- 2.5 การปรับมาตรฐานเชิงตำแหน่งและขนาด
- 2.6 การแทนลำดับการเคลื่อนไหว
- 2.7 Support Vector Machine และ RBF Kernel
- 2.8 การแบ่งข้อมูลและการป้องกันการรั่วไหลของข้อมูล
- 2.9 ตัวชี้วัดการจำแนก
- 2.10 การประมวลผลแบบเวลาจริงและเสียงพูด
- 2.11 งานและแนวคิดที่เกี่ยวข้อง
- 2.12 ความน่าเชื่อถือ จริยธรรม และการเข้าถึง
- 2.13 บทสรุป

2.1 ภาษามือ การรู้จำ และการแปล

ภาษามือเป็นภาษาธรรมชาติที่ใช้รูปมือ ตำแหน่ง ทิศทาง การเคลื่อนไหว การแสดงสีหน้า และโครงสร้างทางภาษา การทำให้คอมพิวเตอร์ระบุหน่วยท่าหรือคำจากวิดีโอเรียกว่า

การรู้จำภาษามือ (Sign Language Recognition: SLR) ส่วนการแปลภาษามือ (Sign Language Translation: SLT)

ต้องแปลงลำดับภาษามือให้เป็นประโยคของภาษาปลายทางโดยคำนึงถึงโครงสร้างและบริบท

ดังนั้นระบบที่ส่งออกชื่อท่าจากคลิปสั้นจึงอยู่ในกลุ่มการรู้จำแบบแยกคำ

ไม่ใช่ระบบแปลภาษามือต่อเนื่อง (Yu et al., 2022; Sarhan & Frintrop, 2023)

การกำหนดคำเรียกให้ตรงกับความสามารถเป็นหลักสำคัญของงานวิจัย

เพราะช่วยป้องกันการนำผลไปใช้เกินขอบเขต HandVox

จึงจำแนกเฉพาะท่าที่ผู้พัฒนาหรือผู้ใช้เก็บไว้ในชุดข้อมูล และต้องให้ผู้ใช้กดเพิ่มคำลงในประโยค

ไม่ได้แบ่งคำหรือวิเคราะห์ไวยากรณ์โดยอัตโนมัติ

2.2 การรู้จำแบบภาพนิ่ง แบบแยกคำ และแบบต่อเนื่อง

รูปแบบ	ข้อมูลนำเข้า	ผลลัพธ์	ขอบเขต
ภาพนิ่ง	หนึ่งเฟรม	คลาสของรูปมือ	ไม่แทนลำดับการเคลื่อนไหว
แบบแยกคำ	คลิปของหนึ่งท่า	หนึ่งคำหรือหนึ่งป้ายกำกับ	เหมาะกับท่าที่มีจุดเริ่มและสิ้นสุดชัดเจน
แบบต่อเนื่อง	วิดีโอหลายท่าต่อกัน	ลำดับคำหรือประโยค	ต้องแบ่งหน่วยท่าและจัดการบริบท

ตารางที่ 2.1 การเปรียบเทียบระดับของการรู้จำ

HandVox เลือกการรู้จำแบบแยกคำจากคลิป 30 เฟรม

เพื่อให้ระบบรับรู้การเคลื่อนไหวของแขนและมือที่ไม่สามารถอธิบายด้วยภาพนิ่งเพียงเฟรมเดียว

อย่างไรก็ดี ความยาว 30 เฟรมเป็นจำนวนตัวอย่างตามลำดับ ไม่ใช่ระยะเวลาแน่นอน

เพราะระยะเวลาจริงขึ้นกับอัตราเฟรมของกล้องและการประมวลผล

2.3 การมองเห็นด้วยคอมพิวเตอร์และจุดสำคัญ

การมองเห็นด้วยคอมพิวเตอร์เป็นกระบวนการรับภาพหรือวิดีโอและสกัดข้อมูลที่ใช้ตัดสินใจได้ OpenCV ทำหน้าที่เปิดกล้อง กลัภาพในแนวนอน วาดส่วนติดต่อ และแสดงผล ส่วน MediaPipe ทำหน้าที่ประมาณพิกัดจุดสำคัญ

การใช้จุดสำคัญแทนภาพดิบช่วยลดมิติข้อมูลและทำให้ตีความได้ง่ายขึ้น

แต่ยังขึ้นกับคุณภาพการตรวจหา การบังมือ แสง มุมกล้อง และความเร็วของการเคลื่อนไหว

งาน MediaPipe Hands เสนอการตรวจหาฝ่ามือร่วมกับแบบจำลองจุดสำคัญ 21

จุดต่อมือสำหรับการทำงานแบบเวลาจริงจากกล้อง RGB (Zhang et al., 2020) ส่วน MediaPipe

Holistic รวมจุดท่าทางร่างกาย ใบหน้า และมือทั้งสองข้างไว้ในกระบวนการเดียว

โดยคงความสอดคล้องของด้านซ้ายและขวาระหว่างเฟรม (Google AI Edge, n.d.)

2.4 MediaPipe Holistic ในโครงการ

โครงการตั้งค่า MediaPipe Holistic ให้ประมวลผลวิดีโอต่อเนื่อง

(static_image_mode=False) ใช้ model_complexity=1 เปิด smooth_landmarks

และกำหนด min_detection_confidence กับ min_tracking_confidence เท่ากับ 0.70 แม้


Holistic จะสามารถส่งออกจุดจำนวนมาก แต่ HandVox เลือกเฉพาะ 15 จุดของช่วงบนและจุดมือ

21 จุดต่อข้างเพื่อควบคุมขนาดข้อมูล

กลุ่มจุด	จำนวนจุด	พิกัดต่อจุด	จำนวนคุณลักษณะ
ช่วงบน: ศีรษะ ไหล่ ศอก ข้อมือ และสะโพก	15	x, y, z	45
มือซ้าย	21	x, y, z	63
มือขวา	21	x, y, z	63
รวมต่อเฟรม	57	3	171

ตารางที่ 2.2 คุณลักษณะที่ HandVox เลือกใช้

ระบบคืนค่า None เมื่อไม่พบโครงร่างท่าทางหรือไม่พบมือทั้งสองข้าง หากพบเพียงมือเดียว ระบบแทนคุณลักษณะของมือที่ไม่พบด้วยศูนย์จำนวน 63 ค่า วิธีนี้ทำให้ทุกเฟรมมีมิติเท่ากัน แต่ต้องระวังว่าศูนย์เป็นสัญลักษณ์ของข้อมูลที่หาย ไม่ใช่ตำแหน่งมือจริง



ภาพที่ 2.1 จุดสำคัญที่ HandVox เลือกใช้จาก MediaPipe Holistic

2.5 การปรับมาตรฐานเชิงตำแหน่งและขนาด

พิกัดจากภาพเปลี่ยนตามตำแหน่งผู้ใช้ ระยะห่าง และขนาดตัว HandVox จึงกำหนดจุดกึ่งกลางไหล่ซ้ายและขวาเป็นจุดอ้างอิง c และใช้ระยะยูลิตระหว่างไหล่เป็นตัวปรับขนาด s สำหรับจุด p_i พิกัดที่ปรับแล้วคำนวณเป็น $p'_i = (p_i - c) / \max(s, 10^{-6})$ ทั้งแกน x , y และ z

การปรับดังกล่าวลดผลจากการเลื่อนตำแหน่งและการเปลี่ยนขนาดโดยรวม แต่ไม่ทำให้ข้อมูลไม่แปรผันต่อการหมุน มุมกล้อง หรือสัดส่วนร่างกายทั้งหมด จึงยังต้องเก็บข้อมูลจากระยะ มุม และความเร็วที่หลากหลาย

2.6 การแทนลำดับการเคลื่อนไหว

หนึ่งคลิปประกอบด้วย 30 เฟรมและแต่ละเฟรมมี 171 คุณลักษณะ จึงแทนได้เป็นเมทริกซ์ขนาด 30×171 ก่อนฝึก ระบบเรียงค่าทุกเฟรมต่อกันเป็นเวกเตอร์ 5,130 ค่า

การเรียงตามลำดับเวลาเก็บข้อมูลการเคลื่อนไหวทางอ้อม

เพราะตำแหน่งของคุณลักษณะในเวกเตอร์สัมพันธ์กับลำดับเฟรม

ข้อดีของวิธีนี้คือใช้งานร่วมกับตัวจำแนกแบบดั้งเดิมได้ง่ายและฝึกได้รวดเร็วเมื่อข้อมูลมีขนาดเล็ก ข้อจำกัดคือทุกคลิปต้องมีจำนวนเฟรมเท่ากัน และแบบจำลองอาจไวต่อความเร็วหรือจังหวะที่ต่างจากข้อมูลฝึกมาก



ภาพที่ 2.2 การแทนคลิปหนึ่งทำเป็นลำดับ 30 เฟรม

2.7 Support Vector Machine และ RBF Kernel

Support Vector Machine

เป็นวิธีการเรียนรู้แบบมีผู้สอนที่สร้างขอบเขตการตัดสินใจโดยอาศัยตัวอย่างที่อยู่ใกล้ขอบเขตของคลาส แนวคิดดั้งเดิมเสนอการแปลงข้อมูลไปยังปริภูมิที่มีมิติสูงเพื่อสร้างขอบเขตที่แยกข้อมูลได้ดี (Cortes & Vapnik, 1995) RBF kernel

ช่วยสร้างขอบเขตไม่เชิงเส้นและเหมาะสมกับความสัมพันธ์ที่ซับซ้อนระหว่างตำแหน่งจุดหลายเฟรม

HandVox ใช้ SVC ของ scikit-learn โดยกำหนด `kernel='rbf'`, `C=10`, `gamma='scale'`, `probability=True` และ `class_weight='balanced'` ค่า C

ควบคุมการแลกเปลี่ยนระหว่างขอบเขตที่กว้างกับข้อผิดพลาดบนข้อมูลฝึก ส่วน `gamma`

กำหนดอิทธิพลของตัวอย่างต่อรูปร่างขอบเขต

การถ่วงน้ำหนักคลาสช่วยลดผลจากจำนวนคลิปที่ไม่เท่ากัน และการเปิด `probability`

ทำให้ระบบรายงานค่าประกอบการตัดสินใจ

แต่ค่าดังกล่าวไม่ควรถูกตีความเป็นการรับประกันความถูกต้องในโลกจริง

2.8 การแบ่งข้อมูลและการป้องกันการรั่วไหลของข้อมูล

การแบ่งชุดข้อมูลฝึกและทดสอบต้องทำก่อนประเมินผล

โดยใช้ข้อมูลทดสอบเฉพาะสำหรับวัดความสามารถกับตัวอย่างที่โมเดลไม่ได้ใช้ฝึก HandVox

ใช้การแบ่ง 80:20 แบบ stratified และ random_state=42 เพื่อรักษาสัดส่วนคลาสและทำซ้ำได้

อย่างไรก็ตาม คลิปที่เก็บต่อเนื่องจากผู้ทำท่าคนเดียว เซสชันเดียว

และพื้นหลังเดียวอาจคล้ายกันมาก แม้จะอยู่คนละไฟล์คลิป หากสุ่มคลิประหว่างชุดฝึกและทดสอบ

คะแนนอาจสะท้อนความสามารถในการจำลักษณะของเซสชันมากกว่าความสามารถกับผู้ใช้ใหม่

แนวทางที่เข้มงวดกว่าคือแบ่งตามผู้ให้ข้อมูลหรือรอบการเก็บ (grouped split)

และมีชุดทดสอบภายนอกที่แยกจากกระบวนการพัฒนา

2.9 ตัวชี้วัดการจำแนก

Accuracy คือสัดส่วนตัวอย่างที่ทำนายถูกทั้งหมด

แต่เมื่อจำนวนตัวอย่างหรือความยากของแต่ละคลาสต่างกัน ควรรายงาน precision, recall และ F1-score รายคลาส รวมถึงค่าเฉลี่ยแบบ macro ซึ่งให้น้ำหนักทุกคลาสเท่ากัน Confusion matrix ช่วยแสดงว่าทำไ้ถูกสับสนกับทำไ้ (Sokolova & Lapalme, 2009)

ตัวชี้วัด	ความหมาย	การใช้ในโครงการ
Accuracy	สัดส่วนการทำนายถูกทั้งหมด	ภาพรวมของชุดทดสอบ
Precision	เมื่อระบบทำนายเป็นคลาสหนึ่ง มีสัดส่วนถูกเท่าใด	ตรวจการทำนายเกิน
Recall	ตัวอย่างจริงของคลาสหนึ่งถูกพบเท่าใด	ตรวจการพลาดคลาส
F1-score	ค่าเฉลี่ยฮาร์โมนิกของ precision และ recall	เปรียบเทียบรายคลาส
Confusion matrix	จำนวนจริงและทำนายของทุกคู่คลาส	ค้นหาคู่ทำที่สับสน

ตารางที่ 2.3 ตัวชี้วัดที่ควรรายงาน

2.10 การประมวลผลแบบเวลาจริงและเสียงพูด

ขณะใช้งาน ระบบเก็บคุณลักษณะล่าสุดในคิว 30 เฟรม

เมื่อคิวเต็มจึงคำนวณความน่าจะเป็นของทุกคลาส รับเฉพาะผลที่มีค่าน้อย 0.40

และใช้ผลย้อนหลัง 3 ครั้งเพื่อเลือกคลาสที่พบมากที่สุด หากไม่พบมือเกิน 0.4 วินาที

ระบบล้างคิวและสถานะ การประมวลผลนี้ช่วยลดการสั่นของหน้าจอ

แต่ไม่ได้แทนการประเมินความถูกต้องของโมเดล

ผลลัพธ์สามารถเพิ่มเป็นประโยคด้วยแป้นพิมพ์และส่งให้ gTTS สร้างเสียงภาษาไทย โดย pygame เล่นไฟล์เสียงที่สร้างชั่วคราว TTS เป็นช่องทางนำเสนอผล ไม่ได้มีส่วนในการรู้จำท่าทาง และต้องใช้อินเทอร์เน็ตในขณะสร้างเสียงตามการติดตั้งปัจจุบัน

2.11 งานและแนวคิดที่เกี่ยวข้อง

แหล่งอ้างอิง	ประเด็นสำคัญ	ความสัมพันธ์กับ HandVox
Cortes & Vapnik (1995)	หลักการ Support Vector Networks	ฐานของตัวจำแนก SVM
Zhang et al. (2020)	การติดตามโครงร่างมือ 21 จุดแบบเวลาจริง	ฐานของคุณลักษณะมือ
Yu et al. (2022)	ทบทวนงานรู้จำระดับท่าทาง คำแยก และประโยคต่อเนื่อง	ใช้กำหนดขอบเขตการกล่าวอ้าง
Sarhan & Frintrop (2023)	สำรวจการรู้จำภาษามือแบบแยกคำและชุดข้อมูล	ใช้วิเคราะห์ข้อจำกัดด้านผู้ทำท่าและข้อมูล
Chalotompised et al. (2026)	ชุดข้อมูลภาษามือไทยระดับคำจากหลายผู้ทำท่า	ใช้เปรียบเทียบขนาดข้อมูลและการทดสอบแบบ signer-independent
Google AI Edge (n.d.)	MediaPipe Holistic สำหรับจุดร่างกาย ใบหน้า และมือ	กระบวนการตรวจหาจุดของระบบ

ตารางที่ 2.4 งานและแนวคิดที่เกี่ยวข้อง

งาน TSL-ONE-S รายงานชุดข้อมูลภาษามือไทยระดับคำ 4,152 วิดีโอ ครอบคลุม 184 คำจากผู้ทำท่า 29 คน และประเมินแบบแยกผู้ทำท่า (signer-independent) (Chalotompised et al., 2026) งานดังกล่าวชี้ให้เห็นความสำคัญของความหลากหลายด้านบุคคลและสภาพแวดล้อม ดังนั้นชุดข้อมูล 350 คลิปจาก 16 ท่าของ HandVox

ควรถูกอธิบายว่าเป็นชุดข้อมูลต้นแบบภายในโครงการ ไม่ใช่หลักฐานความสามารถทั่วไปของระบบ

2.12 ความน่าเชื่อถือ จริยธรรม และการเข้าถึง

ข้อมูลท่าทางอาจเกี่ยวข้องกับอัตลักษณ์ การเคลื่อนไหว และสภาพแวดล้อมของผู้ให้ข้อมูล การเก็บข้อมูลจากบุคคลจึงควรแจ้งวัตถุประสงค์ ขอความยินยอม จำกัดการใช้ และเก็บเฉพาะข้อมูลที่จำเป็น โครงการปัจจุบันจัดเก็บจุดสำคัญและป้ายกำกับในไฟล์ NPZ ไม่ได้บันทึกวิดีโอต้นฉบับเป็นชุดข้อมูล

แต่ภาพจากกล้องยังถูกประมวลผลในหน่วยความจำระหว่างเก็บและใช้งาน

ระบบควรรายงานข้อจำกัดอย่างชัดเจน

ไม่อ้างว่าสามารถแทนที่หรือรองรับภาษามือไทยทั้งหมด

และควรประเมินกับผู้ให้หลายคนก่อนใช้งานจริง การออกแบบส่วนติดต่อควรแสดงผลที่อ่านง่าย มีทางเลือกข้อความเมื่อเสียงใช้ไม่ได้ และให้ผู้ใช้แก้ไขหรือลบคำที่ระบบทำนายผิด

2.13 บทสรุป

HandVox เป็นระบบรู้จำท่าทางภาษามือแบบแยกคำจากลำดับ 30 เฟรม โดยใช้ MediaPipe Holistic สกัด 171 คุณลักษณะต่อเฟรม ปรับมาตรฐานด้วยตำแหน่งและระยะไหล่ เรียงเป็นเวกเตอร์ 5,130 ค่า และจำแนกด้วย SVM แบบ RBF แนวทางนี้เหมาะกับต้นแบบข้อมูลขนาดเล็กและตรวจสอบกระบวนการได้ง่าย แต่ยังคงต้องควบคุมการรั่วไหลของข้อมูล ทดสอบกับผู้ทำท่าและสภาพแวดล้อมใหม่ และจำกัดการกล่าวอ้างให้ตรงกับการรู้จำแบบแยกคำ

รายการอ้างอิงของบท

- Bradski, G. (2000). The OpenCV Library. Dr. Dobb's Journal of Software Tools.
- Cortes, C., & Vapnik, V. (1995). Support-vector networks. Machine Learning, 20, 273–297.
<https://doi.org/10.1007/BF00994018>
- Chalotonpised, J., Chen, W. H., Vijitkunsawat, W., & Lin, Y. C. (2026). TSL-ONE-S: A real-world Thai sign language dataset with deep learning benchmarks. IEEE Access, 14, 37845–37870.
<https://doi.org/10.1109/ACCESS.2026.3670970>
- Google AI Edge. (n.d.). Holistic landmarks detection task guide. Retrieved August 1, 2026, from https://developers.google.com/edge/mediapipe/solutions/vision/holistic_landmarker

- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12(85), 2825–2830.
- Sarhan, N., & Frintrop, S. (2023). Unraveling a decade: A comprehensive survey on isolated sign language recognition. *Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops*, 3210–3219.
https://openaccess.thecvf.com/content/ICCV2023W/AMFG/html/Sarhan_Unraveling_a_Decade_A_Comprehensive_Survey_on_Isolated_Sign_Language_ICCVW_2023_paper.html
- Sokolova, M., & Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, 45(4), 427–437.
<https://doi.org/10.1016/j.ipm.2009.03.002>
- Yu, M., Jia, J., Xue, C., Yan, G., Guo, Y., & Liu, Y. (2022). A review of sign language recognition research. *Journal of Intelligent & Fuzzy Systems*, 43(4), 3879–3898.
<https://doi.org/10.3233/JIFS-210050>
- Zhang, F., Bazarevsky, V., Vakunov, A., Tkachenka, A., Sung, G., Chang, C.-L., & Grundmann, M. (2020). MediaPipe Hands: On-device real-time hand tracking. *arXiv:2006.10214*.
<https://doi.org/10.48550/arXiv.2006.10214>