

บทที่ 5

สรุปผล อภิปรายผล และข้อเสนอแนะ

บทนี้สรุปผลการพัฒนา HandVox เทียบกับวัตถุประสงค์
อภิปรายความหมายของผลประเมินภายในชุดข้อมูล ระบุข้อจำกัด
และเสนอแนวทางพัฒนาระบบกับงานวิจัยต่อยอด โดยยึดขอบเขตว่า HandVox
เป็นระบบรู้จำท่าทางภาษามือแบบแยกคำจากคลิปสั้น ไม่ใช่ระบบแปลภาษามือไทยต่อเนื่องทั้งภาษา
โดยมีหัวข้อดังนี้

- 5.1 สรุปผลการพัฒนา
- 5.2 ผลสำเร็จตามวัตถุประสงค์
- 5.3 อภิปรายผล
- 5.4 ข้อจำกัดของโครงงาน
- 5.5 ข้อเสนอแนะ
- 5.6 สรุปภาพรวม

5.1 สรุปผลการพัฒนา

โครงการได้พัฒนา HandVox ซึ่งรับภาพเว็บแคม ใช้ MediaPipe Holistic สกัดจุดช่วงบน 15 จุดและมือข้างละ 21 จุด รวม 171 คุณลักษณะต่อเฟรม

ปรับมาตรฐานด้วยจุดกึ่งกลางและระยะระหว่างไหล่ สะสม 30 เฟรมเป็นเวกเตอร์ 5,130 ค่า และใช้ SVC แบบ RBF จำแนกท่าที่กำหนดไว้ล่วงหน้า

ระบบรองรับวงจรตั้งแต่เพิ่มชื่อท่า เก็บคลิป ตรวจสอบความพร้อมของข้อมูล ฝึกแบบจำลอง บันทึกโมเดล ใช้งานแบบเวลาจริง แสดงค่าความเชื่อมั่น สะสมค่าเป็นประโยค อ่านเสียงภาษาไทย และลบท่าพร้อมสำรองข้อมูล ชุดข้อมูลปัจจุบันมี 16 ท่า รวม 350 คลิป โดยแต่ละท่ามี 10–30 คลิป

การทดลองด้วยแบบ stratified holdout 80:20 ทำนายถูก 66 จาก 70 คลิป ให้ Accuracy 94.29% และ Macro F1 93.75% คลาส “เข้าใจ” กับ “ไม่เข้าใจ” มี F1 เท่ากับ 0.500 และถูกทำนายสลับกัน อย่างไรก็ตาม

ตัวเลขนี้สะท้อนเฉพาะการแบ่งระดับคลิปภายในชุดข้อมูลเดียวกันและยังไม่ใช่ผล signer-independent

ด้าน	ผลการพัฒนาที่ตรวจสอบได้
ข้อมูล	350 คลิป × 30 เฟรม × 171 คุณลักษณะ; 16 ป้ายกำกับ
แบบจำลอง	SVC แบบ RBF, C=10, gamma=scale, probability=True, class_weight=balanced
การประเมิน	Holdout 66/70 ถูก; Accuracy 94.29%; Macro F1 93.75%
ระบบเวลาจริง	หน้าต่าง 30 เฟรม เกณฑ์ 0.40 และ smoothing 3 ผลล่าสุด
การนำเสนอ	ชื่อท่า ความเชื่อมั่น ประโยค และเสียงภาษาไทย
การจัดการ	เพิ่ม/ลบท่า เก็บคลิป ฝึกใหม่ และสำรองข้อมูล

ตารางที่ 5.1 สรุปผลการพัฒนา HandVox

5.2 ผลสำเร็จตามวัตถุประสงค์

วัตถุประสงค์	ผลที่ได้	สถานะและหลักฐาน
รู้จำท่าจากลำดับภาพแบบเวลาจริง	พัฒนาท่อประมวลผล 30 เฟรมและ SVM	บรรลุในระดับต้นแบบ; run_detector.py
เพิ่ม/ลบท่าและฝึกใหม่โดยไม่แก้ไขโค้ด	มีเมนู ไฟล์ BAT และ custom_gestures.json	บรรลุตามฟังก์ชันที่พัฒนา
แสดงข้อความ ประโยค และเสียงไทย	มีชื่อท่า ความเชื่อมั่น ตัวแก้ไขประโยค และ TTS	บรรลุตามซอร์ส; TTS ต้องทดสอบเครือข่ายจริง
ประเมินผลและระบุข้อจำกัด	มี holdout รายคลาสและ confusion matrix	บรรลุสำหรับ quick trial; signer-independent ยังไม่เสร็จ

ตารางที่ 5.2 ผลสำเร็จเทียบกับวัตถุประสงค์

5.3 อภิปรายผล

5.3.1 ความหมายของผลการประเมิน

Accuracy 94.29% และ Macro F1 93.75% แสดงว่าคุณลักษณะลำดับ 5,130 ค่าและ SVM แยกตัวอย่างส่วนใหญ่ในชุดข้อมูลปัจจุบันได้ แต่ผลรายคลาสชี้จุดอ่อนชัดเจนที่คู่ “เข้าใจ” กับ “ไม่เข้าใจ” ซึ่งมี precision, recall และ F1 เท่ากับ 0.500

จึงควรทบทวนความแตกต่างของท่าและเก็บตัวอย่างที่หลากหลายขึ้น

แม้จะแนรวมผ่านเกณฑ์คัดกรอง แต่ยังไม่ควรสรุปว่าระบบทำงานกับผู้ใช้ทั่วไป เพราะคลิปปากคนหรือเซสชันเดียวกันอาจถูกสุ่มไปอยู่ทั้งชุดฝึกและชุดทดสอบ อีกทั้งข้อมูลฐานเดิมไม่มี metadata ที่ใช้ตรวจสอบการรั่วไหลได้

5.3.2 ผลของการใช้ข้อมูลลำดับการเคลื่อนไหว

การเปลี่ยนจากภาพนิ่งหนึ่งเฟรมเป็นลำดับ 30 เฟรมทำให้ข้อมูลคงลำดับการเคลื่อนไหวของแขนและมือไว้ และการใช้จุดช่วงบนร่วมกับมือสองข้างช่วยอธิบายตำแหน่งสัมพันธ์กับร่างกายได้มากขึ้นกว่าคุณลักษณะ

ณ่มือข้างเดียว อย่างไรก็ตาม

การเรียงทุกเฟรมเป็นเวกเตอร์ยาวทำให้โมเดลไวต่อจังหวะและกำหนดให้ทุกคลิปยาวเท่ากัน

5.3.3 การใช้งานแบบเวลาจริง

เกณฑ์ความเชื่อมั่น 0.40 การรวมผลล่าสุด 3 ครั้ง และการรีเซ็ตเมื่อไม่พบมือ 0.4

วินาทีเป็นกลไกจัดการผลหลังการทำนาย ช่วยให้ข้อความบนหน้าจอมีเสถียรภาพและลดคำเดิมค้าง

แต่ยังไม่มีบททดลองเปรียบเทียบค่าพารามิเตอร์เหล่านี้กับอัตราความผิดพลาดหรือเวลาแฝง

การสะสมค่าและเสียงไทยช่วยให้ผู้ใช้ส่งผลลัพธ์ต่อไปยังผู้ฟังได้

แต่ไม่ใช้การวิเคราะห์ไวยากรณ์ภาษามือ ประโยคเกิดจากการเลือกคำที่ละคำของผู้ใช้ และ gTTS

ต้องใช้อินเทอร์เน็ตขณะสร้างเสียงตามสถาปัตยกรรมปัจจุบัน

5.4 ข้อจำกัดของโครงการ

ประเด็น	ข้อจำกัด	ผลต่อข้อสรุป
ขอบเขตภาษา	รู้จำ 16 ท่าแบบแยกคำ	ไม่เท่ากับการแปลภาษามือไทยต่อเนื่อง
ผู้ทำท่า	Dataset V2 มี 2 รหัส; ข้อมูลฐานเดิมไม่มีรหัส	ยังประเมินแยกผู้ทำท่าครบทุกคลาสไม่ได้
เซสชัน	Dataset V2 มี 2 เซสชัน; ข้อมูลเดิมไม่ระบุ	ยังตรวจการรื้อไหลทั้งชุดไม่ได้
การประเมิน	สุ่มแบ่งระดับคลิปจากชุดเดียวกัน	คะแนนอาจสูงกว่าการใช้งานกับข้อมูลใหม่
ข้อมูล	350 คลิป; 10–30 คลิปต่อคลาส; ไม่มีชุดทดสอบภายนอก	ยังสรุปความสามารถทั่วไปไม่ได้
ความเร็ว	ไม่มีบันทึก FPS และเวลาแฝง	ยังสรุปสมรรถนะเวลาจริงเชิงปริมาณไม่ได้
เสียง	gTTS ฟังอินเทอร์เน็ต	เสียงอาจไม่พร้อมในพื้นที่เครือข่ายไม่เสถียร
ผู้ใช้	ยังไม่มี user study กับกลุ่มเป้าหมาย	ยังไม่ทราบความสะดวกและความเหมาะสมจริง

ตารางที่ 5.3 ข้อจำกัดของโครงการ

5.5 ข้อเสนอแนะ

5.5.1 ข้อเสนอแนะเพื่อปรับปรุงระบบ

- 1) ตรวจสอบและกำหนดพจนานุกรมป้ายกำกับร่วมกับผู้ใช้ภาษามือหรือผู้เชี่ยวชาญ
แก้คำอธิบายที่สะกดผิด และกำหนดวิธีเริ่ม-จบทำให้เหมือนกันก่อนเก็บข้อมูลเพิ่ม
- 2) เพิ่ม metadata ได้แก่ รหัสผู้ให้ข้อมูล รหัสเซสชัน แสง ฉากหลัง ระยะเวลา มุม กล้อง
และความเร็ว เพื่อรองรับการตรวจสอบและแบ่งข้อมูลแบบกลุ่ม
- 3) แยกชุดฝึก ชุดตรวจสอบ และชุดทดสอบภายนอกตามผู้ให้ข้อมูลหรือเซสชัน
ห้ามให้ข้อมูลของกลุ่มทดสอบปรากฏในกระบวนการปรับโมเดล
- 4) วัด FPS เวลาแฝง อัตราการปฏิเสธคำ อัตราคำผิด และความสำเร็จของ TTS
ในสภาพแวดล้อมหลายแบบ พร้อมบันทึกเวอร์ชันข้อมูลและซอฟต์แวร์
- 5) ปรับเกณฑ์ความเชื่อมั่นจากชุดตรวจสอบ
เพิ่มสถานะไม่ทราบ/ปฏิเสธเมื่อไม่มีคลาสเหมาะสม
และประเมินการสอบเทียบค่าความน่าจะเป็น
- 6) เพิ่มทางเลือกเสียงภาษาไทยแบบออฟไลน์และตัวเลือกปิดการพูดอัตโนมัติ
เพื่อรองรับพื้นที่เครือข่ายจำกัดและความต้องการที่ต่างกัน

5.5.2 ข้อเสนอแนะสำหรับงานวิจัยต่อยอด

- 1) ขยายจำนวนคำและผู้ทำอย่างเป็นระบบ โดยวางแผนตัวอย่างต่อกลุ่มก่อนเก็บข้อมูล
ไม่เพิ่มเฉพาะคลิปจากสถานการณ์เดิม
- 2) เปรียบเทียบ SVM กับแบบจำลองลำดับ เช่น HMM, LSTM, Temporal Convolutional
Network หรือ Transformer
เมื่อมีข้อมูลมากพอและใช้ชุดทดสอบเดียวกันอย่างยุติธรรม
- 3) ศึกษาการแบ่งช่วงทำอัตโนมัติและการรู้จำหลายคำต่อเนื่อง
โดยแยกโจทย์การแบ่งหน่วยทำ การรู้จำ และการจัดลำดับภาษาปลายทาง
- 4) ศึกษาว่า สีหน้าและท่าทางที่ไม่ใช้มือมีบทบาทต่อความหมายของคำอย่างไร
พร้อมประเมินผลกระทบด้านความเป็นส่วนตัว

- 5) ออกแบบและทดสอบร่วมกับชุมชนผู้ใช้ภาษามือ ผู้เชี่ยวชาญด้านภาษา และผู้เชี่ยวชาญด้านการเข้าถึง เพื่อให้โจทย์ คำศัพท์ และเกณฑ์ความสำเร็จสอดคล้องกับการใช้งานจริง

5.5.3 ชุดคำศัพท์ที่เสนอให้เพิ่มในอนาคต 9 ท่า

หลังจากเพิ่มคำศัพท์รุ่นปัจจุบันจนมี 16 ท่าแล้ว ไฟล์ planned_gestures.json ยังระบุคำที่วางแผนไว้อีก 9 ท่า ดังตารางที่ 5.4 รายการนี้เป็นชื่อคำสำหรับวางแผนชุดข้อมูล ไม่ใช่ข้อกำหนดรูปแบบการทำท่า โดยต้องตรวจสอบรูปแบบภาษามือไทย ความหมายตามบริบท และความเหมาะสมร่วมกับผู้ใช้ภาษามือหรือผู้เชี่ยวชาญก่อนบันทึกข้อมูลจริง

ลำดับ	คำศัพท์ที่เสนอ	วัตถุประสงค์การใช้งาน
1	ไม่ต้อง	ใช้ปฏิเสธความต้องการหรือบริการ
2	มา	ใช้สื่อสารการเคลื่อนเข้าหาผู้พูดหรือจุดหมาย
3	ได้	ใช้ตอบรับความเป็นไปได้หรือความสามารถตามบริบท
4	ไป	ใช้สื่อสารการเคลื่อนออกจากจุดหรือไปยังสถานที่
5	ไม่ได้	ใช้ปฏิเสธความเป็นไปได้หรือความสามารถตามบริบท
6	ที่ไหน	ใช้สร้างคำถามเกี่ยวกับสถานที่
7	นอน	ใช้สื่อสารกิจวัตรหรือความต้องการพักผ่อน
8	ป่วย	ใช้แจ้งอาการไม่สบาย
9	ยา	ใช้สื่อสารเรื่องยาและการรักษา

ตารางที่ 5.4 ชุดคำศัพท์ที่เสนอให้เพิ่มในอนาคต 9 ท่า

แผนเก็บข้อมูลควรกำหนดจำนวนคลิปต่อท่าให้เท่ากัน

เก็บจากผู้ทำท่าหลายคนและหลายเซสชัน พร้อมบันทึกรหัสผู้ให้ข้อมูล สภาพแสง ฉากหลัง ระยะมุมกล้อง และความเร็วในการทำท่า จากนั้นแบ่งชุดฝึก ชุดตรวจสอบ และชุดทดสอบโดยไม่ให้ข้อมูลของผู้ทำท่าหรือเซสชันเดียวกันรั่วไหลข้ามชุด

5.6 สรุปภาพรวม

HandVox แสดงให้เห็นความเป็นไปได้ของการใช้ MediaPipe Holistic ร่วมกับ SVM เพื่อรู้จำท่าทางแบบแยกคำจากคลิปสั้น ระบบเชื่อมขั้นตอนเก็บข้อมูล ฝึกแบบจำลอง ทำนาย

แสดงข้อความ สร้างประโยค และอ่านเสียงไว้ในต้นแบบเดียว รุ่นปัจจุบันมี 16 ท่า 350 คลิป
และผ่านเกณฑ์คัดกรองภายในด้วย Accuracy 94.29% และ Macro F1 93.75%

คุณค่าของผลลัพธ์จึงอยู่ที่การพิสูจน์กระบวนการและเป็นฐานสำหรับทดลองต่อ
มากกว่าการรับรองความแม่นยำในโลกจริง
ขั้นตอนสำคัญถัดไปคือเก็บข้อมูลหลายผู้ทำท่าและหลายเซสชัน จัดทำ metadata
ประเมินแบบแยกกลุ่มและภายนอก วัดเวลาแฝง
และทดสอบกับผู้ใช้เป้าหมายภายใต้การขอความยินยอมและการคุ้มครองข้อมูลที่เหมาะสม