

บทที่ 3

วิธีดำเนินการและการออกแบบระบบ

บทนี้อธิบายวิธีพัฒนา HandVox ตามซอร์สโค้ด ชุดข้อมูล

และไฟล์แบบจำลองของโครงการปัจจุบัน

ตั้งแต่การวิเคราะห์ความต้องการจนถึงการทดสอบและควบคุมคุณภาพ โดยมีหัวข้อดังนี้

- 3.1 รูปแบบการดำเนินโครงการ
- 3.2 การวิเคราะห์ความต้องการ
- 3.3 สถาปัตยกรรมระบบ
- 3.4 การสร้างและจัดเก็บชุดข้อมูล
- 3.5 การสกัดและปรับมาตรฐานคุณลักษณะ
- 3.6 สถานะชุดข้อมูลปัจจุบัน
- 3.7 การฝึกแบบจำลอง
- 3.8 การทำงานแบบเวลาจริง
- 3.9 ส่วนติดต่อผู้ใช้และการแปลงข้อความเป็นเสียง
- 3.10 แผนการประเมินผล
- 3.11 การควบคุมคุณภาพและจริยธรรมข้อมูล
- 3.12 บทสรุป

3.1 รูปแบบการดำเนินโครงการ

โครงการใช้รูปแบบการวิจัยและพัฒนาเชิงทดลอง ประกอบด้วย การกำหนดข้อกำหนด การออกแบบสถาปัตยกรรม การพัฒนาซอฟต์แวร์ การสร้างชุดข้อมูลที่มีป้ายกำกับ การฝึกและประเมินแบบจำลอง และการทดสอบการใช้งานแบบเวลาจริง การตัดสินใจทุกขั้นอ้างอิงจากไฟล์โปรแกรมเพื่อให้ตรวจสอบย้อนกลับได้

3.2 การวิเคราะห์ความต้องการ

ตารางที่ 3.1 ความต้องการเชิงหน้าที่


รหัส	ความต้องการ	เกณฑ์ตรวจสอบ
FR-01	รับภาพจากเว็บแคมและตรวจหาช่วงบนกับมือ	เมื่อพบ pose และมืออย่างน้อยหนึ่งข้างจึงสร้างคุณลักษณะ
FR-02	เก็บคลิปท่าที่มีป้ายกำกับ	หนึ่งคลิปมี 30 เฟรม และหนึ่งท่ามีอย่างน้อย 30 คลิป
FR-03	ฝึกตัวจำแนกหลายคลาส	มืออย่างน้อย 2 ท่าและจำนวนคลิปขั้นต่ำครบ
FR-04	รู้จำแบบเวลาจริง	แสดงชื่อท่าและความเชื่อมั่นเมื่อผ่านเกณฑ์
FR-05	จัดการคำและเสียง	เพิ่ม/ลบ/สลับคำ และอ่านออกเสียงได้เมื่อ TTS พร้อม
FR-06	จัดการท่าที่ผู้ใช้เพิ่ม	เพิ่ม ลบ สำรองข้อมูล และฝึกใหม่ได้จากเมนู

ตารางที่ 3.2 ความต้องการที่ไม่ใช่เชิงหน้าที่

รหัส	ความต้องการที่ไม่ใช่เชิงหน้าที่	แนวทาง
NFR-01	ความสอดคล้องของข้อมูล	ใช้ฟังก์ชัน <code>extract_features</code> เดียวกันระหว่างเก็บและทำนาย
NFR-02	การทำซ้ำ	ใช้ <code>random_state=42</code> และบันทึกเวอร์ชันไลบรารี
NFR-03	ความเป็นส่วนตัว	บันทึกเฉพาะคุณลักษณะและป้ายกำกับ ไม่บันทึกวิดีโอเป็นชุดข้อมูล

รหัส	ความต้องการที่ไม่ใช่เชิงหน้าที่	แนวทาง
NFR-04	ความทนทาน	สร้างสถานะเมื่อไม่พบมือ และสำรองข้อมูลก่อนลบหรือรีเซ็ต

3.3 สถาปัตยกรรมระบบ



ภาพที่ 3.1 สถาปัตยกรรมการประมวลผลของ HandVox

สถาปัตยกรรมแบ่งเป็น 6 ส่วน ได้แก่ การรับภาพ การตรวจหาจุด การปรับมาตรฐาน การสะสมลำดับ 30 เฟรม การจำแนกด้วย SVM และการนำเสนอผล กระบวนการเก็บข้อมูลและกระบวนการใช้งานจริงเรียกใช้ `body_features.extract_features` ร่วมกัน จึงลดความเสี่ยงที่รูปแบบคุณลักษณะระหว่างฝึกและทำนายไม่ตรงกัน

ตารางที่ 3.3 องค์ประกอบซอฟต์แวร์

ไฟล์	หน้าที่หลัก	ข้อมูลเข้า/ออก
<code>body_features.py</code>	สกัด 171 คุณลักษณะและกรอบช่วงบน	MediaPipe results → feature vector
<code>sequence_dataset.py</code>	จัดเก็บและจัดการคลิป	<code>gesture_sequences.npz</code>
<code>collect_data.py</code>	เปิดกล้องและเก็บคลิปตามป้ายกำกับ	30 เฟรม → 1 คลิป

ไฟล์	หน้าที่หลัก	ข้อมูลเข้า/ออก
train_model.py	แบ่งข้อมูล ฝึก SVM และบันทึก โมเดล	NPZ → model/labels PKL
run_detector.py	ทำนายแบบเวลาจริงและแสดงผล	30 เฟรมล่าสุด → คำ/เสียง
gesture_config.py	โหลดชื่อ คำอธิบาย และสีของท่า	custom_gestures.json

3.4 การสร้างและจัดเก็บชุดข้อมูล

ผู้ใช้เพิ่มชื่อท่าและคำอธิบายผ่าน `add_gesture.py` จากนั้น `collect_data.py` เปิดกล้องที่ตั้งค่าความละเอียด 1280×720 พิกเซล กล้องภาพแนวนอน และใช้ MediaPipe Holistic ประมวลผลเฟรม เมื่อผู้ใช้กด Space โปรแกรมจะบันทึกและเก็บเฉพาะเฟรมที่ `extract_features` คืนค่าครบ จนครบ 30 เฟรมจึงบันทึกเป็นหนึ่งคลิป

`sequence_dataset.py` จัดเก็บคลิปทั้งหมดใน `gesture_sequences.npz` เป็นอาร์เรย์ชนิด `float32` รูปร่าง (จำนวนคลิป, 30, 171) และเก็บป้ายกำกับเป็นข้อความ หนึ่งท่าต้องมีอย่างน้อย 30 คลิปก่อนฝึก หากพบไฟล์ข้อมูลภาพนิ่งจากระบบรุ่นเก่า โปรแกรมจะย้ายไปยัง `gesture_backups` เพื่อป้องกันการใช้อ้างอิงข้อมูลที่มีโครงสร้างไม่เข้ากัน

ข้อควรระวังในการเก็บข้อมูล: ควรเริ่มและจบท่าภายในคลิปทุกครั้ง

จัดให้เห็นไหล่และมืออย่างน้อยหนึ่งข้าง และเก็บความหลากหลายด้านผู้ทำท่า แสง ระยะ มุม และความเร็วโดยไม่เปลี่ยนความหมายของท่า

[เว้นพื้นที่สำหรับภาพประกอบ]

ภาพที่ต้องการ: ภาพหน้าจอจริงของ `collect_data.py` ขณะนับถอยหลังหรือบันทึกคลิป โดยต้องเห็นชื่อท่า
เลขคลิป/30 กรอบช่วงบน และสถานะการบันทึก

ภาพที่ 3.2 หน้าจอเก็บคลิปท่าทาง

3.5 การสกัดและปรับมาตรฐานคุณลักษณะ

ระบบเลือกจุด pose หมายเลข 0, 2, 5, 7–16, 23 และ 24 รวม 15 จุด

พร้อมมือซ้ายและขวาข้างละ 21 จุด แต่ละจุดมีพิกัด x, y และ z รวม 171 ค่า หากไม่พบ pose
หรือไม่พบมือทั้งสองข้างจะไม่รับเฟรมนั้น หากพบเพียงมือเดียวจะเติมศูนย์แทนมือที่หาย

ให้ c เป็นจุดกึ่งกลางระหว่างไหล่ซ้ายและขวา และ s เป็นระยะยูคลิดระหว่างไหล่
ระบบคำนวณพิกัดมาตรฐานของทุกจุดด้วย $p'_i = (p_i - c) / \max(s, 10^{-6})$

จากนั้นเรียงคุณลักษณะตามลำดับ pose มือซ้าย และมือขวา

การใช้จุดและลำดับเดียวกันในทุกไฟล์เป็นเงื่อนไขสำคัญของความถูกต้อง

3.6 สถานะชุดข้อมูลปัจจุบัน

การตรวจสอบไฟล์ `gesture_sequences.npz` ณ วันที่ 4 สิงหาคม 2569 พบข้อมูล 120 คลิป
รูปร่างอาร์เรย์ (120, 30, 171) และชนิดข้อมูล float32 ป้ายกำกับมี 4
คลาสและแต่ละคลาสมีจำนวนเท่ากัน ดังตารางที่ 3.4

ตารางที่ 3.4 ผลการตรวจสอบชุดข้อมูลปัจจุบัน

ป้ายกำกับ	จำนวนคลิป	เฟรมต่อคลิป	คุณลักษณะต่อเฟรม
สวัสดี	30	30	171
ขอโทษ	30	30	171

ป้ายกำกับ	จำนวนคลิป	เฟรมต่อคลิป	คุณลักษณะต่อเฟรม
ไม่เป็นไร	30	30	171
ขอบคุณ	30	30	171
รวม	120	3,600 เฟรมที่ใช้	5,130 ค่าต่อคลิป

จำนวนดังกล่าวเพียงพอให้โปรแกรมฝึกตัวจำแนกต้นแบบ

แต่ยังไม่เพียงพอสำหรับสรุปความสามารถทั่วไปของระบบ เนื่องจากจำนวนผู้ให้ข้อมูล

จำนวนเซสชัน และความหลากหลายของสภาพแวดล้อมยังไม่ได้บันทึกเป็น metadata

ในไฟล์ชุดข้อมูล

3.7 การฝึกแบบจำลอง

train_model.py ตรวจสอบว่ารายชื่อป้ายกำกับตรงกับ gesture_config.py มียังน้อย 2

คลาส และทุกคลาสมีอย่างน้อย 30 คลิป จากนั้นใช้ LabelEncoder แปลงชื่อทำเป็นรหัสจำนวนเต็ม

เรียงเมทริกซ์ 30×171 เป็นเวกเตอร์ 5,130 ค่า และแบ่งข้อมูลฝึกกับทดสอบแบบ stratified

ตารางที่ 3.5 การตั้งค่าการฝึก

รายการ	ค่าที่ใช้	ผลจากข้อมูลปัจจุบัน
จำนวนข้อมูล	120 คลิป	4 คลาส $\times$ 30 คลิป
การแบ่งข้อมูล	80:20, stratified, random_state=42	ฝึก 96 คลิป; ทดสอบ 24 คลิป
ตัวจำแนก	SVC	หลายคลาสผ่าน scikit-learn
Kernel	RBF	ขอบเขตไม่เชิงเส้น
C	10	ค่าคงที่ตามซอร์สโค้ด
gamma	scale	คำนวณจากจำนวนคุณลักษณะและความแปรปรวน
probability	True	ใช้ predict_proba ในเวลาจริง
ไฟล์ผลลัพธ์	gesture_model.pkl, gesture_labels.pkl	แบบจำลองและตัวเข้ารหัสป้าย

รายการ	ค่าที่ใช้	ผลจากข้อมูลปัจจุบัน
		กำกับ

3.8 การทำงานแบบเวลาจริง

- 1) โหลด `gesture_model.pkl` และ `gesture_labels.pkl` และตรวจว่ารายชื่อคลาสตรงกับ `gesture_config.py`
- 2) เปิด MediaPipe Holistic และเว็บแคม จากนั้นสกัดคุณลักษณะของทุกเฟรมที่ผ่านเงื่อนไข
- 3) สะสมคุณลักษณะล่าสุด 30 เฟรมใน `motion_frames` และเรียงเป็นเวกเตอร์ 5,130 ค่า
- 4) คำนวณ `predict_proba` เลือกคลาสที่มีค่าสูงสุด และรับผลเมื่อค่าความเชื่อมั่น ไม่น้อยกว่า 0.40
- 5) เก็บผลย้อนหลัง 3 ครั้ง เลือกคลาสที่พบมากที่สุด และเฉลี่ยค่าความเชื่อมั่นของคลาสนั้น
- 6) ล้างคิวและสถานะเมื่อไม่พบมือนานกว่า 0.4 วินาที เพื่อลดการค้างของคำทำนายเดิม
- 7) แสดงกรอบ ชื่อท่า ค่าความเชื่อมั่น ประโยค และสถานะเสียงบนหน้าจอ

3.9 ส่วนติดต่อผู้ใช้และการแปลงข้อความเป็นเสียง

ตารางที่ 3.6 ปุ่มควบคุมขณะตรวจจับ

ปุ่ม	การทำงาน	ข้อความควบคุม
Space	เพิ่มคำที่ยืนยันแล้วลงในประโยค	หน่วยอย่างน้อย 1 วินาทีระหว่างการเพิ่ม
Backspace	ลบคำล่าสุด	ทำงานเมื่อประโยคไม่ว่าง
Enter	ล้างประโยค	ลบรายการคำทั้งหมด
S	อ่านประโยค	ทำงานเมื่อมีข้อความและ TTS พร้อม
Esc	ออกจากโปรแกรม	คืนกล้องและปิดหน้าต่าง

ระบบยังอ่านชื่อท่าอัตโนมัติเมื่อทำเดียวกันถูกยืนยันต่อเนื่องครบ 1 วินาที และอนุญาตให้พูดซ้ำหลังผู้ใช้เอามือออกจากระบบปริเซต การสร้างเสียงทำในเรดแยกเพื่อไม่ให้วงรอบภาพหยุดรอจนเสียงเล่นจบ

3.10 แผนการประเมินผล

3.10.1 การประเมินภายในชุดข้อมูล

- 1) รายงาน accuracy บนชุดทดสอบ 24 คลิป พร้อมจำนวนที่ทำนายถูกและผิด
- 2) รายงาน confusion matrix, precision, recall และ F1-score รายคลาส รวมทั้ง macro average
- 3) บันทึกเวอร์ชันข้อมูล รายชื่อคลาส random_state และเวลาที่ฝึก เพื่อทำซ้ำผลได้

สถานะผลประเมิน: ได้ประเมินซ้ำจากชุดข้อมูลคลิปรุ่นปัจจุบันแบบอ่านอย่างเดียวแล้ว โดยใช้การแบ่ง 80:20 ตามซอร์สโค้ดและ 5-fold StratifiedKFold ผลเชิงตัวเลข รายคลาส และข้อจำกัดของการแบ่งระดับคลิปนำเสนอในบทที่ 4

3.10.2 การประเมินกับข้อมูลภายนอก

ก่อนสรุปว่าระบบใช้ได้กับผู้ใช้ทั่วไป

ควรสร้างชุดทดสอบที่แยกตามผู้ให้ข้อมูลและรอบการเก็บ

โดยไม่ให้คลิปของบุคคลหรือเซสชันทดสอบอยู่ในชุดฝึก ควรทดสอบแสง ฉากหลัง ระยะ มุมกล้อง ความเร็ว มือข้างเดียวและสองข้าง และบันทึกเวลาแฝงตั้งแต่รับภาพจนแสดงผล

3.10.3 การทดสอบเชิงหน้าที่

ตารางที่ 3.7 กรณีทดสอบเชิงหน้าที่

กรณีทดสอบ	ผลที่คาดหวัง
ไม่พบ pose หรือมือ	ไม่เพิ่มเฟรมและไม่ทำนาย
คลิปของท่าไม่ครบ 30	ไม่อนุญาตให้ฝึกและแจ้งรายชื่อท่าที่ยังไม่ครบ
มีเพียง 1 คลาส	ไม่ฝึกตัวจำแนกหลายคลาส
โมเดลไม่ตรงกับรายการท่า	หยุดและแจ้งให้ฝึกใหม่
ความเชื่อมั่นต่ำกว่า 0.40	ไม่ยืนยันชื่อท่า
ไม่พบมือนานกว่า 0.4 วินาที	ล้างคิว สถานะ และตัวจับเวลาพูด

กรณีทดสอบ	ผลที่คาดหวัง
TTS ใช้งาน ไม่ได้	ระบบรู้จำยังทำงานและแสดงข้อความได้

3.11 การควบคุมคุณภาพและจริยธรรมข้อมูล

- 1) ใช้คำอธิบายท่าและป้ายกำกับที่ไม่ซ้ำ ตรวจสอบการสะกดก่อนเก็บ และฝึกใหม่ทุกครั้งเมื่อเปลี่ยนรายการท่า
- 2) เก็บ metadata ของผู้ให้ข้อมูล เชื้อชาติ สภาพแสง ระยะ และกล้องในรุ่นถัดไป เพื่อรองรับการแบ่งข้อมูลแบบกลุ่ม
- 3) ขอความยินยอมจากผู้ให้ข้อมูล ระบุวัตถุประสงค์ ระยะเวลาเก็บ และสิทธิในการถอนข้อมูล
- 4) ไม่ใช่ค่าความเชื่อมั่นแทนหลักฐานความถูกต้อง และไม่ใช้ระบบในบริบทสำคัญโดยไม่มีการยืนยันจากมนุษย์
- 5) รายงานจำนวนผู้ให้ข้อมูลและเงื่อนไขการทดสอบในบทที่ 4 เพื่อให้ผู้อ่านประเมินความสามารถทั่วไปของผลได้

3.12 บทสรุป

HandVox รับภาพเว็บแคมและใช้ MediaPipe Holistic สกัดจุดช่วงบน 15 จุดกับมือสองข้าง รวม 171 คุณลักษณะต่อเฟรม จากนั้นปรับมาตรฐาน เก็บลำดับ 30 เฟรมเป็นเวกเตอร์ 5,130 ค่า และฝึก SVM แบบ RBF ชุดข้อมูลปัจจุบันมี 120 คลิปจาก 4 ท่า แบ่งเป็นชุดฝึก 96 คลิปและชุดทดสอบ 24 คลิป

ขั้นตอนนี้ทำให้การเก็บข้อมูลและการทำนายสอดคล้องกัน แต่บทถัดไปต้องใช้ผลจากโมเดลคลิปรุ่นปัจจุบัน บันทึกตัวชี้วัดอย่างเป็นระบบ และทดสอบกับผู้ให้ข้อมูลและสภาพแวดล้อมใหม่ก่อนสรุปการใช้งานจริง