

## บทที่ 3

### วิธีดำเนินการและการออกแบบระบบ

บทนี้อธิบายวิธีพัฒนา HandVox ตามซอร์สโค้ด ชุดข้อมูล

และไฟล์แบบจำลองของโครงการปัจจุบัน

ตั้งแต่การวิเคราะห์ความต้องการจนถึงการทดสอบและควบคุมคุณภาพ โดยมีหัวข้อดังนี้

- 3.1 รูปแบบการดำเนินโครงการ
- 3.2 การวิเคราะห์ความต้องการ
- 3.3 สถาปัตยกรรมระบบ
- 3.4 การสร้างและจัดเก็บชุดข้อมูล
- 3.5 การสกัดและปรับมาตรฐานคุณลักษณะ
- 3.6 สถานะชุดข้อมูลปัจจุบัน
- 3.7 การฝึกแบบจำลอง
- 3.8 การทำงานแบบเวลาจริง
- 3.9 ส่วนติดต่อผู้ใช้และการแปลงข้อความเป็นเสียง
- 3.10 แผนการประเมินผล
- 3.11 การควบคุมคุณภาพและจริยธรรมข้อมูล
- 3.12 บทสรุป

### 3.1 รูปแบบการดำเนินโครงการ

โครงการใช้รูปแบบการวิจัยและพัฒนาเชิงทดลอง ประกอบด้วย การกำหนดข้อกำหนด การออกแบบสถาปัตยกรรม การพัฒนาซอฟต์แวร์ การสร้างชุดข้อมูลที่มีป้ายกำกับ การฝึกและประเมินแบบจำลอง และการทดสอบการใช้งานแบบเวลาจริง การตัดสินใจทุกขั้นอ้างอิงจากไฟล์โปรแกรมเพื่อให้ตรวจสอบย้อนกลับได้

### 3.2 การวิเคราะห์ความต้องการ

| รหัส  | ความต้องการ                           | เกณฑ์ตรวจสอบ                                           |
|-------|---------------------------------------|--------------------------------------------------------|
| FR-01 | รับภาพจากเว็บแคมและตรวจหาช่วงบนกับมือ | เมื่อพบ pose และมืออย่างน้อยหนึ่งข้างจึงสร้างคุณลักษณะ |
| FR-02 | เก็บคลิปท่าที่มีป้ายกำกับ             | หนึ่งคลิปมี 30 เฟรม และหนึ่งท่ามีอย่างน้อย 30 คลิป     |
| FR-03 | ฝึกตัวจำแนกหลายคลาส                   | มืออย่างน้อย 2 ท่าและจำนวนคลิปขั้นต่ำครบ               |
| FR-04 | รู้จำแบบเวลาจริง                      | แสดงชื่อท่าและความเชื่อมั่นเมื่อผ่านเกณฑ์              |
| FR-05 | จัดการคำและเสียง                      | เพิ่ม/ลบ/ล้างคำ และอ่านออกเสียงได้เมื่อ TTS พร้อม      |
| FR-06 | จัดการท่าที่ผู้ใช้เพิ่ม               | เพิ่ม ลบ สำรองข้อมูล และฝึกใหม่ได้จากเมนู              |


ตารางที่ 3.1 ความต้องการเชิงหน้าที่

| รหัส   | ความต้องการที่ไม่ใช่เชิงหน้าที่ | แนวทาง                                                                |
|--------|---------------------------------|-----------------------------------------------------------------------|
| NFR-01 | ความสอดคล้องของข้อมูล           | ใช้ฟังก์ชัน <code>extract_features</code> เดียวกันระหว่างเก็บและทำนาย |
| NFR-02 | การทำซ้ำ                        | ใช้ <code>random_state=42</code> และบันทึกเวอร์ชันไลบรารี             |
| NFR-03 | ความเป็นส่วนตัว                 | บันทึกเฉพาะคุณลักษณะและป้ายกำกับ ไม่บันทึกวิดีโอเป็นชุดข้อมูล         |

| รหัส   | ความต้องการที่ไม่ใช่เชิงหน้าที่ | แนวทาง                                                   |
|--------|---------------------------------|----------------------------------------------------------|
| NFR-04 | ความทนทาน                       | ล้างสถานะเมื่อไม่พบมือ<br>และสำรองข้อมูลก่อนลบหรือรีเซ็ต |

ตารางที่ 3.2 ความต้องการที่ไม่ใช่เชิงหน้าที่

### 3.3 สถาปัตยกรรมระบบ



ภาพที่ 3.1 สถาปัตยกรรมการประมวลผลของ HandVox

สถาปัตยกรรมแบ่งเป็น 6 ส่วน ได้แก่ การรับภาพ การตรวจหาจุด การปรับมาตรฐาน การสะสมลำดับ 30 เฟรม การจำแนกด้วย SVM และการนำเสนอผล

กระบวนการเก็บข้อมูลและกระบวนการใช้งานจริงเรียกใช้ `body_features.extract_features` ร่วมกัน

จึงลดความเสี่ยงที่รูปแบบคุณลักษณะระหว่างฝึกและทำนายไม่ตรงกัน

| ไฟล์                             | หน้าที่หลัก                       | ข้อมูลเข้า/ออก                     |
|----------------------------------|-----------------------------------|------------------------------------|
| <code>body_features.py</code>    | สกัด 171 คุณลักษณะและกรอบช่วงบน   | MediaPipe results → feature vector |
| <code>sequence_dataset.py</code> | จัดเก็บและจัดการคลิป              | <code>gesture_sequences.npz</code> |
| <code>collect_data.py</code>     | เปิดกล้องและเก็บคลิปตามป้ายกำกับ  | 30 เฟรม → 1 คลิป                   |
| <code>train_model.py</code>      | แบ่งข้อมูล ฝึก SVM และบันทึกโมเดล | NPZ → model/labels PKL             |

| ไฟล์              | หน้าที่หลัก                   | ข้อมูลเข้า/ออก           |
|-------------------|-------------------------------|--------------------------|
| run_detector.py   | ทำนายแบบเวลาจริงและแสดงผล     | 30 เฟรมล่าสุด → คำ/เสียง |
| gesture_config.py | โหลดชื่อ คำอธิบาย และสีของท่า | custom_gestures.json     |

ตารางที่ 3.3 องค์ประกอบซอฟต์แวร์

### 3.4 การสร้างและจัดเก็บชุดข้อมูล

ผู้ใช้เพิ่มชื่อท่าและคำอธิบายผ่าน `add_gesture.py` จากนั้น `collect_data.py` เปิดกล้องที่ตั้งค่าความละเอียด  $1280 \times 720$  พิกเซล กล้องภาพแนวนอน และใช้ MediaPipe Holistic ประมวลผลเฟรม เมื่อผู้ใช้กด Space โปรแกรมจะบันทึกและเก็บเฉพาะเฟรมที่ `extract_features` คืนค่าครบ จนครบ 30 เฟรมจึงบันทึกเป็นหนึ่งคลิป

`sequence_dataset.py` จัดเก็บคลิปทั้งหมดใน `gesture_sequences.npz` เป็นอาร์เรย์ชนิด `float32` รูปร่าง (จำนวนคลิป, 30, 171) และเก็บป้ายกำกับเป็นข้อความ หนึ่งท่าต้องมีอย่างน้อย 30 คลิปก่อนฝึก หากพบไฟล์ข้อมูลภาพหนึ่งจากระบบรุ่นเก่า โปรแกรมจะย้ายไปยัง `gesture_backups` เพื่อป้องกันการใช้ข้อมูลที่มีโครงสร้างไม่เข้ากัน

**ข้อควรระวังการเก็บข้อมูล:** ควรเริ่มและจบท่าภายในคลิปทุกครั้ง

จัดให้เห็นไหล่และมืออย่างน้อยหนึ่งข้าง และเก็บความหลากหลายด้านผู้ทำท่า แสง ระยะ มุม และความเร็วโดยไม่เปลี่ยนความหมายของท่า

[เว้นพื้นที่สำหรับภาพประกอบ]

ภาพที่ต้องการ: ภาพหน้าจอจริงของ `collect_data.py` ขณะนับถอยหลังหรือบันทึกคลิป โดยต้องเห็นชื่อท่า  
เลขคลิป/30 กรอบช่วงบน และสถานะการบันทึก

ภาพที่ 3.2 หน้าจอเก็บคลิปท่าทาง

### 3.5 การสกัดและปรับมาตรฐานคุณลักษณะ

ระบบเลือกจุด pose หมายเลข 0, 2, 5, 7–16, 23 และ 24 รวม 15 จุด

พร้อมมือซ้ายและขวาข้างละ 21 จุด แต่ละจุดมีพิกัด x, y และ z รวม 171 ค่า หากไม่พบ pose  
หรือไม่พบมือทั้งสองข้างจะไม่รับเฟรมนั้น หากพบเพียงมือเดียวจะเติมศูนย์แทนมือที่หาย

ให้  $c$  เป็นจุดกึ่งกลางระหว่างไหล่ซ้ายและขวา และ  $s$  เป็นระยะยูคลิดระหว่างไหล่

ระบบคำนวณพิกัดมาตรฐานของทุกจุดด้วย  $p'_i = (p_i - c) / \max(s, 10^{-6})$

จากนั้นเรียงคุณลักษณะตามลำดับ pose มือซ้าย และมือขวา

การใช้จุดและลำดับเดียวกันในทุกไฟล์เป็นเงื่อนไขสำคัญของความถูกต้อง

### 3.6 สถานะชุดข้อมูลปัจจุบัน

การตรวจสอบไฟล์ `gesture_sequences.npz` ณ วันที่ 4 สิงหาคม 2569 พบข้อมูล 120 คลิป

รูปร่างอาร์เรย์ (120, 30, 171) และชนิดข้อมูล float32 ป้ายกำกับมี 4

คลาสและแต่ละคลาสมีจำนวนเท่ากัน ดังตารางที่ 3.4

| ป้ายกำกับ | จำนวนคลิป | เฟรมต่อคลิป | คุณลักษณะต่อเฟรม |
|-----------|-----------|-------------|------------------|
| สวัสดี    | 30        | 30          | 171              |
| ขอโทษ     | 30        | 30          | 171              |
| ไม่เป็นไร | 30        | 30          | 171              |

| ป้ายกำกับ | จำนวนคลิป | เฟรมต่อคลิป      | คุณลักษณะต่อเฟรม |
|-----------|-----------|------------------|------------------|
| ขอบคุณ    | 30        | 30               | 171              |
| รวม       | 120       | 3,600 เฟรมที่ใช้ | 5,130 ค่าต่อคลิป |

ตารางที่ 3.4 ผลการตรวจสอบชุดข้อมูลปัจจุบัน

จำนวนดังกล่าวเพียงพอให้โปรแกรมฝึกตัวจำแนกต้นแบบ

แต่ยังไม่เพียงพอสำหรับสรุปความสามารถทั่วไปของระบบ เนื่องจากจำนวนผู้ให้ข้อมูล

จำนวนเซสชัน และความหลากหลายของสภาพแวดล้อมยังไม่ได้บันทึกเป็น metadata

ในไฟล์ชุดข้อมูล

### 3.7 การฝึกแบบจำลอง

`train_model.py` ตรวจสอบว่ารายชื่อป้ายกำกับตรงกับ `gesture_config.py` มีอย่างน้อย 2

คลาส และทุกคลาสมีอย่างน้อย 30 คลิป จากนั้นใช้ `LabelEncoder` แปลงชื่อทำเป็นรหัสจำนวนเต็ม

เรียงเมทริกซ์  $30 \times 171$  เป็นเวกเตอร์ 5,130 ค่า และแบ่งข้อมูลฝึกกับทดสอบแบบ stratified

| รายการ        | ค่าที่ใช้                          | ผลจากข้อมูลปัจจุบัน                       |
|---------------|------------------------------------|-------------------------------------------|
| จำนวนข้อมูล   | 120 คลิป                           | 4 คลาส $\times$ 30 คลิป                   |
| การแบ่งข้อมูล | 80:20, stratified, random_state=42 | ฝึก 96 คลิป; ทดสอบ 24 คลิป                |
| ตัวจำแนก      | SVC                                | หลายคลาสผ่าน scikit-learn                 |
| Kernel        | RBF                                | ขอบเขตไม่เชิงเส้น                         |
| C             | 10                                 | ค่าคงที่ตามซอร์สโค้ด                      |
| gamma         | scale                              | คำนวณจากจำนวนคุณลักษณะและความแปรปรวน      |
| probability   | True                               | ใช้ <code>predict_proba</code> ในเวลาจริง |

| รายการ      | ค่าที่ใช้                             | ผลจากข้อมูลปัจจุบัน             |
|-------------|---------------------------------------|---------------------------------|
| ไฟล์ผลลัพธ์ | gesture_model.pkl, gesture_labels.pkl | แบบจำลองและตัวเข้ารหัสป้ายกำกับ |

ตารางที่ 3.5 การตั้งค่าการฝึก

### 3.8 การทำงานแบบเวลาจริง

- 1) โหลด gesture\_model.pkl และ gesture\_labels.pkl และตรวจสอบว่ารายชื่อคลาสตรงกับ gesture\_config.py
- 2) เปิด MediaPipe Holistic และเว็บแคม  
จากนั้นสกัดคุณลักษณะของทุกเฟรมที่ผ่านเงื่อนไข
- 3) สะสมคุณลักษณะล่าสุด 30 เฟรมใน motion\_frames และเรียงเป็นเวกเตอร์ 5,130 ค่า
- 4) คำนวณ predict\_proba เลือกคลาสที่มีค่าสูงสุด และรับผลเมื่อค่าความเชื่อมั่นไม่น้อยกว่า 0.40
- 5) เก็บผลย้อนหลัง 3 ครั้ง เลือกคลาสที่พบมากที่สุด และเฉลี่ยค่าความเชื่อมั่นของคลาสนั้น
- 6) ล้างคิวและสถานะเมื่อไม่พบมือนานกว่า 0.4 วินาที เพื่อลดการค้างของคำทำนายเดิม
- 7) แสดงกรอบ ชื่อท่า ค่าความเชื่อมั่น ประโยค และสถานะเสียงบนหน้าจอ

### 3.9 ส่วนติดต่อผู้ใช้และการแปลงข้อความเป็นเสียง

| ปุ่ม      | การทำงาน                        | ข้อความ                                |
|-----------|---------------------------------|----------------------------------------|
| Space     | เพิ่มคำที่ขึ้นต้นแล้วลงในประโยค | หน่วยอย่างน้อย 1 วินาทีระหว่างการเพิ่ม |
| Backspace | ลบคำล่าสุด                      | ทำงานเมื่อประโยคไม่ว่าง                |
| Enter     | ล้างประโยค                      | ลบรายการคำทั้งหมด                      |
| S         | อ่านประโยค                      | ทำงานเมื่อมีข้อความและ TTS พร้อม       |

| ปุ่ม | การทำงาน      | ข้อควบคุม              |
|------|---------------|------------------------|
| Esc  | ออกจากโปรแกรม | คืนกล้องและปิดหน้าต่าง |

ตารางที่ 3.6 ปุ่มควบคุมขณะตรวจจับ

ระบบยังอ่านชื่อทำอัตโนมิติเมื่อทำเดียวกันถูกยืนยันต่อเนื่องครบ 1 วินาที และอนุญาตให้พุดซ้ำหลังผู้ใช้เอามือออกจากระบบปริเซ็ค การสร้างเสียงทำในเรคดแยกเพื่อไม่ให้วงรอบภาพหยุดจนเสียงเล่นจบ

### 3.10 แผนการประเมินผล

#### 3.10.1 การประเมินภายในชุดข้อมูล

- 1) รายงาน accuracy บนชุดทดสอบ 24 คลิป พร้อมจำนวนที่ทำนายถูกและผิด
- 2) รายงาน confusion matrix, precision, recall และ F1-score รายคลาส รวมทั้ง macro average
- 3) บันทึกเวอร์ชันข้อมูล รายชื่อคลาส random\_state และเวลาที่ฝึก เพื่อทำซ้ำผลได้

**สถานะผลประเมิน:** ได้ประเมินซ้ำจากชุดข้อมูลคลิปรุ่นปัจจุบันแบบอ่านอย่างเดียวนแล้ว โดยใช้การแบ่ง 80:20 ตามซอร์สโค้ดและ 5-fold StratifiedKFold ผลเชิงตัวเลข รายคลาส และข้อจำกัดของการแบ่งระดับคลิปนำเสนอในบทที่ 4

#### 3.10.2 การประเมินกับข้อมูลภายนอก

ก่อนสรุปว่าระบบใช้ได้กับผู้ใช้ทั่วไป

ควรสร้างชุดทดสอบที่แยกตามผู้ให้ข้อมูลและรอบการเก็บ

โดยไม่ให้คลิปของบุคคลหรือเซสชันทดสอบอยู่ในชุดฝึก ควรทดสอบแสง ฉากหลัง ระยะ มุมกล้อง ความเร็ว มือข้างเดียวและสองข้าง และบันทึกเวลาแฝงตั้งแต่รับภาพจนแสดงผล

#### 3.10.3 การทดสอบเชิงหน้าที่

| กรณีทดสอบ          | ผลที่คาดหวัง            |
|--------------------|-------------------------|
| ไม่พบ pose หรือมือ | ไม่เพิ่มเฟรมและไม่ทำนาย |

| กรณีทดสอบ                  | ผลที่คาดหวัง                                 |
|----------------------------|----------------------------------------------|
| คลิปของท่าไม้ครบ 30        | ไม่อนุญาตให้ฝึกและแจ้งรายชื่อท่าที่ยังไม่ครบ |
| มีเพียง 1 คลาส             | ไม่ฝึกตัวจำแนกหลายคลาส                       |
| โมเดลไม่ตรงกับรายการท่า    | หยุดและแจ้งให้ฝึกใหม่                        |
| ความเชื่อมั่นต่ำกว่า 0.40  | ไม่ยืนยันชื่อท่า                             |
| ไม่พบมีอนานกว่า 0.4 วินาที | ล้างคิว สถานะ และตัวจับเวลาพูด               |
| TTS ใช้งานไม่ได้           | ระบบรู้จำยังทำงานและแสดงข้อความได้           |

ตารางที่ 3.7 กรณีทดสอบเชิงหน้าที่

### 3.11 การควบคุมคุณภาพและจริยธรรมข้อมูล

- 1) ใช้คำอธิบายท่าและป้ายกำกับที่ไม่ซ้ำ ตรวจสอบการสะกดก่อนเก็บ และฝึกใหม่ทุกครั้งเมื่อเปลี่ยนรายการท่า
- 2) เก็บ metadata ของผู้ให้ข้อมูล เชตชน สภาพแสง ระยะเวลา และกล้องในรุ่นถัดไป เพื่อรองรับการแบ่งข้อมูลแบบกลุ่ม
- 3) ขอความยินยอมจากผู้ให้ข้อมูล ระบุวัตถุประสงค์ ระยะเวลาเก็บ และสิทธิในการถอนข้อมูล
- 4) ไม่ใช้ค่าความเชื่อมั่นแทนหลักฐานความถูกต้อง และไม่ใช้ระบบในบริบทสำคัญโดยไม่มีการยืนยันจากมนุษย์
- 5) รายงานจำนวนผู้ให้ข้อมูลและเงื่อนไขการทดสอบในบทที่ 4 เพื่อให้ผู้อ่านประเมินความสามารถทั่วไปของผลได้

### 3.12 บทสรุป

HandVox รับภาพเว็บแคมและใช้ MediaPipe Holistic สกัดจุดช่วงบน 15 จุดกับมือสองข้าง รวม 171 คุณลักษณะต่อเฟรม จากนั้นปรับมาตรฐาน เก็บลำดับ 30 เฟรมเป็นเวกเตอร์ 5,130 ค่า และฝึก SVM แบบ RBF ชุดข้อมูลปัจจุบันมี 120 คลิปจาก 4 ท่า แบ่งเป็นชุดฝึก 96 คลิปและชุดทดสอบ 24 คลิป

ขั้นตอนนี้ทำให้การเก็บข้อมูลและการทำนายสอดคล้องกัน  
แต่บทถัดไปต้องใช้ผลจากโมเดลลิปรุ่นปัจจุบัน บันทึกตัวชี้วัดอย่างเป็นระบบ  
และทดสอบกับผู้ให้ข้อมูลและสภาพแวดล้อมใหม่ก่อนสรุปการใช้งานจริง