

## บทที่ 2

### ความรู้พื้นฐานและงานที่เกี่ยวข้อง

บทนี้อธิบายแนวคิดที่จำเป็นต่อการพัฒนา HandVox  
ตั้งแต่ขอบเขตของการรู้จำภาษามือด้วยคอมพิวเตอร์ การตรวจหาจุดสำคัญ  
การแทนลำดับการเคลื่อนไหว การจำแนก และหลักการประเมินผล โดยมีหัวข้อดังนี้

- 2.1 ภาษามือ การรู้จำ และการแปล
- 2.2 การรู้จำแบบภาพนิ่ง แบบแยกคำ และแบบต่อเนื่อง
- 2.3 การมองเห็นด้วยคอมพิวเตอร์และจุดสำคัญ
- 2.4 MediaPipe Holistic ในโครงการ
- 2.5 การปรับมาตรฐานเชิงตำแหน่งและขนาด
- 2.6 การแทนลำดับการเคลื่อนไหว
- 2.7 Support Vector Machine และ RBF Kernel
- 2.8 การแบ่งข้อมูลและการป้องกันการรั่วไหลของข้อมูล
- 2.9 ตัวชี้วัดการจำแนก
- 2.10 การประมวลผลแบบเวลาจริงและเสียงพูด
- 2.11 งานและแนวคิดที่เกี่ยวข้อง
- 2.12 ความน่าเชื่อถือ จริยธรรม และการเข้าถึง
- 2.13 บทสรุป

## 2.1 ภาษามือ การรู้จำ และการแปล

ภาษามือเป็นภาษาธรรมชาติที่ใช้รูปมือ ตำแหน่ง ทิศทาง การเคลื่อนไหว การแสดงสีหน้า และโครงสร้างทางภาษา การทำให้คอมพิวเตอร์ระบุหน่วยทำหรือคำจากวิดีโอเรียกว่า การรู้จำภาษามือ (Sign Language Recognition: SLR) ส่วนการแปลภาษามือ (Sign Language Translation: SLT)

ต้องแปลงลำดับภาษามือให้เป็นประโยคของภาษาปลายทางโดยคำนึงถึงโครงสร้างและบริบท ดังนั้นระบบที่ส่งออกชื่อทำจากคลิปสั้นจึงอยู่ในกลุ่มการรู้จำแบบแยกคำ ไม่ใช่ระบบแปลภาษามือต่อเนื่อง (Yu et al., 2022; Sarhan & Frintrop, 2023)

การกำหนดคำเรียกให้ตรงกับความสามารถเป็นหลักสำคัญของงานวิจัย เพราะช่วยป้องกันการนำไปใช้เกินขอบเขต HandVox จึงจำแนกเฉพาะทำที่ผู้พัฒนาหรือผู้ใช้เก็บไว้ในชุดข้อมูล และต้องให้ผู้ใช้กดเพิ่มคำลงในประโยค ไม่ได้แบ่งคำหรือวิเคราะห์ไวยากรณ์โดยอัตโนมัติ

## 2.2 การรู้จำแบบภาพนิ่ง แบบแยกคำ และแบบต่อเนื่อง

ตารางที่ 2.1 การเปรียบเทียบระดับของการรู้จำ

| รูปแบบ       | ข้อมูลนำเข้า        | ผลลัพธ์                   | ขอบเขต                                   |
|--------------|---------------------|---------------------------|------------------------------------------|
| ภาพนิ่ง      | หนึ่งเฟรม           | คลาสของรูปมือ             | ไม่แทนลำดับการเคลื่อนไหว                 |
| แบบแยกคำ     | คลิปของหนึ่งท่า     | หนึ่งคำหรือหนึ่งป้ายกำกับ | เหมาะกับท่าที่มีจุดเริ่มและสิ้นสุดชัดเจน |
| แบบต่อเนื่อง | วิดีโอหลายท่าต่อกัน | ลำดับคำหรือประโยค         | ต้องแบ่งหน่วยท่าและจัดการบริบท           |

HandVox

เลือกการรู้จำแบบแยกคำจากคลิป

30

เฟรม

เพื่อให้ระบบรับรู้การเคลื่อนไหวของแขนและมือที่ไม่สามารถอธิบายด้วยภาพนิ่งเพียงเฟรมเดียว

อย่างไรก็ดี ความยาว 30 เฟรมเป็นจำนวนตัวอย่างตามลำดับ ไม่ใช่ระยะเวลาแน่นอน เพราะระยะเวลาจริงขึ้นกับอัตราเฟรมของกล้องและการประมวลผล

## 2.3 การมองเห็นด้วยคอมพิวเตอร์และจุดสำคัญ

การมองเห็นด้วยคอมพิวเตอร์เป็นกระบวนการรับภาพหรือวิดีโอและสกัดข้อมูลที่ใช้ตัดสินใจได้ OpenCV ทำหน้าที่เปิดกล้อง กล้องภาพในแนวนอน วาดส่วนติดต่อ และแสดงผล ส่วน MediaPipe ทำหน้าที่ประมาณพิกัดจุดสำคัญ

การใช้จุดสำคัญแทนภาพดิบช่วยลดมิติข้อมูลและทำให้ตีความได้ง่ายขึ้น

แต่ยังขึ้นกับคุณภาพการตรวจหา การบังมือ แสง มุมกล้อง และความเร็วของการเคลื่อนไหว

งาน MediaPipe Hands เสนอการตรวจหาฝ่ามือร่วมกับแบบจำลองจุดสำคัญ 21 จุดต่อมือสำหรับการทำงานแบบเวลาจริงจากกล้อง RGB (Zhang et al., 2020) ส่วน MediaPipe Holistic รวมจุดท่าทางร่างกาย ใบหน้า และมือทั้งสองข้างไว้ในกระบวนการเดียว โดยคงความสอดคล้องของด้านซ้ายและขวาระหว่างเฟรม (Google AI Edge, n.d.)

## 2.4 MediaPipe Holistic ในโครงการ

โครงการตั้งค่า MediaPipe Holistic ให้ประมวลผลวิดีโอต่อเนื่อง (static\_image\_mode=False) ใช้ model\_complexity=1 เปิด smooth\_landmarks และกำหนด min\_detection\_confidence กับ min\_tracking\_confidence เท่ากับ 0.70 แม้ Holistic จะสามารถส่งออกจุดจำนวนมาก แต่ HandVox เลือกเฉพาะ 15 จุดของช่วงบนและจุดมือ 21 จุดต่อข้างเพื่อควบคุมขนาดข้อมูล

ตารางที่ 2.2 คุณลักษณะที่ HandVox เลือกใช้

| กลุ่มจุด                               | จำนวนจุด | พิกัดต่อจุด | จำนวนคุณลักษณะ |
|----------------------------------------|----------|-------------|----------------|
| ช่วงบน: ศีรษะ ไหล่ สอก ข้อมือ และสะโพก | 15       | x, y, z     | 45             |
| มือซ้าย                                | 21       | x, y, z     | 63             |
| มือขวา                                 | 21       | x, y, z     | 63             |
| รวมต่อเฟรม                             | 57       | 3           | 171            |

ระบบคืนค่า None เมื่อไม่พบโครงร่างท่าทางหรือไม่พบมือทั้งสองข้าง หากพบเพียงมือเดียว ระบบแทนคุณลักษณะของมือที่ไม่พบด้วยศูนย์จำนวน 63 ค่า

วิธีนี้ทำให้ทุกเฟรมมีมิติเท่ากัน แต่ต้องระวังว่าศูนย์เป็นสัญลักษณ์ของข้อมูลที่หายไป ไม่ใช่ตำแหน่งมือจริง

## 2.5 การปรับมาตรฐานเชิงตำแหน่งและขนาด

พิกัดจากภาพเปลี่ยนตามตำแหน่งผู้ใช้ ระยะห่าง และขนาดตัว HandVox จึงกำหนดจุดกึ่งกลางไหล่ซ้ายและขวาเป็นจุดอ้างอิง  $c$  และใช้ระยะยูนิตระหว่างไหล่เป็นตัวปรับขนาด  $s$  สำหรับจุด  $p_i$  พิกัดที่ปรับแล้วคำนวณเป็น  $p'_i = (p_i - c) / \max(s, 10^{-6})$  ทั้งแกน  $x, y$  และ  $z$

การปรับดังกล่าวลดผลจากการเลื่อนตำแหน่งและการเปลี่ยนขนาดโดยรวม แต่ไม่ทำให้ข้อมูลไม่แปรผันต่อการหมุน มุมกล้อง หรือสัดส่วนร่างกายทั้งหมด จึงยังต้องเก็บข้อมูลจากระยะ มุม และความเร็วที่หลากหลาย

## 2.6 การแทนลำดับการเคลื่อนไหว

หนึ่งคลิปประกอบด้วย 30 เฟรมและแต่ละเฟรมมี 171 คุณลักษณะ จึงแทนได้เป็นเมทริกซ์ขนาด  $30 \times 171$  ก่อนฝึก ระบบเรียงค่าทุกเฟรมต่อกันเป็นเวกเตอร์ 5,130 ค่า การเรียงตามลำดับเวลาเก็บข้อมูลการเคลื่อนไหวไว้ทางอ้อม เพราะตำแหน่งของคุณลักษณะในเวกเตอร์สัมพันธ์กับลำดับเฟรม ข้อดีของวิธีนี้คือใช้งานร่วมกับตัวจำแนกแบบดั้งเดิมได้ง่ายและฝึกได้รวดเร็วเมื่อข้อมูลมีขนาดเล็ก ข้อจำกัดคือทุกคลิปต้องมีจำนวนเฟรมเท่ากัน และแบบจำลองอาจไวต่อความเร็วหรือจังหวะที่ต่างจากข้อมูลฝึกมาก

## 2.7 Support Vector Machine และ RBF Kernel

Support Vector Machine เป็นวิธีการเรียนรู้แบบมีผู้สอนที่สร้างขอบเขตการตัดสินใจโดยอาศัยตัวอย่างที่อยู่ใกล้ขอบเขตของคลาส แนวคิดดั้งเดิมเสนอการแปลงข้อมูลไปยังปริภูมิที่มีมิติสูงเพื่อสร้างขอบเขตที่แยกข้อมูลได้ดี (Cortes & Vapnik, 1995) RBF kernel ช่วยสร้างขอบเขตไม่เชิงเส้นและเหมาะสมกับความสัมพันธ์ที่ซับซ้อนระหว่างตำแหน่งจุดหลายเฟรม

HandVox ใช้ SVC ของ scikit-learn โดยกำหนด kernel='rbf', C=10, gamma='scale' และ probability=True ค่า C ควบคุมการแลกเปลี่ยนระหว่างขอบเขตที่กว้างกับข้อผิดพลาดบนข้อมูลฝึก ส่วน gamma กำหนดอิทธิพลของตัวอย่างต่อรูปร่างขอบเขต การเปิด probability ทำให้ระบบรายงานค่าประกอบการตัดสินใจ แต่ค่าดังกล่าวไม่ควรถูกตีความเป็นการรับประกันความถูกต้องในโลกจริง

## 2.8 การแบ่งข้อมูลและการป้องกันการรั่วไหลของข้อมูล

การแบ่งชุดข้อมูลฝึกและทดสอบต้องทำก่อนประเมินผล โดยใช้ข้อมูลทดสอบเฉพาะสำหรับวัดความสามารถกับตัวอย่างที่โมเดลไม่ได้ใช้ฝึก HandVox ใช้การแบ่ง 80:20 แบบ stratified และ random\_state=42 เพื่อรักษาสัดส่วนคลาสและทำซ้ำได้ อย่างไรก็ตาม คลิปที่เก็บต่อเนื่องจากผู้ทำท่าคนเดียว เซสชันเดียว และพื้นหลังเดียวอาจคล้ายกันมาก แม้จะอยู่คนละไฟล์คลิป หากสุ่มคลิประหว่างชุดฝึกและทดสอบ คะแนนอาจสะท้อนความสามารถในการจำลักษณะของเซสชันมากกว่าความสามารถกับผู้ใช้ใหม่ แนวทางที่เข้มงวดกว่าคือแบ่งตามผู้ให้ข้อมูลหรือรอบการเก็บ (grouped split) และมีชุดทดสอบภายนอกที่แยกจากกระบวนการพัฒนา

## 2.9 ตัวชี้วัดการจำแนก

Accuracy คือสัดส่วนตัวอย่างที่ทำนายถูกทั้งหมด แต่เมื่อจำนวนตัวอย่างหรือความยากของแต่ละคลาสต่างกัน ควรรายงาน precision, recall และ F1-score รายคลาส รวมถึงค่าเฉลี่ยแบบ macro ซึ่งให้น้ำหนักทุกคลาสเท่ากัน Confusion matrix ช่วยแสดงว่าทำไ้ถูกสับสนกับทำไ้ (Sokolova & Lapalme, 2009)

ตารางที่ 2.3 ตัวชี้วัดที่ควรรายงาน

| ตัวชี้วัด | ความหมาย                                       | การใช้ในโครงการ   |
|-----------|------------------------------------------------|-------------------|
| Accuracy  | สัดส่วนการทำนายถูกทั้งหมด                      | ภาพรวมของชุดทดสอบ |
| Precision | เมื่อระบบทำนายเป็นคลาสหนึ่ง มีสัดส่วนถูกเท่าใด | ตรวจการทำนายเกิน  |

| ตัวชี้วัด        | ความหมาย                                   | การใช้ในโครงการ    |
|------------------|--------------------------------------------|--------------------|
| Recall           | ตัวอย่างจริงของคลาสหนึ่งถูกพบเท่าใด        | ตรวจการพลาดคลาส    |
| F1-score         | ค่าเฉลี่ยฮาร์โมนิกของ precision และ recall | เปรียบเทียบรายคลาส |
| Confusion matrix | จำนวนจริงและทำนายของทุกคู่คลาส             | ค้นหาจุดที่สับสน   |

## 2.10 การประมวลผลแบบเวลาจริงและเสียงพูด

ขณะใช้งาน ระบบเก็บคุณลักษณะล่าสุดในคิว 30 เฟรม เมื่อคิวเต็มจึงคำนวณความน่าจะเป็นของทุกคลาส รับเฉพาะผลที่มีค่าน้อย 0.40 และใช้ผลย้อนหลัง 3 ครั้งเพื่อเลือกคลาสที่พบมากที่สุด หากไม่พบมือเกิน 0.4 วินาที ระบบล้างคิวและสถานะ การประมวลผลนี้ช่วยลดการสั่นของหน้าจอ แต่ไม่ได้แทนการประเมินความถูกต้องของโมเดล

ผลลัพธ์สามารถเพิ่มเป็นประโยคด้วยแป้นพิมพ์และส่งให้ gTTS สร้างเสียงภาษาไทย โดย pygame เล่นไฟล์เสียงที่สร้างชั่วคราว TTS เป็นช่องทางนำเสนอผล ไม่ได้มีส่วนในการรู้จำท่าทาง และต้องใช้อินเทอร์เน็ตในขณะที่สร้างเสียงตามการติดตั้งปัจจุบัน

## 2.11 งานและแนวคิดที่เกี่ยวข้อง

ตารางที่ 2.4 งานและแนวคิดที่เกี่ยวข้อง

| แหล่งอ้างอิง             | ประเด็นสำคัญ                                      | ความสัมพันธ์กับ HandVox                   |
|--------------------------|---------------------------------------------------|-------------------------------------------|
| Cortes & Vapnik (1995)   | หลักการ Support Vector Networks                   | ฐานของตัวจำแนก SVM                        |
| Zhang et al. (2020)      | การติดตามโครงร่างมือ 21 จุดแบบเวลาจริง            | ฐานของคุณลักษณะมือ                        |
| Yu et al. (2022)         | ทบทวนงานรู้จำระดับท่าทาง คำแยก และประโยคต่อเนื่อง | ใช้กำหนดขอบเขตการกล่าวอ้าง                |
| Sarhan & Frintrop (2023) | สำรวจการรู้จำภาษามือแบบแยกคำและชุดข้อมูล          | ใช้วิเคราะห์ข้อจำกัดด้านผู้ทำท่าและข้อมูล |

| แหล่งอ้างอิง                | ประเด็นสำคัญ                                     | ความสัมพันธ์กับ HandVox                                   |
|-----------------------------|--------------------------------------------------|-----------------------------------------------------------|
| Chalotonpised et al. (2026) | ชุดข้อมูลภาษามือไทยระดับคำจากหลายผู้ทำท่า        | ใช้เปรียบเทียบขนาดข้อมูลและการทดสอบแบบ signer-independent |
| Google AI Edge (n.d.)       | MediaPipe Holistic สำหรับจู่ร่างกายใบหน้า และมือ | กระบวนการตรวจหาจุดของระบบ                                 |

งาน TSL-ONE-S รายงานชุดข้อมูลภาษามือไทยระดับคำ 4,152 วิดีโอ ครอบคลุม 184 คำจากผู้ทำท่า 29 คน และประเมินแบบแยกผู้ทำท่า (signer-independent) (Chalotonpised et al., 2026) งานดังกล่าวชี้ให้เห็นความสำคัญของความหลากหลายด้านบุคคลและสภาพแวดล้อม

ดังนั้นชุดข้อมูล 90 คลิปจาก 3 ท่าของ HandVox ควรถูกอธิบายว่าเป็นชุดข้อมูลต้นแบบภายในโครงการ ไม่ใช่หลักฐานความสามารถทั่วไปของระบบ

## 2.12 ความน่าเชื่อถือ จริยธรรม และการเข้าถึง

ข้อมูลท่าทางอาจเกี่ยวข้องกับอัตลักษณ์ การเคลื่อนไหว และสภาพแวดล้อมของผู้ให้ข้อมูล การเก็บข้อมูลจากบุคคลจึงควรแจ้งวัตถุประสงค์ ขอความยินยอม จำกัดการใช้ และเก็บเฉพาะข้อมูลที่จำเป็น โครงการปัจจุบันจัดเก็บจุดสำคัญและป้ายกำกับในไฟล์ NPZ ไม่ได้บันทึกวิดีโอต้นฉบับเป็นชุดข้อมูล

แต่ภาพจากกล้องยังถูกประมวลผลในหน่วยความจำระหว่างเก็บและใช้งาน

ระบบควรรายงานข้อจำกัดอย่างชัดเจน

ไม่อ้างว่าสามารถแทนค่าหรือรองรับภาษามือไทยทั้งหมด

และควรประเมินกับผู้ใช้งานหลายคนก่อนใช้งานจริง การออกแบบส่วนติดต่อควรแสดงผลที่อ่านง่าย มีทางเลือกข้อความเมื่อเสียงใช้ไม่ได้ และให้ผู้แก้ไขหรือลบคำที่ระบบทำนายผิด

## 2.13 บทสรุป

HandVox เป็นระบบรู้จำท่าทางภาษามือแบบแยกคำจากลำดับ 30 เฟรม โดยใช้ MediaPipe Holistic สกัด 171 คุณลักษณะต่อเฟรม ปรับมาตรฐานด้วยตำแหน่งและระยะใกล้ เรียงเป็นเวกเตอร์ 5,130 คำ และจำแนกด้วย SVM แบบ RBF

แนวทางนี้เหมาะกับต้นแบบข้อมูลขนาดเล็กและตรวจสอบกระบวนการได้ง่าย

แต่ยังต้องควบคุมการรั่วไหลของข้อมูล

ทดสอบกับผู้ทำท่าและสภาพแวดล้อมใหม่

และจำกัดการกล่าวอ้างให้ตรงกับการรู้จำแบบแยกคำ

## รายการอ้างอิงของบท

- Bradski, G. (2000). The OpenCV Library. Dr. Dobb's Journal of Software Tools.
- Cortes, C., & Vapnik, V. (1995). Support-vector networks. Machine Learning, 20, 273–297. <https://doi.org/10.1007/BF00994018>
- Chalotompised, J., Chen, W. H., Vijitkunsawat, W., & Lin, Y. C. (2026). TSL-ONE-S: A real-world Thai sign language dataset with deep learning benchmarks. IEEE Access, 14, 37845–37870. <https://doi.org/10.1109/ACCESS.2026.3670970>
- Google AI Edge. (n.d.). Holistic landmarks detection task guide. Retrieved August 1, 2026, from [https://developers.google.com/edge/mediapipe/solutions/vision/holistic\\_landmarker](https://developers.google.com/edge/mediapipe/solutions/vision/holistic_landmarker)
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12(85), 2825–2830.
- Sarhan, N., & Frintrop, S. (2023). Unraveling a decade: A comprehensive survey on isolated sign language recognition. Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops, 3210–3219. [https://openaccess.thecvf.com/content/ICCV2023W/AMFG/html/Sarhan\\_Unraveling\\_a\\_Decade\\_A\\_Comprehensive\\_Survey\\_on\\_Isolated\\_Sign\\_Language\\_ICCVW\\_2023\\_paper.html](https://openaccess.thecvf.com/content/ICCV2023W/AMFG/html/Sarhan_Unraveling_a_Decade_A_Comprehensive_Survey_on_Isolated_Sign_Language_ICCVW_2023_paper.html)
- Sokolova, M., & Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. Information Processing & Management, 45(4), 427–437. <https://doi.org/10.1016/j.ipm.2009.03.002>
- Yu, M., Jia, J., Xue, C., Yan, G., Guo, Y., & Liu, Y. (2022). A review of sign language recognition research. Journal of Intelligent & Fuzzy Systems, 43(4), 3879–3898. <https://doi.org/10.3233/JIFS-210050>
- Zhang, F., Bazarevsky, V., Vakunov, A., Tkachenka, A., Sung, G., Chang, C.-L., & Grundmann, M. (2020). MediaPipe Hands: On-device real-time hand tracking. arXiv:2006.10214. <https://doi.org/10.48550/arXiv.2006.10214>