

บทที่ 3

วิธีดำเนินการและการออกแบบระบบ

บทนี้อธิบายวิธีพัฒนา HandVox ตามซอร์สโค้ด ชุดข้อมูล

และไฟล์แบบจำลองของโครงการปัจจุบัน

ตั้งแต่การวิเคราะห์ความต้องการจนถึงการทดสอบและควบคุมคุณภาพ โดยมีหัวข้อดังนี้

- 3.1 รูปแบบการดำเนินโครงการ
- 3.2 การวิเคราะห์ความต้องการ
- 3.3 สถาปัตยกรรมระบบ
- 3.4 การสร้างและจัดเก็บชุดข้อมูล
- 3.5 การสกัดและปรับมาตรฐานคุณลักษณะ
- 3.6 สถานะชุดข้อมูลปัจจุบัน
- 3.7 การฝึกแบบจำลอง
- 3.8 การทำงานแบบเวลาจริง
- 3.9 ส่วนติดต่อผู้ใช้และการแปลงข้อความเป็นเสียง
- 3.10 แผนการประเมินผล
- 3.11 การควบคุมคุณภาพและจริยธรรมข้อมูล
- 3.12 บทสรุป

3.1 รูปแบบการดำเนินโครงการ

โครงการใช้รูปแบบการวิจัยและพัฒนาเชิงทดลอง ประกอบด้วย การกำหนดข้อกำหนด การออกแบบสถาปัตยกรรม การพัฒนาซอฟต์แวร์ การสร้างชุดข้อมูลที่มีป้ายกำกับ การฝึกและประเมินแบบจำลอง และการทดสอบการใช้งานแบบเวลาจริง การตัดสินใจทุกชั้นอ้างอิงจากไฟล์โปรแกรมเพื่อให้ตรวจสอบย้อนกลับได้

3.2 การวิเคราะห์ความต้องการ

รหัส	ความต้องการ	เกณฑ์ตรวจสอบ
FR-01	รับภาพจากเว็บแคมและตรวจหาช่วงบนกับมือ	เมื่อพบ pose และมืออย่างน้อยหนึ่งข้างจึงสร้างคุณลักษณะ
FR-02	เก็บคลิปท่าที่มีป้ายกำกับ	หนึ่งคลิปมี 30 เฟรม พร้อมบันทึกท่า ผู้ทำท่า และเซสชันใน Dataset V2
FR-03	ฝึกตัวจำแนกหลายคลาส	มืออย่างน้อย 2 ท่าและจำนวนคลิปขั้นต่ำครบ
FR-04	รู้จำแบบเวลาจริง	แสดงชื่อท่าและค่าความเชื่อมั่นเมื่อผ่านเกณฑ์
FR-05	จัดการคำและเสียง	เพิ่ม/ลบ/ล้างคำ และอ่านออกเสียงได้เมื่อ TTS พร้อม
FR-06	จัดการท่าที่ผู้ใช้เพิ่ม	เพิ่ม ลบ สำรองข้อมูล และฝึกใหม่ได้จากเมนู

ตารางที่ 3.1 ความต้องการเชิงหน้าที่

รหัส	ความต้องการที่ไม่ใช่เชิงหน้าที่	แนวทาง
NFR-01	ความสอดคล้องของข้อมูล	ใช้ฟังก์ชัน extract_features เดียวกันระหว่างเก็บและทำนาย
NFR-02	การทำซ้ำ	ใช้ random_state=42 และบันทึกเวอร์ชันไลบรารี
NFR-03	ความเป็นส่วนตัว	บันทึกเฉพาะคุณลักษณะและป้ายกำกับ ไม่บันทึกวิดีโอเป็นชุดข้อมูล

รหัส	ความต้องการที่ไม่ใช่เชิงหน้าที่	แนวทาง
NFR-04	ความทนทาน	ล้างสถานะเมื่อไม่พบมือ และสำรองข้อมูลก่อนลบหรือรีเซ็ต

ตารางที่ 3.2 ความต้องการที่ไม่ใช่เชิงหน้าที่

3.3 สถาปัตยกรรมระบบ

สถาปัตยกรรมการทำงานของ HandVox



ใช้คุณลักษณะรูปทรงและการเคลื่อนไหวที่กำหนดไว้ล่วงหน้า ไม่ใช้การแปลภาษาหรือการถอดเสียง

ภาพที่ 3.1 สถาปัตยกรรมการประมวลผลของ HandVox

สถาปัตยกรรมแบ่งเป็น 6 ส่วน ได้แก่ การรับภาพ การตรวจหาจุด การปรับมาตรฐาน การสะสมลำดับ 30 เฟรม การจำแนกด้วย SVM และการนำเสนอผล กระบวนการเก็บข้อมูลและกระบวนการใช้งานจริงเรียกใช้ `body_features.extract_features` ร่วมกัน จึงลดความเสี่ยงที่รูปแบบคุณลักษณะระหว่างฝึกและทำนายไม่ตรงกัน

ไฟล์	หน้าที่หลัก	ข้อมูลเข้า/ออก
<code>body_features.py</code>	สกัด 171 คุณลักษณะและกรอบช่วงบน	MediaPipe results → feature vector
<code>sequence_dataset.py</code>	จัดเก็บและจัดการคลิป	<code>gesture_sequences.npz</code>
<code>collect_data.py</code>	เปิดกล้องและเก็บคลิปตามป้ายกำกับ	30 เฟรม → 1 คลิป
<code>train_model.py</code>	แบ่งข้อมูล ฝึก SVM และบันทึกโมเดล	NPZ → model/labels PKL
<code>run_detector.py</code>	ทำนายแบบเวลาจริงและแสดงผล	30 เฟรมล่าสุด → คำ/เสียง
<code>gesture_config.py</code>	โหลดชื่อ คำอธิบาย และสีของท่า	<code>custom_gestures.json</code>

ตารางที่ 3.3 องค์ประกอบซอฟต์แวร์

3.4 การสร้างและจัดเก็บชุดข้อมูล

ผู้ใช้เพิ่มชื่อท่าและคำอธิบายผ่าน `add_gesture.py` จากนั้น `collect_data.py` เปิดกล้องที่ตั้งค่าความละเอียด 1280×720 พิกเซล กลับภาพแนวนอน และใช้ MediaPipe Holistic ประมวลผลเฟรม เมื่อผู้ใช้กด Space โปรแกรมนับถอยหลังและเก็บเฉพาะเฟรมที่ `extract_features` คำนวณครบ จนครบ 30 เฟรมจึงบันทึกเป็นหนึ่งคลิป

`sequence_dataset.py` จัดเก็บชุดรวมใน `gesture_sequences.npz` เป็นอาร์เรย์ชนิด float32 รูปร่าง (จำนวนคลิป, 30, 171) และเก็บป้ายกำกับเป็นข้อความ ส่วน Dataset V2 จัดเก็บลำดับ .npy วิดีโอตัวอย่าง .mp4 และ metadata เช่น ผู้ทำท่า เซสชัน เวลา และสถานะคุณภาพ เพื่อรองรับการตรวจสอบย้อนหลัง หากพบข้อมูลโครงสร้างเก่า ระบบจะสำรองไว้ก่อนเปลี่ยนแปลง

ข้อควมคุมการเก็บข้อมูล: ควรเริ่มและจบท่าภายในคลิปทุกครั้ง จัดให้เห็นไหล่และมืออย่างน้อยหนึ่งข้าง และเก็บความหลากหลายด้านผู้ทำท่า แสง ระยะ มุม และความเร็วโดยไม่เปลี่ยนความหมายของท่า



ภาพที่ 3.2 ตัวอย่างหน้าจอเก็บคลิปท่าทางของ HandVox

3.5 การสกัดและปรับมาตรฐานคุณลักษณะ

ระบบเลือกจุด pose หมายเลข 0, 2, 5, 7–16, 23 และ 24 รวม 15 จุด พร้อมมือซ้ายและขวาข้างละ 21 จุด แต่ละจุดมีพิกัด x, y และ z รวม 171 ค่า หากไม่พบ pose หรือไม่พบมือทั้งสองข้างจะไม่รับเฟรมนั้น หากพบเพียงมือเดียวจะเติมศูนย์แทนมือที่หาย

ให้ c เป็นจุดกึ่งกลางระหว่างไหล่ซ้ายและขวา และ s เป็นระยะยุคลิดระหว่างไหล่ ระบบคำนวณพิกัดมาตรฐานของทุกจุดด้วย $p'_i = (p_i - c) / \max(s, 10^{-6})$ จากนั้นเรียงคุณลักษณะตามลำดับ pose มือซ้าย และมือขวา การใช้จุดและลำดับเดียวกันในทุกไฟล์เป็นเงื่อนไขสำคัญของความถูกต้อง

3.6 สถานะชุดข้อมูลปัจจุบัน

การตรวจสอบไฟล์ gesture_sequences.npz ณ วันที่ 16 สิงหาคม 2569 พบข้อมูล 350 คลิป รูปร่างอาร์เรย์ (350, 30, 171) ชนิด float32 และ 16 ป้ายกำกับ จำนวนต่อคลาสไม่เท่ากันตั้งแต่ 10–30 คลิป ดังตารางที่ 3.4 นอกจากนี้ Dataset V2 มี 230 คลิปที่สถานะ accepted จากผู้ทำท่า 2 รหัสและ 2 เซสชัน ส่วนข้อมูลฐานเดิม 120 คลิปยังไม่มี metadata ระดับผู้ทำท่าและเซสชัน

กลุ่มป้ายกำกับ	จำนวนต่อท่า	รวมคลิป	สถานะข้อมูล
ขอบคุณ, ขอโทษ, สวัสดี, ไม่เป็นไร	30	120	ข้อมูลฐานเดิม; ไม่มี metadata รายคลิป
กิน, ช่วยด้วย, ต้องการ, น้ำ, หมอ, หยุด, ห้องน้ำ, เข้าใจ, เจ็บ, ใช่, ไม่เข้าใจ	20	220	Dataset V2; accepted
ไม่ใช่	10	10	Dataset V2; accepted
รวม 16 ป้ายกำกับ	10–30	350	30 เฟรม $\times$ 171 ค่าต่อคลิป

ตารางที่ 3.4 ผลการตรวจสอบชุดข้อมูลปัจจุบัน

จำนวนดังกล่าวเพียงพอสำหรับทดลองตัวจำแนกต้นแบบ

แต่ยังไม่เพียงพอสำหรับสรุปความสามารถทั่วไป เพราะข้อมูลฐานเดิมขาด metadata และ Dataset V2 ยังมีผู้ทำท่าเพียง 2 รหัส จำนวนคลิปต่อคลาสไม่สมดุล และยังไม่มีการทดสอบภายนอก

3.7 การฝึกแบบจำลอง

กระบวนการทดลองตรวจสอบรายชื่อป้ายกำกับและมิติข้อมูล ใช้ LabelEncoder

แปลงชื่อท่าเป็นรหัสจำนวนเต็ม เรียงเมทริกซ์ 30×171 เป็นเวกเตอร์ 5,130 ค่า และแบ่งข้อมูลแบบ stratified holdout 80:20 เพื่อคัดกรองเบื้องต้น

การตั้งค่าโครงการกำหนดเป้าหมายมาตรฐานไว้เป็น leave-one-signer-out

เมื่อมีข้อมูลผู้ทำท่าครบสำหรับทุกคลาส

รายการ	ค่าที่ใช้	ผลจากข้อมูลปัจจุบัน
จำนวนข้อมูล	350 คลิป	16 คลาส; 10–30 คลิปต่อคลาส
การแบ่งข้อมูลรอบปัจจุบัน	80:20 แบบ stratified	ฝึก 280 คลิป; ทดสอบ 70 คลิป
ตัวจำแนก	SVC	หลายคลาสผ่าน scikit-learn
Kernel	RBF	ขอบเขตไม่เชิงเส้น
C	10	ค่าคงที่ตามซอร์สโค้ด
gamma	scale	คำนวณจากจำนวนคุณลักษณะและความแปรปรวน
probability	True	ใช้ predict_proba ในเวลาจริง
class_weight	balanced	ถ่วงน้ำหนักตามจำนวนตัวอย่างแต่ละคลาส
ไฟล์ผลลัพธ์	gesture_model.pkl, gesture_labels.pkl	แบบจำลองและตัวเข้ารหัสป้ายกำกับ

ตารางที่ 3.5 การตั้งค่าการฝึก

3.8 การทำงานแบบเวลาจริง

- 1) โหลด `gesture_model.pkl` และ `gesture_labels.pkl` และตรวจว่ารายชื่อคลาสตรงกับ `gesture_config.py`
- 2) เปิด MediaPipe Holistic และเว็บแคม
จากนั้นสกัดคุณลักษณะของทุกเฟรมที่ผ่านเงื่อนไข
- 3) สะสมคุณลักษณะล่าสุด 30 เฟรมใน `motion_frames` และเรียงเป็นเวกเตอร์ 5,130 ค่า
- 4) คำนวณ `predict_proba` เลือกคลาสที่มีค่าสูงสุด
และรับผลเมื่อค่าความเชื่อมั่นไม่น้อยกว่า 0.40
- 5) เก็บผลย้อนหลัง 3 ครั้ง เลือกคลาสที่พบมากที่สุด และเฉลี่ยค่าความเชื่อมั่นของคลาสนั้น
- 6) ล้างคิวและสถานะเมื่อไม่พบมีอนานกว่า 0.4 วินาที เพื่อลดการค้างของคำทำนายเดิม
- 7) แสดงกรอบ ชื่อท่า ค่าความเชื่อมั่น ประโยค และสถานะเสียงบนหน้าจอ

3.9 ส่วนติดต่อผู้ใช้และการแปลงข้อความเป็นเสียง

ปุ่ม	การทำงาน	ข้อควบคุม
Space	เพิ่มคำที่ยืนยันแล้วลงในประโยค	หน่วยอย่างน้อย 1 วินาทีระหว่างการเพิ่ม
Backspace	ลบคำล่าสุด	ทำงานเมื่อประโยคไม่ว่าง
Enter	ล้างประโยค	ลบรายการคำทั้งหมด
S	อ่านประโยค	ทำงานเมื่อมีข้อความและ TTS พร้อม
Esc	ออกจากโปรแกรม	คืนกล้องและปิดหน้าต่าง

ตารางที่ 3.6 ปุ่มควบคุมขณะตรวจจับ

ระบบยังอ่านชื่อท่าอัตโนมัติเมื่อท่าเดียวกันถูกยืนยันต่อเนื่องครบ 1 วินาที และอนุญาตให้พูดซ้ำหลังผู้ใช้เอามือออกจากระบบรีเซ็ต

การสร้างเสียงทำในเรดแยกเพื่อไม่ให้วงรอบภาพหยุดรอจนเสียงเล่นจบ

3.10 แผนการประเมินผล

3.10.1 การประเมินภายในชุดข้อมูล

- 1) รายงาน accuracy บนชุดทดสอบ 70 คลิป พร้อมจำนวนที่ทำนายถูกและผิด
- 2) รายงาน confusion matrix, precision, recall และ F1-score รายคลาส รวมทั้ง macro average
- 3) บันทึกเวอร์ชันข้อมูล รายชื่อคลาส random_state และเวลาที่ฝึก เพื่อทำซ้ำผลได้

สถานะผลประเมิน: การทดลองถ้วนล่าสุดใช้ stratified holdout 80:20 บนข้อมูล 350 คลิป ได้ Accuracy 94.29% และ Macro F1 93.75% ผลนี้ใช้คัดกรองเบื้องต้นเท่านั้น เพราะข้อมูลฐานเดิมขาด metadata และยังไม่ใช้การประเมินแบบแยกผู้ทำท่า

3.10.2 การประเมินกับข้อมูลภายนอก

ก่อนสรุปว่าระบบใช้ได้กับผู้ใช้ทั่วไป

ควรสร้างชุดทดสอบที่แยกตามผู้ให้ข้อมูลและรอบการเก็บ

โดยไม่ให้คลิปของบุคคลหรือเซสชันทดสอบอยู่ในชุดฝึก ควรทดสอบแสง ฉากหลัง ระยะ มุมกล้อง ความเร็ว มือข้างเดียวและสองข้าง และบันทึกเวลาแฝงตั้งแต่รับภาพจนแสดงผล

3.10.3 การทดสอบเชิงหน้าที่

กรณีทดสอบ	ผลที่คาดหวัง
ไม่พบ pose หรือมือ	ไม่เพิ่มเฟรมและไม่ทำนาย
คลิปของท่าไม่ครบ 30	ไม่อนุญาตให้ฝึกและแจ้งรายชื่อท่าที่ยังไม่ครบ
มีเพียง 1 คลาส	ไม่ฝึกตัวจำแนกหลายคลาส
โมเดลไม่ตรงกับรายการท่า	หยุดและแจ้งให้ฝึกใหม่
ความเชื่อมั่นต่ำกว่า 0.40	ไม่ยืนยันชื่อท่า
ไม่พบมือนานกว่า 0.4 วินาที	ล้างคิว สถานะ และตัวจับเวลาพูด

กรณีทดสอบ	ผลที่คาดหวัง
TTS ใช้งานไม่ได้	ระบบรู้จำยังทำงานและแสดงข้อความได้

ตารางที่ 3.7 กรณีทดสอบเชิงหน้าที่

3.11 การควบคุมคุณภาพและจริยธรรมข้อมูล

- 1) ใช้คำอธิบายท่าและป้ายกำกับที่ไม่ซ้ำ ตรวจสอบการสะกดก่อนเก็บ และฝึกใหม่ทุกครั้งเมื่อเปลี่ยนรายการท่า
- 2) เก็บ metadata ของผู้ให้ข้อมูล เซสชัน สภาพแสง ระยะ และกล้องในรุ่นถัดไป เพื่อรองรับการแบ่งข้อมูลแบบกลุ่ม
- 3) ขอความยินยอมจากผู้ให้ข้อมูล ระบุวัตถุประสงค์ ระยะเวลาเก็บ และสิทธิในการถอนข้อมูล
- 4) ไม่ใช่ค่าความเชื่อมั่นแทนหลักฐานความถูกต้อง และไม่ใช้ระบบในบริบทสำคัญโดยไม่มีการยืนยันจากมนุษย์
- 5) รายงานจำนวนผู้ให้ข้อมูลและเงื่อนไขการทดสอบในบทที่ 4 เพื่อให้ผู้อ่านประเมินความสามารถทั่วไปของผลได้

3.12 บทสรุป

HandVox ใช้ MediaPipe Holistic สกัด 171 คุณลักษณะต่อเฟรม เก็บ 30 เฟรมเป็นเวกเตอร์ 5,130 ค่า และฝึก SVM แบบ RBF ข้อมูลปัจจุบันมี 350 คลิปจาก 16 ท่า การทดลองดาวน์แบ่งฝึก 280 คลิปและทดสอบ 70 คลิป แต่ยังเป็น holdout ระดับคลิป
จึงต้องประเมินแบบแยกผู้ทำท่าและสภาพแวดล้อมใหม่ก่อนสรุปการใช้งานจริง