

บทที่ 2

ความรู้พื้นฐานและงานวิจัยที่เกี่ยวข้อง

บทนี้รวบรวมแนวคิดทฤษฎีและเทคโนโลยีที่เกี่ยวข้องกับการพัฒนาระบบ Hand Sign Translator-TH

ซึ่งเป็นต้นแบบระบบรู้จำท่ามือผ่านกล้องเว็บแคมและแสดงผลเป็นคำภาษาไทยแบบเวลาจริงเนื้อหาทุกส่วนอ้างอิงจากขอบเขตที่ตรวจสอบได้จากซอร์สโค้ดชุดข้อมูลและผลการทดลองของโครงการเพื่อให้การนำเสนอมีความสอดคล้องกับสิ่งที่ระบบทำได้จริง

แนวคิดหลักของระบบคือการรับภาพจากกล้องตรวจหาตำแหน่งจุดสำคัญของมือแปลงตำแหน่งดังกล่าวเป็นตัวเลขและจำแนกตัวเลขด้วยแบบจำลองการเรียนรู้ของเครื่องจากนั้นจึงแสดงชื่อคำที่ระบบทำนายและอาจอ่านออกเสียงภาษาไทยได้การศึกษาความรู้พื้นฐานในบทนี้จึงครอบคลุมความหมายของขอบเขตการสื่อสารด้วยท่ามือการมองเห็นด้วยคอมพิวเตอร์ MediaPipe Hands การสกัดคุณลักษณะ SVM การแสดงผลเวลาจริงและเกณฑ์ประเมินผล

- 2.1 การสื่อสารด้วยท่ามือและขอบเขตของระบบ
- 2.2 การมองเห็นด้วยคอมพิวเตอร์สำหรับการรู้จำท่ามือ
- 2.3 MediaPipe Hands และจุดโครงร่างมือ
- 2.4 การสกัดและการปรับมาตรฐานคุณลักษณะ
- 2.5 การเรียนรู้ของเครื่องด้วย Support Vector Machine
- 2.6 การแสดงผลแบบเวลาจริงและการแปลงข้อความเป็นเสียง
- 2.7 เกณฑ์การประเมินผลการจำแนก
- 2.8 งานและแนวคิดที่เกี่ยวข้อง
- 2.9 บทสรุป

2.1 การสื่อสารด้วยท่ามือและขอบเขตของระบบ

การสื่อสารด้วยท่ามือเป็นการสื่อสารเชิงภาพที่อาศัยองค์ประกอบหลายด้านร่วมกันได้แก่ รูปมือตำแหน่งของมือทิศทางฝ่ามือการเคลื่อนไหวสีหน้าและบริบทของข้อความความหมายของการสื่อสารจึงไม่ได้ขึ้นกับการยกมือเป็นรูปหนึ่งรูปเพียงอย่างเดียวผู้พัฒนาระบบที่เกี่ยวข้องกับท่ามือจำเป็นต้องระบุขอบเขตให้ชัดว่าระบบรองรับองค์ประกอบใดและไม่รองรับองค์ประกอบใดเพื่อป้องกันการตีความผลลัพธ์เกินกว่าความสามารถจริงของแบบจำลอง

โครงการ Hand Sign Translator-TH

กำหนดขอบเขตเป็นการรู้จำท่ามือแบบสถิตที่กำหนดไว้ล่วงหน้าหรือ predefined hand gestures ระบบรับภาพสีจากกล้องเว็บแคมตรวจหามือหนึ่งข้างและทำนายชื่อป้ายกำกับจากลักษณะจุดโครงร่างมือในเฟรมปัจจุบันผลลัพธ์ถูกนำเสนอเป็นข้อความภาษาไทยบนหน้าจอและรองรับการอ่านออกเสียงเมื่อสภาพแวดล้อมของโปรแกรมพร้อมใช้งานแนวทางนี้เหมาะกับการสาธิตการประยุกต์ใช้ปัญญาประดิษฐ์เพื่อช่วยสื่อสารระดับคำ

ดังนั้นผลลัพธ์ของระบบควรเรียกว่า “การจำแนกท่ามือที่ระบบรองรับ” มากกว่าการแปลภาษาไทยแบบสมบูรณ์ระบบยังไม่วิเคราะห์ลำดับของการเคลื่อนไหวต่อเนื่องมือสองข้างสีหน้าหรือโครงสร้างประโยคและไม่ควรใช้แทนล่ามภาษามือในสถานการณ์ที่ต้องอาศัยความถูกต้องด้านภาษาความปลอดภัยหรือสิทธิของผู้สื่อสารการระบุข้อจำกัดนี้เป็นส่วนสำคัญของความรับผิดชอบในการพัฒนาระบบช่วยสื่อสาร

2.2 การมองเห็นด้วยคอมพิวเตอร์สำหรับการรู้จำท่ามือ

การมองเห็นด้วยคอมพิวเตอร์หรือ Computer Vision

คือการใช้โปรแกรมประมวลผลข้อมูลจากภาพและวิดีโอเพื่อสกัดสารสนเทศที่คอมพิวเตอร์นำไปใช้ตัดสินใจได้ในโครงการนี้กล้องเว็บแคมทำหน้าที่เป็นอุปกรณ์รับข้อมูลภาพส่วนโปรแกรมใช้ OpenCV เพื่ออ่านเฟรมจากกล้องกลับภาพในแนวนอนและแสดงผลบนหน้าจอภาพแต่ละเฟรมจะถูกส่งต่อไปยังขั้นตอนตรวจจับจุดมือก่อนเข้ากระบวนการจำแนก

แทนที่จะส่งภาพดิบทั้งหมดให้ตัวจำแนกระบบเลือกใช้ตำแหน่งจุดโครงร่างของมือเป็นตัวแทนข้อมูลวิธีนี้ทำให้ข้อมูลนำเข้ามีจำนวนค่าน้อยลงและสื่อถึงรูปทรงสัมผัสของนิ้วมือได้โดยตรงชุดคุณลักษณะดังกล่าวช่วยลดผลกระทบบางส่วนจากรายละเอียดที่ไม่จำเป็นของภาพเช่นพื้นหลังหรือสีของวัตถุรอบตัวผู้ใช้ อีกทั้งยังช่วยให้ลำดับการทำงานของระบบอธิบายและตรวจสอบได้ง่ายกว่าการใช้ภาพดิบทั้งหมด

อย่างไรก็ตามการมองเห็นด้วยคอมพิวเตอร์ยังขึ้นอยู่กับคุณภาพของภาพจากกล้องหากมืออยู่ไกลเกินไปมีเงาบังแสงไม่เพียงพอ นิ้วถูกบังหรือหันมือในมุมที่ต่างจากข้อมูลฝึกระบบอาจตรวจจับจุดมีหรือจำแนกทำได้ไม่ดีเท่าเดิมด้วยเหตุนี้การเก็บข้อมูลให้ครอบคลุมหลายสภาพแสงหลายระยะและหลายมุมมองจึงเป็นปัจจัยสำคัญต่อการนำระบบไปใช้งานจริง

2.3 MediaPipe Hands และจุดโครงร่างมือ

MediaPipe Hands

เป็นกระบวนการติดตามมือแบบเวลาจริงที่ใช้ตัวตรวจหาบริเวณฝ่ามือร่วมกับแบบจำลองทำนายจุดสำคัญของมือจากภาพ RGB

แนวทางนี้ช่วยให้โปรแกรมสามารถรับรู้โครงสร้างของมือได้โดยไม่ต้องกำหนดตำแหน่งนิ้วด้วยมือทุกเฟรมงานของ Zhang

และคณะ(2020)อธิบายแนวคิดของการติดตามมือบนอุปกรณ์ที่ต้องการความเร็วซึ่งเป็นพื้นฐานที่สอดคล้องกับลักษณะการทำงานของโครงงานนี้

ในซอร์สโค้ดของ Hand Sign Translator-TH กำหนด `static_image_mode` เป็น `False` เพื่อรองรับข้อมูลวิดีโอ กำหนด `max_num_hands` เป็น 1

เพื่อให้ตรวจจับมือครั้งละหนึ่งข้างและใช้ค่า `min_detection_confidence` กับ

`min_tracking_confidence` เท่ากับ 0.85


เพื่อคัดกรองผลตรวจจับที่มีความมั่นใจต่ำนอกจากนี้กำหนด `model_complexity` เป็น 1

ซึ่งเป็นค่าที่เลือกใช้สำหรับการติดตามมือของระบบต้นแบบ

เมื่อระบบตรวจพบมือ MediaPipe Hands จะคืนค่าจุดสำคัญทั้งหมด 21 จุดแต่ละจุดมีพิกัด `x,y` และ `z`

จุดเหล่านี้ครอบคลุมบริเวณข้อมือข้อมือข้อมือและปลายนิ้วจึงสามารถใช้บรรยายความสัมพันธ์ของนิ้วมือในแต่ละท่าได้ข้อมูลจาก 21 จุดรวมกันให้คุณลักษณะ 63

ค่าและถูกใช้เป็นข้อมูลนำเข้าของขั้นตอนปรับมาตรฐานและตัวจำแนก SVM ในหัวข้อถัดไป



ภาพที่ 2.1 จุดสำคัญของมือ 21 จุดที่ใช้ในการประมวลผล

2.4 การสกัดและการปรับมาตรฐานคุณลักษณะ

พิกัดของจุดมือเปลี่ยนไปตามตำแหน่งที่ผู้ใช้ยกมือระยะจากกล้องและขนาดมือของแต่ละบุคคลหากนำพิกัดไปฝึกโดยตรงโมเดลอาจเรียนรู้ความแตกต่างจากตำแหน่งหรือขนาดแทนที่จะเรียนรู้รูปทรงของท่ามือโครงการจึงมีขั้นตอนปรับมาตรฐานคุณลักษณะก่อนบันทึกข้อมูลและก่อนทำนายผลเพื่อให้ข้อมูลในสองช่วงมีรูปแบบเดียวกัน

วิธีที่ใช้กำหนด landmark0

ซึ่งเป็นจุดข้อมือให้เป็นจุดอ้างอิงจากนั้นนำพิกัดของทุกจุดลบด้วยพิกัดข้อมือและหารด้วยระยะระหว่าง landmark0 กับ landmark9

พร้อมเพิ่มค่าขนาดเล็กเพื่อป้องกันการหารด้วยศูนย์เขียนเป็นแนวคิดได้ว่า


$$p_i = (p_i - p_0) / (\|p_9 - p_0\| + \epsilon)$$
 ขั้นตอนนี้ทำให้ตำแหน่งที่เลื่อนทั้งมือและการย่อขยายมือมีผลต่อเวกเตอร์ลดลง

หลังการปรับมาตรฐานระบบยังเก็บข้อมูล 63 ค่าเท่าเดิมคือ x,y และ z ของ 21

จุดแต่ค่าทั้งหมดแสดงความสัมพันธ์เชิงเรขาคณิตกับข้อมือและขนาดมือมากขึ้นเวกเตอร์ที่ได้ถูกบันทึกในไฟล์ gesture_data.csv พร้อม label

เพื่อใช้ฝึกโมเดลและฟังก์ชันปรับมาตรฐานเดียวกันถูกเรียกใช้ใน run_detector.py

ก่อนการทำนายเพื่อรักษาความสอดคล้องระหว่างข้อมูลฝึกและข้อมูลระหว่างใช้งาน



ภาพที่ 2.2 แนวคิดการสกัดและปรับมาตรฐานคุณลักษณะของมือ

2.5 การเรียนรู้ของเครื่องด้วย SupportVectorMachine

SupportVectorMachine หรือ SVM

เป็นวิธีการเรียนรู้แบบมีผู้สอนที่ใช้ข้อมูลพร้อมป้ายกำกับเพื่อสร้างขอบเขตการตัดสินใจระหว่างกลุ่มข้อมูลหลักการสำคัญคือการหาขอบเขตที่แยกกลุ่มได้เหมาะสมและสามารถใช้ kernel เพื่อจัดการความสัมพันธ์ที่ไม่เป็นเส้นตรงของข้อมูลได้ Cortes และ Vapnik(1995)เสนอ

แนวคิดของ Supportvectornetworks ซึ่งเป็นรากฐานสำคัญของการประยุกต์ใช้ SVM ในงานจำแนกประเภท

โครงงานนี้ใช้ SVC จากไลบรารี scikitlearn โดยตั้งค่า kernel เป็น radialbasisfunction หรือ RBF กำหนด C เท่ากับ 10 กำหนด gamma เป็น scale และเปิด probability=True เพื่อให้ระบบสามารถคำนวณค่าความน่าจะเป็นของคลาสได้ก่อนฝึกโมเดลระบบใช้ LabelEncoder แปลงชื่อ label ภาษาไทยให้เป็นรหัสตัวเลขและบันทึกทั้งโมเดลและตัวเข้ารหัสป้ายกำกับเป็นไฟล์ gesture_model.pkl และ gesture_labels.pkl

SVM เหมาะกับข้อมูลเชิงตัวเลขที่มีจำนวนคุณลักษณะไม่มากมากนักเช่นเวกเตอร์จุดมือ 63 ค่าและสามารถใช้จำแนกข้อมูลหลายคลาสผ่านกลไกของไลบรารีได้อย่างไรก็ตามประสิทธิภาพของ SVM

ไม่ได้ขึ้นกับชนิดของโมเดลเพียงอย่างเดียวแต่ขึ้นกับคุณภาพข้อมูลความถูกต้องของป้ายกำกับและควา

มคล้ายกันระหว่างข้อมูลที่ใช้ฝึกกับสถานการณ์ใช้งานจริงจึงต้องประเมินผลอย่างรอบคอบและไม่สรุปจากค่า accuracy เพียงค่าเดียว

2.6 การแสดงผลแบบเวลาจริงและการแปลงข้อความเป็นเสียง

ขั้นตอนการใช้งานของระบบเริ่มจากการเปิดกล้องรับภาพทีละเฟรมกลับภาพให้อยู่ในลักษณะกระจกตรวจหาจุดมือปรับมาตรฐานคุณลักษณะและส่งข้อมูลให้โมเดลทำนายหาค่าความน่าจะเป็นสูงสุดต่ำกว่าเกณฑ์ที่กำหนดระบบจะไม่ยืนยันคำทำนายในซอร์สโค้ดกำหนดเกณฑ์ความเชื่อมั่นขั้นต่ำไว้ที่ 0.40 เพื่อช่วยลดการแสดงคำจากผลทำนายที่ไม่มั่นใจ

เพื่อช่วยลดการสั่นของผลลัพธ์ในแต่ละเฟรมระบบเก็บผลทำนายล่าสุด 3 เฟรมแล้วเลือก label ที่พบมากที่สุดเป็นคำที่ยืนยันนอกจากนี้ระบบจะรีเซ็ตสถานะเมื่อไม่พบมือเกิน 0.4 วินาทีกลไกดังกล่าวไม่ใช้การเพิ่มความถี่ให้โมเดลแต่เป็นการจัดการลำดับผลทำนายเพื่อให้ข้อความที่ผู้ใช้เห็นมีความต่อเนื่องมากขึ้นระหว่างการยกมือค้างไว้หน้ากล้อง

ส่วนติดต่อผู้ใช้รองรับการต่อคำเป็นประโยคโดยปุ่ม Space ใช้เพิ่มคำปัจจุบัน Backspace ใช้ลบคำล่าสุด Enter ใช้ล้างประโยคและ S ใช้อ่านประโยคทั้งหมดระบบสามารถเรียก gTTS ร่วมกับ pygame เพื่อสร้างและเล่นเสียงภาษาไทยเมื่อผู้ใช้ค้างท่าที่ได้รับการยืนยันครบ 1

วินาทีอย่างไรก็ตามการสร้างเสียงด้วย gTTS

ต้องใช้อินเทอร์เน็ตตามการติดตั้งปัจจุบันจึงควรพิจารณาเงื่อนไขเครือข่ายเมื่อนำไปใช้งานจริง

2.7 เกณฑ์การประเมินผลการจำแนก

การประเมินตัวจำแนกหลายคลาสควรพิจารณาทั้งผลรวมและผลของแต่ละป้ายกำกับโครงานในใช้ accuracy เพื่อแสดงสัดส่วนการทำนายถูกทั้งหมดและใช้ confusion matrix เพื่อแสดงจำนวนตัวอย่างที่แต่ละคลาสถูกทำนายเป็นคลาสใดตารางนี้ช่วยให้มองเห็นความสัมพันธ์ว่างค่าที่มีลักษณะทำมือคล้ายกันซึ่งค่า accuracy รวมเพียงค่าเดียวไม่สามารถอธิบายรายละเอียดดังกล่าวได้

นอกจาก accuracy แล้วการรายงาน precision, recall และ F1-score ยังช่วยอธิบายคุณภาพการจำแนกในมุมที่ต่างกัน Precision สะท้อนความถูกต้องเมื่อระบบทำนายคลาสหนึ่ง Recall สะท้อนความสามารถในการตรวจพบตัวอย่างจริงของคลาสนั้นและ F1-score เป็นค่าที่รวมความสมดุลของ precision กับ recall

แนวคิดการใช้ตัวชี้วัดหลายค่าในงานจำแนกประเภทได้รับการอธิบายอย่างเป็นระบบโดย Sokolova และ Lapalme(2009)

สำหรับการแบ่งข้อมูลโปรแกรม train_model.py ใช้ traintestsplit แบบ stratified โดยกำหนดชุดทดสอบ 20 เปอร์เซนต์และคงสัดส่วนแต่ละ label ไว้ นอกจากนี้ใช้ 5foldcrossvalidation

เพื่อประเมินความสม่ำเสมอของโมเดลจากการแบ่งข้อมูลหลายส่วนแม้วิธีเหล่านี้เป็นแนวทางประเมินภายในชุดข้อมูลที่เหมาะสมแต่ยังไม่เท่ากับการทดสอบกับผู้ใช้ใหม่สภาพแสงใหม่หรือข้อมูลที่เก็บในคนละรอบจึงควรรายงานขอบเขตของผลการประเมินควบคู่กัน

2.8 งานและแนวคิดที่เกี่ยวข้อง

งานและแนวคิดที่เกี่ยวข้องกับโครงงานนี้ประกอบด้วยการติดตามจุดมือแบบเวลาจริงการจำแนกข้อมูลด้วย SVM การประเมินผลการจำแนกและการประมวลผลภาพด้วย OpenCV งานของ Zhang และคณะเป็นพื้นฐานเชิงเทคนิคของ MediaPipe Hands ซึ่งสนับสนุนการนำจุดโครงร่างมือมาใช้เป็นข้อมูลนำเข้าส่วนงานของ Cortes และ Vapnik อธิบายหลักการ SVM ที่ใช้เป็นตัวจำแนกในโครงงาน

ในด้านการประเมินผลแนวคิดของ Sokolova และ Lapalme ช่วยย้ำว่าการรายงานผลควรมีมากกว่า accuracy รวมถึงนำไปสู่การใช้ confusion matrix และตัวชี้วัดรายคลาสในผลการทดลองของระบบขณะเดียวกัน OpenCV เป็นไลบรารีที่ใช้จัดการภาพจากกล้องและแสดงผลแบบเวลาจริงบทบาทของแต่ละแหล่งอ้างอิงไม่ได้หมายความว่าโครงงานทำซ้ำงานเดิมทั้งหมดแต่เป็นการนำองค์ประกอบที่เหมาะสมมาประกอบเป็นระบบต้นแบบตามขอบเขตที่กำหนด

ตารางที่ 2.1 สรุปความเชื่อมโยงระหว่างงานอ้างอิงกับองค์ประกอบของ Hand Sign Translator-TH โดยการใช้แหล่งอ้างอิงอย่างเหมาะสมทำให้ผู้อ่านตรวจสอบได้ว่าแต่ละแนวคิดมีที่มาใดและทำให้ส่วนวิธีดำเนินการวิจัยในบทถัดไปมีเหตุผลรองรับชัดเจน

แหล่งอ้างอิง	สาระสำคัญ	การนำมาใช้ในโครงงาน
Zhangetal.(2020)	เสนอท่อประมวลผลติดตามมือแบบเวลาจริงจากภาพ RGB โดยใช้ตัวตรวจหาฝ่ามือและโมเดลจุดมือ	ใช้เป็นพื้นฐานของขั้นตอนตรวจจับมือและรับ 21landmarks

แหล่งอ้างอิง	สาระสำคัญ	การนำมาใช้ในโครงงาน
Cortes&Vapnik(1995)	อธิบายหลักการ SupportVectorNetwork และการแยกข้อมูลในปริภูมิคุณลักษณะ	ใช้เป็นแนวคิดของ SVM สำหรับจำแนกเวกเตอร์จุดมือ
Sokolova&Lapalme(2009)	วิเคราะห์การใช้ตัวชี้วัดการประเมินงานจำแนกประเภท	ใช้กำหนดการรายงาน confusion matrix, accuracy, precision, recall และ F1-score
Bradski(2000)	นำเสนอไลบรารี OpenCV สำหรับงานประมวลผลภาพ	ใช้รับภาพจากกล้องแสดงผลและจัดการเฟรมวิดีโอ

ตารางที่ 2.1 งานและแนวคิดที่เกี่ยวข้อง

2.9 บทสรุป

บทนี้อธิบายความรู้พื้นฐานของระบบ Hand Sign Translator-TH ตั้งแต่ขอบเขตการสื่อสารด้วยท่ามือการรับภาพด้วยคอมพิวเตอร์การตรวจจุดมือด้วย MediaPipe Hands การปรับมาตรฐานคุณลักษณะการจำแนกด้วย SVM และการแสดงผลข้อความหรือเสียงภาษาไทยแนวคิดทั้งหมดเชื่อมโยงกันเป็นลำดับจากภาพที่กล้องรับเข้าไปสู่ผลลัพธ์ที่ผู้ชมมองเห็นหรือได้ยิน

การออกแบบของโครงงานใช้จุดมือ 21

จุดเป็นตัวแทนของรูปทรงมือแล้วแปลงเป็นคุณลักษณะ 63 ค่าเพื่อส่งให้ SVM จำแนกวิธีนี้ทำให้ระบบต้นแบบสามารถทำงานกับท่ามือแบบสถิตที่กำหนดไว้ได้และช่วยให้การเก็บข้อมูลการฝึกโมเดลและการตรวจสอบผลสามารถอธิบายได้เป็นขั้นตอนอย่างไรก็ตามความสามารถของระบบยังขึ้นกับความชัดเจนของมือคุณภาพข้อมูลและความสอดคล้องของป้ายกำกับในชุดข้อมูล

ข้อสรุปสำคัญคือผลของโครงงานต้องตีความภายในขอบเขตของการจำแนกท่ามือที่กำหนดไว้ไม่ควรขยายความไปเป็นการแปลภาษามือไทยแบบครอบคลุมบทที่ 3 จะอธิบายวิธีดำเนินการวิจัยอย่างละเอียดตั้งแต่การเก็บข้อมูลการฝึก SVM การพัฒนาส่วนตรวจจับแบบเวลาจริงและเกณฑ์ที่ใช้ประเมินเพื่อให้ผู้อ่านสามารถเชื่อมโยงแนวคิดจากบทนี้กับกระบวนการทำงานจริงของระบบได้

รายการอ้างอิงที่ใช้ในบทนี้

Bradski, G. (2000). The OpenCV Library. Dr. Dobb's Journal of Software Tools.

Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3), 273–297. <https://doi.org/10.1007/BF00994018>

Sokolova, M., & Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, 45(4), 427–437. <https://doi.org/10.1016/j.ipm.2009.03.002>

Zhang, F., Bazarevsky, V., Vakunov, A., Tkachenka, A., Sung, G., Chang, C.-L., & Grundmann, M. (2020). MediaPipe Hands: On-device real-time hand tracking. *arXiv:2006.10214*. <https://arxiv.org/abs/2006.10214>