

บทที่ 3

วิธีดำเนินการและการออกแบบระบบ

บทนี้อธิบายวิธีพัฒนา HandVox ตามซอร์สโค้ด ชุดข้อมูล

และไฟล์แบบจำลองของโครงการปัจจุบัน

ตั้งแต่การวิเคราะห์ความต้องการจนถึงการทดสอบและควบคุมคุณภาพ โดยมีหัวข้อดังนี้

- 3.1 รูปแบบการดำเนินโครงการ
- 3.2 การวิเคราะห์ความต้องการ
- 3.3 สถาปัตยกรรมระบบ
- 3.4 การสร้างและจัดเก็บชุดข้อมูล
- 3.5 การสกัดและปรับมาตรฐานคุณลักษณะ
- 3.6 สถานะชุดข้อมูลปัจจุบัน
- 3.7 การฝึกแบบจำลอง
- 3.8 การทำงานแบบเวลาจริง
- 3.9 ส่วนติดต่อผู้ใช้และการแปลงข้อความเป็นเสียง
- 3.10 แผนการประเมินผล
- 3.11 การควบคุมคุณภาพและจริยธรรมข้อมูล
- 3.12 บทสรุป

3.1 รูปแบบการดำเนินโครงการ

โครงการใช้รูปแบบการวิจัยและพัฒนาเชิงทดลอง ประกอบด้วย การกำหนดข้อกำหนด การออกแบบสถาปัตยกรรม การพัฒนาซอฟต์แวร์ การสร้างชุดข้อมูลที่มีป้ายกำกับ การฝึกและประเมินแบบจำลอง และการทดสอบการใช้งานแบบเวลาจริง การตัดสินใจทุกขั้นอ้างอิงจากไฟล์โปรแกรมเพื่อให้ตรวจสอบย้อนกลับได้

3.2 การวิเคราะห์ความต้องการ

ตารางที่ 3.1 ความต้องการเชิงหน้าที่

รหัส	ความต้องการ	เกณฑ์ตรวจสอบ
FR-01	รับภาพจากเว็บแคมและตรวจหาช่วงบนกับมือ	เมื่อพบ pose และมืออย่างน้อยหนึ่งข้างจึงสร้างคุณลักษณะ
FR-02	เก็บคลิปท่าที่มีป้ายกำกับ	หนึ่งคลิปมี 30 เฟรม และหนึ่งท่ามีอย่างน้อย 30 คลิป
FR-03	ฝึกตัวจำแนกหลายคลาส	มืออย่างน้อย 2 ท่าและจำนวนคลิปขั้นต่ำครบ
FR-04	รู้จำแบบเวลาจริง	แสดงชื่อท่าและความเชื่อมั่นเมื่อผ่านเกณฑ์
FR-05	จัดการคำและเสียง	เพิ่ม/ลบ/ล้างคำ และอ่านออกเสียงได้เมื่อ TTS พร้อม
FR-06	จัดการท่าที่ผู้ใช้เพิ่ม	เพิ่ม ลบ สำรองข้อมูล และฝึกใหม่ได้จากเมนู

ตารางที่ 3.2 ความต้องการที่ไม่ใช่เชิงหน้าที่

รหัส	ความต้องการที่ไม่ใช่เชิงหน้าที่	แนวทาง
NFR-01	ความสอดคล้องของข้อมูล	ใช้ฟังก์ชัน <code>extract_features</code> เดียวกันระหว่างเก็บและทำนาย
NFR-02	การทำซ้ำ	ใช้ <code>random_state=42</code> และบันทึกเวอร์ชันไลบรารี
NFR-03	ความเป็นส่วนตัว	บันทึกเฉพาะคุณลักษณะและป้ายกำกับ ไม่บันทึกวิดีโอเป็นชุดข้อมูล

รหัส	ความต้องการที่ไม่ใช่เชิงหน้าที่	แนวทาง
NFR-04	ความทนทาน	ล้างสถานะเมื่อ ไม่พบมือ และสำรองข้อมูลก่อนลบหรือรีเซ็ต

3.3 สถาปัตยกรรมระบบ

สถาปัตยกรรมการทำงานของ HandVox



ใช้คุณลักษณะรูปทรงและการเคลื่อนไหวที่กำหนดไว้ล่วงหน้า ไม่ใช้การแปลภาษามือต่อเนื่องทั้งภาพ

ภาพที่ 3.1 สถาปัตยกรรมการประมวลผลของ HandVox

สถาปัตยกรรมแบ่งเป็น 6 ส่วน ได้แก่ การรับภาพ การตรวจหาจุด การปรับมาตรฐาน การสะสมลำดับ 30 เฟรม การจำแนกด้วย SVM และการนำเสนอผล กระบวนการเก็บข้อมูลและกระบวนการใช้งานจริงเรียกใช้ `body_features.extract_features` ร่วมกัน จึงลดความเสี่ยงที่รูปแบบคุณลักษณะระหว่างฝึกและทำนายไม่ตรงกัน

ตารางที่ 3.3 องค์ประกอบซอฟต์แวร์

ไฟล์	หน้าที่หลัก	ข้อมูลเข้า/ออก
<code>body_features.py</code>	สกัด 171 คุณลักษณะและกรอบช่วงบน	MediaPipe results → feature vector
<code>sequence_dataset.py</code>	จัดเก็บและจัดการคลิป	<code>gesture_sequences.npz</code>
<code>collect_data.py</code>	เปิดกล้องและเก็บคลิปตามป้ายกำกับ	30 เฟรม → 1 คลิป
<code>train_model.py</code>	แบ่งข้อมูล ฝึก SVM และบันทึกโมเดล	NPZ → model/labels PKL
<code>run_detector.py</code>	ทำนายแบบเวลาจริงและแสดงผล	30 เฟรมล่าสุด → คำ/เสียง
<code>gesture_config.py</code>	โหลดชื่อ คำอธิบาย และสีของท่า	<code>custom_gestures.json</code>

3.4 การสร้างและจัดเก็บชุดข้อมูล

ผู้ใช้เพิ่มชื่อท่าและคำอธิบายผ่าน `add_gesture.py` จากนั้น `collect_data.py` เปิดกล้องที่ตั้งค่าความละเอียด 1280×720 พิกเซล กล้องภาพแนวนอน และใช้ MediaPipe Holistic ประมวลผลเฟรม เมื่อผู้ใช้กด Space โปรแกรมจะบันทึกและเก็บเฉพาะเฟรมที่ `extract_features` คืนค่าครบ จนครบ 30 เฟรมจึงบันทึกเป็นหนึ่งคลิป

`sequence_dataset.py` จัดเก็บคลิปทั้งหมดใน `gesture_sequences.npz` เป็นอาร์เรย์ชนิด `float32` รูปร่าง (จำนวนคลิป, 30, 171) และเก็บป้ายกำกับเป็นข้อความ หนึ่งท่าต้องมีอย่างน้อย 30 คลิปก่อนฝึก หากพบไฟล์ข้อมูลภาพนิ่งจากระบบรุ่นเก่า โปรแกรมจะย้ายไปยัง `gesture_backups` เพื่อป้องกันการใช้ข้อมูลที่มีโครงสร้างไม่เข้ากัน

ข้อควรระวังการเก็บข้อมูล: ควรเริ่มและจบท่าภายในคลิปทุกครั้ง

จัดให้เห็นไหล่และมืออย่างน้อยหนึ่งข้าง และเก็บความหลากหลายด้านผู้ทำท่า แสง ระยะ มุม และความเร็วโดยไม่เปลี่ยนความหมายของท่า

3.5 การสกัดและปรับมาตรฐานคุณลักษณะ

ระบบเลือกจุด pose หมายเลข 0, 2, 5, 7–16, 23 และ 24 รวม 15 จุด พร้อมมือซ้ายและขวาข้างละ 21 จุด แต่ละจุดมีพิกัด x, y และ z รวม 171 ค่า หากไม่พบ pose หรือไม่พบมือทั้งสองข้างจะไม่รับเฟรมนั้น หากพบเพียงมือเดียวจะเติมศูนย์แทนมือที่หาย

ให้ c เป็นจุดกึ่งกลางระหว่างไหล่ซ้ายและขวา และ s เป็นระยะยูคลิดระหว่างไหล่ ระบบคำนวณพิกัดมาตรฐานของทุกจุดด้วย $p'_i = (p_i - c) / \max(s, 10^{-6})$ จากนั้นเรียงคุณลักษณะตามลำดับ pose มือซ้าย และมือขวา การใช้จุดและลำดับเดียวกันในทุกไฟล์เป็นเงื่อนไขสำคัญของความถูกต้อง

3.6 สถานะชุดข้อมูลปัจจุบัน

การตรวจสอบไฟล์ `gesture_sequences.npz` ณ วันที่ 1 สิงหาคม 2569 พบข้อมูล 90 คลิป รูปร่างอาร์เรย์ (90, 30, 171) และชนิดข้อมูล `float32` ป้ายกำกับมี 3 คลาสและแต่ละคลาสมีจำนวนเท่ากัน ดังตารางที่ 3.4

ตารางที่ 3.4 ผลการตรวจสอบชุดข้อมูลปัจจุบัน

ป้ายกำกับ	จำนวนคลิป	เฟรมต่อคลิป	คุณลักษณะต่อเฟรม
สวัสดี	30	30	171
ขอบคุณ	30	30	171
ขอโทษ	30	30	171
รวม	90	2,700 เฟรมที่ใช้	5,130 ค่าต่อคลิป

จำนวนดังกล่าวเพียงพอให้โปรแกรมฝึกตัวจำแนกต้นแบบ

แต่ยังไม่เพียงพอสำหรับสรุปความสามารถทั่วไปของระบบ เนื่องจากจำนวนผู้ให้ข้อมูล
จำนวนเซสชัน และความหลากหลายของสภาพแวดล้อมยังไม่ได้บันทึกเป็น metadata
ในไฟล์ชุดข้อมูล

3.7 การฝึกแบบจำลอง

train_model.py ตรวจสอบว่ารายชื่อป้ายกำกับตรงกับ gesture_config.py มียังน้อย 2
คลาส และทุกคลาสมีอย่างน้อย 30 คลิป จากนั้นใช้ LabelEncoder แปลงชื่อทำเป็นรหัสจำนวนเต็ม
เรียงเมทริกซ์ 30×171 เป็นเวกเตอร์ 5,130 ค่า และแบ่งข้อมูลฝึกกับทดสอบแบบ stratified

ตารางที่ 3.5 การตั้งค่าการฝึก

รายการ	ค่าที่ใช้	ผลจากข้อมูลปัจจุบัน
จำนวนข้อมูล	90 คลิป	3 คลาส $\times$ 30 คลิป
การแบ่งข้อมูล	80:20, stratified, random_state=42	ฝึก 72 คลิป; ทดสอบ 18 คลิป
ตัวจำแนก	SVC	หลายคลาสผ่าน scikit-learn
Kernel	RBF	ขอบเขตไม่เชิงเส้น
C	10	ค่าคงที่ตามซอร์สโค้ด
gamma	scale	คำนวณจากจำนวนคุณลักษณะและ ความแปรปรวน

รายการ	ค่าที่ใช้	ผลจากข้อมูลปัจจุบัน
probability	True	ใช้ predict_proba ในเวลาจริง
ไฟล์ผลลัพธ์	gesture_model.pkl, gesture_labels.pkl	แบบจำลองและตัวเข้ารหัสป้ายกำกับ

3.8 การทำงานแบบเวลาจริง

- 1) โหลด gesture_model.pkl และ gesture_labels.pkl และตรวจว่ารายชื่อคลาสตรงกับ gesture_config.py
- 2) เปิด MediaPipe Holistic และเว็บแคม จากนั้นสกัดคุณลักษณะของทุกเฟรมที่ผ่านเงื่อนไข
- 3) สะสมคุณลักษณะล่าสุด 30 เฟรมใน motion_frames และเรียงเป็นเวกเตอร์ 5,130 ค่า
- 4) คำนวณ predict_proba เลือกคลาสที่มีค่าสูงสุด และรับผลเมื่อค่าความเชื่อมั่นไม่น้อยกว่า 0.40
- 5) เก็บผลย้อนหลัง 3 ครั้ง เลือกคลาสที่พบมากที่สุด และเฉลี่ยค่าความเชื่อมั่นของคลาสนั้น
- 6) สั่งคิวและสถานะเมื่อไม่พบมือนานกว่า 0.4 วินาที เพื่อลดการค้างของคำทำนายเดิม
- 7) แสดงกรอบ ชื่อท่า ค่าความเชื่อมั่น ประโยค และสถานะเสียงบนหน้าจอ

3.9 ส่วนติดต่อผู้ใช้และการแปลงข้อความเป็นเสียง

ตารางที่ 3.6 ปุ่มควบคุมขณะตรวจจับ

ปุ่ม	การทำงาน	ข้อความควบคุม
Space	เพิ่มคำที่ยืนยันแล้วลงในประโยค	หน่วยอย่างน้อย 1 วินาทีระหว่างการเพิ่ม
Backspace	ลบคำล่าสุด	ทำงานเมื่อประโยคไม่ว่าง
Enter	สั่งประโยค	ลบรายการคำทั้งหมด
S	อ่านประโยค	ทำงานเมื่อมีข้อความและ TTS พร้อม
Esc	ออกจากโปรแกรม	คืนกล้องและปิดหน้าต่าง

ระบบยังอ่านชื่อท่าอัตโนมัติเมื่อทำเดียวกันถูกยืนยันต่อเนื่องครบ 1 วินาที และอนุญาตให้พุดซ้ำหลังผู้ใช้เอามือออกจากระบบปริเซต การสร้างเสียงทำในเทรดแยกเพื่อไม่ให้วงรอบภาพหยุดจนเสียงเล่นจบ

3.10 แผนการประเมินผล

3.10.1 การประเมินภายในชุดข้อมูล

- 1) รายงาน accuracy บนชุดทดสอบ 18 คลิป พร้อมจำนวนที่ทำนายถูกและผิด
- 2) รายงาน confusion matrix, precision, recall และ F1-score รายคลาส รวมทั้ง macro average
- 3) บันทึกเวอร์ชันข้อมูล รายชื่อคลาส random_state และเวลาที่ฝึก เพื่อทำซ้ำผลได้

สถานะผลประเมิน: ซอร์สโค้ดปัจจุบันพิมพ์เฉพาะ accuracy

บนหน้าจอและไม่ได้เก็บรายงานการรันไว้ในไฟล์ จึงไม่ควรคัดลอกค่าความแม่นยำหรือค่า cross-validation จากระบบภาพนิ่งรุ่นเก่ามาใช้ ผลเชิงตัวเลขของ HandVox รุ่นคลิปต้องรันและบันทึกใหม่ก่อนเขียนบทที่ 4

3.10.2 การประเมินกับข้อมูลภายนอก

ก่อนสรุปว่าระบบใช้ได้กับผู้ใช้ทั่วไป

ควรสร้างชุดทดสอบที่แยกตามผู้ให้ข้อมูลและรอบการเก็บ

โดยไม่ให้คลิปของบุคคลหรือเซสชันทดสอบอยู่ในชุดฝึก ควรทดสอบแสง จากหลัง ระยะ มุมกล้อง ความเร็ว มือข้างเดียวและสองข้าง และบันทึกเวลาแฝงตั้งแต่รับภาพจนแสดงผล

3.10.3 การทดสอบเชิงหน้าที่

ตารางที่ 3.7 กรณีทดสอบเชิงหน้าที่

กรณีทดสอบ	ผลที่คาดหวัง
ไม่พบ pose หรือมือ	ไม่เพิ่มเฟรมและไม่ทำนาย
คลิปของท่าไม่ครบ 30	ไม่อนุญาตให้ฝึกและแจ้งรายชื่อท่าที่ยังไม่ครบ
มีเพียง 1 คลาส	ไม่ฝึกตัวจำแนกหลายคลาส

กรณีทดสอบ	ผลที่คาดหวัง
โมเดลไม่ตรงกับรายการทำ	หยุดและแจ้งให้ฝึกใหม่
ความเชื่อมั่นต่ำกว่า 0.40	ไม่ยืนยันชื่อทำ
ไม่พบมีอนานกว่า 0.4 วินาที	ล้างคิว สถานะ และตัวจับเวลาพูด
TTS ใช้งานไม่ได้	ระบบรู้จำยังทำงานและแสดงข้อความได้

3.11 การควบคุมคุณภาพและจริยธรรมข้อมูล

- 1) ใช้คำอธิบายทำและป้ายกำกับที่ไม่ซ้ำ ตรวจสอบการสะกดก่อนเก็บ และฝึกใหม่ทุกครั้งเมื่อเปลี่ยนรายการทำ
- 2) เก็บ metadata ของผู้ให้ข้อมูล เซสชัน สภาพแสง ระยะเวลา และกล้องในรุ่นถัดไป เพื่อรองรับการแบ่งข้อมูลแบบกลุ่ม
- 3) ขอความยินยอมจากผู้ให้ข้อมูล ระบุวัตถุประสงค์ ระยะเวลาเก็บ และสิทธิในการถอนข้อมูล
- 4) ไม่ใช่ค่าความเชื่อมั่นแทนหลักฐานความถูกต้อง และไม่ใช้ระบบในบริบทสำคัญโดยไม่มีการยืนยันจากมนุษย์
- 5) รายงานจำนวนผู้ให้ข้อมูลและเงื่อนไขการทดสอบในบทที่ 4 เพื่อให้ผู้อ่านประเมินความสามารถทั่วไปของผลได้

3.12 บทสรุป

HandVox รับภาพเว็บแคมและใช้ MediaPipe Holistic สกัดจุดช่วงบน 15 จุดกับมือสองข้าง รวม 171 คุณลักษณะต่อเฟรม จากนั้นปรับมาตรฐาน เก็บลำดับ 30 เฟรมเป็นเวกเตอร์ 5,130 ค่า และฝึก SVM แบบ RBF ชุดข้อมูลปัจจุบันมี 90 คลิปจาก 3 ทำ แบ่งเป็นชุดฝึก 72 คลิปและชุดทดสอบ 18 คลิป

ขั้นตอนนี้ทำให้การเก็บข้อมูลและการทำนายสอดคล้องกัน แต่บทถัดไปต้องใช้ผลจากโมเดลคลิปรุ่นปัจจุบัน บันทึกตัวชี้วัดอย่างเป็นระบบ และทดสอบกับผู้ให้ข้อมูลและสภาพแวดล้อมใหม่ก่อนสรุปการใช้งานจริง