

## บทที่ 2

### ความรู้พื้นฐาน

ในการจัดสร้างโครงงาน HandVox จำเป็นต้องศึกษาความรู้พื้นฐาน แนวคิด ทฤษฎี และงานวิจัยที่เกี่ยวข้อง ดังนี้

- 2.1 ภาษามือและการรู้จำ
- 2.2 การมองเห็นด้วยคอมพิวเตอร์
- 2.3 จุดสำคัญที่ใช้ใน HandVox
- 2.4 การปรับมาตรฐานและการแทนลำดับ
- 2.5 Support Vector Machine
- 2.6 การแบ่งข้อมูลและการป้องกันการรั่วไหล
- 2.7 การประเมินผล
- 2.8 การทำงานแบบเวลาจริงและเสียงพูด
- 2.9 งานวิจัยที่เกี่ยวข้อง

เนื้อหาในบทนี้สืบค้นจาก Google Scholar โดยใช้คำค้นที่เกี่ยวข้องกับ sign language recognition, Thai sign language, MediaPipe, hand landmarks, Support Vector Machine และ real-time sign language translation แล้วตรวจสอบชื่อผู้แต่ง ปีเผยแพร่ วิธีดำเนินการ และผลการทดลองกับหน้าต้นฉบับของวารสารหรือการประชุมวิชาการก่อนนำมาเรียบเรียง

#### 2.1 ภาษามือและการรู้จำ

ภาษามือเป็นภาษาธรรมชาติที่ประกอบด้วยรูปมือ ตำแหน่ง ทิศทาง การเคลื่อนไหว สีหน้า และโครงสร้างทางภาษา การรู้จำแบบแยกคำรับคลิปรูปของท่าหนึ่งคำและส่งออกหนึ่งป้ายกำกับ ส่วนการรู้จำแบบต่อเนื่องต้องแบ่งหน่วยท่าจากวิดีโอหลายคำและจัดการบริบท HandVox เลือกขอบเขตแบบแยกคำเพื่อให้พัฒนาและประเมินต้นแบบได้ชัดเจน

Camgoz และคณะ (2018)

อธิบายว่าการรู้จำภาษามือไม่ควรถูกมองเป็นเพียงการจำแนกท่าทาง เพราะภาษามือมีลำดับคำและโครงสร้างไวยากรณ์ที่แตกต่างจากภาษาพูด งานดังกล่าวแยกปัญหา Sign Language Recognition ซึ่งมุ่งระบุหน่วยท่า ออกจาก Sign Language Translation ซึ่งมุ่งสร้างประโยคภาษาพูดที่มีความหมายสอดคล้องกัน แนวคิดนี้ใช้กำหนดให้ HandVox รุ่นปัจจุบันเป็นระบบรู้จำแบบแยกคำ ไม่อ้างว่าเป็นระบบแปลภาษามืออย่างสมบูรณ์

การจำแนกรูปมือจากภาพนิ่งเหมาะสำหรับคำที่รูปมือในช่วงใดช่วงหนึ่งมีข้อมูลเพียงพอ แต่ทำจำนวนมากมีความหมายต่างกันจากทิศทาง การเคลื่อนเข้า-ออก การหมุนข้อมือ หรือการเปลี่ยนตำแหน่งสัมพันธ์กับร่างกาย หากใช้ภาพเพียงเฟรมเดียว ระบบอาจมองไม่เห็นลำดับดังกล่าว การใช้คลิปจึงช่วยให้แบบจำลองได้รับข้อมูลก่อน ระหว่าง และหลังการเคลื่อนไหว

สำหรับการรู้จำแบบแยกคำ

ผู้เก็บข้อมูลต้องกำหนดจุดเริ่มและจุดสิ้นสุดของท่าให้ใกล้เคียงกันในทุกตัวอย่าง ถ้าบางคลิปเริ่มช้า บางคลิปจบเร็ว หรือมีช่วงอยู่นิ่งยาวเกินไป แบบจำลองอาจเรียนรู้จังหวะที่ไม่เกี่ยวข้องกับความหมาย HandVox จึงกำหนดจำนวนเฟรมคงที่และใช้คำแนะนำการเก็บข้อมูลแบบเดียวกันทุกคลาส

| รูปแบบ       | ข้อมูลนำเข้า        | ผลลัพธ์              | ขอบเขต                                   |
|--------------|---------------------|----------------------|------------------------------------------|
| ภาพนิ่ง      | หนึ่งเฟรม           | คลาสของรูปมือ        | ไม่แทนลำดับการเคลื่อนไหว                 |
| แบบแยกคำ     | คลิปของหนึ่งท่า     | หนึ่งคำหรือป้ายกำกับ | เหมาะกับท่าที่มีจุดเริ่มและสิ้นสุดชัดเจน |
| แบบต่อเนื่อง | วิดีโอหลายท่าต่อกัน | ลำดับคำหรือประโยค    | ต้องแบ่งหน่วยท่าและจัดการบริบท           |

ตารางที่ 2.1 การเปรียบเทียบรูปแบบการรู้จำ

การเลือกแบบแยกคำทำให้ขอบเขตของปัญหาชัดเจนและเหมาะกับชุดข้อมูลขนาดเล็ก ผู้ใช้ต้องทำท่าหนึ่งคำภายในหน้าต่างเก็บข้อมูล และระบบคืนผลหนึ่งป้ายกำกับต่อครั้ง ข้อดีคือสามารถตรวจสอบผลรายการได้ตรงไปตรงมา ส่วนข้อจำกัดคือยังไม่สามารถแบ่งคำจากการเคลื่อนไหวต่อเนื่องหรือเรียงผลเป็นประโยคภาษาพูดโดยอัตโนมัติ

## 2.2 การมองเห็นด้วยคอมพิวเตอร์

OpenCV ทำหน้าที่รับภาพจากกล้อง วาดส่วนติดต่อ และแสดงผล ส่วน MediaPipe Holistic ประเมินตำแหน่งจุดสำคัญของร่างกายและมือ การใช้พิกัดจุดสำคัญแทนภาพดิบช่วยลดมิติข้อมูลและทำให้ระบบเน้นโครงสร้างการเคลื่อนไหว แต่ผลยังขึ้นกับแสง มุมกล้อง การบังมือ และความเร็วของผู้ใช้

Lugaresi และคณะ (2019) เสนอ MediaPipe เป็นกรอบงานสำหรับสร้าง perception pipeline แบบข้ามแพลตฟอร์ม โดยเชื่อมส่วนรับสื่อ แบบจำลอง และการแปลงข้อมูลเป็นกราฟการประมวลผล

ช่วยให้พัฒนาต้นแบบและวัดประสิทธิภาพบนอุปกรณ์เป้าหมายได้ ส่วน Zhang และคณะ (2020) พัฒนา MediaPipe Hands ซึ่งใช้ palm detector ร่วมกับ hand landmark model เพื่อประมาณโครงมือ 21 จุดจากภาพกล้องเดียวและทำงานแบบเวลาจริงบนอุปกรณ์เคลื่อนที่ แนวคิดทั้งสองเป็นฐานของการใช้ MediaPipe Holistic ใน HandVox

กระบวนการตรวจจับจุดสำคัญมีสองช่วงหลัก  
คือการตรวจว่าร่างกายหรือมืออยู่บริเวณใดในภาพ  
และการประมาณพิกัดของจุดข้อต่อภายในบริเวณนั้น เมื่อประมวลผลวิดีโอต่อเนื่อง ระบบสามารถติดตามตำแหน่งจากเฟรมก่อนหน้าเพื่อลดภาระการตรวจใหม่ทุกครั้ง แต่หากมือเคลื่อนเร็ว หลุดกรอบ หรือถูกบัง พิกัดอาจหายหรือกระโดดจนส่งผลต่อเวกเตอร์คุณลักษณะ

HandVox เปิดใช้งานการประมวลผลแบบวิดีโอต่อเนื่อง ใช้ model complexity ระดับกลาง เปิดการทำให้จุดต่อเนื่องราบรื่น และกำหนดค่าความเชื่อมั่นขั้นต่ำของการตรวจจับกับการติดตามเท่ากับ 0.70 การตั้งค่านี้นับเป็นจุดสมดุลเบื้องต้นระหว่างความเสถียรกับความเร็ว และควรทดสอบใหม่เมื่อเปลี่ยนกล้องหรือสภาพแวดล้อม

## 2.3 จุดสำคัญที่ใช้ใน HandVox

ระบบเลือกจุดช่วงบน 15 จุด และมือซ้ายกับมือขวาข้างละ 21 จุด แต่ละจุดมีพิกัด  $x$ ,  $y$  และ  $z$  จึงมีข้อมูลรวม 171 ค่าในหนึ่งเฟรม หากพบมือเพียงข้างเดียว ระบบเติมศูนย์ให้ข้อมูลมืออีกข้างเพื่อรักษารูปแบบข้อมูลให้เท่ากัน

จุดช่วงบนช่วยอธิบายตำแหน่งของมือเมื่อเทียบกับศีรษะ ไหล่ ศอก และลำตัว ขณะที่จุดมืออธิบายรูปร่างและทิศทางฝ่ามือ การใช้ทั้งสองกลุ่มร่วมกันเหมาะกับการทำที่รูปร่างมือคล้ายกันแต่เกิดคนละตำแหน่ง หากไม่พบโครงร่างของช่วงบนหรือไม่พบมือทั้งสองข้าง ระบบจะไม่รับเฟรมนั้น เพราะข้อมูลไม่เพียงพอสำหรับสร้างตัวอย่างที่สอดคล้องกับชุดฝึก

การเติมศูนย์เมื่อพบมือเพียงข้างเดียวทำให้ทุกเฟรมมีจำนวนคุณลักษณะเท่ากัน แต่ศูนย์ในกรณีนี้หมายถึงข้อมูลที่ไม่ตรวจพบ ไม่ใช่ตำแหน่งจริงของมือ ดังนั้นสัดส่วนเฟรมที่มือหายไม่ควรมากเกินไป และควรตรวจคุณภาพคลิปก่อนรวมเข้าในชุดข้อมูล มิฉะนั้นแบบจำลองอาจเรียนรู้รูปแบบของข้อมูลหายแทนรูปแบบของท่าทาง

## 2.4 การปรับมาตรฐานและการแทนลำดับ

ระบบใช้จุดกึ่งกลางระหว่างไหล่เป็นจุดอ้างอิงและใช้ระยะระหว่างไหล่เป็นตัวปรับขนาด เพื่อลดผลจากตำแหน่งและระยะห่างจากกล้อง หนึ่งคลิปมี 30 เฟรม เฟรมละ 171 ค่า ก่อนฝึกจะเรียงเป็นเวกเตอร์ 5,130 ค่า

โดยลำดับของตำแหน่งในเวกเตอร์ยังคงข้อมูลการเคลื่อนไหวตามเวลา

ให้  $c$  เป็นจุดกึ่งกลางระหว่างไหล่ซ้ายกับไหล่ขวา และให้  $s$  เป็นระยะยูคลิดระหว่างไหล่ พิกัดของจุดแต่ละจุดถูกเลื่อนด้วย  $c$  และหารด้วย  $s$  ก่อนจัดเก็บ

วิธีนี้ลดผลจากการยืงค่อนไปทางซ้ายหรือขวาและการอยู่ใกล้หรือไกลกล้อง อย่างไรก็ตาม การปรับดังกล่าวยังไม่ทำให้ข้อมูลไม่แปรผันต่อการหมุนตัว มุมกล้อง หรือสัดส่วนร่างกายทั้งหมด

การเรียงข้อมูล 30 เฟรมต่อกันเป็นเวกเตอร์ทำให้ SVM

สามารถใช้ข้อมูลเวลาได้โดยไม่ต้องมีโครงสร้างแบบจำลองลำดับเฉพาะ ตำแหน่งลำดับที่ 1-171

แทนเฟรมแรก และตำแหน่งช่วงท้ายแทนเฟรมที่ 30

ดังนั้นท่าที่เคลื่อนไหวในทิศทางตรงข้ามจะให้ลำดับค่าแตกต่างกัน แม้บางเฟรมจะมีรูปมือคล้ายกัน

ข้อจำกัดของการกำหนด 30 เฟรมคือผู้ที่ทำท่าต้องปรับจังหวะให้พอดีกับหน้าต่างข้อมูล หากทำท่าเร็วมากจะมีช่วงอยู่นิ่งเหลือมาก แต่หากทำช้ามากท่าอาจไม่จบภายในคลิป

แบบจำลองจึงอาจไวต่อความเร็ว

การเก็บข้อมูลควรมีหลายจังหวะและในอนาคตอาจใช้การปรับแนวเวลา

หรือแบบจำลองที่รองรับความยาวลำดับไม่เท่ากัน

## 2.5 Support Vector Machine

Cortes และ Vapnik (1995) เสนอ Support-Vector Networks

สำหรับสร้างขอบเขตการตัดสินใจที่มีระยะห่างจากตัวอย่างสำคัญมากที่สุด

และใช้การแปลงข้อมูลไปยังปริภูมิมิติสูงเพื่อรองรับข้อมูลที่ไม่สามารถแยกด้วยเส้นตรง

แนวคิดดังกล่าวพัฒนาต่อมาเป็น SVM ที่ใช้ kernel ได้ HandVox ใช้ RBF kernel

เพื่อรองรับความสัมพันธ์ที่ไม่เป็นเส้นตรง กำหนด  $C=10$ ,  $\gamma=scale$ ,  $probability=True$  และ  $class\_weight=balanced$

ค่า  $C$

ควบคุมการแลกเปลี่ยนระหว่างการยอมให้มีข้อผิดพลาดบนข้อมูลฝึกกับการสร้างขอบเขตที่ยืดหยุ่น

ค่า  $\gamma$  กำหนดระยะอิทธิพลของตัวอย่างต่อรูปร่างขอบเขต ส่วน  $class\_weight=balanced$

เพิ่มน้ำหนักให้คลาสที่มีตัวอย่างน้อยกว่า

การตั้งค่าปัจจุบันยึดตามการทดลองของโครงการและควรปรับด้วยชุดตรวจสอบที่แยกจากชุดทดสอบ  
เมื่อมีข้อมูลมากขึ้น

การเปิด probability ทำให้โปรแกรมใช้ predict\_proba  
เพื่อรายงานค่าประกอบการตัดสินใจแบบเวลาจริง  
แต่ค่าความน่าจะเป็นดังกล่าวขึ้นกับการสอบเทียบของแบบจำลองและลักษณะข้อมูล  
ไม่ควรตีความว่าเป็นความถูกต้องที่รับประกันในทุกสภาพแวดล้อม เกณฑ์ 0.40  
จึงเป็นค่าตั้งต้นที่ต้องตรวจสอบกับข้อมูลภายนอก

## 2.6 การแบ่งข้อมูลและการป้องกันการรั่วไหล

การแบ่งแบบ stratified ช่วยรักษาสัดส่วนของแต่ละคลาสระหว่างชุดฝึกกับชุดทดสอบ  
แต่ถ้าคลิปปจากผู้ทำหรือเซสชันเดียวกันกระจายอยู่ทั้งสองชุด  
คะแนนอาจสะท้อนความคล้ายของผู้ทำและฉากหลังมากกว่าความสามารถกับผู้ใช้ใหม่  
แนวทางที่เข้มงวดกว่าคือแบ่งตามรหัสผู้ให้ข้อมูลหรือเซสชัน  
และเก็บชุดทดสอบภายนอกที่ไม่ใช้ระหว่างการพัฒนา

## 2.7 การประเมินผล

Accuracy ใช้สรุปสัดส่วนการทำนายถูกทั้งหมด ส่วน Precision, Recall และ F1-score  
ช่วยพิจารณาผลรายคลาส ค่า Macro F1 ให้น้ำหนักทุกคลาสเท่ากัน และ Confusion Matrix  
แสดงคู่ทำที่ระบบทำนายสับสน  
การแบ่งข้อมูลควรแยกผู้ทำหรือเซสชันเพื่อป้องกันข้อมูลที่คล้ายกันรั่วไหลระหว่างชุดฝึกและชุดทดสอบ

## 2.8 การทำงานแบบเวลาจริงและเสียงพูด

ระบบสะสมคุณลักษณะล่าสุด 30 เฟรม รับผลที่มีค่าความเชื่อมั่นอย่างน้อย 0.40  
และลงคะแนนจากผลล่าสุด 3 ครั้งเพื่อให้ข้อความนิ่งขึ้น  
ผลที่ยืนยันแล้วสามารถเพิ่มลงในประโยคและอ่านออกเสียงภาษาไทยผ่านระบบ Text-to-Speech

กลไกรวมผลย้อนหลังช่วยลดการเปลี่ยนป้ายกำกับไปมาระหว่างเฟรม  
แต่ทำให้เกิดความหน่วงเพิ่มขึ้นเล็กน้อย หากไม่พบมีอนานกว่า 0.4 วินาที  
ระบบจะล้างคิวและสถานะเดิมเพื่อป้องกันผลเก่าค้างบนหน้าจอ การตั้งค่าทั้งสามส่วน ได้แก่  
ขนาดหน้าต่าง เกณฑ์ความเชื่อมั่น และจำนวนผลย้อนหลัง มีผลต่อความไวกับความเสถียรของระบบ

ส่วน Text-to-Speech ทำหน้าที่เปลี่ยนชื่อทำหรือข้อความสะสมเป็นเสียงภาษาไทย  
ช่วยส่งผลลัพธ์ไปยังคู่สนทนาโดยไม่ต้องอ่านหน้าจอ

การสร้างเสียงทำงานแยกจากวงรบกวนเพื่อลดการหยุดค้าง แต่ gTTS ต้องใช้อินเทอร์เน็ต จึงควรมีทางเลือกเสียงแบบออฟไลน์ในรุ่นที่ต้องใช้งานในพื้นที่เครือข่ายไม่เสถียร

## 2.9 งานวิจัยที่เกี่ยวข้อง

การคัดเลือกงานวิจัยพิจารณาความใกล้เคียงกับ HandVox ใน 4 ด้าน ได้แก่ การรู้จำภาษาไทย การใช้ภาพหรือจุดสำคัญของร่างกาย การจำแนกท่าจากลำดับเวลา และการทำงานแบบเวลาจริง

งานที่นำมาอ้างอิงมีทั้งงานภาษาไทยซึ่งสะท้อนข้อจำกัดด้านข้อมูลในประเทศ และงานต่างประเทศที่แสดงแนวทางเมื่อจำนวนคำกับผู้ทำท่าเพิ่มขึ้น

### 2.9.1 การรู้จำนิ้วสะกดภาษาไทยด้วย SVM

Pariwat และ Seresangtakul (2017)

ศึกษาการรู้จำนิ้วสะกดภาษาไทยจากคุณลักษณะภาพแบบ global และ local แล้วเปรียบเทียบ SVM หลาย kernel ข้อมูลที่รายงานในงานทบทวนภายหลังมี 15 ท่า 75 ภาพ จากผู้ทำท่า 5 คน ผลเฉลี่ยของ RBF kernel เท่ากับ 91.2% สูงกว่า linear, polynomial และ sigmoid งานนี้สนับสนุนการเลือก RBF สำหรับข้อมูลท่าทางที่ขอบเขตคลาสไม่เป็นเส้นตรง แต่เป็นภาพนิ่งและชุดข้อมูลขนาดเล็ก จึงไม่ยืนยันผลของ HandVox ที่ใช้ลำดับ 30 เฟรมโดยตรง

### 2.9.2 การรู้จำนิ้วสะกดภาษาไทยด้วย CNN และการปฏิเสธท่าที่ไม่รู้จัก

Nakjai และ Katanyukul (2019) พัฒนาระบบการสองขั้นตอน

คือค้นหาและตัดบริเวณมือ ก่อนจำแนกภาพด้วย CNN หรือ HOG งานใช้ทำนิ้วสะกดภาษาไทย 25 ท่า 125 ภาพ จากผู้ทำท่า 11 คน และรายงาน mean Average Precision 91.26 งานยังเสนอ confidence ratio เพื่อช่วยแยกท่าที่ถูกต้องออกจากท่าช่วงเปลี่ยนหรือท่าที่ไม่อยู่ในชุดคำ แนวคิดดังกล่าวชี้ว่า HandVox ควรมีสถานะ “ไม่ทราบ” แทนการบังคับเลือกหนึ่งใน 16 คลาสทุกครั้ง

### 2.9.3 ชุดข้อมูลวิดีโอเลขภาษาไทย

Vijitkunsawat, Racharak, Nguyen และ Minh (2023)

สร้างชุดข้อมูลวิดีโอเลขภาษาไทย 9 ท่า มีประมาณ 63 วิดีโอต่อท่า รวม 567 วิดีโอจากผู้ทำท่า 21 คน แล้วเปรียบเทียบ CNN-Mode, CNN-LSTM, VGG-Mode และ VGG-LSTM ทั้งภาพเต็มกับภาพที่ตัดเฉพาะมือ ผลพบว่า VGG-LSTM ร่วมกับการประมวลผลล่วงหน้าให้ผลดีที่สุดทั้งชุดทดสอบภายในและภายนอก

งานนี้แสดงความสำคัญของจำนวนผู้ทำท่า การเก็บข้อมูลเป็นวิดีโอ และการรายงานผลกับผู้ทำท่าที่ต่างจากชุดพัฒนา

#### 2.9.4 ระบบตรวจจับภาษามือไทยด้วย MediaPipe และ LSTM

Damrongekarun, Pisitpipattana, Waijanya และ Promrit (2023) ใช้ MediaPipe ดึงจุดสำคัญของมือ ใบหน้า และท่าทางจากวิดีโอ แล้วใช้ LSTM วิเคราะห์ลำดับ แบ่งข้อมูลฝึกและทดสอบ 80:20 ได้ค่า Accuracy 0.83 และนำผลไปแสดงบนแอป Flutter ผ่าน Flask API งานนี้มีโครงสร้างใกล้เคียง HandVox ในด้านการใช้ฟังก์ชันสำคัญและการส่งผลเป็นข้อความไทย แต่เลือกแบบจำลองลำดับเชิงลึกแทน SVM

#### 2.9.5 การแปลภาษามือไทยเป็นข้อความแบบเวลาจริง

Jintanachaiwat และคณะ (2024) ใช้ MediaPipe Holistic เก็บจุดมือ ร่างกาย และใบหน้าเป็นลำดับ 30 เฟรม เฟรมละ 1,662 ค่า แล้วเปรียบเทียบ RNN, Bi-RNN, LSTM, Bi-LSTM และ FNN-LSTM สำหรับคำภาษาไทยที่ใช้ในการประชุม ผลของ LSTM บนชุดทดสอบเท่ากับ 100% แต่ลดเหลือ 86% เมื่อทดสอบแบบเวลาจริง ผู้วิจัยระบุว่า การเก็บข้อมูลจากผู้ทำท่าเพียงคนเดียวเสี่ยงต่อ overfitting ผลดังกล่าวยืนยันว่าคะแนนจากชุดทดสอบภายในอาจสูงกว่าการใช้งานจริงและควรเก็บข้อมูลหลายบุคคล

#### 2.9.6 ชุดข้อมูลภาษามือระดับคำขนาดใหญ่

Li, Rodriguez, Yu และ Li (2020) เสนอ WLASL ซึ่งมีภาษามืออเมริกันระดับคำมากกว่า 2,000 คำและผู้ทำท่ามากกว่า 100 คน พร้อมเปรียบเทียบวิธีที่ใช้ภาพลักษณะโดยรวมกับวิธีที่ใช้โครงร่าง และเสนอ Pose-TGCN เพื่อเรียนรู้ความสัมพันธ์เชิงพื้นที่กับเวลา งานนี้แสดงความหลากหลายของผู้ทำท่าและขนาดคำศัพท์ทำให้ปัญหายากขึ้นมาก การเพิ่มคลาสใน HandVox จึงต้องเพิ่มข้อมูลและทดสอบวิธีลำดับที่ซับซ้อนกว่า SVM ควบคู่กัน

#### 2.9.7 การรู้จำและการแปลภาษามือต่อเนื่อง

Camgoz, Hadfield, Koller, Ney และ Bowden (2018) เสนอปัญหา Neural Sign Language Translation และชุดข้อมูล RWTH-PHOENIX-Weather 2014T ซึ่งมีมากกว่า 67,000 หน่วยท่าจากคำศัพท์ภาษามือมากกว่า 1,000 หน่วย งานใช้แนวคิด Neural Machine Translation

เพื่อเชื่อมวิดีโอกับประโยคภาษาพูด ผลงานนี้มีขอบเขตกว้างกว่า HandVox

เพราะต้องแบ่งทำต่อเนื่องและจัดการไวยากรณ์

แต่เป็นแนวทางระยะยาวสำหรับการพัฒนาจากการสะสมค่าไปสู่การแปลประโยค

| ผู้วิจัยและปี                                                   | ข้อมูลและวิธี                                                     | ผลสำคัญ                                | สิ่งที่ HandVox นำมาใช้                       |
|-----------------------------------------------------------------|-------------------------------------------------------------------|----------------------------------------|-----------------------------------------------|
| Pariwat และ Seresangtakul (2017)<br>KST 2017, หน้า 116–120      | 15 ท่า; 75 ภาพ; 5 คน; คุณลักษณะ global/local และ SVM              | RBF เฉลี่ย 91.2%                       | เลือก RBF และระบุข้อจำกัดของข้อมูลขนาดเล็ก    |
| Nakjai และ Katanyukul (2019)<br>DOI: 10.1007/s11265-018-1375-6  | 25 ท่า; 125 ภาพ; 11 คน; CNN เทียบ HOG                             | mAP 91.26 และเสนอ confidence ratio     | เสนอให้เพิ่มสถานะไม่ทราบและตรวจท่าช่วงเปลี่ยน |
| Vijitkunsawat และคณะ (2023)<br>DOI: 10.5220/0011643700003411    | 9 ท่าเลข; 567 วิดีโอ; 21 คน; CNN/LSTM และ VGG/LSTM                | VGG-LSTM หลังตัดบริเวณมือให้ผลดีที่สุด | เก็บวิดีโอหลายคนและแยกทดสอบภายนอก             |
| Damrongekarun และคณะ (2023)<br>DOI: 10.14456/kkuscij.2023.19    | MediaPipe landmarks, LSTM, แบ่ง 80:20 และแอป Flutter              | Accuracy 0.83                          | ใช้ฟังก์ชันสำคัญและแสดงผลเป็นข้อความไทย       |
| Jintanachaiwat และคณะ (2024)<br>DOI: 10.1007/s44163-024-00113-8 | MediaPipe Holistic; 30 เฟรม; เปรียบเทียบ RNN และ LSTM             | LSTM ชุดทดสอบ 100%; เวลาจริง 86%       | แยกผลภายในออกจากเวลาจริงและระวังข้อมูลคนเดียว |
| Li และคณะ (2020)<br>WACV 2020, หน้า 1459–1469                   | WLASL มากกว่า 2,000 คำ; มากกว่า 100 คน; appearance/pose/Pose-TGCN | แสดงความท้าทายเมื่อคำและผู้ทำท่าเพิ่ม  | วางแผนขยายข้อมูลและเปรียบเทียบโมเดลลำดับ      |
| Camgoz และคณะ (2018)<br>DOI: 10.1109/CVPR.2018.00812            | วิดีโอต่อเนื่อง มากกว่า 67,000 หน่วยท่า และ Neural Translation    | แปลภาษามือโดยคำนึงถึงลำดับและไวยากรณ์  | กำหนดขอบเขตปัจจุบันเป็นแยกคำและวางแผนทางอนาคต |

ตารางที่ 2.2 การเปรียบเทียบงานวิจัยที่เกี่ยวข้องกับ HandVox

สรุปได้ว่าคุณภาพระบบขึ้นกับตัวจำแนก คุณภาพข้อมูล จำนวนผู้ทำท่า และวิธีแบ่งชุดทดสอบ HandVox จึงควรเพิ่มผู้ทำท่า สร้างชุดทดสอบภายนอก เพิ่มสถานะไม่ทราบ และเปรียบเทียบ SVM กับ LSTM ภายใต้ข้อมูลชุดเดียวกัน