

## บทที่ 4

### ผลการศึกษา

จากการศึกษา ออกแบบ และพัฒนาระบบ HandVox

ผู้จัดทำได้ดำเนินการรวบรวมชุดข้อมูลท่าทาง สกัตุจุดสำคัญของช่วงบนและมือ

จัดข้อมูลเป็นลำดับภาพ ฝึกแบบจำลอง Support Vector Machine

และทดสอบการทำงานของระบบตั้งแต่รับภาพจากเว็บแคมจนถึงการแสดงผลเป็นข้อความ ประโยค

และเสียงภาษาไทย ผลการศึกษาแบ่งออกเป็นผลด้านชุดข้อมูล ผลการฝึกแบบจำลอง


และผลการทำงานของระบบ ดังต่อไปนี้

#### 4.1 ผลการพัฒนาชุดข้อมูลและการเตรียมข้อมูล

ชุดข้อมูลที่ใช้ในการศึกษามีทั้งหมด 350 คลิป ครอบคลุมคำภาษาไทยแบบแยกคำ 16 คำ แต่ละคลิปมีความยาว 30 เฟรม โดยระบบใช้ MediaPipe Holistic ตรวจจุดสำคัญช่วงบน 15 จุด และจุดมือข้างละ 21 จุด รวม 57 จุด แต่ละจุดประกอบด้วยพิกัด x, y และ z จึงได้ข้อมูล 171 ค่าต่อเฟรม และเมื่อนำ 30 เฟรมมาเรียงต่อกันจะได้เวกเตอร์ 5,130 ค่าต่อคลิป

##### 4.1.1 ผลการรวบรวมชุดข้อมูล

ข้อมูลประกอบด้วยชุดฐานเดิม 120 คลิปจาก 4 คำ ได้แก่ ขอบคุณ ขอโทษ สวัสดี และไม่เป็นไร คำละ 30 คลิป และ Dataset V2 อีก 230 คลิปจาก 12 คำ โดย 11 คำมีคำละ 20 คลิป ส่วนคำว่าไม่มี 10 คลิป ทำให้จำนวนข้อมูลต่อคำอยู่ระหว่าง 10-30 คลิป กราฟในภาพที่ 4.1 แสดงให้เห็นว่าชุดข้อมูลยังมีความไม่สมดุลระหว่างคำ



ภาพที่ 4.1 การกระจายจำนวนคลิปของชุดข้อมูล HandVox 16 คำ

| กลุ่มข้อมูล            | จำนวนคำ | จำนวนต่อคำ | จำนวนคลิป | รายละเอียด                            |
|------------------------|---------|------------|-----------|---------------------------------------|
| ข้อมูลฐานเดิม          | 4       | 30         | 120       | ไม่มี metadata ระดับผู้ทำท่าและเซสชัน |
| Dataset V2 กลุ่มหลัก   | 11      | 20         | 220       | มีรหัสผู้ทำท่าและเซสชัน 2 รอบ         |
| Dataset V2 คำว่าไม่ใช่ | 1       | 10         | 10        | มีจำนวนตัวอย่างน้อยที่สุด             |
| รวม                    | 16      | 10–30      | 350       | ใช้ร่วมกันในการทดลองรอบปัจจุบัน       |

ตารางที่ 4.1 สรุปการรวบรวมชุดข้อมูล HandVox

ผลการตรวจสอบชุดข้อมูลไม่พบค่า NaN หรือ infinity

และไม่พบคลิปที่มีเวกเตอร์ซ้ำกันทุกค่าแบบตรงตัว ข้อมูลทั้งหมดจัดเก็บเป็นชนิด float32 มีรูปร่าง  $350 \times 30 \times 171$  อย่างไรก็ตาม ข้อมูลฐานเดิมไม่มีรหัสผู้ทำท่าและเซสชัน

จึงไม่สามารถใช้ประเมินแบบแยกบุคคลได้ครบทุกคำ

ข้อจำกัดนี้ต้องนำมาพิจารณาเมื่อตีความผลคะแนนของแบบจำลอง

#### 4.1.2 ผลการตรวจจับจุดสำคัญและบันทึกลำดับภาพ

ระหว่างการเก็บข้อมูล โปรแกรมแสดงตำแหน่งจุดสำคัญของใบหน้า ช่วงบน

และมือทั้งสองข้างบนภาพเว็บแคม พร้อมแสดงชื่อท่า จำนวนคลิป และจำนวนเฟรมที่บันทึก

ผู้เก็บข้อมูลสามารถเริ่มหรือหยุดการบันทึกได้จากแป้นพิมพ์ ตัวอย่างในภาพที่ 4.2

แสดงการตรวจพบจุดสำคัญขณะเก็บท่าสวัสดี โดยจุดมือซ้ายและขวาถูกแสดงคนละสี

ทำให้ตรวจสอบได้ทันทีว่ามืออยู่ภายในกรอบภาพและระบบติดตามได้ต่อเนื่อง



ภาพที่ 4.2 หน้าจอเก็บข้อมูลและตรวจจุดสำคัญของ HandVox

| รายการ     | ผลที่ได้                                                 | การนำไปใช้                       |
|------------|----------------------------------------------------------|----------------------------------|
| จุดช่วงบน  | $15 \text{ จุด} \times 3 \text{ พิกัด} = 45 \text{ ค่า}$ | ใช้เป็นตำแหน่งอ้างอิงของร่างกาย  |
| จุดมือซ้าย | $21 \text{ จุด} \times 3 \text{ พิกัด} = 63 \text{ ค่า}$ | แทนรูปมือและการเคลื่อนไหวมือซ้าย |
| จุดมือขวา  | $21 \text{ จุด} \times 3 \text{ พิกัด} = 63 \text{ ค่า}$ | แทนรูปมือและการเคลื่อนไหวมือขวา  |
| รวมต่อเฟรม | 171 ค่า                                                  | ใช้เป็นคุณลักษณะหนึ่งช่วงเวลา    |
| รวมต่อคลิป | $30 \times 171 = 5,130 \text{ ค่า}$                      | แปลงเป็นเวกเตอร์สำหรับ SVM       |

ตารางที่ 4.2 ผลการจัดรูปข้อมูลคุณลักษณะของหนึ่งคลิป

ข้อมูลพิกัดถูกเลื่อนจุดอ้างอิงไปยังจุดกึ่งกลางไหล่และปรับขนาดตามระยะระหว่างไหล่

เพื่อให้ความแตกต่างด้านตำแหน่งยืนและระยะจากกล้องลดลง

จากนั้นระบบรักษาลำดับคอลัมน์เป็นช่วงบน มือซ้าย และมือขวา เหมือนกันทั้งตอนเก็บข้อมูล

ฝึกแบบจำลอง และทำนายแบบเวลาจริง หากตรวจไม่พบมือข้างใด

ระบบเติมศูนย์เฉพาะส่วนของมือนั้น เพื่อให้ขนาดเวกเตอร์คงที่  
แต่จำนวนเฟรมที่เติมศูนย์มากเกินไปต้องถือเป็นสัญญาณด้านคุณภาพของคลิป

## 4.2 ผลการฝึกและประเมินแบบจำลอง

การทดลองใช้แบบจำลอง SVC ที่มี kernel แบบ RBF

แบ่งชุดข้อมูลเป็นชุดฝึกและชุดทดสอบในอัตรา 80:20 แบบ stratified เพื่อรักษาสัดส่วนของทุกคำ  
กำหนด random state เท่ากับ 42 ทำให้ชุดแบ่งสามารถทำซ้ำได้ แบบจำลองใช้ C เท่ากับ 10,  
gamma เท่ากับ scale, เปิด probability และใช้ class\_weight แบบ balanced  
เพื่อลดผลจากจำนวนคลิปต่อคำที่ไม่เท่ากัน

### 4.2.1 การกำหนดรูปแบบการทดลอง


| รายการ         | ค่าที่ใช้                | รายละเอียด                            |
|----------------|--------------------------|---------------------------------------|
| วิธีแบ่งข้อมูล | Stratified holdout 80:20 | ชุดฝึก 280 คลิป และชุดทดสอบ 70 คลิป   |
| Random state   | 42                       | ใช้ชุดแบ่งเดิมเมื่อทำการทดลองซ้ำ      |
| Algorithm      | SVC                      | จำแนกข้อมูลหลายคลาส                   |
| Kernel         | RBF                      | สร้างขอบเขตการตัดสินใจแบบไม่เชิงเส้น  |
| C              | 10.0                     | ควบคุมการยอมรับความผิดพลาดของแบบจำลอง |
| Gamma          | scale                    | คำนวณตามจำนวนคุณลักษณะและความแปรปรวน  |
| Probability    | True                     | รายงานค่าความน่าจะเป็นรายคำ           |
| Class weight   | balanced                 | ถ่วงน้ำหนักตามจำนวนตัวอย่างของแต่ละคำ |

ตารางที่ 4.3 ค่าที่ใช้ในการฝึกและประเมินแบบจำลอง

การแบ่งข้อมูลแบบ stratified ทำให้ทุกคำมีตัวอย่างอยู่ในชุดฝึกและชุดทดสอบ  
แต่เป็นการสุ่มระดับคลิปภายในชุดข้อมูลเดียวกัน  
จึงยังมีโอกาสที่คลิปจากผู้ทำท่าหรือเซสชันใกล้เคียงกันจะอยู่คนละชุด  
ผลที่ได้จึงเหมาะสำหรับตรวจสอบความเป็นไปได้ของต้นแบบ  
และไม่ควรตีความแทนผลการทดสอบกับผู้ทำท่าคนใหม่ทั้งหมด

#### 4.2.2 ผลการประเมินภาพรวม

จากชุดทดสอบ 70 คลิป แบบจำลองทำนายถูก 66 คลิปและทำนายผิด 4 คลิป คิดเป็น Accuracy ร้อยละ 94.29 ค่า Macro Precision, Macro Recall และ Macro F1 เท่ากับร้อยละ 93.75 ส่วน Weighted F1 เท่ากับร้อยละ 94.29 ผลดังกล่าวผ่านเกณฑ์ขั้นต่ำของโครงการที่กำหนด Accuracy และ Macro F1 ไว้ไม่น้อยกว่าร้อยละ 70



ภาพที่ 4.3 กราฟแสดงผลการประเมินแบบจำลอง HandVox

| ตัวชี้วัด         | ผลลัพธ์   | เกณฑ์ขั้นต่ำ     | ผลการพิจารณา |
|-------------------|-----------|------------------|--------------|
| Accuracy          | 94.29%    | 70.00%           | ผ่าน         |
| Macro Precision   | 93.75%    | รายงานประกอบ     | -            |
| Macro Recall      | 93.75%    | รายงานประกอบ     | -            |
| Macro F1          | 93.75%    | 70.00%           | ผ่าน         |
| Weighted F1       | 94.29%    | รายงานประกอบ     | -            |
| จำนวนทำนายถูก/ผิด | 66/4 คลิป | ชุดทดสอบ 70 คลิป | -            |


ตารางที่ 4.4 ผลการประเมินแบบจำลองโดยรวม

ค่า Macro F1 ต่ำกว่า Accuracy เล็กน้อย เพราะ Macro F1 ให้น้ำหนักทุกค่าเท่ากัน จึงสะท้อนผลของค่าที่จำแนกได้ไม่ดีชัดกว่าคะแนนรวม ขณะที่ Weighted F1

ถ่วงน้ำหนักตามจำนวนตัวอย่าง และมีค่าเท่ากับ Accuracy ในการทดลองรอบนี้  
การรายงานหลายตัวชี้วัดจึงช่วยป้องกันการสรุปจากคะแนนรวมเพียงค่าเดียว

### 4.2.3 ผลการจำแนกรายคำ

เมื่อพิจารณาแยกตามคำ พบว่า 14 จาก 16 คำมี Precision, Recall และ F1-score เท่ากับ 1.000 ส่วนคำว่าเข้าใจและไม่เข้าใจมีค่าเท่ากับ 0.500 ทั้งสามตัวชี้วัด กราฟในภาพที่ 4.4 แสดงความแตกต่างของ F1-score รายคำอย่างชัดเจน



ภาพที่ 4.4 กราฟแสดง F1-score แยกตามคำของ HandVox

| คำ       | Support | Precision | Recall | F1-score |
|----------|---------|-----------|--------|----------|
| กิน      | 4       | 1.000     | 1.000  | 1.000    |
| ขอบคุณ   | 6       | 1.000     | 1.000  | 1.000    |
| ขอโทษ    | 6       | 1.000     | 1.000  | 1.000    |
| ช่วยด้วย | 4       | 1.000     | 1.000  | 1.000    |
| ต้องการ  | 4       | 1.000     | 1.000  | 1.000    |
| น้ำ      | 4       | 1.000     | 1.000  | 1.000    |
| สวัสดี   | 6       | 1.000     | 1.000  | 1.000    |
| หมอ      | 4       | 1.000     | 1.000  | 1.000    |
| หยุด     | 4       | 1.000     | 1.000  | 1.000    |

| คำ        | Support | Precision | Recall | F1-score |
|-----------|---------|-----------|--------|----------|
| ห้องน้ำ   | 4       | 1.000     | 1.000  | 1.000    |
| เข้าใจ    | 4       | 0.500     | 0.500  | 0.500    |
| เจ็บ      | 4       | 1.000     | 1.000  | 1.000    |
| ใช่       | 4       | 1.000     | 1.000  | 1.000    |
| ไม่เข้าใจ | 4       | 0.500     | 0.500  | 0.500    |
| ไม่เป็นไร | 6       | 1.000     | 1.000  | 1.000    |
| ไม่ใช่    | 2       | 1.000     | 1.000  | 1.000    |

ตารางที่ 4.5 ผลการประเมินแยกตามคำทั้ง 16 คำ

คำว่าเข้าใจและไม่เข้าใจมี Support คำละ 4 คลิป


โดยตัวอย่างจริงของแต่ละคำถูกทำนายถูก 2 คลิป และถูกทำนายสลับเป็นอีกคำ 2 คลิป

ความผิดพลาดจึงเกิดแบบสองทิศทางรวม 4 คลิป สาเหตุที่เป็นไปได้คือรูปแบบมือ ตำแหน่ง

และช่วงการเคลื่อนไหวของสองคำมีส่วนใกล้เคียงกัน ประกอบกับจำนวนผู้ทำท่าและตัวอย่างยังน้อย

ควรเพิ่มข้อมูลและตรวจช่วงเริ่ม-จบของท่าเป็นพิเศษ

#### 4.2.4 การวิเคราะห์ Confusion Matrix



ภาพที่ 4.5 Confusion Matrix ของการทดลอง HandVox 16 คำ

Confusion Matrix มีค่าบนแนวทแยงสำหรับคำส่วนใหญ่ แสดงว่าตัวอย่างถูกจัดเข้าคำจริง ตำแหน่งนอกแนวทแยงพบเฉพาะระหว่างเข้าใจกับไม่เข้าใจ โดยแถวเข้าใจมีค่าที่คอลัมน์เข้าใจ 2 และคอลัมน์ไม่เข้าใจ 2 ส่วนแถวไม่เข้าใจมีค่าที่คอลัมน์เข้าใจ 2 และคอลัมน์ไม่เข้าใจ 2 ผลนี้ช่วยระบุค่าที่ควรเก็บข้อมูลเพิ่มเติมได้ตรงกว่าการดู Accuracy เพียงอย่างเดียว

| ประเด็น     | ผลที่พบ                      | แนวทางปรับปรุง                                |
|-------------|------------------------------|-----------------------------------------------|
| 14 คำทั่วไป | ทำนายถูกทุกคลิบในชุดทดสอบ    | เพิ่มผู้ทำาและทดสอบภายนอกเพื่อยืนยัน          |
| เข้าใจ      | ถูก 2 และสลับเป็นไม่เข้าใจ 2 | เพิ่มตัวอย่างและเน้นจังหวะที่ต่างจากไม่เข้าใจ |
| ไม่เข้าใจ   | ถูก 2 และสลับเป็นเข้าใจ 2    | ตรวจป้ายกำกับและช่วงเริ่ม-จบของลำดับ          |

| ประเด็น     | ผลที่พบ                                 | แนวทางปรับปรุง                     |
|-------------|-----------------------------------------|------------------------------------|
| คำว่าไม่ใช่ | ทดสอบเพียง 2 คลิป<br>แม้ทำนายถูกทั้งหมด | เพิ่มจำนวนคลิปเพื่อลดความไม่แน่นอน |

ตารางที่ 4.6 ผลการวิเคราะห์ข้อผิดพลาดจาก Confusion Matrix

### 4.3 ผลการทำงานของระบบ HandVox

ระบบ HandVox เชื่อมการรับภาพจากเว็บแคม การตรวจจุดสำคัญ การปรับมาตรฐานพิกัด การสะสมข้อมูล 30 เฟรม การจำแนกด้วย SVM และการนำผลไปแสดงเป็นข้อความ ประโยค และเสียงพูดภาษาไทย สถาปัตยกรรมในภาพที่ 4.6 แสดงการไหลของข้อมูลตั้งแต่ต้นทางถึงผลลัพธ์

สถาปัตยกรรมการทำงานของ HandVox



ใช้คุณลักษณะรูปทรงและการเคลื่อนไหวที่กำหนดไว้ล่วงหน้า ไม่ใช้การแปลภาษามือต่อเนื่องทั้งภาษา

ภาพที่ 4.6 กระบวนการทำงานของระบบ HandVox

#### 4.3.1 ผลการทำนายแบบเวลาจริง

โปรแกรมเก็บคุณลักษณะล่าสุดไว้ในหน้าต่างขนาด 30 เฟรม เมื่อข้อมูลครบจึงสร้างเวกเตอร์ 5,130 ค่าและเรียก predict\_proba ผลที่ได้ประกอบด้วยชื่อคำและค่าความเชื่อมั่น ระบบใช้เกณฑ์ความเชื่อมั่นขั้นต่ำและยืนยันผลต่อเนื่องหลายเฟรม ก่อนปล่อยคำไปยังหน้าจอ เพื่อลดการเปลี่ยนคำจากผลชั่วคราว และใช้ช่วง cooldown ป้องกันคำเดิมถูกเพิ่มซ้ำทันที

**การตรวจความสอดคล้อง:** ก่อนเริ่มทำนาย

โปรแกรมตรวจว่าจำนวนคุณลักษณะของแบบจำลองเท่ากับ 5,130 ค่า และรายชื่อคำตรงกับไฟล์กำหนดค่า หากไม่ตรงจะหยุดกระบวนการและแจ้งให้ฝึกแบบจำลองใหม่ ช่วยลดความผิดพลาดจากการใช้โมเดลกับรายการคำคนละรุ่น

**การจัดการเมื่อไม่พบมือ:** ระบบหยุดเพิ่มเฟรมเมื่อไม่พบจุดมือ

และล้างสถานะเมื่อหายไปนานกว่าค่าที่กำหนด เพื่อไม่ให้ข้อมูลจากท่าก่อนหน้าปะปนกับท่าถัดไป

### 4.3.2 ผลการสร้างประโยคและเสียงพูด

เมื่อระบบยืนยันคำแล้ว ผู้ใช้สามารถเพิ่มคำลงในประโยค ลบคำล่าสุด หรือล้างข้อความทั้งหมดได้ ข้อความสะสมถูกแสดงบนหน้าจอเพื่อให้ผู้ใช้ตรวจสอบก่อนอ่านออกเสียง ระบบใช้ gTTS สร้างเสียงภาษาไทย และเล่นไฟล์เสียงโดยไม่หยุดการรับภาพจากกล้อง อย่างไรก็ตาม การใช้ gTTS ต้องเชื่อมต่ออินเทอร์เน็ต จึงควรมีเสียงแบบออฟไลน์เป็นทางเลือกในการพัฒนารุ่นถัดไป

### 4.3.3 ผลการทดสอบความสามารถของระบบ

| ความสามารถที่ทดสอบ  | ผลที่ตรวจสอบได้                           | สถานะ/ข้อจำกัด                   |
|---------------------|-------------------------------------------|----------------------------------|
| เปิดกล้องและรับภาพ  | แสดงภาพจากเว็บแคมได้                      | ผ่าน เมื่อกล้องพร้อมใช้งาน       |
| ตรวจจุดช่วงบนและมือ | แสดง landmark และพิกัดตามโครงสร้าง 171 คำ | ผ่าน; ขึ้นกับแสงและการบังมือ     |
| สะสมลำดับ 30 เฟรม   | สร้างเวกเตอร์ 5,130 คำ                    | ผ่าน                             |
| ทำนายข้อความ        | ใช้ SVC และค่าความน่าจะเป็นรายคำ          | ผ่านในรายการคำที่โมเดลรู้จัก     |
| ลดการสั่นของผล      | ยืนยันผลหลายเฟรมและใช้ cooldown           | ผ่าน; ต้องปรับค่าจากการทดสอบจริง |
| สร้างประโยค         | เพิ่ม ลบ และล้างคำที่สะสม                 | ผ่าน                             |
| อ่านเสียงภาษาไทย    | สร้างและเล่นเสียงจากข้อความ               | ผ่านเมื่อเชื่อมต่ออินเทอร์เน็ต   |
| เพิ่มหรือลบท่า      | จัดการรายการคำและเก็บคลิปใหม่ได้          | ผ่าน                             |
| ฝึกแบบจำลองใหม่     | ตรวจสอบข้อมูล สร้างโมเดล และบันทึกผลทดลอง | ผ่าน                             |
| ตรวจโมเดลก่อนใช้งาน | ตรวจจำนวนคุณลักษณะและรายชื่อคลาส          | ผ่าน                             |

ตารางที่ 4.7 ผลการทดสอบความสามารถของระบบ HandVox

ผลการทดสอบยืนยันว่าฟังก์ชันหลักตั้งแต่เก็บข้อมูล ฝึกแบบจำลอง ทำนาย สร้างประโยค และอ่านเสียงสามารถเชื่อมต่อกันได้ ตามขอบเขตของต้นแบบ อย่างไรก็ตาม ยังไม่มีการวัด FPS และเวลาแฝงตั้งแต่รับภาพจนแสดงผล รวมทั้งยังไม่มีกรทดสอบเชิงระบบภายใต้แสงน้อย ฉากหลังซับซ้อน ระยะหลายระดับ มุมกล้องต่างกัน และการบังมือ

#### 4.3.4 ข้อสรุปจากผลการศึกษา

ผลการศึกษาพบว่า HandVox สามารถใช้จุดสำคัญของช่วงบนและมีอรรถาภิธานศัพท์ 30 เฟรม เพื่อจำแนกคำภาษาไทยแบบแยกคำภายในชุดข้อมูลปัจจุบันได้ โดยมี Accuracy ร้อยละ 94.29 และ Macro F1 ร้อยละ 93.75 ระบบยังสามารถแสดงข้อความ สะสมเป็นประโยค และอ่านเสียงภาษาไทยได้ตามวัตถุประสงค์ของต้นแบบ

อย่างไรก็ตาม ผลคะแนนมาจากการแบ่งคลิปภายในชุดข้อมูลเดียวกัน ข้อมูลฐานเดิมไม่มี metadata ระดับบุคคลและเซสชัน และคำว่าเข้าใจกับไม่เข้าใจยังมีการสับสนกัน จึงยังไม่ควรใช้ผลนี้ยืนยันความแม่นยำกับผู้ทั่วไป การประเมินครั้งต่อไปควรเพิ่มผู้ทำทำ เก็บข้อมูลหลายสภาพแวดล้อม แบ่งชุดทดสอบตามบุคคล และวัดสมรรถนะเวลาจริงร่วมกับประสบการณ์ของกลุ่มเป้าหมาย