

บทที่ 5

สรุปผลและข้อเสนอแนะ

5.1 สรุปผลการดำเนินงาน

โครงการ HandVox

มีวัตถุประสงค์เพื่อพัฒนาต้นแบบระบบรู้จำท่าทางภาษามือไทยแบบแยกคำจากภาพเว็บแคม

และนำผลการรู้จำไปแสดงเป็นข้อความ สะสมเป็นประโยค และอ่านออกเสียงภาษาไทย

เพื่อใช้เป็นช่องทางเสริมในการสื่อสารระหว่างผู้ใช้ภาษามือกับบุคคลทั่วไป

การพัฒนาครอบคลุมตั้งแต่การกำหนดรายการท่า การเก็บข้อมูล การตรวจสอบคุณภาพข้อมูล

การฝึกแบบจำลอง การทำนายแบบเวลาจริง

ตลอดจนการจัดการข้อความและเสียงในโปรแกรมเดียวกัน

ระบบใช้มีเดียไปป์โฮลิสติก (MediaPipe Holistic) ตรวจจับจุดสำคัญ (landmarks)

ของช่วงบน 15 จุดและมือข้างละ 21 จุด รวม 57 จุด แต่ละจุดประกอบด้วยพิกัด x, y และ z

จึงได้ข้อมูล 171 ค่าต่อเฟรม

ก่อนนำข้อมูลไปใช้มีการเลื่อนจุดอ้างอิงไปยังกึ่งกลางไหล่และปรับขนาดตามระยะระหว่างไหล่

เพื่อลดผลจากตำแหน่งยืนและระยะห่างจากกล้อง จากนั้นเรียงข้อมูลต่อเนื่อง 30 เฟรมเป็นเวกเตอร์

5,130 ค่าต่อหนึ่งคลิป โดยใช้โครงสร้างเดียวกันทั้งขั้นตอนเก็บข้อมูล ฝึกแบบจำลอง และทำนาย

ชุดข้อมูลที่ใช้ในการทดลองมีทั้งหมด 350 คลิป ครอบคลุมคำภาษามือไทยแบบแยกคำ 16

คำ ประกอบด้วยข้อมูลฐานเดิม 120 คลิปจาก 4 คำ และ Dataset V2 จำนวน 230 คลิปจาก 12 คำ

จำนวนข้อมูลต่อคำอยู่ระหว่าง 10-30 คลิป ทุกคลิปมีความยาว 30 เฟรม

เมื่อตรวจสอบก่อนฝึกไม่พบค่าไม่เป็นตัวเลข (Not a Number: NaN) ค่าความไม่สิ้นสุด

หรือคลิปที่มีเวกเตอร์ซ้ำกันทุกค่าแบบตรงตัว จึงสามารถนำข้อมูลไปใช้ในการทดลองขั้นต้นได้

อย่างไรก็ตาม จำนวนคลิปแต่ละคำยังไม่สมดุลและยังมีจำนวนผู้ทำท่าจำกัด

การจำแนกใช้เครื่องเวกเตอร์สนับสนุนชนิดจำแนก (Support Vector Classifier: SVC)

ร่วมกับเคอร์เนลฟังก์ชันฐานรัศมี (Radial Basis Function: RBF) กำหนดค่า C เท่ากับ 10 ค่า

gamma เป็น scale เปิดการคำนวณค่าความน่าจะเป็น และกำหนดน้ำหนักคลาสแบบสมดุล (class

weight = balanced) การทดลองแบ่งชุดข้อมูลแบบกันไว้โดยคงสัดส่วนคลาส (stratified holdout) อัตรา 80:20 ด้วยเมล็ดสุ่ม (random state) เท่ากับ 42 จึงได้ชุดฝึก 280 คลิปและชุดทดสอบ 70 คลิป

ผลการประเมินพบว่าแบบจำลองทำนายถูก 66 จาก 70 คลิปและทำนายผิด 4 คลิป คิดเป็นค่าความถูกต้อง (Accuracy) ร้อยละ 94.29 ค่าความแม่นยำเฉลี่ยแบบมาโคร (Macro Precision) ค่าความระลึกเฉลี่ยแบบมาโคร (Macro Recall) และคะแนนเอฟวันเฉลี่ยแบบมาโคร (Macro F1-score) เท่ากับร้อยละ 93.75 ส่วนคะแนนเอฟวันแบบถ่วงน้ำหนัก (Weighted F1-score) เท่ากับร้อยละ 94.29 ผลดังกล่าวผ่านเกณฑ์ขั้นต่ำของโครงการที่กำหนด Accuracy และ Macro F1-score ไม่น้อยกว่าร้อยละ 70

เมื่อพิจารณาเป็นรายคำ พบว่า 14 จาก 16 คำมีค่า Precision, Recall และ F1-score เท่ากับ 1.000 ในชุดทดสอบรอบนี้ ส่วนคำว่าเข้าใจและไม่เข้าใจมีค่าเท่ากับ 0.500 โดยตัวอย่างจริงของแต่ละคำถูกทำนายถูก 2 คลิปและถูกทำนายสลับเป็นอีกคำ 2 คลิป เมทริกซ์ความสับสน (Confusion Matrix) จึงแสดงความผิดพลาดเฉพาะระหว่างสองคำนี้ ผลดังกล่าวชี้ว่ารูปมือ ตำแหน่ง หรือจังหวะการเคลื่อนไหวของคู่คำมีส่วนใกล้เคียงกัน และควรได้รับการเก็บข้อมูลเพิ่มเติมเป็นลำดับแรก

ในด้านการใช้งาน ระบบสามารถเปิดกล่อง ตรวจจุดช่วงบนและมือ สะสมข้อมูล 30 เฟรม ตรวจสอบสอตคล้องของจำนวนคุณลักษณะและรายชื่อคลาสก่อนใช้แบบจำลอง และแสดงข้อผิดพลาดพร้อมค่าความเชื่อมั่นได้แบบเวลาจริง กลไกล็อกอินยันผลต่อเนื่องหลายเฟรมและช่วงพักการรับคำซ้ำ (cooldown) ช่วยลดการเปลี่ยนคำจากผลชั่วคราว เมื่อระบบยืนยันคำแล้วผู้ใช้สามารถเพิ่มคำลงในประโยค ลบคำล่าสุด ล้างข้อความ และใช้การแปลงข้อความเป็นเสียงพูด (Text-to-Speech: TTS) ภาษาไทยผ่าน gTTS ได้

เมื่อเปรียบเทียบกับวัตถุประสงค์ในบทที่ 1 โครงการบรรลุการสร้างต้นแบบรู้จำท่าทางจากลำดับภาพ การเพิ่มหรือลบท่าและฝึกแบบจำลองใหม่ การแสดงข้อผิดพลาดและค่าความเชื่อมั่น การสะสมคำเป็นประโยค การอ่านเสียงภาษาไทย และการประเมินด้วยตัวชี้วัดมาตรฐาน

ระบบจึงเหมาะสำหรับการทดลองและการสาธิตในสภาพควบคุม

แต่ผลคะแนนยังไม่ควรใช้ยืนยันความแม่นยำกับผู้ใช้ทั่วไป

เนื่องจากการแบ่งคลิปภายในชุดข้อมูลเดียวกัน

และยังไม่มีทดสอบกับผู้ทำท่าใหม่อย่างสมบูรณ์

5.2 ปัญหาและอุปสรรค

ปัญหาด้านข้อมูลเป็นข้อจำกัดสำคัญที่สุดของโครงการ ชุดข้อมูลมีเพียง 350 คลิปจาก 16 คำ และจำนวนตัวอย่างต่อคำไม่เท่ากัน โดยมีตั้งแต่ 10-30 คลิป แม้การกำหนดน้ำหนักคลาสแบบ

balanced จะช่วยลดผลจากความไม่สมดุลในขั้นฝึก

แต่ไม่สามารถทดแทนความหลากหลายของรูปร่างมือ ความเร็วในการทำท่า อายุ ความถนัด

ระยะจากกล้อง และลักษณะทางกายภาพของผู้ใช้ได้

การเพิ่มคลิปจากบุคคลเดิมหรือสถานที่เดิมเพียงอย่างเดียวจึงอาจทำให้คะแนนภายในสูงขึ้นโดยไม่เพิ่มความสามารถในการใช้งานจริง

ข้อมูลฐานเดิม 120 คลิปไม่มีข้อมูลกำกับ (metadata) ระดับรหัสผู้ทำท่าและเซสชัน จึงไม่สามารถตรวจสอบได้ครบถ้วนว่าคลิปจากบุคคลหรือรอบการเก็บเดียวกันถูกแบ่งไปอยู่ทั้งชุดฝึกและชุดทดสอบหรือไม่

การสุ่มแบ่งระดับคลิปอาจทำให้แบบจำลองพบรูปแบบของผู้ทำท่าหรือสภาพแวดล้อมที่คล้ายกันในทุกชุด ซึ่งเรียกว่าการรั่วไหลของข้อมูล (data leakage)

และอาจทำให้คะแนนสูงกว่าการทดสอบกับผู้ใช้รายใหม่

ปัญหาความสัมพันธ์ระหว่างคำว่าเข้าใจกับไม่เข้าใจแสดงให้เห็นว่าคะแนนรวมเพียงค่าเดียวไม่เพียงพอสำหรับอธิบายคุณภาพของระบบ

คู่คำดังกล่าวมีจำนวนตัวอย่างไม่มากและมีส่วนของการเคลื่อนไหวใกล้เคียงกัน

หากช่วงเริ่มต้นหรือช่วงสิ้นสุดของคลิปไม่ตรงกัน เวกเตอร์ 30 เฟรมอาจเก็บข้อมูลสำคัญไม่ครบ

นอกจากนี้ยังต้องตรวจสอบความถูกต้องของป้ายกำกับและกำหนดวิธีทำท่ามาตรฐานร่วมกับผู้ใช้ภาษา มือหรือผู้เชี่ยวชาญ

การตรวจจุดสำคัญขึ้นอยู่กับคุณภาพภาพจากเว็บแคม แสงน้อย แสงย้อน ฉากหลังซับซ้อน การบังมือ มุมกล้อง ระยะจากกล้อง และการเคลื่อนไหวที่เร็วอาจทำให้ตรวจไม่พบมือหรือพิกัดสั้น

ระบบใช้การเติมศูนย์เมื่อไม่พบมือและล้างลำดับเมื่อมือหายไปนานกว่าค่าที่กำหนด
แต่ยังไม่มี การประเมินเชิงปริมาณว่าคุณภาพการตรวจจับลดลงเท่าใดในแต่ละสภาพแวดล้อม

การกำหนดความยาวข้อมูลคงที่ 30 เฟรมทำให้ผู้ใช้ต้องทำท่าในจังหวะใกล้เคียงกับข้อมูลฝึก
หากทำช้าหรือเร็วเกินไป ตำแหน่งสำคัญของการเคลื่อนไหวอาจอยู่ไม่ครบในหน้าต่าง
ขณะเดียวกันค่าเกณฑ์ความเชื่อมั่นและจำนวนผลย้อนหลังที่ใช้ยืนยันคำยังเป็นค่าที่กำหนดในเชิงวิ
กรรมและยังไม่ได้ปรับจากชุดตรวจสอบเฉพาะ
จึงอาจเกิดทั้งการยอมรับคำที่ไม่แน่นอนและความหน่วงก่อนแสดงผล

โครงการยังไม่มีผลการวัดจำนวนเฟรมต่อวินาที (Frames Per Second: FPS)
เวลาแฝงตั้งแต่รับภาพจนแสดงผล อัตราการปฏิเสธคำ
หรือความทนทานภายใต้สภาพแวดล้อมหลายแบบ
จึงยังไม่สามารถสรุปสมรรถนะเวลาจริงในเชิงปริมาณได้ ส่วนระบบเสียงภาษาไทยใช้ gTTS
ซึ่งต้องเชื่อมต่ออินเทอร์เน็ต หากเครือข่ายไม่พร้อมจะสร้างเสียงไม่ได้
แม้ส่วนการรู้จำและการแสดงข้อความยังทำงานได้

ขอบเขตของ HandVox

รุ่นปัจจุบันเป็นการรู้จำภาษามือแบบแยกคำจากรายการที่กำหนดไว้ล่วงหน้า
ไม่ใช้การแปลภาษามือไทยต่อเนื่อง ประโยคเกิดจากผู้เลือกสะสมคำทีละคำ
ระบบยังไม่วิเคราะห์ไวยากรณ์ สีหน้า หรือองค์ประกอบที่ไม่ใช้มือ
และยังไม่มี การทดสอบความพึงพอใจหรือความสำเร็จของภารกิจกับกลุ่มเป้าหมายจริง
จึงไม่ควรนำต้นแบบไปใช้ตัดสินใจในบริบททางการแพทย์ กฎหมาย
หรือความปลอดภัยโดยไม่มีผู้ตรวจสอบ

5.3 ข้อเสนอแนะ

ควรเพิ่มจำนวนผู้ทำท่า จำนวนเซสชัน และจำนวนคลิปต่อคำให้สมดุล
โดยวางแผนสัดส่วนข้อมูลก่อนเก็บจริงและให้ความสำคัญกับคำว่าไม่ใช่ เข้าใจ
และไม่เข้าใจเป็นลำดับแรก ทุกคลิปควรบันทึกรหัสผู้ให้ข้อมูล รหัสเซสชัน สภาพแสง ฉากหลัง ระยะเวลา
มุมมอง ความเร็วในการทำท่า รุ่นของอุปกรณ์ และสถานะคุณภาพ
เพื่อให้ตรวจสอบย้อนกลับและวิเคราะห์สาเหตุของความผิดพลาดได้

การประเมินรุ่นถัดไปควรแบ่งชุดฝึก ชุดตรวจสอบ และชุดทดสอบตามผู้ทำท่าหรือเซสชัน ห้ามให้ข้อมูลของกลุ่มทดสอบปรากฏในขั้นตอนปรับแบบจำลอง ควรใช้การทดสอบแบบแยกผู้ทำท่าที่ละราย (Leave-One-Signer-Out: LOSO) หรือจัดทำชุดทดสอบภายนอกจากบุคคลและสถานที่ใหม่ พร้อมรายงานค่า Accuracy, Macro Precision, Macro Recall, Macro F1-score, Weighted F1-score และ Confusion Matrix ภายใต้เกณฑ์เดียวกัน

ควรตรวจรูปแบบการทำท่าและความหมายของทุกคำร่วมกับผู้ใช้ภาษามือไทยหรือผู้เชี่ยวชาญ กำหนดช่วงเริ่มต้นและสิ้นสุดของท่าให้ชัดเจน และเก็บตัวอย่างคู่คำที่สับสนในหลายจังหวะ หลายมุม และหลายบุคคล หากพบว่าสองคำมีโครงสร้างการเคลื่อนไหวใกล้เคียงกัน ควรวิเคราะห์จุดช่วงบน รูปมือ ทิศทาง และลำดับเวลาที่ทำให้ความหมายแตกต่างกัน ก่อนเพิ่มข้อมูลเข้าสู่ชุดฝึกโดยไม่ทราบสาเหตุ

ในด้านแบบจำลอง ควรปรับค่า C, gamma, เกณฑ์ความเชื่อมั่น ระยะพักคำซ้ำ และจำนวนผลย้อนหลังจากชุดตรวจสอบ ไม่ควรเลือกค่าจากชุดทดสอบโดยตรง ควรเพิ่มสถานะไม่ทราบหรือปฏิเสธ (unknown/rejection) เมื่อไม่มีคลาสใดมีความเชื่อมั่นเพียงพอ และประเมินการสอบเทียบค่าความน่าจะเป็น เพื่อให้ค่าความเชื่อมั่นที่แสดงสอดคล้องกับโอกาสที่ผลจะถูกต้อง

เมื่อมีข้อมูลมากขึ้น ควรเปรียบเทียบ SVM กับแบบจำลองที่เรียนรู้ลำดับเวลาโดยตรง เช่น หน่วยความจำระยะสั้นแบบยาว (Long Short-Term Memory: LSTM) โครงข่ายคอนโวลูชันตามเวลา (Temporal Convolutional Network: TCN) หรือทรานส์ฟอร์มเมอร์ (Transformer) โดยใช้ชุดข้อมูลและวิธีแบ่งเดียวกัน รวมทั้งศึกษาการปรับความยาวลำดับหรือการจัดแนวเวลาเพื่อรองรับความเร็วในการทำท่าที่แตกต่างกัน

ควรวัด FPS เวลาแฝงเฉลี่ยและค่าสูงสุด การใช้หน่วยประมวลผลและหน่วยความจำ อัตราการปฏิเสธคำ และอัตราคำผิดในสภาพแสง ฉากหลัง ระยะ และมุมกล้องหลายแบบ การทดสอบควรรวมกรณีไม่พบมือ มือถูกบัง กล้องหลุด แบบจำลองกับรายการคำไม่ตรงกัน และระบบเสียงไม่พร้อม

พร้อมเพิ่มระบบแปลงข้อความเป็นเสียงพูดแบบออฟไลน์เพื่อไม่ให้เกิดการสื่อสารขึ้นอยู่กับอินเทอร์เน็ตเพียงช่องทางเดียว

การออกแบบส่วนติดต่อควรทำร่วมกับกลุ่มเป้าหมายและทดสอบภารกิจจริง เช่น การเลือกคำ การแก้ประโยค การรับรู้สถานะระบบ และการอ่านข้อความ ควรรายงานเวลาที่ใช้ทำภารกิจ จำนวนครั้งที่ต้องทำซ้ำ อัตราความสำเร็จ และความพึงพอใจ นอกจากนี้ต้องกำหนดกระบวนการขอความยินยอม การลดการเก็บภาพดิบ การกำหนดสิทธิ์เข้าถึง และการสำรองข้อมูล เพื่อคุ้มครองความเป็นส่วนตัวของผู้เข้าร่วม

ในระยะยาวสามารถขยายจาก 16 คำไปสู่คลังคำที่ใหญ่ขึ้น พัฒนาการแบ่งช่วงทำอัตโนมัติ และการรู้จำหลายคำต่อเนื่อง

รวมทั้งศึกษาสีหน้าและองค์ประกอบที่ไม่ใช้มือซึ่งมีผลต่อความหมายของภาษามือ การพัฒนาควรดำเนินเป็นลำดับ เริ่มจากสร้างชุดข้อมูลที่สมดุลและตรวจสอบได้ ประเมินกับผู้ทำท่ายาใหม่ วัดสมรรถนะเวลาจริง และจึงเปรียบเทียบแบบจำลองที่ซับซ้อนขึ้น หากดำเนินการตามแนวทางนี้ HandVox จะมีหลักฐานรองรับทั้งด้านความถูกต้อง ความทนทาน และประสบการณ์ผู้ใช่มากขึ้นก่อนนำไปประยุกต์ใช้จริง