

บทที่ 1

บทนำ

1.1 ที่มาและความสำคัญของปัญหา

การสื่อสารระหว่างผู้ใช้ภาษามือกับบุคคลที่ไม่เข้าใจภาษามือยังมีข้อจำกัดในหลายสถานการณ์ เช่น การติดต่อขอรับบริการ การเรียน การทำงาน และการสื่อสารในชีวิตประจำวัน หากไม่มีล่ามหรือผู้ช่วย ผู้ใช้ภาษามืออาจต้องใช้การเขียนหรือการพิมพ์ข้อความแทน ซึ่งไม่สะดวกในทุกบริบท จึงเกิดแนวคิดว่าเทคโนโลยีการมองเห็นด้วยคอมพิวเตอร์ (Computer Vision) มาช่วยตรวจจับท่าทางและแสดงผลให้ผู้อื่นเข้าใจได้ง่ายขึ้น

ปัญหาดังกล่าวไม่ได้เกิดจากความสามารถของผู้ใช้ภาษามือ แต่เกิดจากสภาพแวดล้อมและบริการส่วนใหญ่ยังออกแบบโดยยึดภาษาพูดเป็นหลัก เมื่อผู้ให้บริการไม่เข้าใจภาษามือ การสื่อสารเรื่องง่ายอาจใช้เวลานาน เกิดความคลาดเคลื่อน หรือทำให้ผู้ใช้ต้องพึ่งพาบุคคลอื่น การมีเครื่องมือช่วยแสดงผลท่าที่ระบบรู้จักเป็นข้อความจึงสามารถใช้เป็นช่องทางเสริมในสถานการณ์ที่ไม่มีล่ามได้

การพัฒนาบบรู้จำท่าทางจากวิดีโอมีความท้าทายมากกว่าการจำแนกภาพนิ่ง เนื่องจากความหมายของท่าหลายคำขึ้นอยู่กับทิศทางและลำดับการเคลื่อนไหว นอกจากนี้ รูปร่างมือ ตำแหน่งแขน ระยะจากกล้อง แสง ฉากหลัง และความเร็วของผู้ทำท่าล้วนส่งผลต่อข้อมูลที่ตรวจจับได้ ระบบจึงต้องรักษาลำดับเวลาและลดความแปรผันที่ไม่เกี่ยวข้องก่อนนำข้อมูลไปฝึกแบบจำลอง

โครงการ HandVox

พัฒนาขึ้นเป็นต้นแบบระบบรู้จำท่าทางภาษามือไทยแบบแยกคำจากภาพเว็บแคม ระบบใช้ MediaPipe Holistic ตรวจหาจุดสำคัญของข้อมือและมือทั้งสองข้าง เก็บข้อมูลการเคลื่อนไหวต่อเนื่อง 30 เฟรม และใช้เครื่องเวกเตอร์สนับสนุน (Support Vector Machine: SVM) จำแนกท่าที่มีอยู่ในชุดข้อมูล จากนั้นแสดงชื่อท่า ค่าความเชื่อมั่น ข้อความสะสมเป็นประโยค และเสียงพูดภาษาไทย

เหตุผลที่เลือกใช้ข้อมูลจุดสำคัญแทนภาพสีทั้งภาพ คือข้อมูลมีขนาดเล็กกว่า ลดอิทธิพลจากรายละเอียดของเสื้อผ้าและพื้นหลัง และสามารถอธิบายตำแหน่งสัมพันธ์ของข้อศอก ข้อมือ และนิ้วมือได้ชัดเจน ส่วน SVM แบบ RBF เหมาะกับการทดลองที่มีจำนวนตัวอย่างไม่มากและข้อมูลมีขอบเขตระหว่างคลาสไม่เป็นเส้นตรง จึงใช้เป็นแบบจำลองหลักของต้นแบบรุ่นนี้

HandVox ไม่ได้มุ่งทำเฉพาะตัวจำแนกท่าทาง แต่เชื่อมกระบวนการตั้งแต่การกำหนดรายการท่า การเก็บคลิป การตรวจคุณภาพข้อมูล การฝึกแบบจำลอง การทำนายแบบเวลาจริง ไปจนถึงการนำผลไปสะสมเป็นประโยคและอ่านออกเสียง การรวมทุกขั้นตอนไว้ในระบบเดียวช่วยให้ผู้พัฒนาตรวจสอบความสอดคล้องของข้อมูลและปรับปรุง คำศัพท์ได้โดยไม่ต้องสร้างกระบวนการใหม่ทุกครั้ง

แรงบันดาลใจของโครงการคือการสร้างเครื่องมือที่ช่วยลดช่องว่างในการสื่อสารและเป็นพื้นที่ ทดลองกระบวนการสร้างระบบรู้จำท่าทางตั้งแต่การเก็บข้อมูลจนถึงการใช้งานจริง อย่างไรก็ตาม ระบบรุ่นปัจจุบันรู้จำเฉพาะท่าที่กำหนดไว้ล่วงหน้าและยังไม่ใช้การแปลภาษามือต่อเนื่องอย่างสมบูรณ์ การกำหนดขอบเขตให้ชัดเจนจึงช่วยให้ประเมินผลและนำระบบไปพัฒนาต่อได้อย่างเหมาะสม

ผลของโครงการจึงควรถูกมองเป็นต้นแบบเชิงวิศวกรรมและฐานข้อมูลสำหรับการศึกษาต่อ ไม่ใช่ผลิตภัณฑ์ที่รับรองความถูกต้องในทุกสถานการณ์ การรายงานทั้งผลสำเร็จและข้อจำกัดอย่างตรงไปตรงมามีความสำคัญ เพราะช่วยกำหนดว่าต้องเพิ่มข้อมูล ทดสอบกับผู้ใช้ และปรับระบบส่วนใดก่อนนำไปใช้ในสภาพแวดล้อมจริง

1.2 วัตถุประสงค์ของโครงการ

1. เพื่อพัฒนาระบบ HandVox สำหรับรู้จำท่าทางภาษามือไทยแบบแยกคำจากลำดับภาพเว็บแคมแบบเวลาจริง
2. เพื่อพัฒนาระบบการเพิ่มท่า เก็บคลิป ลบท่า และฝึกแบบจำลองใหม่โดยผู้ใช้ไม่จำเป็นต้องแก้ไขซอร์สโค้ดโดยตรง
3. เพื่อแสดงผลการรู้จำเป็นชื่อท่า ค่าความเชื่อมั่น ข้อความสะสมเป็นประโยค และเสียงพูดภาษาไทย
4. เพื่อประเมินการจำแนกภายในชุดข้อมูลด้วยค่าความถูกต้อง (Accuracy), ค่าความแม่นยำ (Precision), ค่าความระลึก (Recall), คะแนนเอฟวัน (F1-score) และเมทริกซ์ความสับสน (Confusion Matrix) พร้อมระบุข้อจำกัด
5. เพื่อตรวจสอบความสอดคล้องของขั้นตอนเก็บข้อมูล ฝึก และทำนาย รวมถึงกรณีข้อมูลหรืออุปกรณ์ไม่พร้อม
6. เพื่อสรุปผลการพัฒนา ปัญหา และแนวทางเพิ่มผู้ทำท่า คำศัพท์ และการประเมินภายนอกในรุ่นถัดไป

1.3 ขอบเขตของการจัดสร้างโครงการ

โครงการครอบคลุมการพัฒนาต้นแบบบนคอมพิวเตอร์ระบบ Windows โดยใช้เว็บแคมหนึ่งตัวสำหรับรับภาพบุคคลหนึ่งคน ตั้งแต่การเก็บข้อมูล การสกัดคุณลักษณะ การฝึกแบบจำลอง การทำนาย และการนำเสนอผล มีขอบเขตดังต่อไปนี้

1. ระบบรับภาพช่วงบนและมีอย่างน้อยหนึ่งข้าง และรู้จำท่าทีละหนึ่งคำจากข้อมูลล่าสุด 30 เฟรม
2. หนึ่งเฟรมใช้จุดสำคัญ 57 จุด รวม 171 คุณลักษณะ และหนึ่งคลิปถูกแปลงเป็นเวกเตอร์ 5,130 ค่าเพื่อฝึก SVM แบบ RBF
3. ชุดข้อมูลที่ใช้ในโครงการมี 16 ท่า รวม 350 คลิป โดยจำแนกเฉพาะท่าที่มีอยู่ในชุดข้อมูลเท่านั้น
4. ระบบแสดงชื่อท่าและความเชื่อมั่น ใช้ผลย้อนหลัง 3 ครั้งเพื่อลดการสั่น และรับผลเมื่อค่าความเชื่อมั่นไม่น้อยกว่า 0.40
5. ผู้ใช้สามารถเพิ่มคำลงในประโยค ลบคำ ล้างประโยค และอ่านออกเสียงภาษาไทย รวมถึงเพิ่มหรือลบท่าและฝึกแบบจำลองใหม่ได้
6. โครงการไม่ครอบคลุมการรู้จำภาษามือต่อเนื่องหลายคำ การวิเคราะห์ไวยากรณ์ การใช้สีหน้าเป็นคุณลักษณะ หรือการใช้แทนล่ามในบริบทสำคัญ

ขอบเขตด้านผู้ใช้และสภาพแวดล้อม:

ระบบออกแบบให้บุคคลหนึ่งคนอยู่หน้ากล้องในระยะที่มองเห็นศีรษะ ไหล่ แขน และมีมือได้ชัดเจน ใช้ฉากหลังทั่วไปและแสงที่เพียงพอสำหรับการตรวจจับจุดสำคัญ การทดลองยังไม่ครอบคลุมพื้นที่กลางแจ้ง แสงน้อย การบังมือมาก หรือการมีหลายคนในภาพเดียวกัน

ขอบเขตด้านข้อมูล: ตัวอย่างหนึ่งรายการแทนการทำท่าหนึ่งครั้งด้วยข้อมูล 30 เฟรม แต่ละเฟรมประกอบด้วย 15 จุดของช่วงบนและมีข้างละ 21 จุด รวม 171 คุณลักษณะ ชุดข้อมูลปัจจุบันมี 16 ป้ายกำกับและ 350 คลิป โดยจำนวนตัวอย่างต่อคลาสยังไม่เท่ากัน

ขอบเขตด้านซอฟต์แวร์: ระบบทำงานบน Windows 10 หรือ Windows 11 ใช้ Python 3.10 หรือ 3.11 ร่วมกับ OpenCV, MediaPipe, NumPy, scikit-learn, Pillow, gTTS และ pygame ใช้ไฟล์ข้อมูลกับไฟล์แบบจำลองภายในโครงการ และต้องเชื่อมต่ออินเทอร์เน็ตเมื่อสร้างเสียงด้วย gTTS

ขอบเขตด้านการประเมิน:

การประเมินเชิงปริมาณใช้การแบ่งข้อมูลแบบกันไว้โดยคงสัดส่วนคลาส (stratified holdout) อัตรา

80:20 เพื่อคัดกรองต้นแบบ รายงานผลรวม ผลรายคลาส และคู่ทำที่สับสน ส่วนการทดสอบกับผู้ใช้ใหม่ การแบ่งแบบแยกผู้ทำท่า การวัดเวลาแฝง และการศึกษาความพึงพอใจยังเป็นงานที่ต้องดำเนินการต่อ

ข้อจำกัดของการกล่าวอ้าง:

คำว่ารู้จำในรายงานหมายถึงการเลือกป้ายกำกับจากรายการที่ระบบเคยเรียนรู้ ไม่ได้หมายถึงการแปลโครงสร้างภาษามือไทยทั้งหมด ระบบจึงไม่ควรใช้แทนล่ามหรือใช้ตัดสินใจในบริบทด้านการแพทย์ กฎหมาย และความปลอดภัยโดยไม่มีมนุษย์ตรวจสอบ

1.4 ประโยชน์ที่คาดว่าจะได้รับ

ผู้ใช้และผู้พัฒนาจะได้ต้นแบบระบบรู้จำท่าทางภาษามือแบบแยกคำที่ทำงานกับกล้องทั่วไป และแสดงผลได้แบบเวลาจริง

พร้อมกระบวนการสร้างชุดข้อมูลการเคลื่อนไหวและฝึกแบบจำลองที่สามารถเพิ่มคำศัพท์ได้ในภายหลัง

สถานศึกษาหรือผู้สนใจยังสามารถใช้โครงงานเป็นกรณีศึกษาการประยุกต์ใช้การมองเห็นด้วยคอมพิวเตอร์ (Computer Vision) และการเรียนรู้ของเครื่อง (Machine Learning) เพื่อสนับสนุนการสื่อสาร รวมถึงเป็นฐานสำหรับการเก็บข้อมูลจากผู้ใช้งานหลายคนและการประเมินภายนอกในอนาคต

1.5 ทรัพยากรที่ใช้ในการจัดทำโครงงาน

ทรัพยากรที่ใช้ประกอบด้วยคอมพิวเตอร์ระบบ Windows เว็บแคม และลำโพงหรือหูฟัง ร่วมกับ Python 3.10 หรือ 3.11 และไลบรารี OpenCV, MediaPipe Holistic, NumPy, scikit-learn, Pillow, gTTS และ pygame รวมถึงชุดข้อมูลลำดับท่าทางกับไฟล์แบบจำลองของ HandVox

1.6 ระยะเวลาการดำเนินงาน

ตารางที่ 1.1 ระยะเวลาการดำเนินโครงการ

แนวทางการดำเนินโครงการ	มิ.ย.	ก.ค.	ส.ค.	ก.ย.	ต.ค.
1. ศึกษาและรวบรวมข้อมูลที่เกี่ยวข้อง					
2. วิเคราะห์ความต้องการและออกแบบระบบ					
3. พัฒนาระบบ เก็บข้อมูล และสกัดจุดสำคัญ					
4. ฝึกแบบจำลอง ทดสอบ และปรับปรุงระบบ					
5. ประเมินผล สรุปผล และจัดทำรายงาน					

1.7 นิยามศัพท์เฉพาะ

1.7.1 HandVox หมายถึง

ระบบรู้จำท่าทางภาษามือไทยแบบแยกคำจากเว็บแคมและแสดงผลเป็นข้อความกับเสียงพูด

1.7.2 การรู้จำภาษามือแบบแยกคำ หมายถึง

การจำแนกคลิปหนึ่งทำเป็นหนึ่งป้ายกำกับ โดยไม่รวมการแบ่งคำและแปลภาษามือต่อเนื่อง

1.7.3 OpenCV หมายถึง

ไลบรารีสำหรับรับภาพจากเว็บแคม ประมวลผลภาพ และแสดงส่วนติดต่อของระบบ

1.7.4 MediaPipe Holistic หมายถึง

เครื่องมือที่ตรวจหาจุดสำคัญของร่างกาย ใบหน้า และมือจากภาพหรือวิดีโอ

1.7.5 จุดสำคัญ (Landmark) หมายถึง

พิกัดข้อต่อของช่วงบนและมือที่ใช้เป็นคุณลักษณะแทนข้อมูลภาพดิบ

1.7.6 ลำดับภาพ 30 เฟรม หมายถึง

ข้อมูลการเคลื่อนไหวของหนึ่งท่าที่เรียงต่อกันเพื่อรักษาทิศทางและจังหวะของท่า

1.7.7 เวกเตอร์คุณลักษณะ (Feature Vector) หมายถึง

ชุดตัวเลขจากพิกัดจุดสำคัญที่จัดรูปแบบเป็นข้อมูลนำเข้าของแบบจำลอง

1.7.8 เครื่องเวกเตอร์สนับสนุน (Support Vector Machine: SVM) และเคอร์เนลฟังก์ชันฐานรัศมี (Radial Basis Function: RBF) หมายถึง

แบบจำลองและฟังก์ชันสำหรับสร้างขอบเขตจำแนกข้อมูลท่าทางที่ไม่เป็นเส้นตรง

1.7.9 ค่าความเชื่อมั่น (Confidence Score) หมายถึง

ค่าประกอบการตัดสินใจก่อนรับผลทำนายเข้าสู่ระบบ

1.7.10 การแปลงข้อความเป็นเสียงพูด (Text-to-Speech: TTS) หมายถึง
เทคโนโลยีแปลงข้อความหรือข้อความสะสมให้เป็นเสียงพูดภาษาไทย