

บทที่ 2

ความรู้พื้นฐาน

ในการจัดสร้างโครงงาน HandVox จำเป็นต้องศึกษาความรู้พื้นฐาน แนวคิด ทฤษฎี เทคโนโลยี และงานวิจัยที่เกี่ยวข้อง เพื่อกำหนดขอบเขต ออกแบบข้อมูล เลือกแบบจำลอง และประเมินผลระบบอย่างเหมาะสม โดยแบ่งเนื้อหาออกเป็นหัวข้อดังนี้

- 2.1 ภาษามือและการรู้จำ
- 2.2 การมองเห็นด้วยคอมพิวเตอร์ (Computer Vision)
- 2.3 จุดสำคัญที่ใช้ใน HandVox
- 2.4 การปรับมาตรฐานและการแทนลำดับ
- 2.5 เครื่องเวกเตอร์สนับสนุน (Support Vector Machine: SVM)
- 2.6 การแบ่งข้อมูลและการป้องกันการรั่วไหล
- 2.7 การประเมินผล
- 2.8 การทำงานแบบเวลาจริงและเสียงพูด
- 2.9 งานวิจัยที่เกี่ยวข้อง

การทบทวนเอกสารดำเนินการโดยสืบค้นผ่าน Google Scholar ด้วยคำค้นภาษาไทยและภาษาอังกฤษ เช่น Thai sign language recognition, Thai finger spelling, isolated sign language recognition, MediaPipe Holistic, hand landmarks, Support Vector Machine, signer-independent evaluation และ real-time sign language translation จากนั้นตรวจสอบชื่อผู้แต่ง ปีเผยแพร่ วิธีทดลอง ชุดข้อมูล และผลที่รายงานกับหน้าต้นฉบับของวารสาร การประชุมวิชาการ หรือคลังบทความของผู้เผยแพร่ก่อนนำมาเรียบเรียง

เนื้อหาในบทนี้แยกความรู้พื้นฐานออกจากผลการดำเนินงานของโครงงาน โดยส่วนทฤษฎีอธิบายหลักการที่ใช้ในการออกแบบ ส่วนที่กล่าวถึงค่าตั้งของ HandVox อ้างอิงจากซอร์สโค้ดและไฟล์กำหนดค่าของระบบรุ่นปัจจุบัน การแยกสองส่วนนี้ช่วยป้องกันการนำผลคาดหมายไปเขียนเสมือนเป็นผลทดลองจริง และทำให้สามารถตรวจสอบย้อนกลับได้ว่าหลักการใดเชื่อมกับองค์ประกอบใดของระบบ

2.1 ภาษามือและการรู้จำ

ภาษามือเป็นภาษาธรรมชาติในช่องทางการมองเห็นและการเคลื่อนไหว ผู้ใช้สร้างความหมายด้วยมือ แขน ใบหน้า ศีรษะ และลำตัวพร้อมกัน จึงมีลักษณะต่างจากท่าทางสั่งงานทั่วไปซึ่งมักกำหนดสัญลักษณ์จำนวนจำกัดและไม่จำเป็นต้องมีโครงสร้างทางภาษา การพัฒนาระบบรู้จำภาษามือจึงต้องกำหนดให้ชัดว่าระบบกำลังจำแนกท่าที่กำหนดไว้ รู้จำลำดับหน่วยภาษา หรือแปลเป็นประโยคภาษาพูด

2.1.1 ภาษามือกับท่าทางทั่วไป

ท่าทางทั่วไปอาจเป็นสัญญาณที่ผู้ออกแบบระบบกำหนดขึ้น เช่น ยกมือเพื่อเริ่มหรือชูนิ้วเพื่อเลือกคำสั่ง แต่ภาษามือมีรูปแบบการใช้ที่เกิดขึ้นในชุมชนผู้ใช้ มีคำศัพท์ หลักการสร้าง ความหมาย และความแตกต่างระหว่างภาษา ภาษามือไทยจึงไม่ควรถูกแทนด้วยชุดท่าของภาษามือประเทศอื่นโดยตรง แม้บางรูปมืออาจมีลักษณะคล้ายกัน

ระบบคอมพิวเตอร์มองเห็นเพียงข้อมูลภาพหรือพิกัด
จึงยังไม่เข้าใจความหมายทางภาษาด้วยตัวเอง
ผู้พัฒนาต้องกำหนดป้ายกำกับตัวอย่างให้สอดคล้องกับคำที่ต้องการรู้จำ
และต้องอาศัยผู้รู้ภาษามือตรวจสอบความถูกต้องของรูปมือ ทิศทาง จุดเริ่ม จุดสิ้นสุด
และบริบทของแต่ละท่า หากป้ายกำกับผิด
แบบจำลองจะเรียนรู้ความสัมพันธ์ที่ผิดแม้กระบวนการฝึกจะทำงานสมบูรณ์

สำหรับ HandVox คำว่า การรู้จำ
หมายถึงการรับคลิปลิ้นของหนึ่งท่าจากเว็บแคมแล้วเลือกป้ายกำกับจากรายการที่ระบบรองรับ
ไม่ได้หมายถึงการตีความภาษามือไทยทุกคำหรือการแปลประโยคต่อเนื่อง
ข้อจำกัดนี้เป็นส่วนสำคัญของการรายงานผล เพราะความถูกต้องภายในชุดคำ 16
คำไม่สามารถขยายความเป็นความสามารถของระบบแปลภาษามือเต็มรูปแบบได้

2.1.2 องค์ประกอบที่สร้างความหมาย

องค์ประกอบแบบใช้มือประกอบด้วยรูปมือ ตำแหน่งของมือ ทิศทางฝ่ามือ
การวางแนวของนิ้ว การเคลื่อนที่ และความสัมพันธ์ระหว่างมือสองข้าง
รูปมือที่เหมือนกันอาจให้ความหมายต่างกันเมื่ออยู่คนละตำแหน่งหรือเคลื่อนคนละทิศทาง
ดังนั้นการเลือกเฉพาะภาพมือที่ตัดออกจากร่างกายอาจทำให้สูญเสียบริบทสำคัญ

องค์ประกอบที่ไม่ใช่มือประกอบด้วยสีหน้า การเคลื่อนไหวศีรษะ การจ้องมอง ปาก ไหล่ และลำตัว องค์ประกอบเหล่านี้อาจทำหน้าที่เปลี่ยนน้ำเสียงทางภาษา แสดงคำถาม ปฏิเสธ หรือเสริมข้อมูลที่มีไม่ได้สื่อเพียงลำพัง Camgoz และคณะ (2020) ย้ำว่าภาษามือใช้หลายช่องทางพร้อมกัน จึงเป็นปัญหาเชิงพื้นที่และเวลาที่ซับซ้อนกว่าการจำแนกรูปมือ

HandVox รุ่นปัจจุบันใช้จุดสำคัญช่วงบนและมือสองข้าง แต่ไม่ใช้จุดใบหน้ารายละเอียดสูง การตัดสินใจนี้ช่วยลดจำนวนคุณลักษณะและภาระการประมวลผล เหมาะกับต้นแบบคำระดับพื้นฐาน อย่างไรก็ตาม คำที่ต่างกันด้วยสีหน้าหรือรูปปากอาจไม่สามารถแยกได้ จึงต้องเลือกชุดคำให้สอดคล้องกับข้อมูลที่ระบบเก็บจริง

ความสัมพันธ์เชิงเวลามีความสำคัญกับท่าที่เคลื่อนไหว เช่น การเคลื่อนไหวเข้าใกล้ลำตัว การหมุนข้อมือ หรือการยกมือขึ้น หากนำทุกเฟรมมาเฉลี่ยเป็นค่าเดียว ระบบอาจสูญเสียทิศทางและลำดับ HandVox จึงเก็บข้อมูลเป็นลำดับ 30 เฟรมและรักษาดำแหน่งของแต่ละเฟรมไว้ในเวกเตอร์สำหรับการจำแนก

2.1.3 ระดับของงานรู้จำภาษามือ

การรู้จำจากภาพหนึ่งรับข้อมูลหนึ่งเฟรมและเหมาะกับรูปมือที่มีเอกลักษณ์ชัดเจน ข้อดีคือเก็บข้อมูลง่ายและใช้ทรัพยากรน้อย แต่ไม่สามารถอธิบายท่าที่ความหมายขึ้นกับการเคลื่อนไหวหรือการเปลี่ยนรูปมือหลายช่วง

การรู้จำแบบแยกคำรับคลิปที่มีท่าหนึ่งคำและทราบขอบเขตเริ่มต้นกับสิ้นสุดโดยประมาณ งานลักษณะนี้ยังต้องวิเคราะห์เวลา แต่ไม่ต้องค้นหาคำเริ่มและจบตรงจุดใดในวิดีโอยาว จึงเหมาะกับการสร้างต้นแบบและการประเมินรายการคลาส

การรู้จำแบบต่อเนื่องรับวิดีโอหลายคำที่เชื่อมกัน ต้องจัดการช่วงเปลี่ยนระหว่างท่า การกลืนท่าจากคำก่อนหน้าและถัดไป และความยาวของแต่ละคำที่ไม่เท่ากัน ส่วนการแปลภาษามือต้องทำขั้นต่อไป คือเปลี่ยนลำดับหน่วยท่าเป็นประโยคภาษาพูดที่มีลำดับคำและไวยากรณ์ต่างกัน Camgoz และคณะ (2018) จึงแยก การรู้จำภาษามือ (Sign Language Recognition) ออกจากการแปลภาษามือ (Sign Language Translation) อย่างชัดเจน

ระดับงาน	ข้อมูลนำเข้า	ผลลัพธ์	ประเด็นสำคัญ
ภาพนิ่ง	ภาพหนึ่งเฟรม	คลาสของรูปมือ	ไม่เก็บลำดับการเคลื่อนไหว

ระดับงาน	ข้อมูลนำเข้า	ผลลัพธ์	ประเด็นสำคัญ
แยกคำ	คลิปหนึ่งท่า	หนึ่งคำหรือหนึ่งป้ายกำกับ	ต้องกำหนดช่วงเริ่มและสิ้นสุดให้สม่ำเสมอ
ต่อเนื่อง	วิดีโอหลายท่า	ลำดับหน่วยท่า	ต้องแบ่งคำและจัดการช่วงเปลี่ยน
การแปล	วิดีโอภาษามือ	ประโยคภาษาพูด	ต้องเรียนรู้ความหมาย ลำดับคำ และไวยากรณ์

ตารางที่ 2.1 ระดับของงานรู้จำและแปลภาษามือ

2.1.4 การรู้จำแบบแยกคำของ HandVox

HandVox กำหนดหนึ่งตัวอย่างเป็นคลิป 30 เฟรมของหนึ่งคำ ผู้ใช้เริ่มจากท่าเตรียม แสดงการเคลื่อนไหวหลัก และจบภายในหน้าต่างข้อมูลเดียวกัน วิธีนี้ทำให้จำนวนคุณลักษณะของทุกตัวอย่างเท่ากันและสามารถใช้ SVM ซึ่งต้องรับเวกเตอร์ขนาดคงที่ได้

ชุดคำที่มองเห็นต่อผู้ใช้มี 16 คำ ได้แก่ สวัสดี ขอโทษ ไม่เป็นไร ขอขอบคุณ ใช่ ไม่ใช่ ช่วยด้วย ห้องน้ำ น้ำ กิน เจ็บ หมอ เข้าใจ ไม่เข้าใจ ต้องการ และหยุด นอกจากนี้ระบบการฝึกรุ่นใหม่กำหนดคลาสภายในเป็นกลาง (neutral) เพื่อช่วยเรียนรู้กรณีที่ไม่ควรปล่อยคำออกไป คลาสภายในจะใช้ระหว่างการจำแนกแต่ไม่แสดงเป็นคำในประโยค

การเลือกคำควรคำนึงถึงความต่างทางสายตา ความสำคัญต่อสถานการณ์ และความสามารถในการเก็บตัวอย่าง คำที่มีการเคลื่อนไหวคล้ายกันมากต้องมีจำนวนตัวอย่างมากขึ้นและควรตรวจเมตริกซ์ความสับสน (Confusion Matrix) เป็นพิเศษ ส่วนคำ ช่วยด้วย ถูกกำหนดเป็นคำสำคัญซึ่งต้องมีค่าความระลึก (Recall) สูงกว่าค่าทั่วไปตามเกณฑ์รับรองของโครงการ

2.1.5 ความแปรผันและความท้าทาย

ผู้ทำท่าต่างกันมีขนาดมือ สัดส่วนร่างกาย ความถนัด ความเร็ว และรูปแบบการเคลื่อนไหวไม่เหมือนกัน แม้เป็นคำเดียวกัน ตำแหน่งพิกัดมือจึงอาจแตกต่างกันมาก หากเก็บข้อมูลจากคนเพียงคนเดียว แบบจำลองอาจจดจำลักษณะของบุคคลนั้นมากกว่ารูปแบบของคำ

สภาพการถ่ายภาพเพิ่มความแปรผันจากแสง ฉากหลัง เสื้อผ้า ระยะกล้อง มุมกล้อง ความละเอียด และการบังมือ จุดสำคัญอาจหายหรือกระโดดเมื่อมือเคลื่อนเร็ว อยู่ชิดขอบภาพ หรือซ้อนกับใบหน้าและลำตัว การประเมินในสภาพควบคุมจึงควรแยกจากการทดสอบใช้งานจริง

อีกปัญหาคือท่าช่วงเปลี่ยนระหว่างคำและท่าที่ไม่อยู่ในชุดฝึก ตัวจำแนกแบบปิดจะพยายามเลือกหนึ่งคลาสเสมอ แม้ข้อมูลนำเข้าไม่ใช่คำที่รู้จัก ระบบใช้งานจริงจึงต้องมีเกณฑ์ความเชื่อมั่น คลาส neutral กลไยยืนย่นหลายเฟรม และสถานะรอให้ผู้ใช้ปล่อยท่า เพื่อลดการสร้างคำผิดจากช่วงที่ผู้ใช้กำลังเปลี่ยนมือ

2.2 การมองเห็นด้วยคอมพิวเตอร์ (Computer Vision)

การมองเห็นด้วยคอมพิวเตอร์เป็นกระบวนการทำให้คอมพิวเตอร์รับและแปลงข้อมูลภาพเป็นตัวแทนที่ใช้ตัดสินใจได้ สำหรับ HandVox กระบวนการเริ่มจากเว็บแคม ส่งภาพให้ OpenCV จัดการเฟรม แปลงลำดับสี และส่งเข้า MediaPipe เพื่อประมาณจุดสำคัญ จากนั้นระบบจึงแปลงพิกัดเป็นคุณลักษณะสำหรับแบบจำลอง

2.2.1 ภาพดิจิทัล วิดีโอ และระบบพิกัด

ภาพดิจิทัลประกอบด้วยพิกเซลเรียงเป็นตาราง แต่ละพิกเซลเก็บค่าความเข้มของช่องสี วิดีโอคือภาพหลายเฟรมที่เรียงตามเวลา อัตราเฟรมกำหนดความถี่ในการสังเกตการเคลื่อนไหว หากอัตราเฟรมต่ำเกินไป การเคลื่อนไหวเร็วอาจขาดช่วง แต่หากสูงมาก ภาระประมวลผลและจำนวนข้อมูลจะเพิ่มขึ้น

OpenCV อ่านภาพในลำดับสี BGR ขณะที่ MediaPipe รับ RGB โปรแกรมจึงต้องแปลงลำดับสีก่อนประมวลผล หากข้ามขั้นตอนนี้ ค่าช่องสีจะสลับและลดคุณภาพการตรวจจับ แม้ภาพบนหน้าจออาจดูใกล้เคียงในบางกรณี

พิกัดภาพ x และ y มักถูกทำให้เป็นสัดส่วนกับความกว้างและความสูงของเฟรม ส่วนค่า z ของ MediaPipe แทนความลึกเชิงสัมพัทธ์ ไม่ใช่ระยะจริงจากกล้องโดยตรง การใช้พิกัดเหล่านี้ต้องคำนึงว่าความละเอียดภาพ อัตราส่วนภาพ และตำแหน่งผู้ใช้ส่งผลต่อค่าที่ได้

2.2.2 บทบาทของ OpenCV

OpenCV ทำหน้าที่เปิดอุปกรณ์กล้อง อ่านเฟรม กลับภาพในแนวนอน แปลงสี วาดกรอบ แสดงข้อความ และรับคีย์หรือการคลิกจากผู้ใช้ การกลับภาพช่วยให้หน้าจอทำงานเหมือนกระจกซึ่งใช้งานง่าย แต่ต้องใช้แนวทางเดียวกันทั้งตอนเก็บข้อมูลและตรวจจับเพื่อไม่ให้ทิศซ้ายขวาของตัวอย่างต่างกัน

HandVox ขอภาพจากกล้องที่ขนาด 1280 x 720 พิกเซล

แต่ความละเอียดจริงขึ้นกับอุปกรณ์และไดรเวอร์ ค่าความละเอียดที่สูงขึ้นช่วยให้เห็นรายละเอียดมือ แต่เพิ่มเวลาถ่ายโอนและประมวลผล

ดังนั้นการตั้งค่าควรทดสอบร่วมกับอัตราเฟรมและความหน่วงบนเครื่องเป้าหมาย

ส่วนติดต่อบนภาพกล้องมีหน้าที่มากกว่าการตกแต่ง

เพราะช่วยให้ผู้ใช้เห็นว่าระบบตรวจพบร่างกายหรือมือหรือไม่ แสดงคำที่กำลังพิจารณา สถานะยืนยัน ค่าความเชื่อมั่น ประโยคปัจจุบัน และปุ่มควบคุม

การให้ข้อมูลย้อนกลับทันทีช่วยให้ผู้ใช้ปรับตำแหน่งและจังหวะการทำท่าได้

2.2.3 การตรวจจับและการติดตาม

การตรวจจับค้นหาวัตถุหรือส่วนร่างกายอยู่บริเวณใดในภาพ

ส่วนการติดตามใช้ข้อมูลจากเฟรมก่อนหน้าเพื่อประมาณตำแหน่งในเฟรมถัดไป

การติดตามช่วยลดการตรวจใหม่ทุกเฟรมและทำให้พิกัดต่อเนื่องขึ้น แต่หากวัตถุหลุดกรอบหรือถูกบัง ระบบอาจต้องกลับไปตรวจจับใหม่

HandVox ใช้ MediaPipe Holistic ในโมเดลวิดีโอต่อเนื่อง กำหนด model_complexity

เท่ากับ 1 เปิด smooth_landmarks

และกำหนดค่าความเชื่อมั่นขั้นต่ำของการตรวจจับกับการติดตามเท่ากับ 0.70

ค่าดังกล่าวเป็นการประนีประนอมระหว่างคุณภาพ ความเร็ว และความต่อเนื่องของจุดสำคัญ

การทำให้จุดราบรื่นช่วยลดการสั่นจากความคลาดเคลื่อนรายเฟรม

แต่มีโอกาสเพิ่มความหน่วงและทำให้การเปลี่ยนเร็วถูกกรองบางส่วน

จึงต้องประเมินร่วมกับขนาดหน้าต่าง 30 เฟรมและกลไกยืนยันผล

ไม่ควรพิจารณาค่าตั้งของตัวติดตามแยกจากพฤติกรรมทั้งระบบ

2.2.4 ภาพติดกับจุดสำคัญ

การเรียนรู้จากภาพติดเก็บข้อมูลพื้นผิว สี รูปร่างมือ ใบหน้า เสื้อผ้า และฉากหลังไว้ครบ

แบบจำลองเชิงลึกสามารถเรียนรู้คุณลักษณะจากข้อมูลจำนวนมาก

แต่ต้องใช้ทรัพยากรสูงและมีความเสี่ยงเรียนรู้สิ่งรบกวน เช่น สีเสื้อหรือสถานที่ถ่ายภาพ

การใช้จุดสำคัญลดภาพให้เหลือโครงสร้างพิกัดของข้อต่อ

ทำให้ข้อมูลมีขนาดเล็กและลดอิทธิพลของพื้นหลัง

เหมาะกับโครงการที่มีข้อมูลจำกัดและต้องทำงานบนคอมพิวเตอร์ทั่วไป อย่างไรก็ตาม

ความผิดพลาดของตัวประมาณจุดสำคัญจะถูกส่งต่อไปยังตัวจำแนก
และรายละเอียดที่ไม่มีในพิกัดจะไม่สามารถกู้คืนได้

แนวทางผสมสามารถใช้ทั้งภาพเฉพาะมือ จุดสำคัญ
และลำดับเวลาเพื่อให้แต่ละแหล่งข้อมูลชดเชยข้อจำกัดกัน งาน SAM-SLR ของ Jiang และคณะ
(2021) แสดงแนวความคิดการรวมข้อมูลภาพ ความลึก และโครงกระดูก
แต่ขอบเขตดังกล่าวต้องใช้ข้อมูลและพลังประมวลผลมากกว่า HandVox รุ่นต้นแบบ

ตัวแทนข้อมูล	ข้อดี	ข้อจำกัด	ความเหมาะสมกับ HandVox
ภาพเต็ม	เก็บบริบทและองค์ประกอบ รอบ	มิติสูงและไวต่อฉากหลัง	เหมาะเมื่อมีข้อมูลและทรัพยากรมาก
ภาพเฉพาะมือ	เน้นรูปมือและรายละเอียดนิ้ว	สูญเสียตำแหน่งเทียบร่างกาย	ใช้เสริมค่าที่ต่างกันด้วยรูปมือ
จุดมือ	ข้อมูลเล็กและลดผลจากพื้น หลัง	ไม่เห็นสี พื้นผิว และสีหน้า	เหมาะกับค่าที่รูปมือเด่น
จุดมือและช่วงบน	เห็นรูปมือ ตำแหน่ง และท่าทาง	ขึ้นกับคุณภาพ landmark	เป็นตัวแทนหลักของระบบปัจจุบัน
หลายรูปแบบร่วมกัน	ข้อมูลแต่ละชนิดชดเชยกัน	ซับซ้อนและใช้ทรัพยากรสูง	เป็นแนวทางพัฒนาต่อยอด

ตารางที่ 2.2 การเปรียบเทียบตัวแทนข้อมูลภาพสำหรับการรู้จำ

2.2.5 ปัจจัยของสภาพแวดล้อม

แสงน้อยทำให้เกิดสัญญาณรบกวนและขอบมือไม่ชัด
แสงจากด้านหลังอาจทำให้มือนี้นิดกว่าฉาก
ส่วนแสงที่เปลี่ยนระหว่างคลิปทำให้คุณภาพการตรวจจับไม่คงที่
ควรเก็บข้อมูลหลายสภาพแสงแต่ยังต้องรักษาให้มือและช่วงบนมองเห็นได้

มุกกล้องเปลี่ยนรูปร่างที่ฉายลงบนภาพและทำให้พิกัด z มีความคลาดเคลื่อน
การฝึกเฉพาะกล้องตรงระดับเดียวอาจให้ผลดีในห้องทดลองแต่ลดลงเมื่อวางกล้องสูงหรือต่ำกว่าเดิม
การกำหนดตำแหน่งใช้งานที่แนะนำและการเก็บตัวอย่างหลายมุมจึงเป็นคุณสมบัติที่ควรทำร่วมกัน

การบังเกิดได้เมื่อมือซ้อนกัน มือผ่านใบหน้า หรือหลุดนอกกรอบ ถ้าพบมือเพียงข้างเดียว
HandVox เติมนูนยให้มือที่หายเพื่อรักษามิติข้อมูล แต่หากจุดหายต่อเนื่องเป็นเวลานาน
ตัวอย่างจะมีข้อมูลไม่พอและควรถูกปฏิเสธในขั้นตรวจคุณภาพ

2.3 จุดสำคัญที่ใช้ใน HandVox

จุดสำคัญ (landmark) เป็นพิกัดตัวแทนตำแหน่งข้อต่อและส่วนของร่างกาย การเลือกจุดต้องครอบคลุมข้อมูลที่จำเป็นต่อการแยกค่าโดยไม่เพิ่มมิติที่ไม่จำเป็น HandVox ใช้จุดช่วงบน 15 จุดและจุดมือข้างละ 21 จุด แต่ละจุดมีค่า x , y และ z รวม 171 ค่าในหนึ่งเฟรม

2.3.1 กรอบงาน MediaPipe

Lugaresi และคณะ (2019) เสนอ MediaPipe เป็นกรอบงานสำหรับประกอบ perception pipeline จากส่วนรับสื่อ แบบจำลอง และตัวแปลงข้อมูลในรูปกราฟ ช่วยให้พัฒนาต้นแบบ วัตถุทรัพยากร และนำการประมวลผลไปใช้ข้ามแพลตฟอร์มได้

แนวคิดแบบ pipeline เหมาะกับ HandVox เพราะสามารถแยกขั้นรับภาพ การตรวจจุดสำคัญ การสกัดคุณลักษณะ การสะสมลำดับ และการจำแนกออกจากกัน เมื่อเกิดปัญหาจึงตรวจได้ว่าความผิดพลาดเริ่มจากกล้อง จุดสำคัญ หรือแบบจำลอง

MediaPipe ไม่ได้ทำหน้าที่จำแนกคำภาษามือให้ HandVox โดยตรง แต่ให้พิกัดที่ใช้เป็นข้อมูลนำเข้าของแบบจำลอง SVM ความถูกต้องของระบบสุดท้ายจึงขึ้นกับทั้งตัวตรวจจุดสำคัญและตัวจำแนก ไม่ควรรายงานผลของส่วนใดส่วนหนึ่งแทนประสิทธิภาพทั้งระบบ

2.3.2 จุดมือ 21 จุด

Zhang และคณะ (2020) อธิบาย MediaPipe Hands ว่าใช้ palm detector เพื่อค้นหาบริเวณมือ แล้วใช้ hand landmark model ประมาณโครงมือจากภาพ RGB กล้องเดียว กระบวนการสองขั้นช่วยให้โมเดล landmark ทำงานกับบริเวณที่จัดแนวแล้วและรองรับการติดตามแบบเวลาจริงบนอุปกรณ์

จุดมือ 21 จุดครอบคลุมข้อมือ โคนนิ้ว ข้อมือ และปลายนิ้วทั้งห้า การเปรียบเทียบตำแหน่งระหว่างจุดช่วยอธิบายการงอ เหยียด กาง และทิศทางของนิ้วได้ดีกว่ากรอบสี่เหลี่ยมรอบมือเพียงอย่างเดียว

พิกัดมือยังมีข้อจำกัดเมื่อมือหันด้านข้าง นิ้วซ้อนกัน หรือส่วนหนึ่งอยู่นอกภาพ การทำให้มองเห็นมือชัดและเก็บหลายตัวอย่างจึงยังจำเป็น แม้ตัวตรวจจุดสำคัญจะผ่านการฝึกมาก่อนแล้วก็ตาม

2.3.3 จุดช่วงบน 15 จุด

HandVox เลือกจุดหมายเลข 0, 2, 5, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 23 และ 24 จากโครงสร้างของ MediaPipe จุดเหล่านี้ครอบคลุมศีรษะบางส่วน ไหล่ ศอก ข้อมือ และสะโพก ซึ่งเพียงพอสำหรับอธิบายตำแหน่งมือเทียบช่วงบนในคำพื้นฐาน

ไหล่ซ้ายและไหล่ขวาใช้สร้างจุดกึ่งกลางและระยะอ้างอิงในการปรับมาตรฐาน ศอกกับข้อมือช่วยอธิบายแนวแขน ส่วนจุดศีรษะและสะโพกช่วยให้เห็นตำแหน่งโดยรวม การใช้เฉพาะ 15 จุดลดจำนวนคุณลักษณะจากการเก็บโครงสร้างทั้งตัว

การตัดจุดขาส่วนล่างออกเหมาะกับการบอกลักษณะที่เน้นช่วงบนและคำที่แสดงด้วยมือ แต่ระบบจะไม่เหมาะกับภาษามือหรือท่าทางที่ใช้การเคลื่อนไหวส่วนล่างอย่างมีความหมาย การเลือกจุดจึงเป็นการกำหนดขอบเขตของสิ่งที่แบบจำลองสามารถเรียนรู้ได้

2.3.4 การสร้างเวกเตอร์ 171 คำ

จุดช่วงบน 15 จุดสร้างข้อมูล 45 คำ เพราะแต่ละจุดมี 3 แกน มือซ้าย 21 จุดสร้าง 63 คำ และมือขวาก็ 63 คำ ผลรวมเท่ากับ $45 + 63 + 63$ หรือ 171 คำในหนึ่งเฟรม ลำดับคอลัมน์ถูกกำหนดค่าที่เป็น pose ก่อน ตามด้วย left_hand และ right_hand

การใช้ลำดับเดียวกันเป็นเงื่อนไขสำคัญ เพราะตัวเลขตำแหน่งหนึ่งไม่มีความหมายในตัวเอง หากขณะฝึกตำแหน่งที่ 46 หมายถึงข้อมือซ้าย แต่ขณะทำนายกลับหมายถึงข้อมือขวา แบบจำลองจะได้รับความหมายคนละแบบแม้จำนวนคุณลักษณะยังเท่ากัน

ไฟล์ body_features.py ถูกใช้ร่วมกันทั้งขั้นเก็บข้อมูลและตรวจจับ เพื่อลดความเสี่ยงที่สูตรปรับมาตรฐาน จำนวนจุด หรือการเติมค่ามือที่หายจะแตกต่างกัน การรวมตรรกะสำคัญไว้ที่เดียวเป็นหลักการควบคุมความสอดคล้องของข้อมูลที่มีผลโดยตรงต่อความถูกต้อง

กลุ่มจุด	จำนวนจุด	ค่าต่อจุด	จำนวนคุณลักษณะ	หน้าที่
ช่วงบน	15	x, y, z	45	ตำแหน่งศีรษะ ไหล่ แขน และลำตัว
มือซ้าย	21	x, y, z	63	รูปมือและการเคลื่อนไหวมือซ้าย
มือขวา	21	x, y, z	63	รูปมือและการเคลื่อนไหวมือขวา
รวมต่อเฟรม	57	3	171	ตัวแทนช่วงบนและมือทั้งสองข้าง
รวม 30 เฟรม	-	-	5,130	เวกเตอร์หนึ่งคลิสำหรับ SVM

ตารางที่ 2.3 จำนวนจุดและมิติคุณลักษณะของ HandVox

2.3.5 ข้อมูลหายและการระบุข้างของมือ

หากไม่พบโครงร่างช่วงบน หรือไม่พบมือทั้งสองข้าง ฟังก์ชันสกัดคุณลักษณะจะคืนค่า None และเฟรมนั้นไม่ถูกเพิ่มในลำดับ เพราะไม่มีจุดอ้างอิงหรือไม่มีข้อมูลมือเพียงพอสำหรับการจำแนก

หากพบมือเพียงข้างเดียว ระบบเติมศูนย์ 63 ค่าให้มือที่หาย

การเติมศูนย์ช่วยรักษารูปร่างขนาดเวกเตอร์ แต่ศูนย์หมายถึง ไม่ตรวจพบ ไม่ใช่ตำแหน่งจริงของมือ ดังนั้นจำนวนเฟรมที่เติมศูนย์ควรถูกใช้เป็นตัวชี้วัดคุณภาพคลิปด้วย

การกลับภาพแบบกระจกและการตีความ left_hand กับ right_hand

ต้องสอดคล้องกันทุกชั้น หากกระบวนการใดกลับภาพต่างจากอีกกระบวนการ

ระบบอาจสลับมือซ้ายและขวา

ควรมีการทดสอบแบบหน่วยที่ยืนยันลำดับคอลัมน์และตัวอย่างที่ใช้มือข้างเดียวโดยเฉพาะ

2.3.6 ข้อดีด้านขนาดข้อมูลและความเป็นส่วนตัว

ลำดับจุดสำคัญมีขนาดเล็กกว่าวิดีโอดิบมาก จึงจัดเก็บ โหลด และฝึกได้รวดเร็วขึ้น อีกทั้งลดรายละเอียดใบหน้า เสื้อผ้า และฉากหลังที่ไม่จำเป็นต่อแบบจำลอง เหมาะกับการทดลองหลายรอบและการตรวจเวอร์ชันชุดข้อมูล

อย่างไรก็ตาม

พิกัดการเคลื่อนไหวยังเป็นข้อมูลเกี่ยวกับบุคคลและอาจเปิดเผยรูปแบบการเคลื่อนไหวหรือสัดส่วนบางอย่างได้ จึงยังต้องควบคุมสิทธิการเข้าถึง ขอความยินยอม และกำหนดระยะเวลาจัดเก็บ

ไม่ควรสรุปว่าการตัดภาพออกทำให้ข้อมูลไม่มีความเสี่ยงด้านความเป็นส่วนตัวทั้งหมด

2.4 การปรับมาตรฐานและการแทนลำดับ

พิกัดที่ได้จากกล้องแปรผันตามตำแหน่งและระยะของผู้ใช้ HandVox

จึงปรับพิกัดให้อยู่ในรูปร่างกายก่อนเก็บ แล้วนำ 30 เฟรมมาเรียงเป็นเวกเตอร์ขนาดคงที่

วิธีนี้ลดความแปรผันบางส่วนและทำให้แบบจำลอง SVM

รับข้อมูลเวลาได้โดยไม่ต้องใช้โครงข่ายลำดับโดยตรง

2.4.1 การเลื่อนจุดอ้างอิง

ระบบคำนวณจุดกึ่งกลางระหว่างไหล่ซ้ายกับไหล่ขวาในสามแกน

แล้วนำพิกัดของทุกจุดลบด้วยจุดกึ่งกลางดังกล่าว

ผลลัพธ์คือพิกัดสัมพันธ์กับลำตัวแทนพิกัดสัมพันธ์กับมุมมองภาพ

การเลื่อนจุดอ้างอิงช่วยลดผลจากการย่นค่อนไปทางซ้ายหรือขวาและการขยับขึ้นลงเล็กน้อย ตัวอย่างของคำเดียวกันจึงอยู่ในระบบพิกัดใกล้เคียงกันมากขึ้น แต่ไม่แก้ผลของการหมุนตัวหรือการเปลี่ยนมุมกล้องทั้งหมด

การเลือกกึ่งกลางไหล่เหมาะกับงานช่วงบนเพราะตรวจพบได้ค่อนข้างสม่ำเสมอและอยู่ใกล้ศูนย์กลางการเคลื่อนไหวของแขน หากไหล่ถูกบังหรือประมาณผิด ความคลาดเคลื่อนจะกระทบทุกจุดในเฟรมนั้นพร้อมกัน

2.4.2 การปรับขนาดด้วยระยะไหล่

หลังเลื่อนจุด ระบบหารค่าพิกัดด้วยระยะยูคลิดระหว่างไหล่ซ้ายกับไหล่ขวา ระยะดังกล่าวทำหน้าที่เป็นสเกลโดยประมาณของผู้ใช้ในภาพ ช่วยลดผลจากการย่นใกล้หรือไกลกล้องและความแตกต่างของขนาดร่างกาย

โค้ดกำหนดค่าต่ำสุดของสเกลเป็น $1e-6$ เพื่อป้องกันการหารด้วยศูนย์ หากตัวตรวจจุดสำคัญให้ตำแหน่งไหล่เกือบตรงกัน การหารด้วยค่าที่เล็กมากอาจสร้างค่าคุณลักษณะสูงผิดปกติ จึงควรตรวจค่าผิดปกติและคุณภาพ landmark ในขั้นเตรียมข้อมูล

การปรับด้วยระยะไหล่ไม่ทำให้ข้อมูลคงที่ต่อมุมมองสามมิติอย่างสมบูรณ์ เพราะระยะที่ฉายบนภาพเปลี่ยนเมื่อผู้ใช้หันตัว และค่า z เป็นความลึกเชิงสัมพัทธ์ ดังนั้นยังควรเก็บข้อมูลหลายมุมที่อยู่ในขอบเขตใช้งานจริง

2.4.3 หน้าต่างเวลา 30 เฟรม

หนึ่งคลิปของ HandVox มี 30 เฟรม จำนวนดังกล่าวสร้างจุดสมดุลระหว่างการเห็นการเคลื่อนไหวทั้งท่าและขนาดข้อมูล หากกล้องทำงานใกล้ 30 เฟรมต่อวินาที หน้าต่างจะครอบคลุมเวลาประมาณหนึ่งวินาที แต่เวลาจริงอาจต่างตามอัตราเฟรมของเครื่อง

ผู้เก็บข้อมูลต้องทำให้ท่าในหน้าต่างเดียวกัน หากทำเร็วมาก ลำดับจะมีช่วงอยู่หนึ่งจำนวนมาก หากทำช้าเกินไป ส่วนท้ายของท่าอาจหลุดนอกคลิป ความต่างของจังหวะทำให้ตำแหน่งเหตุการณ์สำคัญอยู่คนละเฟรมและลดความคล้ายของตัวอย่างในคลาสเดียวกัน

การเก็บตัวอย่างหลายจังหวะช่วยให้แบบจำลองเห็นความแปรผัน แต่ต้องไม่กว้างจนขอบเขตของคลาสไม่ชัด ในอนาคตสามารถทดลอง resampling, Dynamic Time Warping หรือแบบจำลองลำดับที่รองรับความยาวไม่เท่ากันเพื่อจัดแนวเวลาให้ดีขึ้น

2.4.4 การเรียงลำดับเป็นเวกเตอร์

เมื่อได้คุณลักษณะ 171 ค่าต่อเฟรม ระบบเรียงเฟรมที่ 1 ถึง 30 ต่อกันเป็นเวกเตอร์ 5,130 ค่า ตำแหน่ง 1-171 แทนเฟรมแรก ตำแหน่ง 172-342 แทนเฟรมที่สอง และดำเนินต่อไปจนถึงเฟรมที่ 30

แม้ SVM จะไม่มีกลไกหน่วยความจำแบบ RNN

แต่การวางข้อมูลแต่ละเวลาไว้คนละตำแหน่งทำให้แบบจำลองเห็นรูปแบบของลำดับ ทำให้เคลื่อนจากซ้ายไปขวาจึงให้เวกเตอร์ต่างจากทำให้เคลื่อนย้อนกลับ แม้จะมีชุดพิกัดคล้ายกันเมื่อไม่สนใจลำดับ

ข้อแลกเปลี่ยนคือมิติข้อมูลสูงเมื่อเทียบกับจำนวนคลิป หากมีตัวอย่างน้อย แบบจำลองอาจเรียนรู้รายละเอียดเฉพาะของคลิป การปรับมาตรฐาน การเลือกจุด และการประเมินข้ามผู้ทำจึงมีความสำคัญมากกว่าการพิจารณาความถูกต้องบนชุดฝึก

ขั้นตอน	ข้อมูลเข้า	การแปลง	ข้อมูลออก
ตรวจจุดสำคัญ	ภาพ RGB	ประมาณ pose และ hands	พิกัดจุดของหนึ่งเฟรม
เลือกจุด	จุดทั้งหมด	เลือกช่วงบน 15 และมือ 42 จุด	57 จุด
เลื่อนพิกัด	57 จุด	ลบด้วยกึ่งกลางไหล่	พิกัดสัมพันธ์กับลำตัว
ปรับขนาด	พิกัดสัมพันธ์	หารด้วยระยะไหล่	พิกัดมาตรฐาน 171 ค่า
สะสมเวลา	171 ค่าต่อเฟรม	เก็บตามลำดับ 30 เฟรม	เมทริกซ์ 30 x 171
แผ่เวกเตอร์	เมทริกซ์ 30 x 171	เรียงตามเวลา	เวกเตอร์ 5,130 ค่า

ตารางที่ 2.4 ขั้นตอนการแปลงภาพเป็นเวกเตอร์ของหนึ่งคลิป

2.4.5 ความเร็ว จังหวะ และการจัดแนวเวลา

ความเร็วของผู้ทำทำเป็นแหล่งความแปรผันที่ระบบปรับด้วยตำแหน่งและขนาดไม่ได้ หากเหตุการณ์สำคัญเกิดเฟรมที่ 10 ในตัวอย่างหนึ่งแต่เกิดเฟรมที่ 20 ในอีกตัวอย่าง ระยะในเวกเตอร์อาจสูงแม้ความหมายเหมือนกัน

แนวทางพื้นฐานคือให้คำแนะนำการเก็บข้อมูล ใช้ตัวนับก่อนเริ่ม และเก็บหลายรอบในจังหวะธรรมชาติ แนวทางขั้นสูงคือปรับจำนวนเฟรมด้วย interpolation จัดแนวลำดับด้วย Dynamic Time Warping หรือใช้ LSTM, GRU, Temporal Convolution และ Transformer

HandVox เลือกเวกเตอร์คงที่เพื่อให้ระบบง่ายและตรวจสอบได้
การพัฒนาต่อควรเปรียบเทียบวิธีใหม่บนชุดข้อมูลและวิธีแบ่งเดียวกัน
เพื่อให้ทราบว่าผลดีขึ้นจากแบบจำลองจริง ไม่ใช่จากการเปลี่ยนเงื่อนไขทดลอง

2.4.6 การตรวจคุณภาพคุณลักษณะ

ก่อนฝึกควรตรวจมิติข้อมูล ค่า NaN ค่าอนันต์ ค่าผิดปกติ จำนวนเฟรมที่มีมือหาย
และการกระจายของแต่ละแกน หากพบคลิปผิดปกติควรย้อนดูวิดีโอตัวอย่างหรือข้อมูลกำกับ
(metadata) แทนการลบทิ้งโดยไม่บันทึกเหตุผล

การทำภาพตัวอย่างของเส้นทางจุดหรือสถิติต่อเฟรมช่วยตรวจว่าลำดับไม่กลับด้าน
มือไม่สลับ และจุดกึ่งกลางไหล่ทำงานตามคาด

การตรวจคุณภาพก่อนฝึกช่วยลดเวลาที่สูญเสียไปกับการปรับแบบจำลองเพื่อแก้ปัญหาซึ่งเกิดจากข้อ
มูล

2.5 เครื่องเวกเตอร์สนับสนุน (Support Vector Machine: SVM)

เครื่องเวกเตอร์สนับสนุน (Support Vector Machine: SVM)
เป็นวิธีการเรียนรู้แบบมีผู้สอนสำหรับจำแนกข้อมูล
โดยค้นหาขอบเขตการตัดสินใจที่แยกคลาสและมีระยะขอบกว้าง Cortes และ Vapnik (1995) เสนอ
Support-Vector Networks
สำหรับข้อมูลที่ไม่สามารถแยกได้สมบูรณ์และใช้การแปลงไปยังปริภูมิคุณลักษณะเพื่อสร้างขอบเขตไม่
เชิงเส้น

2.5.1 ไฮเปอร์เพลนและระยะขอบ

ในกรณีสองคลาส SVM สร้างไฮเปอร์เพลนเพื่อแบ่งตัวอย่างออกเป็นสองด้าน
ตัวอย่างที่อยู่ใกล้ขอบเขตและมีผลต่อคำตอบเรียกว่า support vectors
ระยะระหว่างขอบเขตกับตัวอย่างสำคัญทั้งสองด้านเรียกว่า margin

แนวคิดระยะขอบกว้างมุ่งสร้างขอบเขตที่ไม่เพียงแยกข้อมูลฝึก
แต่ยังมีพื้นที่เผื่อสำหรับตัวอย่างใหม่ ความสามารถในการทั่วไปจึงขึ้นกับความซับซ้อนของขอบเขต
คุณภาพข้อมูล และความเหมาะสมของพารามิเตอร์
ไม่ได้ขึ้นกับการจำแนกชุดฝึกถูกทั้งหมดเพียงอย่างเดียว

ข้อมูลของ HandVox มี 5,130 มิติต่อคลิป แต่จำนวนคลิปต่อคลาสจำกัด SVM
เหมาะสมกับสถานการณ์ที่ตัวแทนคุณลักษณะถูกกำหนดไว้แล้วและชุดข้อมูลยังไม่ใหญ่พอสำหรับโครงข่าย

ายเชิงลึกขนาดมาก อย่างไรก็ตาม มิติสูงยังเพิ่มความเสี่ยงต่อการเรียนรู้จดจำข้อมูลฝึกมากเกินไป (overfitting) จึงต้องทดสอบกับผู้ทำที่ไม่อยู่ในชุดฝึก

2.5.2 Soft Margin และค่า C

ข้อมูลจริงมีสัญญาณรบกวนและคลาสอาจซ้อนกัน Soft Margin ยอมให้ตัวอย่างบางส่วนอยู่ผิดด้านของขอบเขตโดยมีค่าปรับ ค่า C ควบคุมการแลกเปลี่ยนระหว่างการลดข้อผิดพลาดบนชุดฝึกกับการรักษาขอบเขตให้เรียบ ค่า C สูงให้โทษกับตัวอย่างที่จำแนกผิดมาก ขอบเขตจึงพยายามตามข้อมูลฝึกและอาจไวต่อค่าผิดปกติ ค่า C ต่ำยอมให้ผิดมากขึ้นเพื่อสร้างขอบเขตที่เรียบกว่า ไม่มีค่าเดียวที่ดีที่สุดสำหรับทุกข้อมูล จึงควรเลือกด้วย validation ที่ไม่ปะปนกับชุดทดสอบ

HandVox กำหนด C เท่ากับ 10.0 เป็นค่าเริ่มต้น ค่านี้ต้องรายงานควบคู่กับ kernel, gamma, class_weight และวิธีแบ่งข้อมูล เพราะผลของ C ไม่สามารถตีความแยกจากค่าที่ควบคุมรูปร่างขอบเขตและสัดส่วนคลาส

2.5.3 เคอร์เนล (Kernel) และฟังก์ชันฐานรัศมี (Radial Basis Function: RBF)

Kernel

คำนวณความคล้ายของตัวอย่างเหมือนแปลงข้อมูลไปยังปริภูมิที่ซับซ้อนกว่าโดยไม่ต้องสร้างฟังก์ชันใหม่ทั้งหมด Linear kernel เหมาะเมื่อคลาสแยกได้ด้วยความสัมพันธ์เชิงเส้น ส่วน Polynomial และ RBF รองรับขอบเขตไม่เชิงเส้น

เคอร์เนลฟังก์ชันฐานรัศมี (Radial Basis Function: RBF)

ให้ความคล้ายลดลงตามระยะระหว่างตัวอย่าง ค่า gamma

ควบคุมขอบเขตอิทธิพลของแต่ละตัวอย่าง gamma

สูงทำให้ขอบเขตละเอียดและเสี่ยงตามสัญญาณรบกวน gamma

ต่ำทำให้ขอบเขตกว้างและอาจแยกคลาสที่ซับซ้อนไม่พอ

HandVox ใช้ gamma=scale

ซึ่งคำนวณจากจำนวนคุณลักษณะและความแปรปรวนของข้อมูลโดยอัตโนมัติ

ค่าเริ่มต้นนี้สะดวกแต่ไม่แทนการค้นหาพารามิเตอร์ ควรเปรียบเทียบกับค่าหลายระดับภายในแต่ละ fold ของผู้ทำ

Kernel	ลักษณะขอบเขต	ข้อดี	ข้อควรระวัง
Linear	เชิงเส้น	เร็วและดี ความง่าย	อาจไม่พอกับท่าที่สัมพันธ์ซับซ้อน
Polynomial	โค้งตามดีกรี	แทนปฏิสัมพันธ์หลายระดับ	ไวต่อ degree, gamma และ coef0
RBF	ไม่เชิงเส้นเฉพาะบริเวณ	ยืดหยุ่นและใช้แพร่หลาย	ต้องควบคุม C และ gamma
Sigmoid	คล้ายฟังก์ชันกระตุ้น	ใช้กับข้อมูลบางชนิด	ไม่เหมาะกับทุกค่าพารามิเตอร์

ตารางที่ 2.5 การเปรียบเทียบ Kernel ของ SVM

2.5.4 การจำแนกหลายคลาส

SVM พื้นฐานอธิบายในกรณีสองคลาส แต่ HandVox มีหลายค่าไลบรารี SVC จึงสร้างปัญหาย่อยระหว่างคู่คลาสและรวมผลเพื่อเลือกค่าสุดท้าย จำนวนคู่เพิ่มตามจำนวนคลาส ทำให้เวลาฝึกและความซับซ้อนเพิ่มเมื่อขยายคำศัพท์

คู่ค่าที่สับสนมากควรถูกตรวจรายชื่อใน Confusion Matrix

เพราะคะแนนรวมอาจซ่อนปัญหาเฉพาะคลาส

การเพิ่มตัวอย่างที่เน้นความแตกต่างของคู่หนึ่งหรือเพิ่มคุณลักษณะที่เกี่ยวข้องมีโอกาสแก้ปัญหาดังตรงกว่าการเปลี่ยนแบบจำลองทั้งหมด

2.5.5 พารามิเตอร์ของ HandVox

ไฟล์ training_config.json ระบุ algorithm เป็น SVC ใช้ kernel=rbf, C=10.0, gamma=scale, probability=true, class_weight=balanced และ random_seed=42 การบันทึกค่ากำหนดพร้อมผลทดลองทำให้สามารถสร้างการทดลองซ้ำและเปรียบเทียบรุ่นได้

class_weight=balanced ปรับน้ำหนักผกผันกับจำนวนตัวอย่างของแต่ละคลาส ช่วยลดการเอนเอียงไปยังคลาสที่มีข้อมูลมาก แต่ไม่แก้ปัญหาคูณภาพต่ำหรือความหลากหลายน้อย หากคลาสหนึ่งมีตัวอย่างซ้ำจากคนเดียว น้ำหนักที่สูงขึ้นอาจเพิ่มการเรียนรู้รูปแบบเฉพาะคนนั้น

การปรับพารามิเตอร์ควรทำเฉพาะบนชุดฝึกและ validation ภายใน ไม่ควรดูคะแนนชุดทดสอบแล้วเลือกค่าที่ดีที่สุด เพราะชุดทดสอบจะกลายเป็นส่วนหนึ่งของการพัฒนาและคะแนนสุดท้ายมีอคติ

2.5.6 ค่าความน่าจะเป็นและการสอบเทียบ

SVM ให้คะแนนระยะจากขอบเขตการตัดสินใจ ไม่ได้ให้ความน่าจะเป็นโดยธรรมชาติ เมื่อเปิด probability ไลบรารีจะใช้กระบวนการสอบเทียบเพื่อแปลงคะแนนเป็นค่าความน่าจะเป็น

Lin, Lin และ Weng (2007) อธิบายการปรับปรุงวิธี probabilistic outputs ของ SVM เพื่อลดปัญหาเชิงตัวเลข

ค่าจาก predict_proba ใช้จัดอันดับและกำหนดเกณฑ์ปฏิเสธผลได้ แต่ไม่ควรตีความว่า 0.80 หมายถึงถูก 80 เปอร์เซ็นต์ในทุกสภาพแวดล้อม การสอบเทียบอาจเปลี่ยนเมื่อผู้ใช้ กล้อง หรือสัดส่วนคลาสต่างจากข้อมูลฝึก

HandVox ใช้ค่าความเชื่อมั่นขั้นต่ำ 0.65 ในสถานะตรวจจับ ค่านี้ควรเลือกจาก validation โดยพิจารณาทั้ง Recall ของคำสำคัญและอัตราการสร้างคำผิดจาก neutral หากเพิ่มเกณฑ์สูง ระบบอาจปลอดภัยขึ้นแต่พลาดคำจริงมากขึ้น

2.5.7 SVM กับแบบจำลองลำดับเชิงลึก

SVM มีข้อดีด้านความง่าย ความเร็ว และทำงานได้กับชุดข้อมูลขนาดเล็กเมื่อมีคุณลักษณะที่ดี ส่วน LSTM, GRU, Temporal Convolution และ Transformer สามารถเรียนรู้ความสัมพันธ์ตามเวลาได้ยืดหยุ่นกว่า แต่ต้องใช้ข้อมูล การปรับพารามิเตอร์ และทรัพยากรมากขึ้น

การเปรียบเทียบที่ยุติธรรมต้องใช้ตัวอย่าง ชุดแบ่ง และตัวชี้วัดเดียวกัน หากวิธีหนึ่งใช้ผู้ทำท่าช้าระหว่างฝึกกับทดสอบ ขณะที่อีกวิธีทดสอบกับผู้ทำใหม่ คะแนนไม่สามารถสรุปว่าแบบจำลองใดดีกว่าได้

สำหรับโครงการระดับต้นแบบ การใช้ SVM เป็น baseline ที่ตรวจสอบง่ายมีคุณค่า เมื่อจำนวนผู้ทำและคลิปเพิ่มขึ้น จึงค่อยเปรียบเทียบกับ LSTM หรือโมเดลกราฟบนจุดสำคัญ เพื่อวัดว่าความซับซ้อนที่เพิ่มให้ประโยชน์จริงเพียงใด

2.6 การแบ่งข้อมูลและการป้องกันการรั่วไหล

คุณภาพการประเมินขึ้นกับวิธีสร้างและแบ่งชุดข้อมูลอย่างมาก ระบบอาจได้คะแนนสูงโดยไม่สามารถใช้กับบุคคลใหม่ หากคลิปจากผู้ทำหรือเซสชันเดียวกันกระจายอยู่ทั้งชุดฝึกและชุดทดสอบ HandVox รุ่นใหม่จึงเก็บ signer_id, session_id และประเมินแบบ Leave-One-Signer-Out

2.6.1 การออกแบบชุดข้อมูล

การออกแบบเริ่มจากนิยามคลาส วิธีทำท่า ขอบเขตเฟรม สภาพแวดล้อม และจำนวนตัวอย่างต่อกลุ่ม คำอธิบายต้องชัดเจนให้ผู้เก็บตัวอย่างสร้างตัวอย่างสอดคล้องกัน แต่ไม่ควรบังคับจังหวะจนขาดความเป็นธรรมชาติ

ค่ากำหนดปัจจุบันมีผู้ทำ person_01 และ person_02 เซสชัน session_01 และ session_02 ตั้งเป้า 10 คลิปต่อผู้ทำต่อคลาส และต้องมีคลิป accepted อย่างน้อย 8 คลิปต่อผู้ทำต่อคลาสก่อนฝึกเต็มรูปแบบ โครงสร้างนี้บังคับให้ตรวจสอบความครบถ้วนแยกตามบุคคล ไม่ใช่นับเพียงยอดรวม

การมีเพียงสองผู้ทำยังจำกัดการทั่วไป แม้ Leave-One-Signer-Out จะแยกคนได้ถูกต้อง ผลแต่ละ fold พึ่งผู้ทดสอบเพียงหนึ่งคน การเพิ่มจำนวนผู้ทำที่ต่างวัย รูปร่างมือ ความถนัด และประสบการณ์ใช้ภาษามือจะทำให้การประเมินน่าเชื่อถือขึ้น

2.6.2 การตรวจรับและการปฏิเสธคลิป

Dataset V2 แยกสถานะคลิปเป็น accepted, pending และ rejected ช่วยให้เก็บตัวอย่างก่อนแล้วตรวจสอบคุณภาพภายหลัง คลิปที่จุดสำคัญหายมาก ทำท่าไม่ครบ ป้ายกำกับผิด หรือมีความผิดปกติควรถูกปฏิเสธพร้อมบันทึกเหตุผล

การตรวจรับต้องใช้เกณฑ์เดียวกันทุกคลาส หากตรวจค่าหนึ่งเข้มกว่าค่าอื่น ความต่างของคุณภาพจะกลายเป็นสัญญาณที่แบบจำลองเรียนรู้ การสุ่มตรวจซ้ำโดยผู้ตรวจอีกคนช่วยประเมินความสอดคล้องของป้ายกำกับ

การเก็บวิดีโอตัวอย่างไว้ช่วยตรวจย้อนกลับ แต่เพิ่มขนาดและความเสี่ยงด้านความเป็นส่วนตัว ไฟล์กำหนดค่าเปิด save_preview_video จึงควรกำหนดผู้เข้าถึง ระยะเวลาจัดเก็บ และวิธีลบเมื่อไม่จำเป็น

2.6.3 การแบ่งแบบคงสัดส่วนคลาส (Stratified)

การแบ่งแบบคงสัดส่วนคลาส (stratified) รักษาสัดส่วนของแต่ละคลาสให้ใกล้เคียงกันระหว่างชุดฝึกกับชุดทดสอบ เหมาะสำหรับการทดสอบเบื้องต้นเมื่อแต่ละคลาสมีตัวอย่างน้อยและต้องการให้ทุกคลาสปรากฏในทั้งสองชุด

ข้อจำกัดคือ stratified ที่พิจารณาเฉพาะป้ายกำกับไม่รู้ว่าคลิปใดมาจากผู้ทำหรือเซสชันเดียวกัน ตัวอย่างที่ใกล้เคียงกันมากอาจอยู่คนละชุด ทำให้คะแนนสูงจากการจดจำบุคคล ฉาก และรูปแบบการเก็บข้อมูล

HandVox ใช้ stratified holdout เฉพาะโหมด quick trial เพื่อประเมินค่าใหม่อย่างรวดเร็ว

ผลดังกล่าวควรถูกระบุว่าเป็นผลเบื้องต้นและไม่ใช้แทนการรับรองแบบข้ามผู้ทำของการฝึกเต็มรูปแบบ

2.6.4 การรั่วไหลของข้อมูล

Data leakage เกิดเมื่อข้อมูลที่ไม่ควรมีในขั้นฝึกหรือเลือกแบบจำลองส่งผลต่อโมเดล เช่น ใช้ชุดทดสอบเลือกพารามิเตอร์ ปรับมาตรฐานด้วยสถิติรวมทุกชุด หรือปล่อยคิปลจากเซสชันเดียวกันอยู่ทั้งฝึกและทดสอบ

ในข้อมูลวิดีโอ การตัดคิปลยาวหนึ่งไฟล์เป็นหลายหน้าต่างแล้วสุ่มแบ่งหน้าต่างมีความเสี่ยงสูง เพราะเฟรมติดกันแทบเหมือนกัน หากหน้าต่างเหล่านี้อยู่คนละชุด คะแนนจะวัดความคล้ายของวิดีโอต้นทางมากกว่าความสามารถกับตัวอย่างใหม่

มาตรการป้องกันคือกำหนดกลุ่มก่อนแบ่ง เก็บขั้นตอน preprocessing ไว้ใน pipeline ที่ fit เฉพาะชุดฝึก แยก validation จาก test และบันทึก fingerprint ของชุดข้อมูลที่ใช้ในแต่ละ experiment เพื่อให้รู้ว่าผลใดมาจากข้อมูลรุ่นใด

วิธีแบ่ง	สิ่งที่ควบคุม	ข้อดี	ข้อจำกัด/การใช้
สุ่มทั่วไป	จำนวนรวม	ง่ายและเร็ว	เสี่ยงสัดส่วนคลาสและกลุ่มไม่สมดุล
Stratified	สัดส่วนคลาส	ทุกคลาสอยู่ในแต่ละชุด	ไม่ป้องกันผู้ทำหรือเซสชันซ้ำ
Group by session	เซสชัน	ลดคิปลใกล้เคียงข้ามชุด	ยังอาจมีผู้ทำคนเดิม
Group by signer	ผู้ทำทำ	วัดการใช้กับบุคคลใหม่	ต้องมีผู้ทำหลายคน
Leave-One-Signer-Out	สลับผู้ทำเป็นชุดทดสอบ	ใช้ข้อมูลทุกคนและรายงานราย fold	ใช้เวลาฝึกหลายรอบ
ชุดทดสอบภายนอก (External test)	แหล่งข้อมูลภายนอก	ใกล้เคียงการใช้งานจริงที่สุด	ต้องเก็บข้อมูลที่ไม่แตะระหว่างพัฒนา

ตารางที่ 2.6 การเปรียบเทียบวิธีแบ่งข้อมูล

2.6.5 การเว้นผู้ทำทำหนึ่งคนออก (Leave-One-Signer-Out)

การเว้นผู้ทำทำหนึ่งคนออก (Leave-One-Signer-Out) สร้างจำนวนรอบ (fold) เท่ากับจำนวนผู้ทำ แต่ละ fold ฝึกด้วยข้อมูลของทุกคนยกเว้นหนึ่งคนและใช้คนนั้นเป็นชุดทดสอบ ผลรวมจึงสะท้อนการทั่วไปไปยังผู้ทำที่ไม่เคยเห็นมากกว่าการสุ่มคิปล

HandVox ปัจจุบันมีสองผู้ทำจึงเกิดสอง fold ในแต่ละรอบ แบบจำลองแรกฝึก person_01 และทดสอบ person_02 ส่วนอีกแบบจำลองสลับกัน จากนั้นรวมค่าทำนายของทุก fold เพื่อคำนวณตัวชี้วัด aggregate ก่อนฝึก final model ด้วยข้อมูล accepted ทั้งหมดสำหรับใช้งาน

ควรรายงานทั้งผลรวมและผลราย fold หากคนหนึ่งได้คะแนนสูงแต่อีกคนต่ำ ค่าเฉลี่ยเพียงค่าเดียวอาจซ่อนความไม่เท่าเทียม

การเพิ่มผู้ทำช่วยให้เห็นการกระจายและสร้างช่วงความเชื่อมั่นได้ดีขึ้น

2.6.6 ความไม่สมดุลของคลาส

คลาสไม่สมดุลทำให้ Accuracy สูงแม้โมเดลละเลยคลาสที่มีน้อย HandVox ตั้งเป้าจำนวนต่อผู้ทำต่อคลาสเท่ากันและใช้ `class_weight=balanced` เป็นมาตรการเสริม แต่ยังคงต้องตรวจ support และ Recall รายคลาส

คลาส neutral มีบทบาทต่างจากคำจริง เพราะครอบคลุมท่าที่ไม่ควรปล่อยคำและอาจมีความหลากหลายสูง การเก็บ neutral ควรรวมท่าเตรียม ช่วงเปลี่ยน และท่าที่ไม่อยู่ในรายการ โดยไม่ใช่ตัวอย่างที่คลุมเครือจนทับคำจริง

2.6.7 การเพิ่มข้อมูล

การเพิ่มข้อมูลฝึกยังสามารถทำได้ด้วยการรวบรวมขนาดเล็ก การเปลี่ยนสเกล การเลื่อนเวลา หรือการตัดบางเฟรม แต่การแปลงต้องรักษาความหมายของคำและไม่สร้างท่าที่เป็นไปไม่ได้

การกลับซ้ายขวาไม่ควรใช้โดยอัตโนมัติ เพราะอาจเปลี่ยนมือถนัดหรือความหมาย

ข้อมูลสังเคราะห์ไม่แทนการเก็บจากผู้ใช้นหลายคน

ควรใช้เพื่อเพิ่มความทนต่อความแปรผันที่ทราบ และต้องใช้เฉพาะชุดฝึก

ไม่ควรสร้างตัวอย่างจากคลิปทดสอบแล้วนำกลับไปฝึก

2.6.8 เวอร์ชันและความสามารถในการทำซ้ำ

ระบบบันทึก training_config snapshot, dataset fingerprint, เวอร์ชันสภาพแวดล้อม, metrics, confusion matrix และ model manifest ในโฟลเดอร์ experiment

การเก็บหลักฐานเหล่านี้ทำให้ตรวจสอบย้อนกลับได้ว่าโมเดลใดใช้ข้อมูลและค่ากำหนดชุดใด

การบันทึก random_seed ช่วยให้ขั้นตอนสุ่มซ้ำได้ใกล้เคียงเดิม

แต่ไม่รับประกันผลเหมือนกันทุกแพลตฟอร์ม การทำซ้ำที่ดีต้องรวมเวอร์ชันไลบรารี ซอร์สโค้ด และกฎคัดเลือกข้อมูล ไม่ใช่บันทึกเพียง seed

2.7 การประเมินผล

การประเมินต้องตอบทั้งความถูกต้องของการจำแนก ความสมดุลระหว่างคลาส ความปลอดภัยของคำสำคัญ และพฤติกรรมแบบเวลาจริง Sokolova และ Lapalme (2009) ชี้ว่าตัวชี้วัดแต่ละชนิดตอบคุณสมบัติของ Confusion Matrix ต่างกัน จึงไม่ควรใช้ Accuracy เพียงค่าเดียว

2.7.1 เมทริกซ์ความสับสน (Confusion Matrix)

เมทริกซ์ความสับสน (Confusion Matrix) จัดแถวเป็นคลาสจริงและคอลัมน์เป็นคลาสที่ทำนาย ค่าบนแนวทแยงคือค่าที่ทำนายถูก ส่วนค่านอกแนวทแยงแสดงคู่ค่าที่สับสน รูปแบบของความผิดพลาดช่วยชี้ว่าควรเพิ่มข้อมูลหรือคุณลักษณะใด การอ่านต้องพิจารณาจำนวนตัวอย่างต่อแถว หากคลาสหนึ่งมี support น้อย จำนวนผิดเพียงเล็กน้อยอาจเปลี่ยน Recall มาก ควรแสดงทั้งจำนวนจริงและอัตราที่ทำให้เป็นสัดส่วนเมื่อเปรียบเทียบคลาส

2.7.2 ค่าความถูกต้อง (Accuracy)

ค่าความถูกต้อง (Accuracy) คือจำนวนตัวอย่างที่ทำนายถูกหารด้วยจำนวนตัวอย่างทั้งหมด เหมาะสำหรับสรุปภาพรวมเมื่อคลาสมีจำนวนใกล้เคียงกันและต้นทุนของความผิดพลาดเท่ากัน

ใน HandVox ความผิดพลาดบางชนิดสำคัญกว่า เช่น พลาดคำ ช่วยด้วย หรือสร้างคำจาก neutral ดังนั้น Accuracy ที่ผ่านเกณฑ์ยังไม่เพียงพอ ต้องตรวจ Recall ของคำสำคัญและอัตรา false positive ของ neutral เพิ่มเติม

2.7.3 ค่าความแม่นยำ (Precision) ค่าความระลึก (Recall) และคะแนนเอฟวัน (F1-score)

ค่าความแม่นยำ (Precision) ของคลาสหนึ่งวัดว่าสิ่งที่ระบบทำนายเป็นคลาสนั้นถูกจริงกี่ส่วน ค่า Precision ต่ำหมายถึงระบบเรียกชื่อคลาสนั้นเกินไปและสร้าง false positive มาก

ค่าความระลึก (Recall) วัดว่าตัวอย่างจริงของคลาสถูกตรวจพบกี่ส่วน ค่า Recall ต่ำหมายถึงระบบพลาดคำจริง สำหรับคำสำคัญที่การพลาดมีผลสูง ควรกำหนดเกณฑ์ Recall เฉพาะแม้ Precision กับ Recall จะมีการแลกเปลี่ยนกัน

คะแนนเอฟวัน (F1-score) เป็นค่าเฉลี่ยฮาร์โมนิกของ Precision และ Recall จึงต่ำเมื่อค่าใดค่าหนึ่งต่ำมาก เหมาะสำหรับสรุปสมดุลของการตรวจพบและการหลีกเลี่ยงผลบวกผิด แต่ยังคงเปิดดูสองค่าต้นทางเพื่อเข้าใจสาเหตุ

ตัวชี้วัด	ความหมาย	สูตรย่อ	การใช้ใน HandVox
Accuracy	สัดส่วนที่ทำนายถูกทั้งหมด	ถูกทั้งหมด / ตัวอย่างทั้งหมด	เกณฑ์ภาพรวม
Precision	ความถูกต้องของผลที่ทำนายเป็นคลาส	$TP / (TP + FP)$	ตรวจค่าที่ระบบปล่อยเกิน
Recall	สัดส่วนคำจริงที่ตรวจพบ	$TP / (TP + FN)$	เน้นคำสำคัญและคลาสที่พลาด
F1-score	สมดุล Precision กับ Recall	$2PR / (P + R)$	สรุปผลรายคลาสและ Macro F1
Neutral FPR	neutral ที่ถูกปล่อยเป็นคำ	neutral ผิด / neutral ทั้งหมด	ควบคุม false activation

ตารางที่ 2.7 ตัวชี้วัดสำหรับการประเมิน HandVox

2.7.4 ค่าเฉลี่ยมหภาค (Macro average) และค่าเฉลี่ยถ่วงน้ำหนัก (Weighted average)

ค่าเฉลี่ยมหภาค (Macro average)

คำนวณตัวชี้วัดแยกแต่ละคลาสแล้วเฉลี่ยโดยให้น้ำหนักเท่ากัน

จึงสะท้อนว่าระบบทำงานกับคลาสเล็กได้ดีเพียงใด HandVox ใช้ Macro F1 เป็นเกณฑ์หลักร่วมกับ Accuracy

ค่าเฉลี่ยถ่วงน้ำหนัก (Weighted average) ให้น้ำหนักตาม support ของแต่ละคลาส เหมาะกับสรุปผลตามการกระจายข้อมูลจริง แต่คลาสใหญ่มีอิทธิพลมากกว่า การรายงาน Macro และ Weighted ร่วมกันช่วยเปิดเผยว่าคะแนนรวมดีเพราะคลาสใหญ่หรือดีสม่ำเสมอทุกคลาส

2.7.5 เกณฑ์ยอมรับของโครงการ

training_config.json กำหนด Accuracy ขั้นต่ำ 0.70, Macro F1 ขั้นต่ำ 0.70 และ Recall ต่ำสุดของค่าทั่วไป 0.50 เกณฑ์เหล่านี้ใช้เป็นประตูคุณภาพเบื้องต้น ไม่ใช่การรับรองว่าระบบพร้อมใช้ในสถานการณ์เสี่ยงสูง

คำ ช่วยด้วย ถูกกำหนดเป็น critical gesture และต้องมี Recall อย่างน้อย 0.75 ส่วน neutral false positive rate ต้องไม่เกิน 0.20 การมีเกณฑ์เฉพาะสะท้อนต้นทุนความผิดพลาดที่ต่างกันระหว่างคำ

หากการทดลองไม่ผ่าน ระบบยังบันทึกผลและสาเหตุของเกณฑ์ที่ไม่ผ่านเพื่อให้แก้ไขได้ แต่ไม่ควรเปิดใช้โมเดลนั้นเป็นรุ่นหลักโดยอัตโนมัติ ควรตรวจสอบข้อมูลรายคลาส คู่คำสับสน และผลรายผู้ทำก่อนตัดสินใจเก็บข้อมูลเพิ่มหรือปรับแบบจำลอง

2.7.6 การประเมินแบบเวลาจริง

คะแนนบนคลิปที่ตัดไว้ไม่รวมความผิดพลาดจากการเริ่มจับซ้ำ การเลื่อนหน้าต่าง ช่วงเปลี่ยนการไม่พบมือ และการยืนยันผล

การทดสอบหน้ากล้องจึงต้องวัดความถูกต้องแบบเหตุการณ์ร่วมกับจำนวนครั้งที่ปล่อยคำซ้ำหรือปล่อยคำโดยไม่มีทำจริง

ตัวชี้วัดระบบประกอบด้วยอัตราเฟรม ความหน่วงจากเริ่มทำทำถึงแสดงผล เวลาจากยืนยันถึงเสียงเริ่ม จำนวนเฟรมที่ landmark หาย และการใช้หน่วยประมวลผล ความเร็วที่สูงแต่ผลสั้นไม่ใช่ประสบการณ์ที่ดี ขณะที่ผลนิ่งมากแต่หน่วงหลายวินาทีก็ลดความเป็นธรรมชาติของการสนทนา

การทดสอบควรใช้สถานการณ์ที่ใกล้เคียงจริง เช่น เปลี่ยนระยะกล้อง แสง และผู้ใช้ พร้อมกำหนดสคริปต์คำเพื่อเปรียบเทียบรู้อย่างยุติธรรม การรายงานแยกแบบออฟไลน์ (offline) กับแบบเวลาจริง (real-time) ป้องกันการนำคะแนนในสภาพง่ายไปอ้างแทนประสิทธิภาพใช้งาน

2.7.7 การวิเคราะห์ข้อผิดพลาดและความไม่แน่นอน

หลังได้ผลควรสุ่มตรวจ ผลบวกจริง (true positive), ผลบวกหลง (false positive) และผลลบหลง (false negative) ของทุกคลาส พร้อมดูเส้นทาง landmark เพื่อแยกว่าปัญหาเกิดจากป้ายกำกับ จุดสำคัญ หน้าต่างเวลา หรือขอบเขตของแบบจำลอง

คะแนนจากตัวอย่างจำนวนจำกัดมีความไม่แน่นอน ควรรายงานจำนวนผู้ทำ จำนวนคลิป และ support ควบคู่กับร้อยละ เมื่อเพิ่มผู้ทำสามารถใช้การกระจายราย fold หรือช่วงความเชื่อมั่นเพื่อหลีกเลี่ยงการตีความความแตกต่างเล็กน้อยเกินจริง

การประเมินความเท่าเทียมควรเปรียบเทียบผลตามผู้ทำ ความถนัด สภาพแสง และอุปกรณ์ หากกลุ่มใดได้ผลต่ำ ควรเพิ่มข้อมูลและปรับการออกแบบ ไม่ควรแก้ด้วยการตัดกลุ่มนั้นออกจากชุดทดสอบ

2.8 การทำงานแบบเวลาจริงและเสียงพูด

ระบบใช้งานจริงต้องแปลงผลจำแนกรายเฟรมให้เป็นคำที่นิ่ง ป้องกันคำซ้ำ สะสมเป็นประโยค และอ่านออกเสียงโดยไม่ทำให้วงรอบกล้องหยุด HandVox จึงใช้หน้าต่างเลื่อน เครื่องสถานะยืนยันผล ตัวจับเวลาค้างท่า ตัวสร้างประโยค และบริการเสียงแบบคิว

2.8.1 หน้าต่างเลื่อน

โปรแกรมเก็บคุณลักษณะล่าสุดใน deque ขนาด 30 เฟรม เมื่อครบแล้วทุกเฟรมใหม่จะผลักเฟรมเก่าสุดออกและสร้างเวกเตอร์ใหม่ วิธีนี้ให้ผลต่อเนื่องโดยไม่ต้องรอเก็บคลิปใหม่ทั้งชุดทุกครั้ง

หน้าต่างที่ซ้อนกันมีข้อมูลเหมือนกัน 29 จาก 30 เฟรม ผลทำนายจึงมีความสัมพันธ์สูง การนับทุกผลเป็นหลักฐานอิสระอาจทำให้ความมั่นใจเกินจริง เครื่องสถานะของ HandVox จึงใช้ผลต่อเนื่องเพื่อยืนยันความนิ่ง แต่การประเมินยังต้องนับตามเหตุการณ์หรือคลิป

เมื่อผู้ใช้ปล่อยท่าและระบบตรวจสอบสถานะ released โปรแกรมล้าง motion_frames เพื่อป้องกันเฟรมจากคำเก่าปะปนกับการยกมือรอบใหม่ การล้างที่จุดเปลี่ยนช่วยลดท่าผสมซึ่งไม่มีในชุดฝึก

2.8.2 เกณฑ์ความเชื่อมั่นและเครื่องสถานะ

GestureStateMachine มีสถานะว่าง (IDLE), สถานะรอยืนยัน (CANDIDATE), สถานะยืนยันแล้ว (CONFIRMED) และสถานะพักก่อนรับคำใหม่ (COOLDOWN) ผลจะถูกพิจารณาเมื่อเห็น landmark มีชื่อคลาส และ confidence ไม่น้อยกว่า 0.65 หากคำเดิมผ่านเงื่อนไขต่อเนื่อง 4 เฟรมจึงเปลี่ยนเป็น CONFIRMED

ถ้าคำเปลี่ยนระหว่าง CANDIDATE ระบบเริ่มนับใหม่ ช่วยลดการยืนยันจากผลชั่วคราว เมื่อยืนยันแล้ว confidence ถูกปรับแบบถ่วงเฉลี่ยกับผลใหม่เพื่อให้เห็นค่าเสถียรขึ้น

เมื่อผลไม่ผ่าน ระบบซ่อนชื่อเก่าทันที แต่ยังรอ 0.35 วินาทีก่อน reset เพื่อทนต่อ landmark หายชั่วคราว หากเกินเวลาจึงส่ง released และกลับ IDLE การแยกการซ่อนผลออกจากการรีเซ็ตช่วยไม่ให้คำค้างบนหน้าจอพร้อมรักษาความต่อเนื่องระยะสั้น

ค่าทั้งสามคือ confidence 0.65, confirm_frames 4 และ release_seconds 0.35 ปรับได้ใน settings แต่ต้องทดสอบร่วมกัน เกณฑ์สูงและจำนวนเฟรมมากลด false activation แต่เพิ่มความหน่วงและอาจพลาดผู้ใช้ที่ทำท่าเร็ว

ค่าตั้ง	ค่าเริ่มต้น	หน้าที่	ผลเมื่อเพิ่มค่า
min_confidence	0.65	ปฏิเสธผลไม่มั่นใจ	ผลผิดพลาดแต่ Recall อาจลด
confirm_frames	4	ยืนยันคำซ้ำต่อเนื่อง	นิ่งขึ้นแต่หน่วงขึ้น
release_seconds	0.35 วินาที	รอก่อนถือว่าปล่อยท่า	ทนการหายชั่วคราวแต่รีเซ็ตช้า
speak_hold_seconds	1.0 วินาที	ค้างท่าก่อนเพิ่มคำ/พูด	ลดการยิงเร็วแต่สนทนาช้าลง

ค่าตั้ง	ค่าเริ่มต้น	หน้าที่	ผลเมื่อเพิ่มค่า
sequence_length	30 เฟรม	ขนาดหน้าต่างการเคลื่อนไหว	เห็นท่ายาวขึ้นแต่เพิ่มมิติและหน่วง

ตารางที่ 2.8 ค่าตั้งสำคัญของการตรวจจับแบบเวลาจริง

2.8.3 การป้องกันคำซ้ำและ Cooldown

หลังเพิ่มหรืออ่านคำ ระบบเรียก mark_emitted เพื่อเข้าสู่ COOLDOWN

คำเดิมจะไม่ถูกปล่อยซ้ำจนกว่าผู้ใช้ปล่อยท่าหรือเปลี่ยนเป็นคำใหม่

ช่วยป้องกันหน้าต่างเลื่อนสร้างคำเดิมหลายครั้งจากการค้างมือ

ตัวสร้างประโยคยังมีตัวเลือก prevent_duplicate_words เพื่อไม่เพิ่มคำเดียวกันติดกัน และมี cooldown สำหรับการกดเพิ่มด้วยตนเอง

มาตรการหลายชั้นเหมาะสมกับส่วนติดต่อที่ผู้ใช้สามารถสั่งทั้งอัตโนมัติและด้วยปุ่ม

การป้องกันซ้ำต้องไม่ปิดกั้นกรณีที่ใช้ต้องการพูดคำเดิมสองครั้ง

วิธีออกแบบที่เหมาะสมคือให้ผู้ใช้ปล่อยท่าชัดเจนระหว่างคำหรือมีปุ่มเพิ่มด้วยตนเอง

พร้อมแสดงสถานะว่าระบบกำลังรอการปล่อยท่า

2.8.4 การสร้างประโยคและประวัติ

คำที่ยืนยันสามารถเพิ่มลง SentenceBuilder ลบคำล่าสุด ล้าง อ่าน หรือบันทึกได้

ส่วนติดต่อแสดงจำนวนคำและข้อความปัจจุบัน ช่วยให้ผู้ใช้ตรวจสอบและแก้ก่อนส่งเสียง

ลดผลเสียจากการจำแนกผิดหนึ่งคำ

ประวัติประโยคบันทึกแหล่งที่มา เช่น detector-manual หรือ detector-tts

และจำกัดจำนวนรายการเริ่มต้น 100 รายการ ข้อมูลประวัติช่วยทบทวนการใช้งาน

แต่ต้องให้ผู้ใช้ควบคุมการลบและระวังข้อความส่วนบุคคล

ระบบรองรับการเพิ่มคำอัตโนมัติเมื่อค้างท่าครบหนึ่งวินาทีและการเพิ่มด้วย Space

หรือปุ่มบนจอ การมีทางเลือกช่วยรองรับผู้ใช้ต่างรูปแบบ แต่ควรประเมินความเข้าใจของปุ่ม

ขนาดตัวอักษร และเวลาตอบสนองกับผู้ใช้จริง

2.8.5 การแปลงข้อความเป็นเสียงพูด (Text-to-Speech: TTS)

การแปลงข้อความเป็นเสียงพูด (Text-to-Speech: TTS)

เปลี่ยนข้อความไทยเป็นเสียงเพื่อให้คู่สนทนาที่ไม่รู้ภาษามือรับสารได้ HandVox ลองใช้ gTTS

สร้างไฟล์เสียงภาษาไทยและเล่นด้วย pygame ก่อน หากบริการออนไลน์ไม่พร้อมจะลดยไปใช้

pyttsx3 แบบออฟไลน์เมื่อมีเสียงที่รองรับ

การสร้างเสียงทำงานใน worker thread และรับข้อความผ่านคิวขนาดจำกัด
วงรอบกลิ้งจึงไม่ต้องรอจนเสียงเล่นจบ เสียงหลายคำถูกเล่นตามลำดับและไม่ทับกัน
หากคิวเต็มระบบข้ามข้อความใหม่พร้อมแจ้งเตือนแทนการทำให้หน้าจอค้าง

gTTS ต้องเชื่อมต่อเครือข่ายและสร้างไฟล์ MP3 ชั่วคราว โปรแกรมใช้ชื่อสุ่ม
เล่นเสร็จแล้วลบไฟล์ การใช้งานในสถานที่เครือข่ายไม่แน่นอนควรทดสอบเสียงออฟไลน์และตรวจว่ามี
voice ภาษาไทยในระบบปฏิบัติการ

คุณภาพเสียงไม่ใช่เพียงความดัง ต้องพิจารณาการออกเสียงคำเฉพาะ ความเร็ว
เวลารอก่อนเสียงเริ่ม และความถูกต้องของข้อความต้นทาง
ระบบควรให้ผู้ใช้ตรวจประโยคและหยุดหรือล้างคิวได้เมื่อคำผิด

2.8.6 การออกแบบสำหรับผู้ใช้

ส่วนติดต่อควรแสดงกรอบบริเวณที่ตรวจพบ คำปัจจุบัน confidence สถานะรอยืนยัน
(CANDIDATE) หรือสถานะยืนยันแล้ว (CONFIRMED) และแถบค้ำท่า

เพื่อให้ผู้ใช้เข้าใจว่าเหตุใดระบบยังไม่เพิ่มคำ

การซ่อนความซับซ้อนทั้งหมดอาจทำให้ผู้ใช้คิดว่าระบบไม่ทำงานเมื่อจริง ๆ กำลังรอยืนยัน

ข้อความต้องอ่านง่ายบนฉากหลังที่เปลี่ยน จึงควรใช้แถบพื้นหลัง สีที่มีความต่าง
และขนาดตัวอักษรปรับได้ ปุ่มสำคัญต้องมีทั้งข้อความไทยและคีย์ลัด
และไม่วางทับบริเวณมือที่ใช้ทำท่า

การออกแบบควรร่วมกับผู้ใช้หูหนวกหรือผู้ใช้ภาษามือตั้งแต่การเลือกคำ รูปแบบการทำท่า
ไปจนถึงการทดสอบ ไม่ควรสรุปความต้องการแทนผู้ใช้จากมุมมองผู้พัฒนาเพียงฝ่ายเดียว

2.8.7 ความเป็นส่วนตัวและการนำไปใช้

ระบบกลิ้งควรประมวลผลในเครื่องให้มากที่สุดและไม่บันทึกวิดีโอโดยอัตโนมัติในโหมดใช้งาน
น หากต้องบันทึกเพื่อปรับปรุงโมเดลต้องขอความยินยอม ระบุวัตถุประสงค์ และให้ผู้ใช้ถอนข้อมูลได้

HandVox เป็นเครื่องมือช่วยสื่อสาร ไม่ควรใช้แทนล่ามในสถานการณ์ทางการแพทย์
กฎหมาย หรือเหตุฉุกเฉินโดยไม่มีการตรวจสอบ ความผิดพลาดของคำอาจเปลี่ยนความหมาย
จึงต้องแสดงข้อจำกัดและมีช่องทางสื่อสารสำรอง

2.9 งานวิจัยที่เกี่ยวข้อง

งานวิจัยที่คัดเลือกครอบคลุมภาษามือไทย การรู้จำจากภาพและจุดสำคัญ
ชุดข้อมูลหลายผู้ทำ การจำแนกแบบแยกคำ และการแปลต่อเนื่อง

การเปรียบเทียบไม่ได้มุ่งจัดอันดับจากค่าความถูกต้องเพียงอย่างเดียว เพราะแต่ละงานใช้จำนวนคำ ผู้ทำ อุปกรณ์ และวิธีแบ่งข้อมูลต่างกัน แต่พิจารณาว่าแต่ละงานให้บทเรียนใดต่อการออกแบบ HandVox

2.9.1 การรู้จำนิ้วสะกดภาษาไทยด้วย SVM

Pariwat และ Seresangtakul (2017) ศึกษา Thai finger-spelling sign language recognition using global and local features with SVM และเปรียบเทียบ kernel หลายชนิด งานทบทวนภายหลังรายงาน RBF ให้ค่าเฉลี่ย 91.20 เปอร์เซนต์กับข้อมูล 15 ท่า 75 ภาพจากผู้ทำ 5 คน

งานนี้สนับสนุนว่า RBF สามารถสร้างขอบเขตไม่เชิงเส้นให้คุณลักษณะท่ามือ แต่ข้อมูลเป็นภาพนิ่งและมีขนาดเล็ก ผลจึงไม่ยืนยันความสามารถกับลำดับ 30 เฟรมหรือผู้ใช้ใหม่โดยตรง HandVox นำ SVM-RBF มาเป็น baseline แต่เพิ่มจุดช่วงบน ลำดับเวลา และการประเมินแยกผู้ทำ

2.9.2 CNN และการปฏิเสธท่าที่ไม่รู้จัก

Nakjai และ Katanyukul (2019) พัฒนาระบบรู้จำนิ้วสะกดภาษาไทยแบบสองชั้น เริ่มจากค้นหาและตัดบริเวณมือ แล้วใช้ CNN หรือ HOG จำแนก 25 ท่าจาก 125 ภาพของผู้ทำ 11 คน งานรายงาน mean Average Precision 91.26 และเสนอ confidence ratio เพื่อแยกผลถูกออกจากท่าที่ไม่อยู่ในชุดและช่วงเปลี่ยน

บทเรียนสำคัญต่อ HandVox คือระบบใช้งานต้องมีความสามารถปฏิเสธผล ไม่ใช่บังคับเลือกคลาสทุกครั้ง กลไก neutral, min_confidence และการยืนยันหลายเฟรมตอบปัญหาเดียวกันในระดับระบบ แม้วิธีคำนวณต่างจาก confidence ratio ของงานดังกล่าว

2.9.3 นิ้วสะกดหลายจังหวะในฉากซับซ้อน

Pariwat และ Seresangtakul (2021) เสนอระบบ Multi-Stroke Thai Finger-Spelling โดยใช้ semantic segmentation แยกมือจากฉากหลัง ใช้ optical flow แยกช่วงการเคลื่อนไหว และ CNN เรียนรู้คุณลักษณะ

งานนี้แสดงว่าตัวอักษรบางตัวไม่ได้จบในรูปมือเดียวแต่ประกอบด้วยหลาย stroke

แนวคิดการแยก stroke ชี้ว่าหน้าต่างคงที่ของ HandVox อาจยังไม่เหมาะกับคำที่มีหลายช่วงชัดเจน

การขยายคำศัพท์ควรตรวจโครงสร้างภายในท่าและพิจารณาการแบ่งช่วงหรือแบบจำลองลำดับแทนการเพิ่มคลาสเข้าสู่เวกเตอร์เดิมทันที

2.9.4 ชุดข้อมูลวิดีโอเลขภาษามือไทย

Vijitkunsawat, Racharak, Nguyen และ Minh (2023)

สร้างชุดข้อมูลวิดีโอเลขภาษามือไทย 9 ท่า รวม 567 วิดีโอจากผู้ทำ 21 คน และเปรียบเทียบ CNN-Mode, CNN-LSTM, VGG-Mode และ VGG-LSTM กับทั้งภาพเต็มและภาพที่ตัดเฉพาะมือ

งานรายงานว่า VGG-LSTM

ร่วมกับการประมวลผลล่วงหน้าให้ผลดีที่สุดทั้งชุดทดสอบภายในและภายนอก

จุดเด่นคือจำนวนผู้ทำมากกว่างานไทยขนาดเล็กหลายงานและมีการทดสอบภายนอก HandVox จึงควรเพิ่มผู้ทำและรักษาชุดทดสอบที่ไม่ใช้ระหว่างพัฒนา

2.9.5 MediaPipe และ LSTM สำหรับคำภาษาไทย

Damrongekarun, Pisitpipattana, Waijanya และ Promrit (2023) ใช้ MediaPipe ดึงจุดมือ ใบหน้า และท่าทางจากวิดีโอ แล้วใช้ LSTM วิเคราะห์ลำดับ แบ่งข้อมูลฝึกและทดสอบ 80:20 รายงาน Accuracy 0.83 และแสดงผลภาษาไทยผ่านแอป Flutter ที่เชื่อม Flask API

โครงสร้างใกล้เคียง HandVox ในด้านการใช้ landmark และการนำผลไปยังส่วนติดต่อ แต่แบบจำลองและสถาปัตยกรรมต่างกัน

งานนี้สนับสนุนการใช้ฟีดเป็นตัวแทนข้อมูลและแสดงแนวทางแยกบริการประมวลผลจากแอปผู้ใช้

2.9.6 การแปลภาษามือไทยแบบเวลาจริง

Jintanachaiwat และคณะ (2024) ใช้ MediaPipe Holistic เก็บจุดมือ ร่างกาย และใบหน้าเป็นลำดับ 30 เฟรม เฟรมละ 1,662 ค่า แล้วเปรียบเทียบ RNN, Bi-RNN, LSTM, Bi-LSTM และ FNN-LSTM สำหรับคำที่ใช้ในการประชุม

LSTM ได้ 100 เปอร์เซนต์บนชุดทดสอบแต่ลดเหลือ 86 เปอร์เซนต์เมื่อทดสอบแบบเวลาจริง ผู้วิจัยระบุข้อจำกัดจากข้อมูลผู้ทำเพียงคนเดียว ความต่างนี้เป็นหลักฐานว่าคะแนน offline ไม่ควรถูกใช้แทนผลหน้ากล้อง และสนับสนุนการประเมินข้ามผู้ทำของ HandVox

2.9.7 โปรแกรมแปลภาษามือด้วยจุดมือ

งาน Smart Application for Thai and English Sign Language Translation (2023) ใช้ MediaPipe ตรวจ 21 จุดต่อมือ รองรับสองมือรวม 42 จุด และจำแนก 68 สัญลักษณ์ ผู้ทดลอง 3

คนทำสัญลักษณ์ละ 5 ครั้ง โดยกำหนดระยะเว็บแคมประมาณ 50 เซนติเมตร งานรายงานผลรวม 95.39 เปอร์เซนต์

ผู้วิจัยพบว่าภาษามือไทยบางสัญลักษณ์มีสองระดับของท่าทำให้ผิดพลาดมากกว่าภาษาอังกฤษ ข้อสังเกตนี้สอดคล้องกับความจำเป็นต้องเก็บลำดับและตำแหน่งเทียบร่างกาย HandVox จึงใช้จุดช่วงบนร่วมกับมือ แทนจุดมือเพียงอย่างเดียว

2.9.8 WLASL และคำศัพท์ขนาดใหญ่

Li, Rodriguez, Yu และ Li (2020) เสนอ WLASL

ชุดข้อมูลภาษามืออเมริกันระดับคำมากกว่า 2,000 คำจากผู้ทำมากกว่า 100 คน และเปรียบเทียบวิธี appearance กับ pose รวมทั้ง Pose-TGCN ที่เรียนรู้ความสัมพันธ์ของโครงร่างตามเวลา

ผลบนคำศัพท์ขนาดใหญ่แสดงว่าปัญหายากขึ้นมากเมื่อจำนวนคำและความหลากหลายของผู้ทำเพิ่มขึ้น บทเรียนคือการขยาย HandVox จาก 16 คำต้องเพิ่มข้อมูลและทบทวนแบบจำลอง ไม่ควรคาดหวังว่าค่าดั้งเดิมจะขยายได้โดยไม่ลดประสิทธิภาพ

2.9.9 AUTSL และการประเมินผู้ทำใหม่

Sincan และ Keles (2020) สร้าง AUTSL จำนวน 226 ท่า 38,336 วิดีโอจากผู้ทำ 43 คน มี RGB, depth และ skeleton พร้อมฉากและสภาพแสงหลากหลาย ชุด benchmark แยกผู้ทำ 6 คนออกจากชุดฝึกและ validation

งานรายงานว่าความถูกต้องของ baseline สูงถึง 95.95 เปอร์เซนต์เมื่อสุ่มแบ่ง แต่เหลือ 62.02 เปอร์เซนต์บน user-independent benchmark ช่องว่างนี้แสดงผลของวิธีแบ่งข้อมูลอย่างชัดเจนและสนับสนุน Leave-One-Signer-Out ใน HandVox

2.9.10 การรู้จำและแปลภาษามือต่อเนื่อง

Camgoz, Hadfield, Koller, Ney และ Bowden (2018) เสนอ Neural Sign Language Translation และชุดข้อมูล PHOENIX14T ซึ่งมีมากกว่า 67,000

หน่วยท่าจากคำศัพท์ภาษามือมากกว่า 1,000 หน่วย

งานเชื่อมวิดีโอกับประโยคภาษาพูดและแยกการรู้จำหน่วยท่าออกจากการแปล

ต่อมา Camgoz และคณะ (2020) เสนอ Sign Language Transformers

ที่เรียนรู้การรู้จำต่อเนื่องและการแปลร่วมกันด้วย CTC และ Transformer

งานทั้งสองมีขอบเขตกว้างกว่า HandVox

แต่เป็นแนวทางระยะยาวหากต้องพัฒนาจากการสะสมคำแยกคำไปสู่ประโยคที่คำนึงถึงไวยากรณ์

2.9.11 การรู้จำจากโครงกระดูกหลายรูปแบบ

Jiang และคณะ (2021) เสนอ Skeleton Aware Multi-modal Sign Language Recognition ซึ่งใช้ SL-GCN เรียนรู้พลวัตของโครงกระดูกทั้งตัวและรวมข้อมูลหลายรูปแบบงานได้อันดับสูงในการแข่งขัน isolated sign language recognition บน AUTSL

แนวคิดกราฟสอดคล้องกับธรรมชาติของ landmark ที่จุดเชื่อมกันเป็นโครงสร้าง ไม่ใช่เพียงรายการตัวเลข

การพัฒนาต่อสามารถสร้างกราฟมือและช่วงบนเพื่อเรียนรู้ความสัมพันธ์เชิงพื้นที่กับเวลา แต่ต้องเปรียบเทียบกับ SVM บนข้อมูลเดียวกันและระวัง overfitting เมื่อข้อมูลยังน้อย

2.9.12 การสังเคราะห์ช่องว่างของงานวิจัย

งานไทยจำนวนหนึ่งรายงานผลสูงในชุดข้อมูลขนาดเล็กหรือการสุ่มแบ่ง ขณะที่งานชุดข้อมูลขนาดใหญ่แสดงว่าคะแนนลดลงชัดเจนเมื่อทดสอบกับผู้ทำใหม่ ความแตกต่างไม่ได้หมายความว่างานหนึ่งด้อยกว่า แต่อธิบายว่าความยากของโจทย์และวิธีประเมินมีผลต่อค่าที่รายงาน

HandVox เติมช่องว่างในระดับต้นแบบด้วยการใช้ landmark ช่วงบนและมือ ลำดับ 30 เฟรม SVM-RBF คลาส neutral เครื่องสถานะเวลาจริง และการประเมิน Leave-One-Signer-Out พร้อมเกณฑ์รายคลาส จุดแข็งคือกระบวนการตรวจสอบย้อนกลับได้และใช้ทรัพยากรทั่วไป

ข้อจำกัดยังอยู่ที่จำนวนผู้ทำเพียงสองคน คำศัพท์ 16 คำ หน้าต่างคงที่ และการไม่ใช้รายละเอียดใบหน้า งานต่อยอดที่มีความสำคัญที่สุดคือเพิ่มผู้ทำและเซสชัน สร้างชุดทดสอบภายนอก (external test) เพิ่ม neutral ที่หลากหลาย และเปรียบเทียบ SVM กับ LSTM หรือกราฟบนชุดแบ่งเดียวกัน

งานวิจัย	ข้อมูล/วิธี	ผลหรือข้อค้นพบ	บทเรียนสำหรับ HandVox
Pariwat และ Seresangtakul (2017)	15 ท่า 75 ภาพ 5 คน; global/local features และ SVM	RBF เฉลี่ย 91.20%	ใช้ RBF เป็น baseline แต่ต้องเพิ่มลำดับและผู้ทำ
Nakjai และ Katanyukul (2019) DOI 10.1007/s11265-018-1375-6	25 ท่า 125 ภาพ 11 คน; CNN/HOG	mAP 91.26; confidence ratio	ต้องปฏิเสธท่าที่ไม่รู้จักและช่วงเบลี
Pariwat และ Seresangtakul (2021) DOI 10.3390/sym13020262	multi-stroke; segmentation, optical flow, CNN	จัดการหลาย stroke และฉากซับซ้อน	ท่าหลายช่วงอาจต้องแบ่งหรือใช้โมเดลลำดับ

งานวิจัย	ข้อมูล/วิธี	ผลหรือข้อค้นพบ	บทเรียนสำหรับ HandVox
Vijitkunsawat และคณะ (2023)	9 ท่า 567 วิดีโอ 21 คน; CNN/LSTM และ VGG/LSTM	VGG-LSTM หลังตัดมือให้ผลดีที่สุด	เพิ่มผู้ทำและทดสอบภายนอก
Damrongekarun และคณะ (2023) DOI 10.14456/kkuscij.2023.19	MediaPipe landmarks, LSTM, 80:20	Accuracy 0.83; Flutter/Flask	ใช้ landmark และแยกส่วนบริการกับหน้าจอ
Jintanachaiwat และคณะ (2024) DOI 10.1007/s44163-024-00113-8	MediaPipe Holistic 30 เฟรม; RNN/LSTM	test 100%; real-time 86%	รายงาน offline แยกจากเวลาจริง
Smart Application (2023) DOI 10.14456/jait.2023.13	42 จุดมือ 68 สัญลักษณ์ 3 คน	รวม 95.39%; ทำไทยสองระดับยากกว่า	ใช้ช่วงบนและลำดับเสริมจุดมือ
Li และคณะ (2020) WLASL	>2,000 คำ >100 คน; appearance/pose/Pose-TGCN	คำศัพท์ใหญ่มีความท้าทายสูง	การเพิ่มคลาสต้องเพิ่มข้อมูลและโมเดล
Sincan และ Keles (2020) AUTSL DOI 10.1109/ACCESS.2020.3028072	226 ท่า 38,336 วิดีโอ 43 คน	random 95.95%; user-independent 62.02%	วิธีแบ่งผู้ทำมีผลต่อคะแนนมาก
Camgoz และคณะ (2018) PHOENIX14T	>67,000 หน่วยท่า; Neural Translation	เชื่อมวิดีโอกับประโยคภาษาพูด	แยกการรู้จำออกจากการแปล
Camgoz และคณะ (2020)	CTC และ Transformer แบบรวม	รู้จำต่อเนื่องและแปล end-to-end	แนวทางอนาคตสำหรับประโยคต่อเนื่อง
Jiang และคณะ (2021) SAM-SLR	SL-GCN และข้อมูลหลายรูปแบบ	ใช้โครงกระดูกทั้งตัวและเวลา	landmark สามารถแทนเป็นกราฟได้

ตารางที่ 2.9 การเปรียบเทียบงานวิจัยที่เกี่ยวข้องกับ HandVox

จากแนวคิดและงานวิจัยทั้งหมด

สรุปได้ว่าการสร้างระบบรู้จำภาษามือที่น่าเชื่อถือไม่ได้ขึ้นกับตัวจำแนกเพียงส่วนเดียว แต่เป็นผลร่วมของการกำหนดขอบเขตภาษา คุณภาพป้ายกำกับ ความหลากหลายของผู้ทำ คุณภาพ landmark การแทนลำดับ วิธีแบ่งข้อมูล ตัวชี้วัด และกลไกควบคุมผลแบบเวลาจริง

HandVox เลือกสถาปัตยกรรมที่เหมาะสมกับต้นแบบ ได้แก่ เว็บแคม OpenCV, MediaPipe Holistic, คุณลักษณะ 171 ค่าต่อเฟรม, ลำดับ 30 เฟรม, SVM-RBF, Leave-One-Signer-Out,

คลาสเป็นกลาง (neutral class) และ Text-to-Speech

การพัฒนาต่อไปจึงต้องรักษาความสอดคล้องขององค์ประกอบเหล่านี้ตั้งแต่การเก็บข้อมูลจนถึงการทดสอบหน้ากล้อง

2.9.13 ข้อเสนอแนะเพื่อการออกแบบ HandVox

ผลการทบทวนชี้ให้เห็นว่าแบบจำลองที่มีคะแนนสูงจากการแบ่งข้อมูลแบบสุ่มอาจยังไม่พร้อมใช้กับผู้ทำคนใหม่ ดังนั้นค่า Accuracy จึงต้องอ่านควบคู่กับ Macro F1, Recall รายคลาส, Confusion Matrix และผล Leave-One-Signer-Out การรายงานให้ครบช่วยให้เห็นทั้งความสามารถทั่วไปของระบบและจุดที่ยังต้องปรับปรุงโดยตรงไปตรงมา

ในระดับการออกแบบ ระบบควรแยกความรับผิดชอบของแต่ละส่วนให้ชัดเจน ได้แก่ ส่วนกล้องและการแปลงสี ส่วนตรวจ landmark ส่วนสร้างเวกเตอร์คุณลักษณะ ส่วนจำแนกคำ และส่วนแสดงข้อความหรือเสียง การแยกส่วนเช่นนี้ทำให้ย้อนตรวจได้ว่าความผิดพลาดเกิดจากกล้อง จุดสำคัญ ลำดับเฟรม หรือแบบจำลอง ไม่ควรสรุปว่าเป็นข้อผิดพลาดของ SVM เพียงอย่างเดียว

สำหรับข้อมูลฝึก การกำหนดคลิป accepted, pending และ rejected เป็นหลักฐานของคุณภาพข้อมูล ไม่ใช่ขั้นตอนที่ควรถูกข้าม คลิปที่ landmark หาย มีถูกบัง ป้ายกำกับไม่ตรง หรือเริ่มทำไม่ตรงจึงหวั่นต้องมีเหตุผลกำกับ การเก็บ metadata ของผู้ทำ เซสชัน และสภาพแวดล้อมจึงช่วยให้คัดแยกข้อมูล ป้องกันการรั่วไหล และทำการทดลองซ้ำได้

สำหรับการใช้งานจริง ค่าความมั่นใจและกลไกยืนยันผลมีความสำคัญไม่แพ้ความแม่นยำออฟไลน์ HandVox จึงใช้ min_confidence, confirm_frames, release_seconds และ cooldown เพื่อไม่ปล่อยคำซ้ำหรือคำที่เกิดจากทำผ่าน ระบบควรแสดงสถานะที่ผู้ใช้เข้าใจได้ พร้อมเปิดทางให้แก้ไขหรือพูดซ้ำเมื่อผลยังไม่แน่นอน

ผลจากงานวิจัยยังเสนอทิศทางการต่อยอดอย่างเป็นขั้นตอน หากเพิ่มคำศัพท์ เพิ่มผู้ทำ หรือเพิ่มการเคลื่อนไหวที่ซับซ้อน ควรเพิ่มข้อมูลและทดสอบภายนอกก่อนพิจารณา LSTM, Transformer หรือแบบจำลองกราฟจาก landmark การเปลี่ยนแบบจำลองโดยไม่เพิ่มคุณภาพและความหลากหลายของข้อมูลอาจทำให้ดันแบบซับซ้อนขึ้น แต่ไม่ได้ทำให้เชื่อถือได้มากขึ้น

ขอบเขตของ HandVox รุ่นนี้จึงเป็นการรู้จำคำแบบแยกคำจากชุดคำที่กำหนดไว้ เพื่อช่วยสื่อสารเบื้องต้น ไม่ใช่ระบบแปลภาษามือแทนมนุษย์ในทุกบริบท