

บทที่ 2

ความรู้พื้นฐาน

ในการจัดสร้างโครงงาน HandVox จำเป็นต้องศึกษาความรู้พื้นฐาน แนวคิด ทฤษฎี เทคโนโลยี และงานวิจัยที่เกี่ยวข้อง เพื่อกำหนดขอบเขต ออกแบบข้อมูล เลือกแบบจำลอง และประเมินผลระบบอย่างเหมาะสม โดยแบ่งเนื้อหาออกเป็นหัวข้อดังนี้

- 2.1 ภาษามือและการรู้จำ
- 2.2 การมองเห็นด้วยคอมพิวเตอร์ (Computer Vision)
- 2.3 จุดสำคัญที่ใช้ใน HandVox
- 2.4 การปรับมาตรฐานและการแทนลำดับ
- 2.5 แบบจำลองสำหรับจำแนกลำดับท่าทาง
- 2.6 การแบ่งข้อมูลและการป้องกันการรั่วไหล
- 2.7 การประเมินผล
- 2.8 การทำงานแบบเวลาจริงและเสียงพูด
- 2.9 งานวิจัยที่เกี่ยวข้อง

การทบทวนเอกสารสืบค้นผ่าน SciSpace และตรวจสอบกับแหล่งต้นฉบับบนเว็บเมื่อวันที่ 16 กันยายน พ.ศ. 2569 โดยเน้นช่วง 16 กันยายน พ.ศ. 2564 ถึง 16 กันยายน พ.ศ. 2569 และเสริมงานพื้นฐานที่เก่ากว่า คำค้นหลักครอบคลุมการรู้จำภาษามือไทย Thai sign language recognition, MediaPipe landmarks, skeleton-based recognition, TCN, few-shot learning, signer-independent evaluation, unknown gestures และ text-to-speech คัดเลือกตามความเกี่ยวข้องกับการจำแนกคำ ข้อมูลลำดับ การแบ่งชุดทดสอบ และการนำไปใช้ในระบบ พร้อมแยกหลักฐานจากฉบับเต็ม บทคัดย่อ และเอกสารซอฟต์แวร์

บทนี้แยกหลักการและผลของงานวิจัยจากการออกแบบ HandVox โดยตรวจสอบรายละเอียดระบบกับ README.md, CODE_GUIDE.md, TRAINING_GUIDE.md ไฟล์กำหนดค่า และซอร์สโค้ด ณ วันที่สืบค้น ค่าตั้งและเป้าหมายการเก็บข้อมูลไม่ใช่ผลทดลองหรือจำนวนข้อมูลที่เก็บได้จริง ส่วนผลของงานภาษามืออื่นใช้เพื่อศึกษาแนวทางและข้อจำกัด ไม่ถือว่าใช้แทนผลการทดสอบภาษามือไทยได้

2.1 ภาษามือและการรู้จำ

ภาษามือเป็นภาษาธรรมชาติในช่องทางการมองเห็นและการเคลื่อนไหว ผู้ใช้สร้างความหมายด้วยมือ แขน ใบหน้า ศีรษะ และลำตัวพร้อมกัน จึงมีลักษณะต่างจากท่าทางสั่งงานทั่วไปซึ่งมักกำหนดสัญลักษณ์จำนวนจำกัดและไม่จำเป็นต้องมีโครงสร้างทางภาษา การพัฒนาระบบรู้จำภาษามือจึงต้องกำหนดให้ชัดเจนว่าระบบกำลังจำแนกท่าที่กำหนดไว้ รู้จำลำดับหน่วยภาษา หรือแปลเป็นประโยคภาษาพูด

2.1.1 ภาษามือกับท่าทางทั่วไป

ท่าทางทั่วไปอาจเป็นสัญญาณที่ผู้ออกแบบระบบกำหนดขึ้น เช่น ยกมือเพื่อเริ่มหรือชี้นิ้วเพื่อเลือกคำสั่ง แต่ภาษามือมีรูปแบบการใช้ที่เกิดขึ้นในชุมชนผู้ใช้ มีคำศัพท์ หลักการสร้าง ความหมาย และความแตกต่างระหว่างภาษา ภาษามือไทยจึงไม่ควรถูกแทนด้วยชุดท่าของภาษามือประเทศอื่นโดยตรง แม้บางรูปมืออาจมีลักษณะคล้ายกัน

ระบบคอมพิวเตอร์มองเห็นเพียงข้อมูลภาพหรือพิกัด จึงยังไม่เข้าใจความหมายทางภาษาด้วยตัวเอง ผู้พัฒนาต้องกำหนดป้ายกำกับตัวอย่างให้สอดคล้องกับคำที่ต้องการรู้จำ และต้องอาศัยผู้รู้ภาษามือตรวจสอบความถูกต้องของรูปมือ ทิศทาง จุดเริ่ม จุดสิ้นสุด และบริบทของแต่ละท่า หากป้ายกำกับผิด แบบจำลองจะเรียนรู้ความสัมพันธ์ที่ผิดแม้กระบวนการฝึกจะทำงานสมบูรณ์

สำหรับ HandVox การรู้จำหมายถึงการจำแนกลำดับสั้นของหนึ่งท่าเป็นป้ายกำกับในคลังคำที่แบบจำลองรองรับ แล้วสะสมคำและอ่านออกเสียง ระบบจึงอยู่ในขอบเขตการรู้จำแบบแยกคำ ไม่ใช่การรู้จำภาษามือต่อเนื่องหรือการแปลไวยากรณ์ภาษามือไทยอย่างครบถ้วน จำนวนคลาสที่ใช้งานจริงต้องตรวจจากข้อมูลกำกับของแบบจำลองแต่ละรุ่น ไม่นานจากรายการคำที่วางแผนไว้

2.1.2 องค์ประกอบที่สร้างความหมาย

องค์ประกอบแบบใช้มือประกอบด้วยรูปมือ ตำแหน่งของมือ ทิศทางฝ่ามือ การวางแนวของนิ้ว การเคลื่อนที่ และความสัมพันธ์ระหว่างมือสองข้าง รูปมือที่เหมือนกันอาจให้ความหมายต่างกันเมื่ออยู่คนละตำแหน่งหรือเคลื่อนคนละทิศทาง ดังนั้นการเลือกเฉพาะภาพมือที่ตัดออกจากร่างกายอาจทำให้สูญเสียบริบทสำคัญ

องค์ประกอบที่ไม่ใช้มือประกอบด้วยสีหน้า การเคลื่อนไหวศีรษะ การจ้องมอง ปาก ไหล่ และลำตัว องค์ประกอบเหล่านี้อาจทำหน้าที่เปลี่ยนน้ำเสียงทางภาษา แสดงคำถาม ปฏิเสธ หรือเสริมข้อมูลที่มือไม่ได้สื่อเพียงลำพัง Camgoz และคณะ (2020) ย้ำว่าภาษามือใช้หลายช่องทางพร้อมกัน จึงเป็นปัญหาเชิงพื้นที่และเวลาที่ซับซ้อนกว่าการจำแนกรูปมือ

HandVox รุ่นปัจจุบันใช้จุดสำคัญช่วงบนและมือสองข้าง แต่ไม่ใช้จุดใบหนัารายละเอียดสูง การตัดสินใจนี้ช่วยลดจำนวนคุณลักษณะและการประมวลผล เหมาะกับต้นแบบคำระดับพื้นฐาน อย่างไรก็ตาม คำที่ต่างกันด้วยสีหน้าหรือรูปปากอาจไม่สามารถแยกได้ดี จึงต้องเลือกชุดคำให้สอดคล้องกับข้อมูลที่ระบบเก็บจริง

ความสัมพันธ์เชิงเวลามีความสำคัญต่อท่าที่เคลื่อนไหว เช่น การเปลี่ยนมือเข้าหาลำตัวหรือหมุนข้อมือ การเฉลี่ยทุกเฟรมอาจทำให้สูญเสียลำดับและทิศทาง HandVox จึงเก็บข้อมูลตามเวลา และใช้ Temporal Convolutional Network หรือ TCN จำแนกลำดับ โดยเส้นทาง SVC เดิมยังใช้การแผ่ลำดับเป็นเวกเตอร์และมีบทบาทเป็นทางเลือกสำรองตามเงื่อนไขความเข้ากันได้ของโมเดล

2.1.3 ระดับของงานรู้จำภาษามือ

การรู้จำจากภาพนิ่งรับข้อมูลหนึ่งเฟรมและเหมาะกับรูปมือที่มีเอกลักษณ์ชัดเจน ข้อดีคือเก็บข้อมูลง่ายและใช้ทรัพยากรน้อย แต่ไม่สามารถอธิบายท่าที่ความหมายขึ้นกับการเคลื่อนไหวหรือการเปลี่ยนรูปมือหลายช่วง

การรู้จำแบบแยกคำรับคลิปที่มีท่าหนึ่งคำและทราบขอบเขตเริ่มต้นกับสิ้นสุดโดยประมาณ งานลักษณะนี้ยังต้องวิเคราะห์เวลา แต่ไม่ต้องค้นหาว่าคำเริ่มและจบตรงจุดใดในวิดีโอยาว จึงเหมาะกับการสร้างต้นแบบและการประเมินรายการคลาส

การรู้จำภาษามือต่อเนื่องรับวิดีโอที่ประกอบด้วยหลายหน่วยท่าและต้องจัดการขอบเขตระหว่างท่า ส่วนการแปลภาษามือมีเป้าหมายเป็นข้อความภาษาปลายทางที่ถ่ายทอดความหมาย งานของ Camgoz และคณะ (2020) เรียนรู้การรู้จำและการแปลร่วมกันด้วย Transformer และ CTC จึงแสดงให้เห็นว่าโจทย์ทั้งสองเกี่ยวข้องกันแต่มีผลลัพธ์และเกณฑ์ประเมินต่างกัน การนำคำที่จำแนกได้มาต่อกันใน HandVox ยังไม่ใช่หลักฐานว่าระบบเรียนรู้การแปลภาษา

ระดับงาน	ข้อมูลนำเข้า	ผลลัพธ์	ประเด็นสำคัญ
ภาพนิ่ง	ภาพหนึ่งเฟรม	คลาสของรูปมือ	ไม่เก็บลำดับการเคลื่อนไหว
แยกคำ	คลิปหนึ่งท่า	หนึ่งคำหรือหนึ่งป้ายกำกับ	ต้องกำหนดช่วงเริ่มและสิ้นสุดให้สม่ำเสมอ
ต่อเนื่อง	วิดีโอหลายท่า	ลำดับหน่วยท่า	ต้องแบ่งคำและจัดการช่วงเปลี่ยน
การแปล	วิดีโอภาษามือ	ประโยคภาษาพูด	ต้องเรียนรู้ความหมาย ลำดับคำ และไวยากรณ์

ตารางที่ 2.1 ระดับของงานรู้จำและแปลภาษามือ

2.1.4 การรู้จำแบบแยกคำของ HandVox

HandVox กำหนดความยาวลำดับเป้าหมาย 30 เฟรมสำหรับหนึ่งตัวอย่าง และใช้หน้าต่างข้อมูลจากกล้องในการตรวจจับ ก่อนเข้า TCN มีชั้นเตรียมลำดับและสร้างคุณลักษณะเพิ่มเติมให้คงรูปแบบเดียวกับการฝึก ส่วนเส้นทาง SVC เดิมแผ่ข้อมูล 30×171 เป็นเวกเตอร์ 5,130 ค่า ขนาดลำดับคงที่ไม่ได้หมายความว่าทุกคลิปมีระยะเวลาจริงเท่ากัน

ไฟล์ training_config.json กำหนดชุดคำเริ่มต้นที่ผู้ใช้องเห็น 16 คำ พร้อมคลาสภายใน neutral และ unknown รายการดังกล่าวเป็นข้อกำหนดการฝึก ไม่ใช่การยืนยันว่าทุกคำผ่านการฝึกหรือประเมินแล้ว neutral ใช้แทนท่าพักตามนิยามชุดข้อมูล ส่วน unknown ใช้ตัวอย่างที่ไม่ควรถูกยอมรับเป็นคำในคลัง การเพิ่มคำต้องเก็บข้อมูลและฝึกใหม่โดยรวมคลาสเดิมและคลาสภายใน ไม่ใช่เพียงเพิ่มชื่อคำในส่วนติดต่อ

การเลือกคำควรคำนึงถึงความต่างทางสายตา ความสำคัญต่อสถานการณ์ และความสามารถในการเก็บตัวอย่าง คำที่มีการเคลื่อนไหวคล้ายกันมากต้องมีจำนวนตัวอย่างมากขึ้นและควรตรวจเมทริกซ์ความสับสน (Confusion Matrix) เป็นพิเศษ ส่วนคำ ช่วยด้วย ถูกกำหนดเป็นคำสำคัญซึ่งต้องมีค่าความระลึก (Recall) สูงกว่าค่าทั่วไปตามเกณฑ์รับรองของโครงการ

2.1.5 ความแปรผันและความท้าทาย

ผู้ทำท่าต่างคนมีขนาดมือ สัดส่วนร่างกาย ความถนัด ความเร็ว และรูปแบบการเคลื่อนไหวไม่เหมือนกัน แม้เป็นคำเดียวกัน ตำแหน่งพิกัดมือจึงอาจแตกต่างกันมาก หากเก็บข้อมูลจากคนเพียงคนเดียว แบบจำลองอาจจดจำลักษณะของบุคคลนั้นมากกว่ารูปแบบของคำ

สภาพการถ่ายภาพเพิ่มความแปรผันจากแสง ฉากหลัง เสื้อผ้า ระยะกล้อง มุมกล้อง ความละเอียด และการบังมือ จุดสำคัญอาจหายหรือกระโดดเมื่อมือเคลื่อนไหว อยู่ชิดขอบภาพ หรือซ้อนกับใบหน้าและลำตัว การประเมินในสภาพควบคุมจึงควรแยกจากการทดสอบใช้งานจริง

เมื่อตัวอย่างไม่อยู่ในคลัง ตัวจำแนกแบบปิดยังอาจให้คะแนนสูงแก่คลาสที่รู้จัก HandVox จึงใช้ทั้ง neutral, unknown เกณฑ์คะแนน ความต่างระหว่างสองอันดับแรก และการยืนยันตามเวลา แต่การฝึก unknown จากตัวอย่างจำนวนจำกัดไม่ได้รับประกันว่าจะปฏิเสธท่าที่ไม่เคยพบได้ทั้งหมด แนวคิดการประเมินแบบเปิดจึงต้องแยกจากความถูกต้องภายในคลัง (Bendale และ Boulton, 2016)

2.2 การมองเห็นด้วยคอมพิวเตอร์ (Computer Vision)

การมองเห็นด้วยคอมพิวเตอร์เป็นกระบวนการทำให้คอมพิวเตอร์รับและแปลงข้อมูลภาพเป็นตัวแทนที่ใช้ตัดสินใจได้ สำหรับ HandVox กระบวนการเริ่มจากเว็บแคม ส่งภาพให้ OpenCV จัดการ

เฟรม แปลงลำดับสี และส่งเข้า MediaPipe เพื่อประมวลผลสำคัญ จากนั้นระบบจึงแปลงพิกัดเป็นคุณลักษณะสำหรับแบบจำลอง

2.2.1 ภาพดิจิทัล วิดีโอ และระบบพิกัด

ภาพดิจิทัลประกอบด้วยพิกเซลเรียงเป็นตาราง แต่ละพิกเซลเก็บค่าความเข้มของช่องสี วิดีโอคือภาพหลายเฟรมที่เรียงตามเวลา อัตราเฟรมกำหนดความถี่ในการสังเกตการเคลื่อนไหว หากอัตราเฟรมต่ำเกินไป การเคลื่อนไหวเร็วอาจขาดช่วง แต่หากสูงมาก ภาระประมวลผลและจำนวนข้อมูลจะเพิ่มขึ้น

OpenCV อ่านภาพในลำดับสี BGR ขณะที่ MediaPipe รับ RGB โปรแกรมจึงต้องแปลงลำดับสีก่อนประมวลผล หากข้ามขั้นตอนนี้ ค่าช่องสีจะสลับและลดคุณภาพการตรวจจับ แม้ภาพบนหน้าจอจะดูใกล้เคียงในบางกรณี

พิกัดภาพ x และ y มักถูกทำให้เป็นสัดส่วนกับความกว้างและความสูงของเฟรม ส่วนค่า z ของ MediaPipe แทนความลึกเชิงสัมพัทธ์ ไม่ใช่ระยะจริงจากกล้องโดยตรง การใช้พิกัดเหล่านี้ต้องคำนึงว่าความละเอียดภาพ อัตราส่วนภาพ และตำแหน่งผู้ใช้ส่งผลต่อค่าที่ได้

2.2.2 บทบาทของ OpenCV

OpenCV ทำหน้าที่เปิดอุปกรณ์กล้อง อ่านเฟรม กลับภาพในแนวนอน แปลงสี วาดกรอบแสดงข้อความ และรับคีย์หรือการคลิกจากผู้ใช้ การกลับภาพช่วยให้หน้าจอทำงานเหมือนกระจกซึ่งใช้งานง่าย แต่ต้องใช้แนวทางเดียวกันทั้งตอนเก็บข้อมูลและตรวจจับเพื่อไม่ให้ทิศซ้ายขวาของตัวอย่างต่างกัน

HandVox ขอภาพจากกล้องที่ขนาด 1280×720 พิกเซล แต่ความละเอียดจริงขึ้นกับอุปกรณ์และไดรเวอร์ ค่าความละเอียดที่สูงขึ้นช่วยให้เห็นรายละเอียดมือ แต่เพิ่มเวลาถ่ายโอนและประมวลผล ดังนั้นการตั้งค่าควรทดสอบร่วมกับอัตราเฟรมและความหน่วงบนเครื่องเป้าหมาย

ส่วนติดต่อบนภาพกล้องมีหน้าที่มากกว่าการตกแต่ง เพราะช่วยให้ผู้ใช้เห็นว่าระบบตรวจพบร่างกายหรือมือหรือไม่ แสดงค่าที่กำลังพิจารณา สถานะยืนยัน ค่าความเชื่อมั่น ประโยคปัจจุบัน และปุ่มควบคุม การให้ข้อมูลย้อนกลับทันทีช่วยให้ผู้ใช้ปรับตำแหน่งและจังหวะการทำท่าได้

2.2.3 การตรวจจับและการติดตาม

การตรวจจับค้นหาว่าวัตถุหรือส่วนร่างกายอยู่บริเวณใดในภาพ ส่วนการติดตามใช้ข้อมูลจากเฟรมก่อนหน้าเพื่อประมาณตำแหน่งในเฟรมถัดไป การติดตามช่วยลดการตรวจใหม่ทุกเฟรมและทำให้พิกัดต่อเนื่องขึ้น แต่หากวัตถุหลุดกรอบหรือถูกบัง ระบบอาจต้องกลับไปตรวจจับใหม่

HandVox ใช้ MediaPipe Holistic ในโหมดวิดีโอต่อเนื่อง กำหนด `model_complexity` เท่ากับ 1 เปิด `smooth_landmarks` และกำหนดค่าความเชื่อมั่นขั้นต่ำของการตรวจจับกับการติดตามเท่ากับ 0.70 ค่าดังกล่าวเป็นการประนีประนอมระหว่างคุณภาพ ความเร็ว และความต่อเนื่องของจุดสำคัญ

การทำให้จุดราบรื่นช่วยลดการสั่นจากความคลาดเคลื่อนรายเฟรม แต่มีโอกาสเพิ่มความหน่วงและทำให้การเปลี่ยนเร็วถูกรองบางส่วน จึงต้องประเมินร่วมกับขนาดหน้าต่าง 30 เฟรม และกลไกยืนยันผล ไม่ควรพิจารณาค่าตั้งของตัวติดตามแยกจากพฤติกรรมทั้งระบบ

2.2.4 ภาพติดกับจุดสำคัญ

การเรียนรู้จากภาพติดเก็บข้อมูลพื้นผิว สี รูปร่างมือ ใบหน้า เสื้อผ้า และฉากหลังไว้ครบแบบจำลองเชิงลึกสามารถเรียนรู้คุณลักษณะจากข้อมูลจำนวนมาก แต่ต้องใช้ทรัพยากรสูงและมีความเสี่ยงเรียนรู้สิ่งรบกวน เช่น สีเสื้อหรือสถานที่ถ่ายภาพ

การใช้จุดสำคัญลดภาพให้เหลือโครงสร้างพิกัดของข้อต่อ ทำให้ข้อมูลมีขนาดเล็กและลดอิทธิพลของพื้นหลัง เหมาะกับโครงการที่มีข้อจำกัดและต้องทำงานบนคอมพิวเตอร์ทั่วไป อย่างไรก็ตาม ความผิดพลาดของตัวประมาณจุดสำคัญจะถูกส่งต่อไปยังตัวจำแนก และรายละเอียดที่ไม่มีในพิกัดจะไม่สามารถกู้คืนได้

ข้อมูลโครงกระดูกสามารถสร้างตัวแทนหลายแบบจากแหล่งเดียว เช่น พิกัดข้อต่อ เวกเตอร์กระดูก และการเปลี่ยนตำแหน่งตามเวลา Hu และคณะ (2024) ใช้ข้อมูลเหล่านี้ร่วมกับการรวมข้อมูลเชิงพื้นที่และเวลา อย่างไรก็ตาม หลักฐานจากภาษามืออื่นไม่ได้ยืนยันโดยตรงว่าการเพิ่มทุกช่องข้อมูลจะช่วย HandVox จึงควรทดสอบประโยชน์ของแต่ละกลุ่มคุณลักษณะบนชุดแบ่งเดียวกัน

ตัวแทนข้อมูล	ข้อดี	ข้อจำกัด	ความเหมาะสมกับ HandVox
ภาพเต็ม	เก็บบริบทและองค์ประกอบครบ	มิติสูงและไวต่อฉากหลัง	เหมาะเมื่อมีข้อมูลและทรัพยากรมาก
ภาพเฉพาะมือ	เน้นรูปมือและรายละเอียดนิ้ว	สูญเสียตำแหน่งเทียบร่างกาย	ใช้เสริมค่าที่ต่างกันด้วยรูปมือ
จุดมือ	ข้อมูลเล็กและลดผลจากพื้นหลัง	ไม่เห็นสี พื้นผิว และสีหน้า	เหมาะกับคำที่รูปมือเด่น
จุดมือและช่วงบน	เห็นรูปมือ ตำแหน่ง และท่าทาง	ขึ้นกับคุณภาพ landmark	เป็นตัวแทนหลักของระบบปัจจุบัน
หลายรูปแบบร่วมกัน	ข้อมูลแต่ละชนิดชดเชยกัน	ซับซ้อนและใช้ทรัพยากรสูง	เป็นแนวทางพัฒนาต่อยอด

ตารางที่ 2.2 การเปรียบเทียบตัวแทนข้อมูลภาพสำหรับการรู้จำ

2.2.5 ปัจจัยของสภาพแวดล้อม

แสงน้อยทำให้เกิดสัญญาณรบกวนและขอบมือไม่ชัด แสงจากด้านหลังอาจทำให้มือมืดกว่า ฉาก ส่วนแสงที่เปลี่ยนระหว่างคลิปทำให้คุณภาพการตรวจจับไม่คงที่ ควรเก็บข้อมูลหลายสภาพแสง แต่ยังคงรักษาให้มือและช่วงบนมองเห็นได้

มุมมองเปลี่ยนรูปร่างที่ฉายลงบนภาพและทำให้พิกัด z มีความคลาดเคลื่อน การฝึกเฉพาะกล้องตรงระดับเดียวอาจให้ผลดีในห้องทดลองแต่ลดลงเมื่อบางกล้องสูงหรือต่ำกว่าเดิม การกำหนดตำแหน่งใช้งานที่แนะนำและการเก็บตัวอย่างหลายมุมจึงเป็นคุณสมบัติที่ควรทำร่วมกัน

การบังเกิดเมื่อมือซ้อนกัน ผ่านใบหน้า หรือหลุดนอกรอบ ชั้นสกัดข้อมูลดิบของ HandVox เดิมศูนย์เมื่อไม่พบมือข้างหนึ่งเพื่อคงมิติ ส่วนชั้นเตรียมลำดับสำหรับ TCN มีการจัดการช่วงข้อมูลหลายเส้นและสร้างตัวบอกการมองเห็นมือ การประมาณค่าทดแทนไม่ได้คืนรายละเอียดที่ถูกบังทั้งหมด จึงยังต้องตรวจคุณภาพคลิปและบันทึกกรณีข้อมูลหาย

2.3 จุดสำคัญที่ใช้ใน HandVox

จุดสำคัญ (landmark) เป็นพิกัดตัวแทนตำแหน่งข้อต่อและส่วนของร่างกาย การเลือกจุดต้องครอบคลุมข้อมูลที่จำเป็นต่อการแยกค่าโดยไม่เพิ่มมิติที่ไม่จำเป็น HandVox ใช้จุดช่วงบน 15 จุดและจุดมือข้างละ 21 จุด แต่ละจุดมีค่า x, y และ z รวม 171 ค่าในหนึ่งเฟรม

2.3.1 กรอบงาน MediaPipe

Lugaresi และคณะ (2019) เสนอ MediaPipe เป็นกรอบงานสำหรับประกอบ perception pipeline จากส่วนรับสื่อ แบบจำลอง และตัวแปลงข้อมูลในรูปกราฟ ช่วยให้พัฒนาต้นแบบ วัดทรัพยากร และนำการประมวลผลไปใช้ข้ามแพลตฟอร์มได้

แนวคิดแบบ pipeline เหมาะกับ HandVox เพราะสามารถแยกขั้นรับภาพ การตรวจจุดสำคัญ การสกัดคุณลักษณะ การสะสมลำดับ และการจำแนกออกจากกัน เมื่อเกิดปัญหาจึงตรวจได้ว่าความผิดพลาดเริ่มจากกล้อง จุดสำคัญ หรือแบบจำลอง

MediaPipe ไม่ได้จำแนกคำภาษามือให้ HandVox โดยตรง แต่ประมาณจุดสำคัญเพื่อนำไปสร้างคุณลักษณะให้ TCN หรือเส้นทาง SVC สำรอง ความถูกต้องของระบบจึงขึ้นกับทั้งตัวประมาณจุด ชั้นเตรียมลำดับ ตัวจำแนก และกลไกยืนยันผล ไม่ควรใช้คะแนนหรือเวลาประมวลผลขององค์ประกอบหนึ่งแทนผลของระบบทั้งหมด

2.3.2 จุดมือ 21 จุด

Zhang และคณะ (2020) อธิบาย MediaPipe Hands ว่าใช้ palm detector เพื่อค้นหาบริเวณมือ แล้วใช้ hand landmark model ประมาณโครงมือจากภาพ RGB กล้องเดียว

กระบวนการสองขั้นช่วยให้โมเดล landmark ทำงานกับบริเวณที่จัดแนวแล้วและรองรับการติดตามแบบเวลาจริงบนอุปกรณ์

จุดมือ 21 จุดครอบคลุมข้อมือ โคนนิ้ว ข้อนิ้ว และปลายนิ้วทั้งห้า การเปรียบเทียบตำแหน่งระหว่างจุดช่วยอธิบายการงอ เขยียด กาง และทิศทางของนิ้วได้ดีกว่ากรอบสี่เหลี่ยมรอบมือเพียงอย่างเดียว

พิกัดมือยังมีข้อจำกัดเมื่อมือหันด้านข้าง นิ้วซ้อนกัน หรือส่วนหนึ่งอยู่นอกภาพ การทำให้มองเห็นมือชัดและเก็บหลายตัวอย่างจึงยังจำเป็น แม้ตัวตรวจจุดสำคัญจะผ่านการฝึกมาก่อนแล้วก็ตาม

2.3.3 จุดช่วงบน 15 จุด

HandVox เลือกจุดหมายเลข 0, 2, 5, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 23 และ 24 จากโครงร่างของ MediaPipe เพื่อให้มีบริบทศีรษะ ไหล่ แขน และสะโพกสำหรับอ้างอิงตำแหน่งมือ ความเพียงพอของจุดที่เลือกขึ้นกับค่าที่ต้องการจำแนกและต้องตรวจจากผลทดลอง ไม่อาจสรุปว่าครอบคลุมองค์ประกอบของภาษามือไทยทั้งหมด

ไหล่ซ้ายและไหล่ขวาใช้สร้างจุดกึ่งกลางและระยะอ้างอิงในการปรับมาตรฐาน สอดกับข้อมือช่วยอธิบายแนวแขน ส่วนจุดศีรษะและสะโพกช่วยให้เห็นตำแหน่งโดยรวม การใช้เฉพาะ 15 จุดลดจำนวนคุณลักษณะจากการเก็บโครงร่างทั้งตัว

การตัดจุดบางส่วนล่างออกเหมาะกับการบ่งชี้ที่เน้นช่วงบนและค่าที่แสดงด้วยมือ แต่ระบบจะไม่เหมาะกับภาษามือหรือท่าทางที่ใช้การเคลื่อนไหวส่วนล่างอย่างมีความหมาย การเลือกจุดจึงเป็นการกำหนดขอบเขตของสิ่งที่แบบจำลองสามารถเรียนรู้ได้

2.3.4 การสร้างเวกเตอร์ 171 ค่า

จุดช่วงบน 15 จุดสร้างข้อมูล 45 ค่า เพราะแต่ละจุดมี 3 แกน มือซ้าย 21 จุดสร้าง 63 ค่า และมือขวาอีก 63 ค่า ผลรวมเท่ากับ $45 + 63 + 63$ หรือ 171 ค่าในหนึ่งเฟรม ลำดับคอลัมน์ถูกกำหนดคงที่เป็น pose ก่อน ตามด้วย left_hand และ right_hand

การใช้ลำดับเดียวกันเป็นเงื่อนไขสำคัญ เพราะตัวเลขตำแหน่งหนึ่งไม่มีความหมายในตัวเอง หากขณะฝึกตำแหน่งที่ 46 หมายถึงข้อมือซ้าย แต่ขณะทำนายกลับหมายถึงข้อมือขวา แบบจำลองจะได้รับความหมายคนละแบบแม้จำนวนคุณลักษณะยังเท่ากัน

ไฟล์ body_features.py ถูกใช้ร่วมกันทั้งขั้นเก็บข้อมูลและตรวจจับ เพื่อลดความเสี่ยงที่สูตรปรับมาตรฐาน จำนวนจุด หรือการเติมค่ามือที่หายจะแตกต่างกัน การรวมตรรกะสำคัญไว้ที่เดียวเป็นหลักการควบคุมความสอดคล้องของข้อมูลที่มีผลโดยตรงต่อความถูกต้อง

กลุ่มจุด	จำนวนจุด	ค่าต่อจุด	จำนวนค่า	หน้าที่
ช่วงบน	15	x, y, z	45	บริบทศีรษะ ไหล่ แขน ลำตัว
มือซ้าย	21	x, y, z	63	รูปมือและตำแหน่งมือซ้าย
มือขวา	21	x, y, z	63	รูปมือและตำแหน่งมือขวา
ข้อมูลดิบต่อเฟรม	57	3	171	ก่อนขยายคุณลักษณะ
ข้อมูลเข้า TCN	–	–	510 ต่อเฟรม	รวมพิกัด เรขาคณิต ตัวบอกมือ และผลต่าง
ข้อมูลเข้า SVC เดิม	–	–	5,130 ต่อคลิป	แผ่นลำดับ 30 × 171

ตารางที่ 2.3 จำนวนจุดและมิติคุณลักษณะของ HandVox

2.3.5 ข้อมูลหายและการระบุข้างของมือ

หากไม่พบโครงร่างช่วงบน หรือไม่พบมือทั้งสองข้าง ฟังก์ชันสกัดคุณลักษณะจะคืนค่า None และเฟรมนั้นไม่ถูกเพิ่มในลำดับ เพราะไม่มีจุดอ้างอิงหรือไม่มีข้อมูลมือเพียงพอสำหรับการจำแนก

หากพบมือเพียงข้างเดียว ข้อมูลดิบเต็มศูนย์ 63 ค่าให้มือที่หาย ศูนย์ดังกล่าวหมายถึงไม่ตรวจพบ ไม่ใช่ตำแหน่งจริง ในเส้นทาง TCN ชั้นเตรียมข้อมูลสามารถประมาณช่องว่างสั้นตามค่ากำหนดและสร้างตัวบอกการมองเห็นมือ จึงต้องใช้กระบวนการเดียวกันระหว่างฝึกกับใช้งาน และตรวจสอบสัดส่วนข้อมูลหายในขั้นตรวจรับคลิป

การกลับภาพแบบกระจกและการตีความ left_hand กับ right_hand ต้องสอดคล้องกันทุกชั้น หากกระบวนการใดกลับภาพต่างจากอีกกระบวนการ ระบบอาจสลับมือซ้ายและขวา ควรมีการทดสอบแบบหน่วยที่ยืนยันลำดับคอลัมน์และตัวอย่างที่ใช้มือข้างเดียวโดยเฉพาะ

2.3.6 ข้อดีด้านขนาดข้อมูลและความเป็นส่วนตัว

ลำดับจุดสำคัญลดรายละเอียดภาพให้เหลือข้อมูลพิกัด จึงมีข้อมูลที่ต้องจัดเก็บน้อยกว่าวิดีโอ ดิบในเงื่อนไขที่เทียบกันได้ และลดการส่งต่อรายละเอียดจากหลังสู่ตัวจำแนก อย่างไรก็ตาม ความเร็วจริงยังขึ้นกับขั้นประมาณจุดสำคัญ การสร้างคุณลักษณะ และแบบจำลอง จึงต้องวัดเวลาของระบบบนฮาร์ดแวร์ที่ใช้งาน

อย่างไรก็ตาม พิกัดการเคลื่อนไหวยังเป็นข้อมูลเกี่ยวกับบุคคลและอาจเปิดเผยรูปแบบการเคลื่อนไหวหรือสัดส่วนบางอย่างได้ จึงยังต้องควบคุมสิทธิการเข้าถึง ขอความยินยอม และกำหนดระยะเวลาจัดเก็บ ไม่ควรสรุปว่าการตัดภาพออกทำให้ข้อมูลไม่มีความเสี่ยงด้านความเป็นส่วนตัวทั้งหมด

2.4 การปรับมาตรฐานและการแทนลำดับ

พิกัดจากกล้องแปรผันตามตำแหน่งและระยะผู้ใช้ HandVox จึงปรับพิกัดเทียบกับร่างกายก่อนสร้างลำดับ เส้นทางหลักรักษามิติเวลาและขยายคุณลักษณะเป็น 510 ค่าต่อเฟรมสำหรับ TCN ส่วนเส้นทาง SVC เดิมรับเวกเตอร์ที่แผ่จากข้อมูลดิบ การแยกสองเส้นทางนี้ช่วยอธิบายรูปแบบข้อมูลได้ตรงกับแบบจำลองปัจจุบัน

2.4.1 การเลื่อนจุดอ้างอิง

ระบบคำนวณจุดกึ่งกลางระหว่างไหล่ซ้ายกับไหล่ขวาในสามแกน แล้วนำพิกัดของทุกจุดลบด้วยจุดกึ่งกลางดังกล่าว ผลลัพธ์คือพิกัดสัมพันธ์กับลำตัวแทนพิกัดสัมพันธ์กับมุมมองภาพ

การเลื่อนจุดอ้างอิงช่วยลดผลจากการยืนค่อนไปทางซ้ายหรือขวาและการขยับขึ้นลงเล็กน้อย ตัวอย่างของค่าเดียวกันจึงอยู่ในระบบพิกัดใกล้เคียงกันมากขึ้น แต่ไม่แก้ผลของการหมุนตัวหรือการเปลี่ยนมุมมองทั้งหมด

การเลือกกึ่งกลางไหล่เหมาะกับงานช่วงบนเพราะตรวจพบได้ค่อนข้างสม่ำเสมอและอยู่ใกล้ศูนย์กลางการเคลื่อนไหวของแขน หากไหล่ถูกบังหรือประมาณผิด ความคลาดเคลื่อนจะกระทบทุกจุดในเฟรมนั้นพร้อมกัน

2.4.2 การปรับขนาดด้วยระยะไหล่

หลังเลื่อนจุด ระบบหารค่าพิกัดด้วยระยะยูคลิดระหว่างไหล่ซ้ายกับไหล่ขวา ระยะดังกล่าวทำหน้าที่เป็นสเกลโดยประมาณของผู้ใช้ในภาพ ช่วยลดผลจากการยืนใกล้หรือไกลกล้องและความแตกต่างของขนาดร่างกาย

ได้กำหนดค่าต่ำสุดของสเกลเป็น $1e-6$ เพื่อป้องกันการหารด้วยศูนย์ หากตัวตรวจจุดสำคัญให้ตำแหน่งไหล่เกือบตรงกัน การหารด้วยค่าที่เล็กมากอาจสร้างค่าคุณลักษณะสูงผิดปกติ จึงควรตรวจค่าผิดปกติและคุณภาพ landmark ในขั้นเตรียมข้อมูล

การปรับด้วยระยะไหล่ไม่ทำให้ข้อมูลคงที่ต่อมุมมองสามมิติอย่างสมบูรณ์ เพราะระยะที่ฉายบนภาพเปลี่ยนเมื่อผู้ใช้หันตัว และค่า z เป็นความลึกเชิงสัมพัทธ์ ดังนั้นยังควรเก็บข้อมูลหลายมุมมองที่อยู่ในขอบเขตใช้งานจริง

2.4.3 หน้าต่างเวลา 30 เฟรม

ความยาวเป้าหมายของลำดับคือ 30 เฟรม แต่ระยะเวลาที่ครอบคลุมขึ้นกับเวลาจับภาพและจำนวนเฟรมที่ผ่านการตรวจจุดสำคัญ จึงไม่ควรถือว่าทุกลำดับยาวหนึ่งวินาทีโดยอัตโนมัติ การรายงานเวลาต้องอาศัยข้อมูลเวลาจริงและอัตราประมวลผลที่วัดได้จากเครื่องทดสอบ

ผู้เก็บข้อมูลต้องทำให้จบภายในหน้าต่างเดียวกัน หากทำเร็วมาก ลำดับจะมีช่วงอยู่นิ่งจำนวนมาก หากทำช้าเกินไป ส่วนท้ายของท่าอาจหลุดนอกคลิป ความต่างของจังหวะทำให้ตำแหน่งเหตุการณ์สำคัญอยู่คนละเฟรมและลดความคล้ายของตัวอย่างในคลาสเดียวกัน

ขั้นเตรียมลำดับของ HandVox รองรับการปรับจำนวนเฟรมและการจัดการข้อมูลหาย การใช้ขั้นตอนเดียวกันระหว่างฝึกกับตรวจจับช่วยลดความต่างของรูปแบบข้อมูล แต่ยังคงทดสอบทำที่เร็วหรือช้าต่างจากข้อมูลฝึก เพราะการปรับจำนวนเฟรมไม่สามารถหัดเซตส่วนของท่าที่ไม่ได้บันทึกไว้

2.4.4 คุณลักษณะสำหรับ TCN และเวกเตอร์ของระบบเดิม

ข้อมูลดิบ 171 ค่าต่อเฟรมถูกแปลงใน feature_pipeline.py เป็นพิกัดเดิม 171 ค่า พิกัดมือเฉพาะส่วน 126 ค่า เรายาคณิตของมือ 40 ค่า ตัวบอกการมองเห็นมือ 2 ค่า และผลต่างพิกัดตามเวลา 171 ค่า รวม 510 ค่า ลำดับเป้าหมายที่ส่งเข้า TCN จึงมีรูป 30×510 โดยผลต่างระหว่างเฟรมเป็นตัวแทนการเปลี่ยนตำแหน่ง ไม่ใช่ความเร็วทางกายภาพที่หารด้วยเวลาเป็นวินาทีแล้ว

เส้นทาง SVC สำรองใช้ข้อมูลดิบ 30×171 แผ่นเป็น 5,130 ค่า การรักษาลำดับตำแหน่งในเวกเตอร์ทำให้แต่ละเฟรมอยู่คนละมิติ แต่ไม่มีการใช้ตัวกรองตามเวลาแบบ TCN โปรแกรมจึงต้องตรวจจำนวนคุณลักษณะและรูปแบบข้อมูลของโมเดลก่อนโหลด ไม่สามารถนำโมเดลสองชนิดมาใช้แทนกันโดยไม่ตรวจสอบความเข้ากันได้

ข้อแลกเปลี่ยนคือมิติข้อมูลสูงเมื่อเทียบกับจำนวนคลิป หากมีตัวอย่างน้อย แบบจำลองอาจเรียนรู้รายละเอียดเฉพาะของคลิป การปรับมาตรฐาน การเลือกจุด และการประเมินข้ามผู้ทำจึงมีความสำคัญมากกว่าการพิจารณาความถูกต้องบนชุดฝึก

ขั้นตอน	ข้อมูลเข้า	การแปลง	ข้อมูลออก
ตรวจจุดสำคัญ	ภาพ RGB	ประมาณ pose และ hands	พิกัดหนึ่งเฟรม
เลือกจุด	จุดทั้งหมด	ช่วงบน 15 และมือ 42 จุด	57 จุด
เลื่อนพิกัด	57 จุด	ลบกึ่งกลางไหล่	พิกัดเทียบลำตัว
ปรับขนาด	พิกัดสัมพันธ์	หารด้วยระยะไหล่	171 ค่าต่อเฟรม
เตรียมลำดับ	ข้อมูลตามเวลา	จัดการข้อมูลหายและปรับความยาว	30×171
เส้นทาง TCN	ลำดับพิกัด	ขยายคุณลักษณะตามโครงสร้าง	30×510
เส้นทาง SVC เดิม	ลำดับพิกัดดิบ	แผ่ตามเวลา	5,130 ค่า

ตารางที่ 2.4 ขั้นตอนแปลงภาพเป็นข้อมูลลำดับสำหรับแบบจำลอง

2.4.5 ความเร็ว จังหวะ และการจัดแนวเวลา

ความเร็วของผู้ทำท่าเป็นแหล่งความแปรผันที่ระบบปรับด้วยตำแหน่งและขนาดไม่ได้ หากเหตุการณ์สำคัญเกิดเฟรมที่ 10 ในตัวอย่างหนึ่งแต่เกิดเฟรมที่ 20 ในอีกตัวอย่าง ระยะในเวกเตอร์อาจสูงแม้ความหมายเหมือนกัน

การปรับจำนวนเฟรมด้วยการประมาณค่าและการเพิ่มข้อมูลตามเวลาเป็นแนวทางลดความแปรผันของจังหวะ ส่วน TCN, LSTM, GRU และ Transformer เป็นแนวทางเรียนรู้ความสัมพันธ์ตามเวลาโดยตรง การเปลี่ยนวิธีแทนลำดับต้องตรวจสอบขอบเขตการเคลื่อนไหวที่แยกค้ายังคงอยู่ ไม่ใช่เพียงทำให้ขนาดข้อมูลตรงกัน

HandVox ใช้ TCN กับข้อมูลลำดับเป็นเส้นทางหลักในปัจจุบัน การศึกษาทางเลือกควรตั้งข้อมูล ชุดแบ่ง และเกณฑ์ประเมิน พร้อมรายงานจำนวนพารามิเตอร์และเวลาประมวลผล เพื่อแยกผลของสถาปัตยกรรมออกจากผลของข้อมูลหรือวิธีทดลองที่เปลี่ยนไป

2.4.6 การตรวจคุณภาพคุณลักษณะ

ก่อนฝึกควรตรวจมิติข้อมูล ค่า NaN ค่าอนันต์ ค่าผิดปกติ จำนวนเฟรมที่มีอยู่ และการกระจายของแต่ละแกน หากพบคลิปปิดปกติควรย้อนดูวิดีโอตัวอย่างหรือข้อมูลกำกับ (metadata) แทนการลบทิ้งโดยไม่บันทึกเหตุผล

การทำภาพตัวอย่างของเส้นทางจุดหรือสถิติต่อเฟรมช่วยตรวจว่าลำดับไม่กลับด้าน มีข้อผิดพลาด และจุดกึ่งกลางไหลทำงานตามคาด การตรวจคุณภาพก่อนฝึกช่วยลดเวลาที่สูญเสียไปกับการปรับแบบจำลองเพื่อแก้ปัญหาซึ่งเกิดจากข้อมูล

2.5 แบบจำลองสำหรับจำแนกลำดับท่าทาง

แบบจำลองที่ใช้กับลำดับจุดสำคัญมีทั้งตัวจำแนกเวกเตอร์และโครงข่ายที่เรียนรู้ตามเวลา SVM เป็นพื้นฐานของเส้นทางเดิม (Cortes และ Vapnik, 1995) ขณะที่ TCN เป็นเส้นทางหลักของ HandVox ปัจจุบัน งานของ Bai และคณะ (2018) ใช้เป็นพื้นฐานแนวคิดการคอนโวลูชันตามเวลา แต่ผลบนงานลำดับทั่วไปไม่ใช่หลักฐานความแม่นยำบนภาษามือไทย

2.5.1 โครงข่ายคอนโวลูชันตามเวลา

TCN ใช้ตัวกรองคอนโวลูชันตามแกนเวลาเพื่อเรียนรู้รูปแบบจากหลายเฟรม การเว้นระยะของตัวกรองหรือ dilation ช่วยขยายช่วงเวลาที่ตัวกรองรับข้อมูล ส่วนการเชื่อมแบบ residual ช่วยส่งข้อมูลข้ามชั้น งานของ Bai และคณะ (2018) ศึกษาโครงสร้างแบบ causal ซึ่งไม่ใช่ข้อมูลอนาคตของตำแหน่งที่ทำนาย และเปรียบเทียบกับ LSTM และ GRU บนงานลำดับหลายชนิด

TCN ของ HandVox พัฒนาด้วย PyTorch ใช้ residual blocks ซึ่งประกอบด้วย Conv1d, GroupNorm, ReLU และ dropout พร้อม dilation เพิ่มตามชั้น จากนั้นรวมข้อมูลด้วยค่าเฉลี่ยและค่าสูงสุดตามเวลาเพื่อจำแนกทั้งหน้าต่าง การเติมขอบของคอนโวลูชันในโค้ดเป็นแบบสมมาตร จึงไม่ใช่ causal TCN แบบเดียวกับงานของ Bai และคณะทุกประการ แม้ข้อมูลของหน้าต่างขณะใช้งานจะเป็นเฟรมที่ได้รับมาแล้ว

การจำแนกทั้งหน้าต่างเหมาะกับเป้าหมายหนึ่งป้ายกำกับต่อลำดับ แต่ยังมีควมหน่วงจากการสะสมเฟรมและการยืนยันผล TCN จึงไม่ได้ทำให้ระบบเป็นการรู้จำหลายคำต่อเนื่องโดยตัวมันเอง และยังคงประเมินความเสี่ยงต่อการจำข้อมูลผิดเมื่อจำนวนผู้ทำและคลิปมีจำกัด

2.5.2 LSTM และ GRU

LSTM และ GRU เป็นโครงข่ายแบบเวียนกลับที่มีสถานะส่งต่อไปตามลำดับและใช้กลไกประตูควบคุมข้อมูลที่เก็บหรือปรับปรุง จึงใช้เป็นทางเลือกในการเรียนรู้การเปลี่ยนท่าตามเวลาได้ การเลือกสถาปัตยกรรมต้องพิจารณาทั้งความยาวลำดับ จำนวนข้อมูล และงบเวลาของระบบ ไม่สรุปจากจำนวนชั้นเพียงอย่างเดียว

งานภาษาไทยของ Damrongekarun และคณะ (2023) แสดงการใช้ MediaPipe ร่วมกับ LSTM และ BiLSTM เพื่อจำแนกท่าจากลำดับพิกัด อย่างไรก็ตาม วิธีแบ่งข้อมูลและองค์ประกอบคุณลักษณะต่างจาก HandVox จึงใช้สนับสนุนความเป็นไปได้ของแนวทางได้ แต่ไม่ใช่คะแนนข้ามงานตัดสินว่า LSTM หรือ TCN เหมาะสมกว่ากัน

การทดลองเปรียบเทียบควรใช้กลุ่มผู้ทำและเซสชันเดียวกันในแต่ละชุด กำหนดงบประมาณที่เหมาะสม และเลือกแบบจำลองจากชุดตรวจสอบเท่านั้น ชุดทดสอบที่ถูกใช้เลือกโมเดลเข้าไม่ใช่หลักฐานอิสระของประสิทธิภาพสุดท้าย

2.5.3 แบบจำลองกราฟและ Transformer

แบบจำลองกราฟแทนข้อต่อเป็นโหนดและความเชื่อมโยงระหว่างข้อต่อเป็นเส้นเชื่อม แนวทาง ST-GCN เรียนรู้ทั้งโครงสร้างเชิงพื้นที่และความเปลี่ยนแปลงตามเวลา ส่วน Hu และคณะ (2024) ศึกษาการรวมข้อมูลเชิงพื้นที่แบบปรับเปลี่ยนได้และการคอนโวลูชันหลายช่วงเวลา แนวทางนี้เป็นทางเลือกสำหรับข้อมูล skeleton แต่ต้องตรวจจำนวนจุดและโครงสร้างกราฟให้ตรงกับข้อมูลของ HandVox

Transformer ใช้ attention เพื่อเรียนรู้ความสัมพันธ์ของข้อมูลในลำดับ งานของ Boháček และ Hrúz (2023) ศึกษาการรู้จำแบบแยกคำจากพิกัดและตัวอย่างจำนวนน้อยที่รวบรวมจาก

พจนานุกรมออนไลน์ งานดังกล่าวใช้ตัวประมาณ pose ต่างจาก MediaPipe ของ HandVox จึงต้องทดสอบผลของแหล่งพิกัดและวิธีปรับมาตรฐานเมื่อนำแนวคิดมาประยุกต์

กราฟและ attention เพิ่มทางเลือกในการรวมข้อมูลจากตำแหน่งและเวลา แต่ความซับซ้อนของสถาปัตยกรรมไม่รับประกันผลที่ดีเมื่อข้อมูลจำกัด ควรพิจารณาการเพิ่มข้อมูล การควบคุมความซับซ้อน และการแยกชุดทดสอบควบคู่กัน โดยเปรียบเทียบกับ TCN หลักและ SVC เดิมบนเงื่อนไขเดียวกัน

แบบจำลอง	การแทนเวลา	สิ่งที่ควรศึกษา	บทบาทต่อ HandVox
TCN	คอนโวลูชันตามเวลา	ช่วงรับข้อมูลและความหน่วง	โมเดลหลักปัจจุบัน
LSTM / GRU	สถานะส่งต่อตามลำดับ	ข้อมูลจำกัดและการควบคุมความซับซ้อน	ทางเลือกเปรียบเทียบ
ST-GCN / กราฟ	ข้อต่อและเวลา	โครงสร้างกราฟและจุดที่ใช้	ทางเลือกสำหรับ skeleton
Transformer	attention ในลำดับ	การเพิ่มข้อมูลและความหลากหลาย	ทางเลือกเปรียบเทียบ
SVC เดิม	เวกเตอร์แผ่ตามเวลา	มิติข้อมูลและความเข้ากันได้	fallback หรือ baseline

ตารางที่ 2.5 แนวทางแบบจำลองสำหรับลำดับจุดสำคัญ

2.5.4 บทบาทของ SVM และ SVC เดิม

SVM สร้างขอบเขตจำแนกโดยให้ความสำคัญกับตัวอย่างใกล้ขอบเขต และใช้ kernel เพื่อแทนความสัมพันธ์ที่ไม่เป็นเชิงเส้นได้ (Cortes และ Vapnik, 1995) SVC เป็นตัวจำแนกในไลบรารี scikit-learn ซึ่งเส้นทางเดิมของโครงการใช้กับเวกเตอร์ลำดับขนาดคงที่

โค้ดตรวจจับยังรองรับ SVC เดิมเป็น fallback เมื่อไม่สามารถใช้โมเดล TCN ที่ถูกต้องได้ โดยตรวจว่ารองรับข้อมูล 5,130 คุณลักษณะและการให้ค่าความน่าจะเป็น การมีโค้ดสำรองไม่ได้หมายความว่าทุกครั้งที่ใช้งานจะเรียก SVC จึงต้องระบุชนิดโมเดลที่โหลดจริงในผลการทดลอง

2.5.5 คำกำหนดการฝึกปัจจุบัน

training_config.json ระบุ algorithm เป็น TCN ใช้ hidden channels [64, 64], kernel size 3, dropout 0.2, learning rate 0.001, weight decay 0.0001, batch size 32 และฝึกได้สูงสุด 80 epochs โดยมี patience 10 คำดังกล่าวเป็นการตั้งค่าการฝึก ไม่ใช่หลักฐานว่าโมเดลที่นำมาประเมินทุกไฟล์ถูกสร้างด้วยค่าเหล่านี้ จึงต้องตรวจสอบข้อมูลกับการทดลองร่วมด้วย

การฝึก TCN คำนวณน้ำหนักคลาสจากข้อมูลฝึกเพื่อใช้กับฟังก์ชันสูญเสีย ช่วยลดอิทธิพลจากจำนวนตัวอย่างไม่เท่ากัน แต่ไม่ทดแทนความหลากหลายของผู้ทำท่า หากตัวอย่างส่วนใหญ่ซ้ำจากบุคคลหรือสภาพเดียว แบบจำลองยังอาจเรียนรู้ลักษณะเฉพาะของกลุ่มนั้น

การปรับพารามิเตอร์ควรทำเฉพาะบนชุดฝึกและ validation ภายใน ไม่ควรดูคะแนนชุดทดสอบแล้วเลือกค่าที่ดีที่สุด เพราะชุดทดสอบจะกลายเป็นส่วนหนึ่งของการพัฒนาและคะแนนสุดท้ายมีอคติ

2.5.6 คะแนนความมั่นใจและการปฏิเสธผล

คะแนน softmax ของ TCN และ predict_proba ของ SVC ใช้จัดอันดับคลาสและตั้งเกณฑ์รับผลได้ แต่ไม่ได้รับประกันว่าคะแนนจะตรงกับโอกาสถูกในสภาพใช้งานใหม่ สำหรับ SVM งานของ Lin และคณะ (2007) ศึกษาการปรับปรุงวิธีสร้าง probabilistic outputs จึงเป็นพื้นฐานการอธิบายเส้นทางเดิม ไม่ใช่หลักฐานว่าคะแนนของ TCN ในโครงการได้รับการสอบเทียบแล้ว

ค่าจาก predict_proba ใช้จัดอันดับและกำหนดเกณฑ์ปฏิเสธผลได้ แต่ไม่ควรตีความว่า 0.80 หมายถึงถูก 80 เปอร์เซ็นต์ในทุกสภาพแวดล้อม การสอบเทียบอาจเปลี่ยนเมื่อผู้ใช้ กล้อง หรือ สัตว์ส่วนคลาสด่างจากข้อมูลฝึก

ค่าเริ่มต้นของ HandVox กำหนดคะแนนขั้นต่ำ 0.72 และความต่างระหว่างสองอันดับแรกขั้นต่ำ 0.12 ทั้งยังมีเกณฑ์ขั้นต่ำจากข้อมูลกำกับโมเดล ค่าที่ใช้จริงอาจขึ้นกับการตั้งค่าผู้ใช้และรุ่นโมเดล การปรับเกณฑ์ต้องใช้ชุดตรวจสอบและพิจารณาทั้งการพลาดค่าจริงกับการยอมรับ neutral หรือ unknown เป็นค่า

2.5.7 การเปรียบเทียบแบบจำลองอย่างเป็นธรรม

ข้อได้เปรียบของแต่ละแบบจำลองต้องวัดตามโจทย์ที่ใช้จริง งานพื้นฐาน TCN ไม่ได้แสดงว่า TCN ชนะโครงข่ายเวียนกลับในทุกกรณี และผลจากภาษามืออื่นไม่ใช่ผลของ HandVox จึงควรรายงานทั้งคะแนนจำแนก เวลาแฝง ทรัพยากร และชนิดการแบ่งข้อมูลก่อนเลือกแบบจำลอง

การเปรียบเทียบที่ยุติธรรมต้องใช้ตัวอย่าง ชุดแบ่ง และตัวชี้วัดเดียวกัน หากวิธีหนึ่งใช้ผู้ทำท่าซ้ำระหว่างฝึกกับทดสอบ ขณะที่อีกวิธีทดสอบกับผู้ทำใหม่ คะแนนไม่สามารถสรุปว่าแบบจำลองใดดีกว่าได้

การเก็บ SVC เป็นระบบเดิมหรือ baseline ช่วยให้ติดตามผลของการเปลี่ยนสถาปัตยกรรมได้ ส่วน TCN เป็นระบบหลักที่ต้องตรวจด้วยข้อมูลของโครงการ การเลือก LSTM, GRU, กราฟ หรือ Transformer ในอนาคตควรอาศัยผลทดลอง ไม่สรุปจากข้อสถาปัตยกรรมหรือความใหม่ของปิตีพิมพ์

2.6 การแบ่งข้อมูลและการป้องกันการรั่วไหล

HandVox แยกคำถามการประเมินเป็นการใช้กับผู้ทำที่เคยอยู่ในข้อมูลฝึกแต่ต่างเซสชัน และการใช้กับผู้ทำใหม่ โหมดหลักในค่ากำหนดคือ `known_signers_session_holdout` ส่วนข้อมูลผู้ทำใหม่ใช้การประเมินภายนอกแยกต่างหาก การรายงานสองแบบรวมเป็นคำว่า `signer-independent` เพียงคำเดียวจะให้ความหมายของผลคลาดเคลื่อน

2.6.1 การออกแบบชุดข้อมูล

การออกแบบเริ่มจากนิยามคลาส วิธีทำท่า ขอบเขตเฟรม สภาพแวดล้อม และจำนวนตัวอย่างต่อกลุ่ม คำอธิบายต้องชัดเจนให้ผู้เก็บต่างคนสร้างตัวอย่างสอดคล้องกัน แต่ไม่ควรบังคับจังหวะจนขาดความเป็นธรรมชาติ

ค่ากำหนดการเก็บข้อมูลระบุ `person_01` และ `person_02` กับสี่เซสชัน ตั้งแต่ 16 คลิปต่อผู้ทำต่อคลาส และขั้นต่ำ `accepted` 14 คลิปต่อผู้ทำต่อคลาส ค่าดังกล่าวเป็นเกณฑ์วางแผนและตรวจสอบความครบถ้วน ไม่ใช่จำนวนที่เก็บสำเร็จแล้ว จำนวนจริงต้องอ่านจากข้อมูลและรายงานการทดลองของรุ่นที่นำมาใช้

การเก็บจากผู้ทำจำนวนจำกัดยังจำกัดข้อสรุปต่อประชากรผู้ใช้ แม้แยกเซสชันถูกต้องแบบจำลองยังเคยพบลักษณะของผู้ทำเดิม จึงควรเพิ่มผู้ทำและรายงานผลภายนอกแยกรายบุคคลรวมทั้งระบุความหลากหลายและสภาพการเก็บข้อมูลที่ครอบคลุมจริง

2.6.2 การตรวจรับและการปฏิเสธคลิป

Dataset V2 แยกสถานะคลิปเป็น `accepted`, `pending` และ `rejected` ช่วยให้เก็บตัวอย่างก่อนแล้วตรวจคุณภาพภายหลัง คลิปที่จุดสำคัญหายมาก ทำท่าไม่ครบ ป้ายกำกับผิด หรือมีความผิดปกติควรถูกปฏิเสธพร้อมบันทึกเหตุผล

การตรวจรับต้องใช้เกณฑ์เดียวกันทุกคลาส หากตรวจคำหนึ่งเข้มกว่าคำอื่น ความต่างของคุณภาพจะกลายเป็นสัญญาณที่แบบจำลองเรียนรู้ การสุ่มตรวจซ้ำโดยผู้ตรวจอีกคนช่วยประเมินความสอดคล้องของป้ายกำกับ

การเก็บวิดีโอตัวอย่างไว้ช่วยตรวจย้อนกลับ แต่เพิ่มขนาดและความเสี่ยงด้านความเป็นส่วนตัว ไฟล์กำหนดค่าเปิด `save_preview_video` จึงควรกำหนดผู้เข้าถึง ระยะเวลาจัดเก็บ และวิธีลบเมื่อไม่จำเป็น

2.6.3 การแบ่งแบบคงสัดส่วนคลาส (Stratified)

การแบ่งแบบคงสัดส่วนคลาส (stratified) รักษาสัดส่วนของแต่ละคลาสให้ใกล้เคียงกันระหว่างชุดฝึกกับชุดทดสอบ เหมาะสำหรับการทดสอบเบื้องต้นเมื่อแต่ละคลาสมีตัวอย่างน้อยและต้องการให้ทุกคลาสปรากฏในทั้งสองชุด

ข้อจำกัดคือ stratified ที่พิจารณาเฉพาะป้ายกำกับไม่รู้ว่าคลิป์ใดมาจากผู้ทำหรือเซสชันเดียวกัน ตัวอย่างที่ใกล้เคียงกันมากอาจอยู่คนละชุด ทำให้คะแนนสูงจากการจดจำบุคคล ฉาก และรูปแบบการเก็บข้อมูล

โหมดทดลองคำอย่างรวดเร็วต้องแยกจากการประเมินหลักอย่างชัดเจน หากใช้การแบ่งคลิป์แบบ stratified ผลนั้นยังไม่รับรองความสามารถกับผู้ใช้ใหม่ การเลือกใช้เกณฑ์ใดควรบันทึกไว้กับผลทุกครั้ง ไม่แทนชื่อวิธีแบ่งด้วยคำกว้าง ๆ ว่า train/test

2.6.4 การรั่วไหลของข้อมูล

Data leakage เกิดเมื่อข้อมูลที่ไม่ควรมีในขั้นฝึกหรือเลือกแบบจำลองส่งผลต่อโมเดล เช่น ใช้ชุดทดสอบเลือกพารามิเตอร์ ปรับมาตรฐานด้วยสถิติรวมทุกชุด หรือปล่อยคลิป์จากเซสชันเดียวกันอยู่ทั้งฝึกและทดสอบ

ในข้อมูลวิดีโอ การตัดคลิป์ยาวหนึ่งไฟล์เป็นหลายหน้าต่างแล้วสุ่มแบ่งหน้าต่างมีความเสี่ยงสูงเพราะเฟรมติดกันแทบเหมือนกัน หากหน้าต่างเหล่านี้อยู่คนละชุด คะแนนจะวัดความคล้ายของวิดีโอต้นทางมากกว่าความสามารถกับตัวอย่างใหม่

มาตรการป้องกันคือกำหนดกลุ่มก่อนแบ่ง เก็บขั้นตอน preprocessing ไว้ใน pipeline ที่ fit เฉพาะชุดฝึก แยก validation จาก test และบันทึก fingerprint ของชุดข้อมูลที่ใช้ในแต่ละ experiment เพื่อให้รู้ว่าผลใดมาจากข้อมูลรุ่นใด

วิธีแบ่ง	สิ่งที่ควบคุม	ข้อดี	ข้อจำกัด/การใช้
สุ่มทั่วไป	จำนวนรวม	ง่ายและเร็ว	เสี่ยงสัดส่วนคลาสและกลุ่มไม่สมดุล
Stratified	สัดส่วนคลาส	ทุกคลาสอยู่ในแต่ละชุด	ไม่ป้องกันผู้ทำหรือเซสชันซ้ำ
Group by session	เซสชัน	ลดคลิป์ใกล้เคียงข้ามชุด	ยังอาจมีผู้ทำคนเดิม
Group by signer	ผู้ทำทำ	วัดการใช้กับบุคคลใหม่	ต้องมีผู้ทำหลายคน
Leave-One-Signer-Out	สลับผู้ทำเป็นชุดทดสอบ	ใช้ข้อมูลทุกคนและรายงานราย fold	ใช้เวลาฝึกหลายรอบ

วิธีแบ่ง	สิ่งที่ควบคุม	ข้อดี	ข้อจำกัด/การใช้
ชุดทดสอบภายนอก (External test)	แหล่งข้อมูลภายนอก	วัดผลกับผู้ทำหรือข้อมูลที่กันไว้	ต้องตรึงโมเดลและแยกข้อมูลจากการพัฒนา

ตารางที่ 2.6 การเปรียบเทียบวิธีแบ่งข้อมูล

2.6.5 การแยกเซสชันและการทดสอบผู้ทำใหม่

โมเดลหลักแบ่งกลุ่มตามผู้ทำร่วมกับเซสชัน ในแต่ละรอบใช้สองเซสชันฝึก หนึ่งเซสชันตรวจสอบ และหนึ่งเซสชันทดสอบ โดยหมุนเวียนชุดแบ่งสลับตามค่ากำหนดปัจจุบัน ผู้ทำเดิมจึงอาจปรากฏในทั้งสามชุด แต่คลิปของเซสชันที่กันไว้ต้องไม่ใช่ฝึกหรือเลือกพารามิเตอร์

ผลรวมจากคำทำนายของชุดทดสอบในแต่ละรอบใช้ประเมินแบบแยกเซสชัน แล้วจึงฝึกโมเดลใช้งานด้วยข้อมูล accepted ที่อนุญาตทั้งหมด การทดสอบผู้ใช้ใหม่ใช้ชุดข้อมูลภายนอกและโมเดลที่ตรึงไว้ แยกรหัสผู้ทำออกจากการฝึกและตรวจตัวอย่างซ้ำ จึงตอบคำถามต่างจากการหมุนเวียนเซสชัน

โค้ดยังรองรับ Leave-One-Signer-Out ซึ่งเว้นผู้ทำหนึ่งคนออกจากการฝึกในแต่ละรอบ แต่ไม่ใช่โมเดลหลักที่เลือกอยู่ในค่ากำหนดปัจจุบัน รายงานควรระบุโมเดลที่ใช้จริง จำนวนผู้ทำและคลิปในแต่ละชุด และผลรายรอบหรือรายบุคคล ไม่ใช่คำว่าแยกคนแทนการแยกเซสชัน

2.6.6 ความไม่สมดุลของคลาส

เมื่อคลาสไม่สมดุล Accuracy อาจถูกครอบงำโดยคลาสใหญ่ HandVox กำหนดเป้าหมายจำนวนคลิปต่อกลุ่มและใช้น้ำหนักคลาสในการฝึก TCN เป็นมาตรการเสริม แต่ยังคงต้องตรวจจำนวนตัวอย่างและ Recall รายคลาส โดยไม่ใช้การถ่วงน้ำหนักแทนการเก็บข้อมูลที่หลากหลาย

neutral และ unknown ต้องมีนิยามต่างกันชัดเจน neutral แทนการพักหรือการกลับสู่สถานะพร้อมตามเกณฑ์ข้อมูล ส่วน unknown ครอบคลุมตัวอย่างที่ควรปฏิเสธว่าไม่ใช่คำในคลัง ช่วงเปลี่ยนท่าควรเก็บและตรวจป้ายกำกับอย่างสม่ำเสมอ ไม่รวมทุกกรณีเป็น neutral เพราะจะกระทบกลไกอนุญาตให้รับคำซ้ำ

2.6.7 การเพิ่มข้อมูล

ขั้นเพิ่มข้อมูลรองรับการหมุน เลื่อนตำแหน่ง เปลี่ยนสเกล รบกวนพิกัด และเปลี่ยนจังหวะหรือทิ้งบางเฟรมในขอบเขตที่กำหนด โดยไม่กลับซ้ายขวาโดยอัตโนมัติ การแปลงต้องรักษาความหมายและใช้กับชุดฝึกหลังแบ่งกลุ่มแล้วเท่านั้น เพื่อไม่ให้สำเนาที่ดัดแปลงจากคลิปเดียวกันข้ามไปอยู่ในชุดทดสอบ

ข้อมูลสังเคราะห์ไม่แทนการเก็บจากผู้ใช้งานหลายคน ควรใช้เพื่อเพิ่มความทนต่อความแปรผันที่ทราบ และต้องใช้เฉพาะชุดฝึก ไม่ควรสร้างตัวอย่างจากคลิปทดสอบแล้วนำกลับไปฝึก

2.6.8 เวอร์ชันและความสามารถในการทำซ้ำ

ระบบบันทึก training_config snapshot, dataset fingerprint, เวอร์ชันสภาพแวดล้อม, metrics, confusion matrix และ model manifest ในโฟลเดอร์ experiment การเก็บหลักฐานเหล่านี้ทำให้ตรวจสอบย้อนกลับได้ว่าโมเดลใดใช้ข้อมูลและค่ากำหนดชุดใด

การบันทึก random_seed ช่วยให้ขั้นตอนสุ่มซ้ำได้ใกล้เคียงเดิม แต่ไม่รับประกันผลเหมือนกันทุกแพลตฟอร์ม การทำซ้ำที่ดีต้องรวมเวอร์ชันไลบรารี ซอร์สโค้ด และกฎคัดเลือกข้อมูล ไม่ใช่บันทึกเพียง seed

2.7 การประเมินผล

การประเมินต้องตอบทั้งความถูกต้องของการจำแนก ความสมดุลระหว่างคลาส ความปลอดภัยของคำสำคัญ และพฤติกรรมแบบเวลาจริง Sokolova และ Lapalme (2009) ชี้ว่าตัวชี้วัดแต่ละชนิดตอบคุณสมบัติของ Confusion Matrix ต่างกัน จึงไม่ควรใช้ Accuracy เพียงค่าเดียว

2.7.1 เมทริกซ์ความสับสน (Confusion Matrix)

เมทริกซ์ความสับสน (Confusion Matrix) จัดแถวเป็นคลาสจริงและคอลัมน์เป็นคลาสที่ทำนาย ค่าบนแนวทแยงคือค่าที่ทำนายถูก ส่วนค่านอกแนวทแยงแสดงคู่ค่าที่สับสน รูปแบบของความผิดพลาดช่วยชี้ว่าควรเพิ่มข้อมูลหรือคุณลักษณะใด

การอ่านต้องพิจารณาจำนวนตัวอย่างต่อแถว หากคลาสหนึ่งมี support น้อย จำนวนผิดเพียงเล็กน้อยอาจเปลี่ยน Recall มาก ควรแสดงทั้งจำนวนจริงและอัตราที่ทำให้เป็นสัดส่วนเมื่อเปรียบเทียบคลาส

2.7.2 ค่าความถูกต้อง (Accuracy)

ค่าความถูกต้อง (Accuracy) คือจำนวนตัวอย่างที่ทำนายถูกหารด้วยจำนวนตัวอย่างทั้งหมด เหมาะสำหรับสรุปภาพรวมเมื่อคลาสมีจำนวนใกล้เคียงกันและต้นทุนของความผิดพลาดเท่ากัน

ใน HandVox ความผิดพลาดบางชนิดสำคัญกว่า เช่น พลาดคำ ช่วยด้วย หรือสร้างคำจาก neutral ดังนั้น Accuracy ที่ผ่านเกณฑ์ยังไม่เพียงพอ ต้องตรวจ Recall ของคำสำคัญและอัตรา false positive ของ neutral เพิ่มเติม

2.7.3 ค่าความแม่นยำ (Precision) ค่าความระลึก (Recall) และคะแนนเอฟวัน (F1-score)

ค่าความแม่นยำ (Precision) ของคลาสหนึ่งวัดว่าสิ่งที่ระบบทำนายเป็นคลาสนั้นถูกจริงกี่ส่วน ค่า Precision ต่ำหมายถึงระบบเรียกชื่อคลาสนั้นเกินไปและสร้าง false positive มาก

ค่าความระลึก (Recall) วัดว่าตัวอย่างจริงของคลาสถูกตรวจพบกี่ส่วน ค่า Recall ต่ำหมายถึงระบบพลาดค่าจริง สำหรับคำสำคัญที่การพลาดมีผลสูง ควรกำหนดเกณฑ์ Recall เฉพาะแม้ Precision กับ Recall จะมีการแลกเปลี่ยนกัน

คะแนนเอฟวัน (F1-score) เป็นค่าเฉลี่ยฮาร์โมนิกของ Precision และ Recall จึงต่ำเมื่อค่าใดค่าหนึ่งต่ำมาก เหมาะสำหรับสรุปสมมูลของการตรวจพบและการหลีกเลี่ยงผลบวกผิด แต่ยังคงควรเปิดดูสองค่าต้นทางเพื่อเข้าใจสาเหตุ

ตัวชี้วัด	ความหมาย	สูตรย่อ	การใช้ใน HandVox
Accuracy	สัดส่วนที่ทำนายถูกทั้งหมด	ถูกทั้งหมด / ตัวอย่างทั้งหมด	เกณฑ์ภาพรวม
Precision	ความถูกต้องของผลที่ทำนายเป็นคลาส	$TP / (TP + FP)$	ตรวจค่าที่ระบบปล่อยเกิน
Recall	สัดส่วนค่าจริงที่ตรวจพบ	$TP / (TP + FN)$	เน้นคำสำคัญและคลาสที่พลาด
F1-score	สมมูล Precision กับ Recall	$2PR / (P + R)$	สรุปผลรายคลาสและ Macro F1
Neutral FPR	คลิ๊ป neutral ที่ถูกรับเป็นคำ	neutral ที่รับเป็นคำ / neutral ทั้งหมด	ผลระดับคลิ๊ป ไม่ใช่ค่าเกินตอนาที

ตารางที่ 2.7 ตัวชี้วัดสำหรับการประเมิน HandVox

2.7.4 ค่าเฉลี่ยมหภาค (Macro average) และค่าเฉลี่ยถ่วงน้ำหนัก (Weighted average)

ค่าเฉลี่ยมหภาค (Macro average) คำนวณตัวชี้วัดแยกแต่ละคลาสแล้วเฉลี่ยโดยให้น้ำหนักเท่ากัน จึงสะท้อนว่าระบบทำงานกับคลาสเล็กได้ดีเพียงใด HandVox ใช้ Macro F1 เป็นเกณฑ์หลัก ร่วมกับ Accuracy

ค่าเฉลี่ยถ่วงน้ำหนัก (Weighted average) ให้น้ำหนักตาม support ของแต่ละคลาส เหมาะกับสรุปผลตามการกระจายข้อมูลจริง แต่คลาสใหญ่มีอิทธิพลมากกว่า การรายงาน Macro และ Weighted ร่วมกันช่วยเปิดเผยว่าคะแนนรวมดีเพราะคลาสใหญ่หรือดีสม่ำเสมอทุกคลาส

2.7.5 เกณฑ์ยอมรับของโครงการ

training_config.json กำหนด Accuracy ขั้นต่ำ 0.70, Macro F1 ขั้นต่ำ 0.70 และ Recall ต่ำสุดของค่าทั่วไป 0.50 เกณฑ์เหล่านี้ใช้เป็นประตูลดคุณภาพเบื้องต้น ไม่ใช่การรับรองว่าระบบพร้อมใช้ในสถานการณ์เสี่ยงสูง

คำ ช่วยด้วย ถูกกำหนดเป็น critical gesture และต้องมี Recall อย่างน้อย 0.75 ส่วนเกณฑ์ neutral false positive rate ไม่เกิน 0.20 เป็นเกณฑ์ภายในของต้นแบบ การคำนวณจากคลิปวัดการยอมรับคลาสภายในเป็นค่าที่แสดงได้ ไม่ใช่จำนวนค่าที่เครื่องสถานะปล่อยจริงต่ออนาที จึงต้องประเมินพฤติกรรมหน้ากล้องเพิ่มเติม

รายงานการฝึกบันทึกผลและสถานะผ่านเกณฑ์เพื่อใช้ประกอบการตรวจสอบข้อมูลและโมเดล ผลผ่านเกณฑ์ภายในไม่ได้รับการใช้งานในทุกสภาพแวดล้อม และไม่ควรรนำคะแนนจากโมเดลสุดท้ายที่ฝึกด้วยข้อมูลทั้งหมดมาแทนคะแนนชุดทดสอบที่กันได้

2.7.6 การประเมินแบบเวลาจริง

คะแนนบนคลิปที่ตัดไว้ไม่รวมความผิดพลาดจากการเริ่มจับซ้ำ การเลื่อนหน้าต่าง ช่วงเปลี่ยนการไม่พบมือ และการยืนยันผล การทดสอบหน้ากล้องจึงต้องวัดความถูกต้องแบบเหตุการณ์ร่วมกับจำนวนครั้งที่ปล่อยคำซ้ำหรือปล่อยคำโดยไม่มีท่าจริง

ตัวชี้วัดระบบโดยรวม FPS ของวงรอบประมวลผล อัตราการทำงานจริง เวลาแฝงจากทำถึงผลยืนยัน และเวลาจากยืนยันถึงเสียงเริ่ม พร้อมระบุ CPU, GPU, กล้อง ความละเอียด และเวอร์ชันซอฟต์แวร์ HandVox มีการบันทึกประสิทธิภาพการตรวจจับ แต่ต้องอ่านผลการวัดจริงก่อนสรุปว่ารองรับความเร็วที่ต้องการ Accuracy เพียงอย่างเดียวไม่ยืนยันการทำงานแบบเวลาจริง

การทดสอบควรใช้สถานการณ์ที่ใกล้เคียง เช่น เปลี่ยนระยะกล้อง แสง และผู้ใช้ พร้อมกำหนดสคริปต์คำเพื่อเปรียบเทียบรุ่นอย่างยุติธรรม การรายงานแยกแบบออฟไลน์ (offline) กับแบบเวลาจริง (real-time) ป้องกันการนำคะแนนในสภาพง่ายไปอ้างแทนประสิทธิภาพใช้งาน

2.7.7 การวิเคราะห์ข้อผิดพลาดและความไม่แน่นอน

หลังได้ผลควรสุ่มตรวจ ผลบวกจริง (true positive), ผลบวกหลง (false positive) และผลลบหลง (false negative) ของทุกคลาส พร้อมดูเส้นทาง landmark เพื่อแยกว่าปัญหาเกิดจากป้ายกำกับ จุดสำคัญ หน้าต่างเวลา หรือขอบเขตของแบบจำลอง

คะแนนจากตัวอย่างจำนวนจำกัดมีความไม่แน่นอน ควรรายงานจำนวนผู้ทำ จำนวนคลิป และ support ควบคู่กับร้อยละ เมื่อเพิ่มผู้ทำสามารถใช้การกระจายราย fold หรือช่วงความเชื่อมั่นเพื่อหลีกเลี่ยงการตีความความต่างเล็กน้อยเกินจริง

การประเมินความเท่าเทียมควรเปรียบเทียบผลตามผู้ทำ ความถนัด สภาพแสง และอุปกรณ์ หากกลุ่มใดได้ผลต่ำ ควรเพิ่มข้อมูลและปรับการออกแบบ ไม่ควรแก้ด้วยการตัดกลุ่มนั้นออกจากชุดทดสอบ

2.8 การทำงานแบบเวลาจริงและเสียงพูด

ระบบรับภาพต่อเนื่องต้องเปลี่ยนผลจำแนกแต่ละหน้าต่างให้เป็นเหตุการณ์คำ ป้องกันคำซ้ำ สะสมข้อความ และอ่านเสียงโดยไม่รอให้เสียงจบก่อนประมวลผลกล่อง HandVox จึงใช้หน้าต่างเลื่อน เครื่องสถานะ ตัวจับเวลาค้างท่า และบริการเสียงแบบคิว การประมวลผลภาพต่อเนื่องนี้ต่างจากโจทย์การรู้จำภาษามือต่อเนื่อง

2.8.1 หน้าต่างเลื่อน

โปรแกรมสะสมข้อมูลล่าสุดในหน้าต่างเป้าหมาย 30 เฟรม แล้วเตรียมลำดับให้ตรงกับรูปแบบของโมเดลที่โหลด การเลื่อนหน้าต่างทำให้สามารถประเมินข้อมูลใหม่ได้โดยไม่ต้องเริ่มเก็บคลิปทั้งหมดทุกครั้ง แต่อัตราเฟรมกล่อง อัตราวงรอบ และอัตราการทำนายอาจไม่เท่ากัน

หน้าต่างที่ซ้อนกันมีข้อมูลเหมือนกัน 29 จาก 30 เฟรม ผลทำนายจึงมีความสัมพันธ์สูง การนับทุกผลเป็นหลักฐานอิสระอาจทำให้ความมั่นใจเกินจริง เครื่องสถานะของ HandVox จึงใช้ผลต่อเนื่องเพื่อยืนยันความนิ่ง แต่การประเมินยังต้องนับตามเหตุการณ์หรือคลิป

เมื่อผู้ใช้ปล่อยท่าและระบบตรวจสอบสถานะ released โปรแกรมล้าง motion_frames เพื่อป้องกันเฟรมจากคำเก่าปะปนกับการยกมือรอบใหม่ การล้างที่จุดเปลี่ยนช่วยลดท่าผสมซึ่งไม่มีในชุดฝึก

2.8.2 เกณฑ์ความเชื่อมั่นและเครื่องสถานะ

GestureStateMachine แยกสถานะ IDLE, CANDIDATE, CONFIRMED และ COOLDOWN โดยค่าเริ่มต้นใช้คะแนนขั้นต่ำ 0.72 และยืนยันผลค่าเดิมที่ผ่านเงื่อนไขต่อเนื่อง 6 ครั้ง ร่วมกับเกณฑ์ความต่างคะแนน 0.12 ในกระบวนการรับผล การยืนยันหลายครั้งวัดความคงที่ของผลที่สัมพันธ์กันตามเวลา ไม่ใช่หลักฐานอิสระหกตัวอย่าง

ถ้าค่าเปลี่ยนระหว่าง CANDIDATE ระบบเริ่มนับใหม่ ช่วยลดการยืนยันจากผลชั่วคราว เมื่อยืนยันแล้ว confidence ถูกปรับแบบถ่วงเฉลี่ยกับผลใหม่เพื่อให้แสดงค่าเสถียรขึ้น

เมื่อข้อมูลหรือคะแนนไม่ผ่าน ระบบจัดการการซ่อนผลและการปล่อยสถานะตามเวลาที่กำหนด โดยมี release_seconds เริ่มต้น 0.35 วินาที ส่วน neutral มีการนับต่อเนื่องเพื่ออนุญาตให้รับค่าเดิมอีกครั้ง unknown ใช้ปฏิเสธผลและไม่ทำหน้าที่ปลดเงื่อนไขคำซ้ำแบบเดียวกับ neutral

ค่าเริ่มต้นดังกล่าวปรับได้และต้องอ่านร่วมกับข้อมูลกำกับโมเดล การเพิ่มเกณฑ์หรือเวลายืนยันอาจลดผลชั่วคราว แต่ก็อาจเพิ่มความหน่วงหรือพลาดท่าเร็ว จึงต้องวัดทั้งค่าที่ยอมรับผิด ค่าจริงที่ถูกปฏิเสธ และเวลาตอบสนอง แทนการสรุปว่าค่าที่เข้มกว่าจะดีกว่าเสมอ

ค่าตั้ง	ค่าเริ่มต้น	หน้าที่	ข้อควรพิจารณา
min_confidence	0.72	คะแนนขั้นต่ำ	ปรับร่วมกับการปฏิเสธคำจริง
probability margin	0.12	ส่วนต่างสองอันดับแรก	ผลต่อคลาสที่คล้ายกัน
confirm_frames	6	ยืนยันผลต่อเนื่อง	เพิ่มความหน่วงได้
neutral_release_frames	3	ยืนยันการพักก่อนคำซ้ำ	unknown ไม่แทน neutral
release_seconds	0.35 วินาที	รอก่อนปล่อยสถานะ	ขึ้นกับการจัดการข้อมูลหาย
speak_hold_seconds	1.0 วินาที	ค้างท่าก่อนเพิ่มคำ/พูด	ต้องวัดเวลาตอบสนองจริง
sequence_length	30 เฟรม	ความยาวลำดับเป้าหมาย	ไม่ใช่เวลาหนึ่งวินาทีเสมอ

ตารางที่ 2.8 ค่าตั้งสำคัญของการตรวจจับแบบเวลาจริง

2.8.3 การป้องกันคำซ้ำและ Cooldown

หลังปล่อยคำ ระบบเข้าสู่ COOLDOWN เพื่อป้องกันหน้าต่างซ้อนกันสร้างคำเดิมหลายครั้ง การรับคำเดิมซ้ำต้องมีหลักฐานการกลับสู่ neutral ตามเงื่อนไข ซึ่งค่าเริ่มต้นกำหนด neutral_release_frames เป็น 3 การพบ unknown ไม่ควรถูกอธิบายว่าเป็นการพักที่อนุญาตให้ปล่อยคำเดิมทันที

ตัวสร้างประโยคยังมีตัวเลือก prevent_duplicate_words เพื่อไม่เพิ่มคำเดียวกันติดกัน และมี cooldown สำหรับการกดเพิ่มด้วยตนเอง มาตรการหลายชั้นเหมาะสมกับส่วนติดต่อที่ผู้ใช้สามารถสั่งทั้งอัตโนมัติและด้วยปุ่ม

การทดสอบคำซ้ำควรรวมการค้างท่า การกลับสู่ neutral และการแทรก unknown เพื่อดูว่าระบบทั้งป้องกันคำเกินและยังรับคำซ้ำที่ตั้งใจได้ ส่วนทางเลือกเพิ่มคำด้วยปุ่มควรทดสอบรวมกับการตั้งค่าป้องกันคำซ้ำของตัวสร้างประโยค

2.8.4 การสร้างประโยคและประวัติ

คำที่ยืนยันสามารถเพิ่มลง SentenceBuilder ลบคำล่าสุด ล้าง อ่าน หรือบันทึกได้ ส่วนติดต่อแสดงจำนวนคำและข้อความปัจจุบัน ช่วยให้ผู้ใช้ตรวจและแก้ก่อนส่งเสียง ลดผลเสียจากการจำแนกผิดหนึ่งคำ

ประวัติประโยคบันทึกแหล่งที่มา เช่น detector-manual หรือ detector-tts และจำกัดจำนวนรายการเริ่มต้น 100 รายการ ข้อมูลประวัติช่วยทบทวนการใช้งาน แต่ต้องให้ผู้ใช้ควบคุมการลบและระงับข้อความส่วนบุคคล

ระบบรองรับการเพิ่มคำอัตโนมัติเมื่อค้างทำครบหนึ่งวินาทีและการเพิ่มด้วย Space หรือปุ่มบนจอ การมีทางเลือกช่วยรองรับผู้ใช้ต่างรูปแบบ แต่ควรประเมินความเข้าใจของปุ่ม ขนาดตัวอักษร และเวลาตอบสนองกับผู้ใช้จริง

2.8.5 การแปลงข้อความเป็นเสียงพูด (Text-to-Speech: TTS)

การแปลงข้อความเป็นเสียงพูดเปลี่ยนข้อความที่ยืนยันแล้วเป็นเสียง HandVox ใช้ gTTS ซึ่งติดต่อบริการ text-to-speech ของ Google Translate แล้วเล่นเสียงด้วย pygame และมี pyttsx3 เป็นทางเลือกออนไลน์เมื่อมีเสียงที่ใช้ได้ เอกสาร gTTS เป็นหลักฐานซอฟต์แวร์ ไม่ใช่บทความวิจัย ด้านการรู้จำภาษามือ (Durette, ม.ป.ป.) การอ่านออกเสียงข้อความไม่ใช่การแปลไวยากรณ์ของภาษา

การสร้างเสียงทำงานใน worker thread และรับข้อความผ่านคิวขนาดจำกัด วงรอบลิ่งจึงไม่ต้องรอนเสียงเล่นจบ เสียงหลายคำถูกเล่นตามลำดับและไม่ทับกัน หากคิวเต็มระบบข้ามข้อความใหม่พร้อมแจ้งเตือนแทนการทำให้หน้าจอค้าง

gTTS ต้องเชื่อมต่อเครือข่ายและสร้างไฟล์ MP3 ชั่วคราว โปรแกรมใช้ชื่อสุ่ม เล่นเสร็จแล้วลบไฟล์ การใช้งานในสถานที่เครือข่ายไม่แน่นอนควรทดสอบเสียงออนไลน์และตรวจว่ามี voice ภาษาไทยในระบบปฏิบัติการ

คุณภาพเสียงไม่ใช่เพียงความดัง ต้องพิจารณาการออกเสียงคำเฉพาะ ความเร็ว เวลาออกเสียงเริ่ม และความถูกต้องของข้อความต้นทาง ระบบควรให้ผู้ใช้ตรวจสอบประโยคและหยุดหรือล้างคิวได้เมื่อคำผิด

2.8.6 การออกแบบสำหรับผู้ใช้

ส่วนติดต่อควรแสดงกรอบบริเวณที่ตรวจพบ คำปัจจุบัน confidence สถานะรอยืนยัน (CANDIDATE) หรือสถานะยืนยันแล้ว (CONFIRMED) และแถบค้างทำ เพื่อให้ผู้ใช้เข้าใจว่าเหตุใดระบบยังไม่เพิ่มคำ การซ่อนความซับซ้อนทั้งหมดอาจทำให้ผู้ใช้คิดว่าระบบไม่ทำงานเมื่อจริง ๆ กำลังรอยืนยัน

ข้อความต้องอ่านง่ายบนฉากหลังที่เปลี่ยน จึงควรใช้แถบพื้นหลัง สีที่มีความต่าง และขนาดตัวอักษรปรับได้ ปุ่มสำคัญต้องมีทั้งข้อความไทยและคีย์ลัด และไม่วางทับบริเวณมือที่ใช้ทำท่า

การออกแบบควรร่วมกับผู้ใช้หูหนวกหรือผู้ใช้ภาษามือตั้งแต่การเลือกคำ รูปแบบการทำท่า ไปจนถึงการทดสอบ ไม่ควรสรุปความต้องการแทนผู้ใช้จากมุมมองผู้พัฒนาเพียงฝ่ายเดียว

2.8.7 ความเป็นส่วนตัวและการนำไปใช้

ระบบกล้องควรประมวลผลในเครื่องให้มากที่สุดและไม่บันทึกวิดีโอโดยอัตโนมัติในโหมดใช้งาน หากต้องบันทึกเพื่อปรับปรุงโมเดลต้องขอความยินยอม ระบุวัตถุประสงค์ และให้ผู้ใช้ถอนข้อมูลได้

HandVox เป็นเครื่องมือช่วยสื่อสาร ไม่ควรใช้แทนล่ามในสถานการณ์ทางการแพทย์ กฎหมาย หรือเหตุฉุกเฉินโดยไม่มีการตรวจสอบ ความผิดพลาดของคำอาจเปลี่ยนความหมาย จึงต้องแสดงข้อจำกัดและมีช่องทางสื่อสารสำรอง

2.9 งานวิจัยที่เกี่ยวข้อง

งานที่คัดเลือกในส่วนนี้มี 8 เรื่อง ครอบคลุมภาษามือไทย การเรียนรู้ลำดับจากพิกัด ข้อมูลจำกัด การปฏิเสธสิ่งที่ไม่รู้จัก และขอบเขตการแปลภาษา ประเภทหลักฐานและระดับการเข้าถึงระบุไว้เพื่อให้ใช้ข้อสรุปตามที่ตรวจสอบได้ คะแนนของต่างงานไม่นำมาจัดอันดับร่วมกัน เนื่องจากภาษาจำนวนคลาส ชุดข้อมูล และวิธีแบ่งข้อมูลต่างกัน

2.9.1 งานภาษามือไทยจากจุดสำคัญและลำดับภาพ

Sanalohit และ Katanyukul (2022) ศึกษาการสะกดนิ้วภาษาไทยด้วย MediaPipe Hands และโครงข่ายประสาทในบทความ preprint งานใช้ภาพมือเดียว 30 คลาส จำนวน 2,518 ภาพฝึกและ 1,801 ภาพทดสอบ โดยพิกัดสัมพัทธ์ให้ Accuracy 84.57% เทียบกับ 82.12% ของพิกัดสัมบูรณ์ภายใต้การทดลองเดียวกัน หลักฐานนี้สนับสนุนการศึกษารูปแบบพิกัด แต่เป็นการจำแนกภาพสะกดนิ้ว ไม่ใช่คำเคลื่อนไหวของ HandVox และไม่พบข้อมูลที่ตรวจสอบได้ว่าชุดแบ่งดังกล่าวแยกผู้ทำหรือเซสชัน

Damrongekarun และคณะ (2023) เผยแพร่บทความใน KKU Science Journal โดยใช้ MediaPipe Holistic กับ LSTM และ BiLSTM และเชื่อมผลไปยังแอป Flutter ผ่าน Flask API การทดลองใช้ 10 คลาส รวม 600 คลิป แบ่งฝึก 480 และทดสอบ 120 คลิป ลำดับ 30 เฟรมมี 1,662 ค่าต่อเฟรม ซึ่งเป็นจำนวนค่าคุณลักษณะ ไม่ใช่จำนวนจุด บทคัดย่อรายงาน 0.83 ขณะที่ส่วนผลทดลองแยกผล LSTM และ BiLSTM และตารางประเมินรายงาน Accuracy ประมาณ 0.91 จึงไม่ควรนำตัวเลขเหล่านี้มาเขียนเป็นผลเดียวโดยไม่ระบุแบบจำลองและบริบท ทั้งยังไม่พบข้อมูลที่ยืนยันการแยกผู้ทำในชุดทดสอบ

Chalotnopsis และคณะ (2026) เสนอ TSL-ONE-S ใน IEEE Access โดยบทความอธิบายวิธีวิดีโอ 4,152 รายการ 184 หน่วยคำ จากผู้ทำ 29 คนใน 9 โรงเรียน และรายงานการประเมินแบบ signer-independent ด้วย I3D และ SPOTER ที่ Top-1 Accuracy 79.69% และ 80.83% ตามลำดับ การตรวจครั้งนี้เข้าถึงเฉพาะบทความและระเบียบสถาบัน จึงไม่เต็มจำนวนผู้ทำใน train/validation/test หรือวิธีแยกเซตที่ยังตรวจไม่ได้ งานนี้สนับสนุนความสำคัญของรหัสผู้ทำและข้อมูลที่หลากหลาย แต่ไม่ได้ยืนยันผลของ TCN หรือระบบอ่านเสียงของ HandVox

เมื่อพิจารณาร่วมกัน งานไทยแสดงการใช้พิถีพิถันกับรูปมือและลำดับ แต่ขนาดข้อมูลและการแบ่งทดสอบเป็นตัวกำหนดความหมายของผล สำหรับ HandVox จึงควรแยกการปรับคุณลักษณะจากการเพิ่มความหลากหลายของผู้ทำ และรายงานผลผู้ใช้เดิมต่างเซตแยกจากผู้ใช้นิยามอย่างชัดเจน การใช้ MediaPipe เหมือนกันไม่ได้ทำให้เงื่อนไขทดลองเทียบกันได้โดยอัตโนมัติ

2.9.2 งานวิเคราะห์ลำดับและข้อมูลฝึกจำกัด

Bai และคณะ (2018) เสนอการทดลองเปรียบเทียบ TCN กับโครงข่ายเวียนกลับบนงานลำดับหลายประเภทใน preprint โดยใช้ dilated causal convolution และ residual connections งานนี้เป็นพื้นฐานด้านสถาปัตยกรรม ไม่ใช่ภาษามือและไม่มีผู้ทำทำหรือคลาสคำภาษามือให้เปรียบเทียบกับ HandVox ประโยชน์ต่อโครงงานคือแนวทางกำหนดช่วงรับข้อมูลและตั้ง baseline ขณะที่การเติมขอบแบบสมมาตรและการรวมข้อมูลทั้งหน้าต่างของโค้ดปัจจุบันต้องอธิบายตามที่พัฒนาจริง

Boháček และ Hruš (2023) ศึกษาการเรียนรู้จากพจนานุกรมภาษามือออนไลน์ในงานประชุม IEEE FG ใช้โมเดล SPOTER และวิธีเลือกตัวอย่างที่พิจารณาผลชุดตรวจสอบ พร้อมเสนอ UWB-SL-Wild จำนวน 307 วิดีโอ 100 คลาสภาษามืออเมริกัน จากผู้ทำ 25 คน ผลที่รายงานบน ASLLVD-skeleton มี Top-1 Accuracy 30.97% การทดลองนี้ชี้ว่าข้อมูลจำนวนน้อยและข้อมูลต่างแหล่งยังเป็นโจทย์ยาก และชุดตรวจสอบมีบทบาทต่อการฝึก จึงไม่ควรอธิบายว่าเป็นการทดสอบข้อมูลเป้าหมายที่ไม่เคยใช้พัฒนาเลย

บทเรียนต่อ HandVox คือการใช้ augmentation เฉพาะชุดฝึกหลังแบ่งกลุ่ม และเลือกโมเดลหรือเกณฑ์จาก validation เท่านั้น การเพิ่มสำเนาฝึกช่วยศึกษาความทนต่อการเปลี่ยนตำแหน่งหรือจังหวะ แต่ไม่เท่ากับเพิ่มผู้ทำจริง งานต่างภาษายังมีข้อจำกัดจากชุดคำ ตัวประมาณ pose และรูปแบบการเคลื่อนไหว จึงต้องทดสอบการถ่ายโอนแนวทางบนภาษามือไทย

2.9.3 งานโครงกระดูกและความสัมพันธ์เชิงพื้นที่กับเวลา

Hu และคณะ (2024) เสนอ Dynamic Spatial-Temporal Aggregation for Skeleton-Aware Sign Language Recognition ใน LREC-COLING โดยรวมความสัมพันธ์ของข้อต่อแบบปรับเปลี่ยนได้กับการคอนโวลูชันตามเวลาหลายระดับ และใช้ข้อมูลข้อต่อ กระดูก และการเคลื่อนที่ ผล WLASL2000 รายงาน Top-1 แบบรายตัวอย่าง 53.68% และแบบเฉลี่ยรายคลาส 51.17% ซึ่งเป็นคนละวิธีเฉลี่ย ข้อมูล WLASL มี 2,000 คลาสและผู้ทำ 119 คน จึงไม่อาจนำคะแนนนี้มาเทียบตรงกับคลังคำขนาดเล็กของ HandVox

งานดังกล่าวสนับสนุนการตรวจประโยชน์ของพิกัดและผลต่างตามเวลาที่ HandVox ใช้อยู่ และเสนอทางเลือกกราฟสำหรับการต่อยอด อย่างไรก็ตาม การทดสอบตามชุดแบ่งมาตรฐานของแต่ละฐานข้อมูลไม่ควรถูกตีความว่าแยกผู้ทำเหมือนกันทุกฐาน ต้องตรวจนิยามชุดแบ่งก่อนใช้ผลสนับสนุนข้อสรุปต่อผู้ใช้ใหม่ รวมทั้งวัดเวลาอนุมานจริงก่อนนำความเร็วการฝึกหรือชนิด GPU มาอ้างว่าเป็นระบบเวลาจริง

2.9.4 การปฏิเสธสิ่งที่ไม่รู้จักและช่วงเปลี่ยนท่า

Bendale และ Boulton (2016) เสนอ OpenMax ในงาน CVPR เพื่อจัดการตัวอย่างนอกคลาสที่รู้จัก โดยปรับคะแนนจากลักษณะการกระตุ้นของโครงข่ายและแบบจำลองส่วนหางของการกระจาย การทดลองเป็นการจำแนกภาพบน ImageNet ไม่ใช่ท่าภาษามือ งานนี้จึงใช้เป็นพื้นฐานอธิบายว่าการเลือกคะแนนสูงสุดของตัวจำแนกแบบปิดไม่เพียงพอต่อการปฏิเสธสิ่งที่ไม่รู้จัก ไม่ใช่หลักฐานว่า HandVox ใช้ OpenMax แล้ว

สำหรับ HandVox ควรประเมิน unknown ที่ไม่ได้อยู่ในตัวอย่างฝึก รวมทั้งการเคลื่อนไหวทั่วไปและช่วงเปลี่ยนท่า แยกจาก neutral ที่ระบบใช้กับการรับคำซ้ำ ตัวชี้วัดระดับระบบควรรวมจำนวนคำที่ยอมรับผิดต่อหน้าที่และอัตราปฏิเสธคำจริงร่วมกับผลระดับคลิป แนวทางนี้เป็นข้อเสนอการประเมินจากข้อจำกัดของตัวจำแนก ไม่ใช่ผลทดลองที่ยืนยันแล้วของโครงการ

2.9.5 การรู้จำ การแปล และการอ่านออกเสียง

Camgoz และคณะ (2020) เสนอ Sign Language Transformers ใน CVPR ซึ่งเรียนรู้การรู้จำภาษามือต่อเนื่องและการแปลร่วมกันด้วย CTC และ Transformer บนชุด PHOENIX14T ภาษามือเยอรมัน งานนี้มีวิดีโอหลายหน่วยท่าและข้อความภาษาปลายทาง จึงต่างจากการจำแนกหนึ่งคำแล้วสะสมข้อความของ HandVox ประโยชน์ต่อรายงานคือการกำหนดขอบเขตและหลีกเลี่ยงการเรียกการต่อคำหรืออ่านเสียงว่าเป็นการแปลไวยากรณ์เต็มรูปแบบ

การนำผลรู้จำไปอ่านเสียงเป็นงานระบบอีกส่วนหนึ่ง หลักฐานซอฟต์แวร์ gTTS อธิบายการสร้างเสียงจากข้อความผ่านบริการออนไลน์ แต่ไม่ได้ประเมินความถูกต้องของภาษามือ (Durette, ม.ป.ป.) HandVox จึงต้องวัดเวลาเตรียมเสียง ความสำเร็จเมื่อเครือข่ายเปลี่ยน และเสียงที่รองรับใน fallback ออฟไลน์แยกจาก Accuracy ของตัวจำแนก พร้อมให้ผู้ใช้ตรวจสอบข้อความก่อนพูด

2.9.6 โค้ดที่เกี่ยวข้องและการสังเคราะห์เพื่อออกแบบ HandVox

โค้ดสาธารณะที่ศึกษาประกอบได้ ได้แก่ TCN ของ Locus Lab ซึ่งใช้ PyTorch และใบอนุญาต MIT, SPOTER ของ Boháček ซึ่งใช้ใบอนุญาต Apache-2.0 สำหรับโค้ด และ gTTS ของ Durette ซึ่งใช้ MIT ส่วนข้อมูลประกอบ SPOTER มีเงื่อนไขต่างจากโค้ด จึงต้องตรวจแยกก่อนนำมาใช้ แหล่งเหล่านี้เป็นหลักฐานการพัฒนาซอฟต์แวร์ ไม่ใช่แทนการประเมินในบทความวิจัย (Locus Lab, ม.ป.ป.; Boháček และ Hružík, ม.ป.ป.; Durette, ม.ป.ป.)

ข้อจำกัดร่วมของหลักฐานคือความต่างของภาษา หน่วยที่จำแนก จำนวนผู้ทำ วิธีแบ่งข้อมูล และระดับการเข้าถึงฉบับเต็ม การออกแบบ HandVox จึงเชื่อมการปรับพิกัด การเรียนรู้ลำดับด้วย TCN การเก็บ SVC สำรอง การแยก neutral/unknown และเครื่องสถานะเข้ากับการทดสอบที่ตรวจย้อนกลับได้ โดยยังไม่มีหลักฐานให้สรุปว่าระบบใหม่กว่า ดีกว่า หรือแม่นยำกว่างานที่พบทวน

การประเมินควรดำเนินเป็นสามส่วน ได้แก่ ผลคลิปของผู้ทำเดิมที่กันเซชันไว้ ผลของโมเดลที่ตรงกับผู้ทำใหม่ และผลหน้ากล้องที่รวมช่วงเปลี่ยนท่า การยืนยันคำ และเสียงพูด ต้องรายงานจำนวนข้อมูลจริงและฮาร์ดแวร์ร่วมกับคะแนน การขยายคำศัพท์ควรเก็บข้อมูลทุกกลุ่มที่จำเป็นและฝึกใหม่ โดยรักษาชุดทดสอบภายนอกให้เป็นอิสระจากการเลือกพารามิเตอร์

งานวิจัย	ข้อมูลและแนวทาง	หลักฐานที่ใช้	การเชื่อมโยงและข้อจำกัด
Sanalohit และ Katanyukul (2022)	สะกดนิ้วไทย 30 คลาส; MediaPipe + ANN	preprint; อ่านฉบับเต็ม	ปรับพิกัด; ไม่ยืนยันแยกคน
Damrongekarun และคณะ (2023)	ไทย 10 คลาส 600 คลิป; LSTM/BiLSTM	บทความวารสาร; อ่านฉบับเต็ม	ลำดับพิกัด; แบ่ง 80:20 ไม่ยืนยันแยกคน
Chalotompised และคณะ (2026)	TSL-ONE-S; 184 หน่วยคำ 29 คน	บทความวารสาร; บทความย่อ	แยกผู้ทำ; ยังไม่ยืนยันรายละเอียดชุดแบ่ง
Bai และคณะ (2018)	TCN เทียบ RNN บนงานลำดับ	preprint; อ่านฉบับเต็ม	พื้นฐาน TCN; ไม่ใช่ภาษามือ
Boháček และ Hružík (2023)	ASL จากพจนานุกรม; SPOTER	บทความประชุม; อ่านฉบับเต็ม	ข้อมูลน้อย; validation มีส่วนเลือกการฝึก
Hu และคณะ (2024)	skeleton; หลายชุดข้อมูล	บทความประชุม; อ่านฉบับเต็ม	กราฟและเวลา; ชุดแบ่งต่างกัน
Bendale และ Boulton (2016)	OpenMax; ภาพ ImageNet	บทความประชุม; อ่านฉบับเต็ม	แนวคิด unknown; ไม่ใช่ท่ามือ

งานวิจัย	ข้อมูลและแนวทาง	หลักฐานที่ใช้	การเชื่อมโยงและข้อจำกัด
Camgoz และคณะ (2020)	ภาษามือเยอรมัน; Transformer + CTC	บทความประชุม; อ่านฉบับเต็ม	แยกการรู้จำกับแปล; ขอบเขตกว้างกว่า

ตารางที่ 2.9 งานวิจัยที่คัดเลือกและขอบเขตการนำมาใช้

เอกสารอ้างอิงประจำบทที่ 2

- Bai, S., Kolter, J. Z., & Koltun, V. (2018). *An empirical evaluation of generic convolutional and recurrent networks for sequence modeling* [Preprint]. arXiv. <https://arxiv.org/abs/1803.01271>
- Bendale, A., & Boulton, T. E. (2016). Towards open set deep networks. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition* (pp. 1563–1572). <https://doi.org/10.1109/CVPR.2016.173>
- Boháček, M., & Hruš, M. (ม.ป.ป.). *SPOTER* [ซอฟต์แวร์]. GitHub. สืบค้น 16 กันยายน 2569, จาก <https://github.com/maty-bohacek/spoter>
- Boháček, M., & Hruš, M. (2023). Learning from what is already out there: Few-shot sign language recognition with online dictionaries. In *2023 IEEE 17th International Conference on Automatic Face and Gesture Recognition (FG)* (pp. 1–6). <https://doi.org/10.1109/FG57933.2023.10042544>
- Camgoz, N. C., Koller, O., Hadfield, S., & Bowden, R. (2020). Sign language transformers: Joint end-to-end sign language recognition and translation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition* (pp. 10023–10033). https://openaccess.thecvf.com/content_CVPR_2020/html/Camgoz_Sign_Language_Transformers_Joint_End-to-End_Sign_Language_Recognition_and_Translation_CVPR_2020_paper.html
- Chalotnong, J., Chen, W.-H., Vijitkunsawat, W., & Lin, Y.-C. (2026). TSL-ONE-S: A real-world Thai sign language dataset with deep learning benchmarks. *IEEE Access*, 14, 37845–37870. <https://doi.org/10.1109/ACCESS.2026.3670970>
- Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20, 273–297. <https://doi.org/10.1007/BF00994018>
- Damrongekarun, C., Pisitpipattana, L., Waijanya, S., & Promrit, N. (2023). Development of Thai sign language detection and conversion system into Thai with deep learning. *KKU Science Journal*, 51(3), 216–225. <https://doi.org/10.14456/kkuscij.2023.19>

- Durette, P. N. (ม.ป.ป.). *gTTS* [ซอฟต์แวร์และเอกสารประกอบ]. GitHub. สืบค้น 16 กันยายน 2569, จาก <https://github.com/pndurette/gTTS>
- Hu, L., Gao, L., Liu, Z., & Feng, W. (2024). Dynamic spatial-temporal aggregation for skeleton-aware sign language recognition. In *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)* (pp. 5450–5460). ELRA and ICCL. <https://aclanthology.org/2024.lrec-main.484/>
- Lin, H.-T., Lin, C.-J., & Weng, R. C. (2007). A note on Platt's probabilistic outputs for support vector machines. *Machine Learning*, 68(3), 267–276. <https://doi.org/10.1007/s10994-007-5018-6>
- Locus Lab. (ม.ป.ป.). *TCN* [ซอฟต์แวร์]. GitHub. สืบค้น 16 กันยายน 2569, จาก <https://github.com/locuslab/TCN>
- Lugaresi, C., Tang, J., Nash, H., McClanahan, C., Uboweja, E., Hays, M., Zhang, F., Chang, C.-L., Yong, M. G., Lee, J., Chang, W.-T., Hua, W., Georg, M., & Grundmann, M. (2019). *MediaPipe: A framework for building perception pipelines* [Preprint]. arXiv. <https://arxiv.org/abs/1906.08172>
- Sanalohit, J., & Katanyukul, T. (2022). *Thai finger spelling recognition: Investigating MediaPipe Hands potentials* [Preprint]. arXiv. <https://arxiv.org/abs/2201.03170>
- Sokolova, M., & Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, 45(4), 427–437. <https://doi.org/10.1016/j.ipm.2009.03.002>
- Zhang, F., Bazarevsky, V., Vakunov, A., Tkachenka, A., Sung, G., Chang, C.-L., & Grundmann, M. (2020). *MediaPipe Hands: On-device real-time hand tracking* [Preprint]. arXiv. <https://arxiv.org/abs/2006.10214>